doi:10.3969/j.issn.1009-8984.2025.01.019

基于关键词提取模型与强化学习的高校图书馆图书自动分类方法

庄辉凤

（厦门工学院，福建 厦门 361024）

摘要：图书馆是高等院校的主要构成部分之一，为学生获取知识提供充足的文献资源。随着高校图书馆建设规模的扩大，文献种类与数量也呈现急剧增加的趋势，但图书分类手段依旧落后，无法满足图书的分类管理需求，故提出基于关键词提取模型与强化学习的高校图书馆图书自动分类方法。构建图书文本关键词提取模型，精准地提取图书文本关键词，以此为基础表征图书。以关键词在图书文本中出现的次数为依据，衡量关键词在图书文本中占据的权重系数，以此为依据降序排列关键词，保留固定数量的关键词，获取图书文本最终表征结果。基于强化学习理论制订图书自动分类程序，确定图书分类规则，接下来执行制订程序即自动可获取最终的图书分类结果。试验数据显示：在不同试验组别背景下，提出的方法被应用后获得的图书分类敏感度最大值为 96%，图书分类几何平均值最大值为 92%，充分证实了提出方法的图书分类效果更佳。

关键词：强化学习；高校图书馆；关键词提取模型；图书分类；相似度计算；图书管理

中图分类号：TP391　　**文献标志码**：A　　**文章编号**：1009-8984(2025)01-0114-05

对于传统高校图书馆来说，图书查询、借阅、管理等均是通过人工来完成的，不但需要耗费大量的人力与物力，还存在管理周期较长、错误率较高等缺陷，已无法满足高校学生的阅读需求[1]。信息时代的到来，使得高校图书馆图书种类与数量急剧增加，学生在海量图书中查询、借阅图书所花费的时间成本越来越高。根据调查研究发现，造成前述问题的主要原因是图书分类性能、效率较差，图书分类成本高等缺点[2]。

伴随着图书数量的飞涨，通过人工对图书进行分类是不现实的，所以各式各样的图书管理系统应运而生。但是，图书管理系统避重就轻地将重点放在了前端界面上，并未关注到图书馆以及学生的实际需求，致使图书馆图书分类性能依然不尽如人意，故本文提出基于关键词提取模型与强化学习的高校图书馆图书自动分类方法。

1　高校图书馆图书自动分类方法

1.1　图书文本关键词提取模型的构建

以图书文本关键词作为分类的主要依据，构建图书文本关键词提取模型，精准地提取图书文本关键词，为后续研究奠定基础。

根据高校图书馆图书文本信息特性，研究基于朴素贝叶斯模型构建图书文本关键词提取模型[3]，具体如图 1 所示。朴素贝叶斯模型是现今分类领域中应用较为广泛的模型之一，具有良好的数学基础和较为稳定的分类性能[4]。为了保障构建模型的有效运行，需对其进行详细合理的训练，以获取准确的图书文本关键词判定原则。

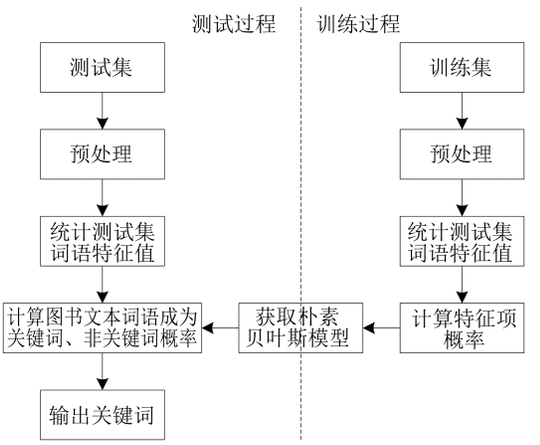


图 1　图书文本关键词提取模型示意图

本研究从词性、词长及词语 TF-IDF 3 个方面衡量图书文本词语属于关键词与非关键词的概率，并对

收稿日期：2024-01-11

作者简介：庄辉凤(1985－)，女(汉)，福建泉州人，助理馆员
主要研究人力资源管理。

中国知网　https://www.cnki.net

其进行有效地融合即可获得最终的图书文本词语关键词判定原则[5]。其中,以词性为依据,计算图书文本词语属于关键词与非关键词的概率,表达式为

$$\begin{cases} P(p_{\text{pos}} \mid C_1)=\dfrac{S_1}{Q_1} \\ P(p_{\text{pos}} \mid C_2)=\dfrac{S_2}{Q_2} \end{cases}, \tag{1}$$

式中:$P(p_{\text{pos}} \mid C_1)$ 表示当词性 pos 是名词或者动词时,图书文本词语属于关键词的概率;$P(p_{\text{pos}} \mid C_2)$ 表示当词性 pos 是名词或者动词时,图书文本词语属于非关键词的概率;S_1 为关键词中名词或者动词的总数量;Q_1 为图书文本关键词总数量;S_2 为非关键词中名词或者动词的总数量;Q_2 为图书文本非关键词总数量。

以词长为依据,计算图书文本词语属于关键词与非关键词的概率,表达式为

$$\begin{cases} P(l_{\text{wl}} \mid C_1)=\dfrac{l_{\text{wl}}(x_i)}{\max\{l_{\text{wl}}(x_1),l_{\text{wl}}(x_2),\cdots,l_{\text{wl}}(x_n)\}} \\ P(l_{\text{wl}} \mid C_2)=\dfrac{l_{\text{wl}}(y_i)}{\max\{l_{\text{wl}}(y_1),l_{\text{wl}}(y_2),\cdots,l_{\text{wl}}(y_m)\}} \end{cases}, \tag{2}$$

式中:$P(l_{\text{wl}} \mid C_1)$ 与 $P(l_{\text{wl}} \mid C_2)$ 分别表示以词长 l_{wl} 为依据,图书文本词语属于关键词与非关键词的概率数值;$l_{\text{wl}}(x_i)$ 为候选关键词 x_i 的长度;$\max\{l_{\text{wl}}(x_1),l_{\text{wl}}(x_2),\cdots,l_{\text{wl}}(x_n)\}$ 为候选关键词集合中词长的最大值;n 为候选关键词集合中词语的总数量;$l_{\text{wl}}(y_i)$ 为候选非关键词 y_i 的长度;$\max\{l_{\text{wl}}(y_1),l_{\text{wl}}(y_2),\cdots,l_{\text{wl}}(y_m)\}$ 为候选非关键词集合中词长的最大值;m 为候选非关键词集合中词语的总数量。

以词语 TF-IDF 为依据,计算图书文本词语属于关键词与非关键词的概率,表达式为

$$\begin{cases} P(F_{\text{TF-IDF}} \mid C_1)=\sum\limits_{i=1}^{n} P(F_{\text{TF-IDF}_i} \mid C_1) \\ P(F_{\text{TF-IDF}} \mid C_2)=\sum\limits_{j=1}^{m} P(F_{\text{TF-IDF}j} \mid C_2) \end{cases}, \tag{3}$$

式中:$P(F_{\text{TF-IDF}} \mid C_1)$ 与 $P(F_{\text{TF-IDF}} \mid C_2)$ 分别表示以词语 TF-IDF 为依据,图书文本词语属于关键词与非关键词的概率数值;TF-IDF_i 为候选关键词加权后的 TF-IDF 数值;TF-IDF_j 为候选非关键词加权后的 TF-IDF 数值。

需要注意的是,词语 TF-IDF 数值计算过程中要考虑到词语在图书文本中的跨度加权系数,以此来显示词语在图书文本中的结构作用[6]。词语 TF-IDF 数值计算公式为

$$F_{\text{TF-IDF}}=F_{\text{TF-IDF}^o} \times \text{LOC}[\alpha] \times \beta, \tag{4}$$

式中:$F_{\text{TF-IDF}}$ 为任意图书文本词语的 TF-IDF 数值;$F_{\text{TF-IDF}^o}$ 为词语 TF-IDF 对应的标准值;$\text{LOC}[\alpha]$ 为图书文本特殊位置词语的加权系数,例如开头、结尾词语等;β 为图书文本中词语的跨度加权系数,取值范围为[0,1]。

以式(1)~(3)计算结果为依据,确定图书文本词语属于关键词与非关键词的概率,其计算公式为

$$\begin{cases} P(C_1 \mid p_{\text{pos}},l_{\text{wl}},F_{\text{TF-IDF}})=\dfrac{P(p_{\text{pos}} \mid C_1)\times P(l_{\text{wl}} \mid C_1)\times P(F_{\text{TF-IDF}} \mid C_1)}{P(p_{\text{pos}},l_{\text{wl}},F_{\text{TF-IDF}})}\times P(C_1) \\ P(C_2 \mid p_{\text{pos}},l_{\text{wl}},F_{\text{TF-IDF}})=\dfrac{P(p_{\text{pos}} \mid C_2)\times P(l_{\text{wl}} \mid C_2)\times P(F_{\text{TF-IDF}} \mid C_2)}{P(p_{\text{pos}},l_{\text{wl}},F_{\text{TF-IDF}})}\times P(C_2) \end{cases}, \tag{5}$$

式中:$P(C_1 \mid p_{\text{pos}},l_{\text{wl}},F_{\text{TF-IDF}})$ 和 $P(C_2 \mid p_{\text{pos}},l_{\text{wl}},F_{\text{TF-IDF}})$ 分别为图书文本某词语属于关键词与非关键词的概率数值;$P(p_{\text{pos}},l_{\text{wl}},F_{\text{TF-IDF}})$ 为图书文本某词语的词性、词长与词语 $F_{\text{TF-IDF}}$ 数值集合;$P(C_1)$ 和 $P(C_2)$ 分别为图书文本词语中关键词与非关键词的占比数值。

为了方便图书文本关键词的判定与提取,设置关键词提取因子[7],其计算公式为

$$x_i=\frac{P(C_1 \mid p_{\text{pos}},l_{\text{wl}},F_{\text{TF-IDF}})}{P(C_2 \mid p_{\text{pos}},l_{\text{wl}},F_{\text{TF-IDF}})}, \tag{6}$$

式中:x_i 为图书文本关键词提取因子。当式(6)计算结果 $x_i \geqslant$ 阈值 $x^{\diamondsuit}$ 时,则认定该图书文本词语为关键词,应对其进行相应的提取;当式(6)计算结果 $x_i <$ 阈值 $x^{\diamondsuit}$ 时,则认定该图书文本词语为非关键词,对其进行忽略处理。

依据前述过程即可完成图书文本关键词的提取,为实现最终研究目标提供支撑[8]。

1.2 图书文本关键词的筛选

常规情况下,一个图书文本由多个关键词构成,其表达式为

$$K_i=\{z_1,z_2,\cdots,z_j,\cdots,z_q\}, \tag{7}$$

式中:K_i 为第 i 个图书文本关键词的集合,z_j 为第 j 个图书文本关键词,q 为图书文本关键词的总数量。

中国知网 https://www.cnki.net

由式(7)可以看出,每个图书文本关键词数量不固定,这个数量普遍较多,若是直接对其进行应用,会增加图书自动分类的运算量,降低图书自动分类的精确度[9]。因此,在图书自动分类之前,需要对图书文本关键词进行筛选。本研究以关键词在图书文本中出现的次数为依据,衡量关键词在图书文本中的权重,以此为依据,对关键词进行降序排列,保留固定数量的关键词,即可完成图书文本关键词的筛选[10]。

图书文本关键词对应的权重系数计算公式为

$$\omega_j=\frac{\delta(z_j)}{\delta(K_i)},\tag{8}$$

式中:ω_j 为关键词 z_j 对应的权重系数,$\delta(z_j)$ 为关键词 z_j 在图书文本中出现的次数,$\delta(K_i)$ 为全部关键词 K_i 在图书文本中出现的总次数。

以式(8)计算结果 ω_j 为依据,对图书文本关键词进行降序排列,确定前 L 个关键词作为筛选结果。而关键词筛选数量 L 需要根据图书分类的实际情况进行具体设置,其关系着图书分类过程的最终运算量与精度[11]。

经过关键词筛选得到图书文本最终表示结果为

$$K'_i=\{z_1,z_2,\cdots,z_L\}。\tag{9}$$

前述过程完成了图书文本关键词的筛选,为最终的图书分类提供依据。

1.3 图书馆图书自动分类的实现

以前述确定的图书文本最终表示结果 $K_i'=\{z_1,z_2,\cdots,z_L\}$ 为基础,基于强化学习理论制订图书自动分类程序,确定图书分类规则,执行制订程序,即可自动获取最终的图书分类结果[12]。

基于强化学习理论的图书自动分类程序如图 2 所示。

强化学习理论主要是借助智能体 Agent 与环境的交互来强化学习高校图书馆图书分类行为的,从中得到图书分类的经验序列,抽取一部分经验样本训练强化学习网络,其训练停止规则公式表示为

$$\min L(\theta)=(Y-Q(\theta))^2,\tag{10}$$

式中:$\min L(\theta)$ 为强化学习网络损失函数最小值,Y 为强化学习网络目标值,$Q(\theta)$ 为当前网络输出值。

依据式(10)训练好的强化学习网络输出结果即为图书分类规则,公式表示为

$$\begin{cases}\dfrac{K_i'\cap K_j'}{K_i'\cup K_j'}\geqslant\zeta & K_i'\text{ 与 }K_j'\text{ 划分为 1 个类别}\\ \dfrac{K_i'\cap K_j'}{K_i'\cup K_j'}<\zeta & K_i'\text{ 与 }K_j'\text{ 划分为 2 个类别}\end{cases},\tag{11}$$

式中:$\dfrac{K_i'\cap K_j'}{K_i'\cup K_j'}$ 为任意两个图书文本关键词集合的相似程度,ζ 为图书分类阈值[13]。

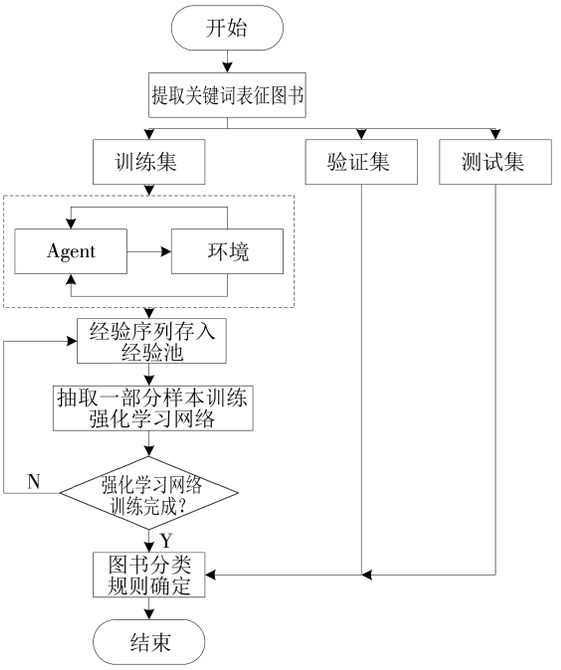


图 2 图书自动分类程序图

执行前述制订程序即可实现图书的自动分类,为高校图书馆图书的管理提供有效的方法支撑。

2 试验与结果分析

选取 5G 环境下高校图书馆自媒体平台多标签文本分类方法[14]与基于知识增强的 ERBERT-GRU 中文图书分类方法[15]作为对比方法 1 和对比方法 2,与本文提出的方法进行高校图书馆图书自动分类对比试验,以此来验证提出方法的应用效果。

2.1 关键词筛选数量的确定

因本文提出的方法在图书文本关键词筛选过程中,关键词筛选数量未确定,需根据图书实际情况进行设置,其直接关系着图书分类的运算量,因此,在试验进行之前需要确定关键词筛选数量。

通过测试获得关键词筛选数量与图书分类运算量之间的关系,如图 3 所示。

关键词筛选数量为 0 时,图书无法被正常表征,故采用虚线圆圈来表示将其忽略。当关键词筛选数量为 13 时,图书分类运算量达到最小值1 000 MB,并且不会影响图书分类的精准度,故确定关键词筛选数量为 14。

2.2 评价指标的选取

为了直观显示本文提出方法的应用性能,选取

中国知网 https://www.cnki.net

合适的评价指标——图书分类敏感度与图书分类几何平均值,其计算公式为

$$\begin{cases} g = \dfrac{T_{TP}}{T_{TP} + F_{FN}} \times 100\% \\ f = \sqrt{g \times h} \times 100\% \end{cases}, \tag{12}$$

式中:g、f 分别为图书分类敏感度与图书分类几何平均值,前者体现的是方法对于不同图书的分类敏感性,后者体现的是方法的整体分类性能,两者与图书分类性能呈现明显的正比例关系;T_{TP} 为正确分类的图书数量;F_{FN} 为错误分类的图书数量;h 为图书分类的特异度。

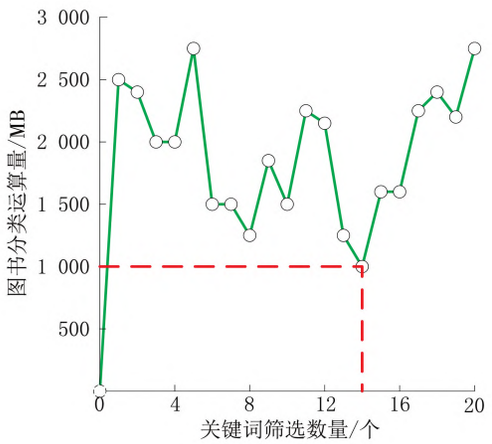


图 3 关键词筛选数量与图书分类运算量关系示意图

前述过程完成了评价指标的选取与计算公式的确定,以便顺利进行后续试验。

2.3 试验结果分析

以前述确定的关键词筛选数量与选取的评价指标为依据,进行高校图书馆图书自动分类对比试验,记录试验数据,根据式(11)计算评价指标数值,以此为基础,对试验结果进行深入的分析。

通过试验得出图书分类敏感度数据如图 4 所示。

在不同试验组别下,应用本文提出的方法后获得的图书分类敏感度高于对比方法 1 与对比方法 2 的,其在第 8 组试验组别下获得图书分类敏感度最大值为 96%。

通过试验获得图书分类几何平均值如图 5 所示。

在不同试验组别下,应用本文提出的方法后获得的图书分类几何平均值均高于对比方法 1 与对比方法 2 的,其在第 9 组试验组别下获得图书分类几何平均值最大值为 92%。

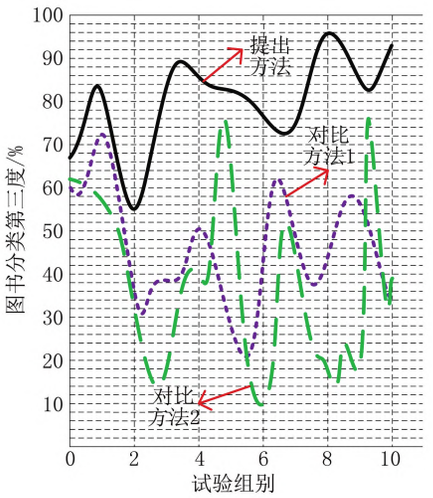


图 4 图书分类敏感度示意图

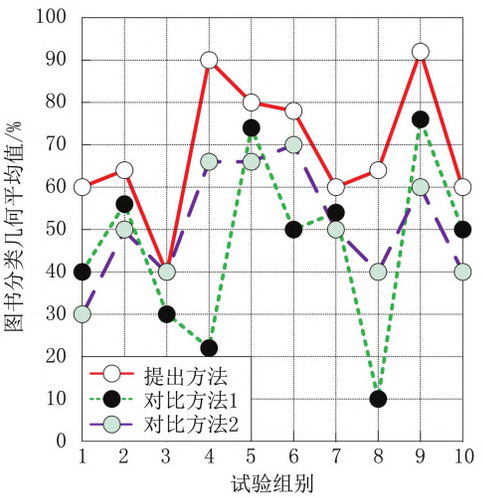


图 5 图书分类几何平均值示意图

前述试验数据显示:相较于对比方法 1 与对比方法 2,本文提出的方法获得的图书分类敏感度与图书分类几何平均值更大,表明本文提出的方法应用性能较强。

3 结语

高等院校图书馆建设规模逐渐扩大,图书种类与数量急剧增加,学生的阅读需求也不断上涨,对图书馆图书管理工作提出了更高的要求,尤其是图书分类性能,直接决定着图书管理是否合理,图书查询成本是否过高,故提出基于关键词提取模型与强化学习的高校图书馆图书自动分类方法。此方法极大地提升了图书分类敏感度与图书分类几何平均值,为高校图书馆图书管理工作提供了有效的方法支撑。

中国知网 https://www.cnki.net

参考文献

[1] 李香月.傅熊湘对民国图书分类法的探索与突破[J].图书馆杂志,2021,40(6):20-29.

[2] 张小丽.20世纪上半叶教育学科在中国图书分类法中的变迁[J].北京社会科学,2022,229(5):96-106.

[3] 谢康,熊光耀,何艳秋,等.基于RFID技术的电子图书分类编目系统设计[J].现代电子技术,2021,44(5):171-174.

[4] 蒋彦廷.依据《中国图书馆分类法》的英文图书分类探索[J].北京大学学报(自然科学版),2023,59(1):11-20.

[5] 张凤斌,刘亚丽,李海英.高校图书馆为学校人力资源项目提供决策支撑的探索与实践——以东北林业大学图书馆为例[J].图书情报工作,2022,66(2):82-89.

[6] 王惠君,吴昊,潘咏怡,等.图书采分编智能作业系统的研究与应用[J].图书馆论坛,2021,41(1):58-63.

[7] 毛立琦,石拓,吴林,等.基于领域自适应的无监督文本关键词提取模型——以"人工智能风险"领域文本为例[J].情报理论与实践,2022,45(3):182-187.

[8] 叶子诚,闫桂英.基于图模型的关键词提取算法研究[J].系统科学与数学,2021,41(4):967-975.

[9] 李晨亮,龙俊辉,唐作立,等.结合邻域知识的文档级关键词抽取方法[J].电子科技大学学报,2021,50(4):551-557.

[10] 王昊,刘丹,刘硕.基于句法分析及主题分布的关键词抽取模型[J].计算机应用研究,2022,39(9):2603-2607.

[11] 吴昊,黄德根,林晓惠.基于强化学习的医疗问题诉求分类[J].中文信息学报,2021,35(3):100-106.

[12] 侯春萍,华中华,杨阳,等.联合迁移学习和强化学习的不平衡分类方法[J].计算机工程与设计,2022,43(10):2769-2776.

[13] 纪雪,唐秋华,陈义兰,等.联合支持向量机和增强学习算法的多波束声学底质分类[J].测绘学报,2021,50(7):972-981.

[14] 程雅倩,黄玮,金晓祥,等.5G环境下高校图书馆自媒体平台多标签文本分类方法研究[J].情报科学,2022,39(2):155-161.

[15] 刘磊,许婕,周勇.基于知识增强的ERBERT-GRU中文图书分类方法研究[J].江西师范大学学报(自然科学版),2021,45(3):299-304.

Reinforcement Learning and Keyword Extraction-Based Automatic Book Classification in Academic Libraries

ZHUANG Huifeng

(*Xiamen Institute of Technology Library*, *Xiamen Fujian* 361024, *China*)

Abstract: The library is one of the main components of higher education institutions, providing sufficient book resources for students to acquire knowledge. With the expansion of the construction scale of university libraries, the types and quantities of books also show a sharp increase trend, but the means of book classification is still backward, unable to meet the needs of book classification management, so this paper proposes a research on automatic classification methods of university library books based on keyword extraction model and reinforcement learning. Build a book text keyword extraction model, accurately extract book text keywords, and represent books based on this. Based on the number of occurrences of keywords in the book text, the weight coefficient of keywords in the book text is measured. Based on this, keywords are arranged in descending order, retaining a fixed number of keywords to obtain the final representation result of the book text. Based on the theory of reinforcement learning, the automatic book classification program is developed, and the rules of book classification are determined. The final results of automatic book classification can be obtained by executing the program. The experimental data shows that under different experimental group backgrounds, the maximum sensitivity of book classification obtained after the application of the proposed method is 96%, and the maximum geometric average of book classification is 92%, fully confirming that the proposed method has better book classification performance.

Key words: reinforcement learning; university libraries; keywords extraction model; book classification; similarity calculation; library management

中国知网 https://www.cnki.net