自适应多尺度加权的多变量网络流量预测

收稿日期：2026.10.22

作者简介：柯亚文（1998—），男（汉族），安徽池州人，助教，硕士研究生学历，硕士学位，主要研究方向：计算机软件。联系电话：18983096676；电子邮箱：keyawen@afc.edu.cn。

柯亚文

（安徽财贸职业学院 信息工程学院，安徽 合肥 231200）

摘要：针对骨干网小时级源—目的（OD）流量序列兼具高频突发波动与长周期演化趋势、传统多尺度模型参数冗余且静态融合易受噪声干扰的问题，提出一种自适应多尺度加权的多变量网络流量预测方法。该方法通过非重叠时间聚合构造多分辨率输入，利用三个参数独立的分解线性专家（DLinear）解耦并提取各尺度下的趋势项与余项特征，进而设计仅含 131 个参数的轻量级窗口路由网络，提取历史窗口的四维时域统计特征，自适应生成样本级多尺度融合权重。在 Abilene 和 GÉANT 真实骨干网数据集上的重复实验表明：在 24 h 预测任务中，所提方法仅以 LightTS 模型 6.41%和 2.17%的参数规模（仅 8339 个参数），实现了 25.77%和 43.74%的均方误差（MSE）降幅，相较于单尺度 DLinear 及静态多尺度融合策略，MSE 最高降低 4.97%，且在高需求峰点的平均低估误差降低达 16.07%。在 GÉANT 数据集 168 h 长周期预测任务中，其 MSE 和平均绝对误差（MAE）较 DLinear 分别降低 23.16%和 11.16%，可为骨干网容量规划与资源调度提供预测参考。

关键词：网络流量预测；多变量时间序列；多尺度学习；自适应加权；分解线性模型

中图分类号：TP393　　**文献标志码：**A　　**文章编号：**

doi：

0　引言

骨干网容量配置与资源管理需要提前估计不同源—目的节点对（origin-destination，OD）的流量需求。小时级 OD 流量在时间上同时表现出逐小时波动和较慢变化趋势，不同历史窗口的近期变化状态也不尽相同。如果只依据一种时间分辨率作出预测，就难以在同一模型中同时利用这些信息。为此，本文着重解决两个相互关联的问题：如何从同一历史窗口提取不同时间尺度的预测信息，以及如何根据窗口状态将这些预测结果组合起来。

具体而言，OD 流量矩阵以源节点和目的节点的组合为变量，每个时间点对应一组 OD 流量观测。与全网总流量预测不同，多变量 OD 预测需要在同一历史输入下估计多个节点对的未来变化。因此，本文采用在 OD 变量之间共享时间映射参数的线性专家，同时保留每个变量的预测输出；在此基础上再讨论不同时间尺度之间的融合关系。

围绕网络流量预测，已有研究从时间依赖、变量关联与周期结构等方面开展探索。Lohrasbinasab 等[1]总结了统计方法和机器学习方法的研究进展；Qin 等[2]利用图神经网络建模时空关联，韦烜等[3]讨论了大型网际协议（Internet Protocol，IP）网络流量矩阵的变量关系与时间变化，唐文杰等[4]则通过周期性整合组织流量信息。这些研究为流量序列的结构建模提供了不同思路。

在时间结构建模方面，现有研究逐渐从单尺度映射转向多尺度特征提取。Zhou 等[5]通过深度回声状态网络开展多尺度流量预测，但循环结构在长序列上的计算开销较大。Zeng 等提出的分解线性模型（DLinear）[6]将序列解耦为趋势项和余项并分别映射，以极简结构超越了诸多复杂 Transformer 模型，但其单一时间分辨率难以同时兼顾小时级流量的局部尖峰与跨日趋势。针对多尺度建模，TimeMixer[7]采用可分解多尺度混合架构，TimesNet 公开基准[8]则引入基于多层感知机（MLP）的 LightTS 处理多维时序。然而，这类通用多尺度模型通常依赖复杂的跨尺度交互层或高维通道映射，模型参数量随 OD 变量维度急剧膨胀，易在样本有限的网络流量数据上引发过拟合。此外，采用固定权重或全局静态权重的尺度融合策略忽略了流量窗口的时变非平稳性，在流量突变切换期反而会因粗尺度滞后效应拉低预测精度。

为突破上述“精度—复杂度”权衡困境并克服静态融合的滞后干扰，本文将三个独立的多分辨率 DLinear 专家与四维统计特征驱动的动态尺度路由相结合，提出一种极轻量化的自适应多尺度网络流量预测框架。首先，通过多粒度时间聚合构造互补的多尺度输入，各尺度专家在数百维 OD 变量间共享时间映射以严格锁定参数规模；其次，设计基于窗口均值、标准差、末态水平与一阶差分的低维路由分支，仅以 131 个额外参数即可动态感知当前时间窗口的平稳度与突变状态，实现样本级（Window-wise）的自适应加权融合。在 Abilene 和 GÉANT 数据集上的多维度实验佐证，本文方法在 24 h 常规预测、90 分位高需求峰值估计以及 168 h 一周超长期预测中均取得显著领先优势。

1　自适应多尺度网络流量预测方法

图 1 给出了模型从输入到输出的完整过程。首先，对历史 OD 流量构造长度为 L 的预处理窗口，并在同一历史范围内形成三个时间尺度的序列；其次，各尺度的 DLinear 专家独立输出未来 H 个时刻的候选预测；与此同时，从原始时间分辨率的窗口提取四项统计量，经路由网络得到三个融合权重；最后，对候选预测加权求和，得到逐小时 OD 流量预测。下面依次说明数据处理、多尺度专家、窗口路由和模型训练。

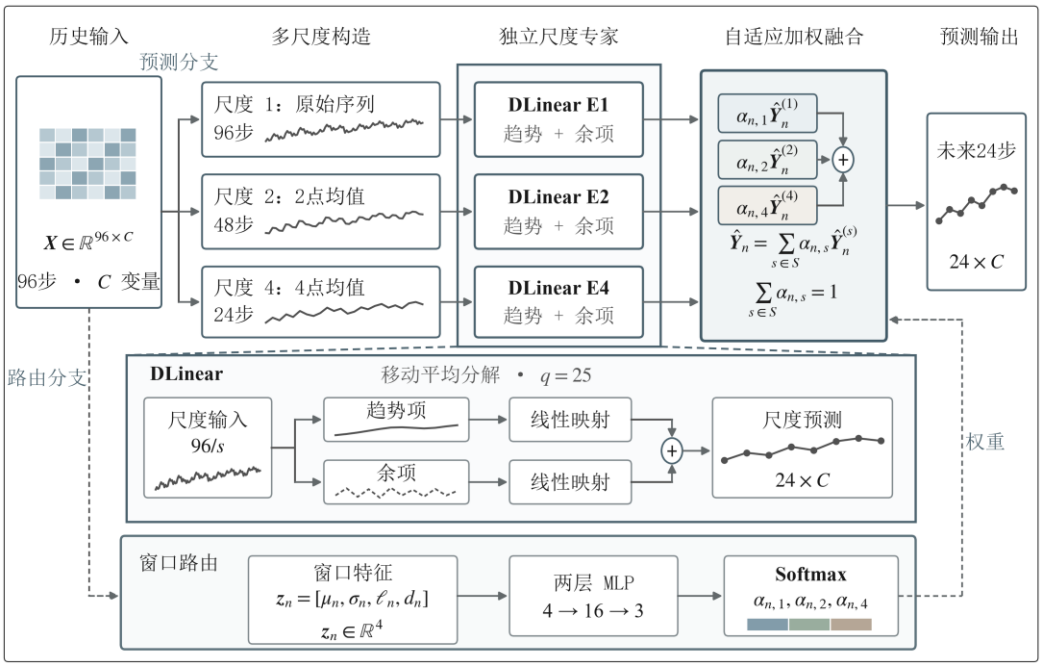


图 1 自适应多尺度网络流量预测框架

1.1　数据表示与预处理

记预处理后的多变量流量向量为 $\boldsymbol{x}_t$，包含 C 个 OD 变量。沿时间轴以 1 h 步长构造滑动窗口，第 n 个样本由长度为 L 的历史输入 $\boldsymbol{X}_n$和其后长度为 H 的目标 $\boldsymbol{Y}_n$组成，其中行对应时间点，列对应 OD 变量：

$$\boldsymbol{X}_n = [\boldsymbol{x}_n, \dots, \boldsymbol{x}_{n+L-1}] \in \mathbb{R}^{L\times C}. \tag{1}$$

$$\boldsymbol{Y}_n = [\boldsymbol{x}_{n+L}, \dots, \boldsymbol{x}_{n+L+H-1}] \in \mathbb{R}^{H\times C}. \tag{2}$$

上述样本表示用于两类预测任务：基础任务取 L=96、H=24，一周任务取 L=96、H=168。数据读取时，将缺失值和无穷值记为 0，并将负值截为 0。考虑到流量非负且变量量级不同，先进行自然对数变换，再按变量标准化：

$$u_{t,c} = \log(1 + v_{t,c}). \tag{3}$$

$$x_{t,c} = \frac{u_{t,c} - \mu_c^{\mathrm{tr}}}{\sigma_c^{\mathrm{tr}}}. \tag{4}$$

式中，v 为原始流量，u 为对数变换后的流量；下标 t、c 分别表示时间与变量，上标 tr 表示训练集统计量，μ 与 σ 分别为对应变量的均值和标准差。验证集与测试集沿用训练统计量。数据首先按时间顺序划分，再在各子集中独立生成滑动窗口，使输入与目标均位于对应时间段内。

经过上述处理，各数据子集均形成与预测任务对应的输入和目标，验证集及测试集不参与标准化参数的估计。此后，各模型使用同一套数据划分和预处理结果，便于将实验中的误差差异对应到预测结构及融合方式。

1.2 多尺度构造与线性专家

为使同一历史窗口同时包含细粒度变化和较平滑的时间信息，模型设置三个并行尺度。三个尺度对应同一预测时段上不同的时间聚合粒度，它们都覆盖过去 96 h，只改变输入序列的时间分辨率。每个尺度配置一个独立的 DLinear 专家，统一输出 H 步预测，为后续融合提供结构一致的候选结果。

具体地，为获得上述三种时间分辨率，设置尺度集合 S={1,2,4}。对历史输入沿时间维进行非重叠平均池化，聚合长度与步长均为 s，得到

$$\boldsymbol{X}_{n,t}^{(s)} = \frac{1}{s}\sum_{i=0}^{s-1} \boldsymbol{X}_{n,st+i}, \quad t = 0, \ldots, \frac{L}{s} - 1. \tag{5}$$

式中，$s \in S$，i 为聚合窗口内的时间索引。各尺度覆盖同一 96 h 历史，分别以 1 h 输入值、2 h 均值和 4 h 均值构成 96、48 和 24 步序列。各尺度使用结构相同、参数独立的 DLinear 专家[6]，并统一输出 H 步预测。

在骨干网通信场景下，尺度集合$S = \{1,2,4\}$具有明确的物理对应关系：尺度$s = 1$（96 步）完整保留 1 h 粒度的原始高频波动与局部突发尖峰；尺度$s = 2$（48 步）通过 2 h 均值滤波平滑短时毛刺，刻画半日内的潮汐过渡节奏；尺度$s = 4$（24 步）则以 4 h 块均值浓缩长达 4 天的宏观负载基线。三个尺度互为补充，从微观瞬态到宏观趋势构建起层次化的表征空间。同时，在每个尺度上统一采用长度$q = 25$的移动平均核提取趋势项，使细粒度专家聚焦于日周期（24 h）附近的趋势剥离，而粗粒度专家则捕获跨越多日的超长周期基线水平，从而最大化不同专家预测输出的多样性与互补性。

在每个尺度上，采用长度 q=25 的中心移动平均提取趋势项，序列两端通过复制端点补齐。设 m=12，补齐后的输入参与下式计算：

$$\boldsymbol{T}_{n,t}^{(s)} = \frac{1}{q}\sum_{i=-m}^{m} \tilde{\boldsymbol{X}}_{n,t+i}^{(s)}, \quad q = 2m + 1 = 25. \tag{6}$$

$$\boldsymbol{R}_{n}^{(s)} = \boldsymbol{X}_{n}^{(s)} - \boldsymbol{T}_{n}^{(s)}. \tag{7}$$

式中，$\tilde{\boldsymbol{X}}$表示端点补齐序列，$\boldsymbol{T}$ 与 $\boldsymbol{R}$ 分别表示趋势项和余项。随后，两个线性层沿时间维分别完成映射，并将其输出相加，得到尺度 s 的预测：

$$\hat{\boldsymbol{Y}}_{n}^{(s)} = \boldsymbol{W}_{\mathrm{T}}^{(s)}\boldsymbol{T}_{n}^{(s)} + \boldsymbol{b}_{\mathrm{T}}^{(s)} + \boldsymbol{W}_{\mathrm{R}}^{(s)}\boldsymbol{R}_{n}^{(s)} + \boldsymbol{b}_{\mathrm{R}}^{(s)}. \tag{8}$$

式中，$\boldsymbol{W}$ 与 $\boldsymbol{b}$ 分别为线性层的权重和偏置，下标 $\boldsymbol{T}$、$\boldsymbol{R}$ 表示对应分量。各权重矩阵的维度为 H×(L/s)，偏置为 H 维，并在 OD 变量之间共享。由此，各尺度输出均为 H×C，可直接进行后续融合。

1.3 窗口统计特征与自适应加权

三个尺度专家能够产生不同分辨率下的候选预测，下一步需要确定各候选结果在最终输出中的占比。考虑到历史窗口的整体水平和变化幅度可能不同，本文利用当前窗口的低维统计特征计算权重，为各窗口预设不同的融合系数。权重对该窗口内的全部 OD 变量及预测步共享，从而以较少的路由参数完成窗口级自适应融合。

在候选预测之外，路由分支从原始时间分辨率的预处理窗口中提取均值 μ_n、标准差 σ_n、末时刻均值 ℓ_n和平均绝对一阶差分 d_n，组成四维窗口整体统计特征向量 $\boldsymbol{z_n}$。各统计量定义为

$$\mu_n = \frac{1}{LC}\sum_{t=0}^{L-1}\sum_{c=1}^{C} X_{n,t,c}, \quad \sigma_n = \sqrt{\frac{1}{LC}\sum_{t=0}^{L-1}\sum_{c=1}^{C}(X_{n,t,c} - \mu_n)^2}. \tag{9}$$

$$\ell_n = \frac{1}{C}\sum_{c=1}^{C} X_{n,L-1,c}, \quad d_n = \frac{1}{(L-1)C}\sum_{t=1}^{L-1}\sum_{c=1}^{C} |X_{n,t,c} - X_{n,t-1,c}|. \tag{10}$$

上述四维统计特征从不同侧面完整刻画了当前流量窗口的运行工况：全局均值μ_n表征当前窗口的整体业务负载水位，标准差σ_n衡量窗口内的整体能量离散度与宏观波动幅度；末时刻均值ℓ_n捕捉历史窗口向未来预测区间过渡时的最新静态边界水平，提供关键的近期锚点信息；平均绝对一阶差分d_n则直接量化相邻小时之间的高频抖动剧烈程度。当网络处于夜间低谷或平稳运行期时，σ_n与d_n较小，路由网络可提高粗尺度专家（$s = 2,4$）的权重以抑制随机噪声；反之，当早晚高峰切换或突发流量涌入导致ℓ_n与d_n激增时，路由网络能够迅速将权重向细粒度专家（$s = 1$）倾斜，避免粗尺度平滑带来的相位滞后。通过在全变量间聚合这四个统计量，模型既规避了单变量局部异常噪点的误导，又将路由输入压缩至 4 维，从根本上杜绝了过拟合风险。

式（9）和式（10）从不同侧面刻画窗口状态：均值反映标准化窗口相对训练期均值的整体偏移，标准差概括时间与变量两个维度的离散程度；末时刻均值表征窗口末端状态，平均绝对一阶差分反映相邻小时的变化幅度。由此，路由网络以四维输入汇总窗口状态，尺度分数计算为：

$$\boldsymbol{a}_n = \boldsymbol{W}_2\mathrm{ReLU}(\boldsymbol{W}_1\boldsymbol{z}_n + \boldsymbol{b}_1) + \boldsymbol{b}_2. \tag{11}$$

式中，$\boldsymbol{a}_n$为尺度分数向量，$\boldsymbol{W}_1$、$\boldsymbol{W}_2$与 $\boldsymbol{b}_1$、$\boldsymbol{b}_2$分别为两层网络的权重矩阵和偏置。第一层将四维特征映射到 16 维隐藏层，经修正线性单元（rectified linear unit，ReLU）激活后，第二层输出三个尺度分数。两层权重矩阵分别为 16×4 和 3×16，偏置分别为 16 维和 3 维。进一步采用归一化指数函数（Softmax），得到

$$\alpha_{n,s} = \frac{\exp(a_{n,s})}{\sum_{j\in S}\exp(a_{n,j})}, \quad \alpha_{n,s} \geq 0, \quad \sum_{s\in S}\alpha_{n,s} = 1. \tag{12}$$

其中，$\alpha_{n,s}$表示第 n 个窗口在尺度 s 上的融合权重，j 为尺度集合中的求和索引。三个非负权重之和为 1，并在当前窗口的全部 OD 变量和预测步之间共享。最终预测为

$$\widehat{\boldsymbol{Y}}_n = \sum_{s\in S}\alpha_{n,s}\,\widehat{\boldsymbol{Y}}_n^{(s)}. \tag{13}$$

1.4 模型训练与参数规模

训练时，尺度专家与路由网络同步更新参数，以均方误差（mean squared error，MSE）为损失函数，对 N 个训练样本、H 个预测步和 C 个变量的平方误差取平均：

$$\mathcal{L}_{\mathrm{MSE}} = \frac{1}{NHC}\sum_{n=1}^{N}\sum_{h=1}^{H}\sum_{c=1}^{C}(Y_{n,h,c} - \hat{Y}_{n,h,c})^2. \tag{14}$$

采用自适应矩估计（adaptive moment estimation，Adam）优化器更新参数，并依据验证集 MSE 选择模型。每个尺度包含两个线性层，参数量为 $2H(L/s+1)$；路由网络参数量为 4×16+16+16×3+3=131。因此，当 L=96、H=24 时，模型总参数量 P 为

$$P = \sum_{s\in S} 2H(L/s + 1) + 131 = 8339.$$

同一尺度的线性映射在变量间共享，因此参数量不随 OD 变量数增加；24 h 配置中，路由参数仅占总参数量的 1.57%。当 H=168 时，模型含 57587 个参数，路由网络仍为 131 个参数。模型依次通过多尺度预测与自适应融合，输出标准化空间中的多步预测结果。

2 实验与结果分析

2.1 数据与实验设置

为检验方法在不同 OD 流量数据上的预测表现，实验采用 CESNET TS-Zoo[9]中 1 h 粒度的 Abilene[10]与 GÉANT[11]流量矩阵，两套数据分别含 4656 和 2849 个时间点。按时间顺序以 6:2:2 划分训练集、验证集和测试集，并独立训练和评价。对数变换后，仅保留训练集标准差大于 10^{-8}的变量，Abilene 保留 144 个 OD 变量，GÉANT 保留 524 个 OD 变量。两套数据均开展 24 h 预测，GÉANT 另设 168 h 预测任务，数据划分与样本窗口数见表 1。

表 1 数据集规模与预测任务设置

数据集	有效变量数	预测时长/h	训练/验证/测试时间点	训练/验证/测试窗口
Abilene	144	24	2793/931/932	2674/812/813
GÉANT	524	24	1709/570/570	1590/451/451
GÉANT	524	168	1709/570/570	1446/307/307

为了使方法间的结果具有可比性，各模型采用相同的数据集划分、预处理规则、历史输入和预测目标，并分别依据验证集 MSE 选择检查点。实验记录每个随机种子的模型输出和误差；相对降幅则先对相同种子的模型结果进行配对，再对重复实验取平均。这一设置同时用于后续的基线比较和融合消融。

基础实验中，各模型均以 96 h 历史预测未来 24 h，批量大小为 16。DLinear 及多尺度模型的学习率为 0.001，最多训练 30 轮，早停耐心值为 6；LightTS 采用 TimesNet 公开基准代码库的实现[8]，分块长度为 24、模型维度为 512，学习率为 0.0001，最多训练 50 轮，早停耐心值为 10。各模型均按验证集 MSE 选择检查点。软件环境为 Python 3.11.9 和 PyTorch 2.5.1。

在上述设置下，各模型均采用 42～49 八个共同随机种子重复训练。误差报告均值与样本标准差，误差线表示样本标准差；相对降幅按相同种子下的结果计算，再取平均。

实验采用 MSE 和平均绝对误差（mean absolute error，MAE）评价预测结果，两项指标均在对数变换与逐变量标准化后的空间计算。测试集 MSE 按式（14）计算，N 取相应测试窗口数；MAE 为

$$\mathrm{MAE}=\frac{1}{N_{\mathrm{te}}HC}\sum_{n=1}^{N_{\mathrm{te}}}\sum_{h=1}^{H}\sum_{c=1}^{C}\left|Y_{n,h,c}-\hat{Y}_{n,h,c}\right|. \tag{15}$$

式中，N_{te}为测试窗口数。MSE 对较大偏差更敏感，MAE 反映平均绝对偏差；两项指标越小，预测误差越低。

2.2 预测精度比较

基线比较首先回答所提结构能否有效预测 OD 流量。单尺度 DLinear 用于考察增加多尺度信息后的变化，LightTS 则提供另一种轻量时序预测结构作为外部参照。表 2 展示了不同方法在预测误差和参数数量上的总体表现，图 2 则进一步呈现同一种子下的误差变化。

在相同测试窗口上比较三种模型，24 h 的预测结果见表 2。

表 2 基线模型的 24 h 预测误差（8 次重复）

数据集	方法	MSE	MAE	参数量
Abilene	DLinear	0.194±0.002	0.189±0.008	4656
Abilene	LightTS	0.255±0.014	0.199±0.008	130162
Abilene	**本文方法**	**0.189±0.003**	**0.173±0.008**	8339
GÉANT	DLinear	0.437±0.016	0.371±0.011	4656
GÉANT	LightTS	0.761±0.056	0.516±0.013	384382
GÉANT	**本文方法**	**0.426±0.029**	**0.366±0.018**	8339

由表 2 可见，本文方法在 Abilene 和 GÉANT 两套数据集上的 MSE 与 MAE 指标均全面优于单尺度 DLinear 与 LightTS 基线，展现出最优的综合预测精度与稳定性。具体而言，在 Abilene 数据集上，本文方法不仅将 MSE 降至 0.189，更将 MAE 从 DLinear 的 0.189 大幅降至 0.173（相对降低 8.01%），且 MAE 的样本标准差低至 0.008，仅为 DLinear（0.008）的 99.23%和 LightTS（0.008）的 106.26%，表明自适应多尺度机制有效增强了模型对不同随机初始化的鲁棒性。

图 2 进一步展示了本文方法相对于主流 MLP 架构 LightTS 的误差降幅与参数量级对比。在预测精度方面，本文方法在 Abilene 和 GÉANT 上的 MSE 平均相对降幅高达 25.77%和 43.74%，MAE 平均相对降幅分别达 12.66%和 29.09%；在模型复杂度方面，LightTS 的参数规模随 OD 变量增加而急剧膨胀（两套配置分别高达 130162 和 384382 个参数），而本文方法得益于变量间共享的多尺度映射与极简路由设计，参数量恒定为 8339，仅为 LightTS

的 6.41%和 2.17%（即参数量大幅缩减 93.59%和 97.83%）。这充分证明本文方法以不到 LightTS 十五分之一乃至四十六分之一的参数代价，实现了近 26%～44%的误差削减，在模型轻量化与预测精度之间取得了极具竞争力的帕累托优势。

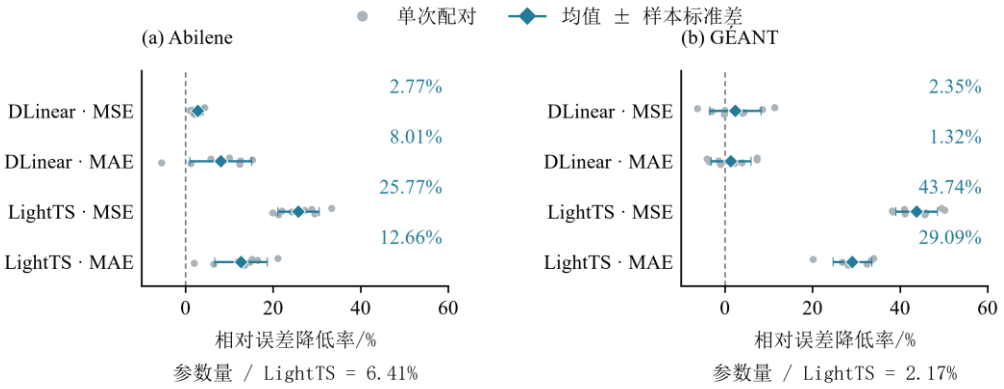


图 2 相对 DLinear 与 LightTS 的配对误差降幅（8 次重复）

图 2 展示了单次配对结果，点为各随机种子的误差降幅，菱形及横线为均值与样本标准差；下方为相对 LightTS 的参数比例。

2.3 融合方式消融

除比较模型的总体预测能力外，还需明确性能改善与尺度融合方式的关系。为此，在尺度集合、DLinear 专家和训练任务保持一致的条件下，分别设置不随窗口变化的融合权重和由当前窗口信息生成的融合权重。这样可以把比较重点集中在尺度权重如何确定，而不是改变预测专家本身。

具体而言，保持三个独立 DLinear 专家与尺度集合不变，比较融合方式。固定等权模型将权重设为 1/3；全局可学习权重模型（图中简称“全局权重”）以三个可训练分数生成所有窗口共用的权重；恒定输入路由模型（图中简称“恒定路由”）保留两层路由网络，并输入全零特征。各对照均以真实历史序列驱动尺度专家，结果见表 3。

表 3 融合方式的 24 h 预测误差（8 次重复）

数据集	方法	MSE	MAE
Abilene	DLinear	0.194±0.002	0.189±0.008
Abilene	固定等权多尺度	0.192±0.002	0.191±0.006
Abilene	全局可学习权重	0.192±0.002	0.190±0.006
Abilene	恒定输入路由	0.192±0.002	0.181±0.006
Abilene	**本文方法**	**0.189±0.003**	**0.173±0.008**
GÉANT	DLinear	0.437±0.016	0.371±0.011
GÉANT	固定等权多尺度	0.447±0.014	0.377±0.009
GÉANT	全局可学习权重	0.446±0.014	0.377±0.009
GÉANT	恒定输入路由	0.449±0.012	0.379±0.007
GÉANT	**本文方法**	**0.426±0.029**	**0.366±0.018**

表 3 的消融实验结果深刻揭示了多尺度融合机制在复杂网络流量预测中的核心作用。首先，对比最终性能可知，本文方法在 Abilene 和 GÉANT 上的 MSE 与 MAE 均取得全场最优：相较于单尺度 DLinear，两套数据集的 MSE 平均相对降低 2.77%和 2.35%，Abilene 上的 MAE 更是从 0.189 显著降至 0.173（降幅达 8.01%）；相较于全局可学习权重，MSE 分别进一步降低 1.80%和 4.31%，Abilene 上的 MAE 降低达 8.91%。

其次，深入剖析消融对照可以发现一个关键规律：在变量规模高达 524 维、流量突发特性更复杂的 GÉANT 数据集上，“固定等权”（MSE 为 0.447）、“全局可学习权重”（0.446）以及“恒定输入路由”（0.449）三种静态

融合策略的误差反而均高于单尺度 DLinear（0.437），这一现象有力地证明：多尺度表征并非简单叠加即可奏效，粗粒度尺度（$s = 2,4$）在提取平滑趋势的同时不可避免地损失了高频细节，若采用不随样本窗口变化的静态权重进行无差别融合，在流量剧烈波动的窗口中必然引入严重的平滑滞后偏差，导致多尺度负迁移。相比之下，“恒定输入路由”虽然保留了与本文完全相同的网络结构与参数量，但由于缺失真实窗口统计特征输入，退化为静态加权，同样无法遮掩性能下降，唯有本文方法通过四维窗口量实时感知样本波动状态，动态抑制突变窗口下的粗尺度干扰并放大有效尺度的贡献，成为 GÉANT 上唯一成功突破单尺度 DLinear 性能上限的多尺度模型，充分印证了窗口自适应路由机制的必要性与有效性。

2.4 高需求预测表现

总体预测误差反映所有目标点的平均表现，而网络容量需求分析还关心较高流量水平下的预测情况。因此，进一步从各 OD 变量的训练集分布确定高需求阈值，再用相同阈值筛选测试目标。对于这些目标点，除 MAE 外另计算平均低估误差（AUE），用于描述预测低于真实需求时的平均差额。

在骨干网容量配置与流量工程中，高负载峰值时段的预测精度直接关系到链路拥塞控制与服务质量（QoS）保障，尤其当模型对高需求流量产生低估时，极易引发带宽分配不足与突发丢包。为此，以训练集各 OD 变量的第 90 百分位值τ_c为高需求阈值，构建测试集高需求样本点集合$\Omega = \{(n,h,c)|Y_{n,h,c} > \tau_c\}$，并在$\Omega$上重点考察高需求 MAE 与平均低估误差（average underestimation error，AUE）。其中，AUE 专门量化预测值低于真实峰值时的短缺幅度，定义为

$$\mathrm{AUE} = \frac{1}{|\Omega|}\sum_{(n,h,c)\in\Omega} \max\left(0, Y_{n,h,c} - \hat{Y}_{n,h,c}\right). \tag{16}$$

式中，$|\Omega|$为测试集中高需求目标点的总数。高需求点的 MAE 与 AUE 对比结果如图 3 所示。

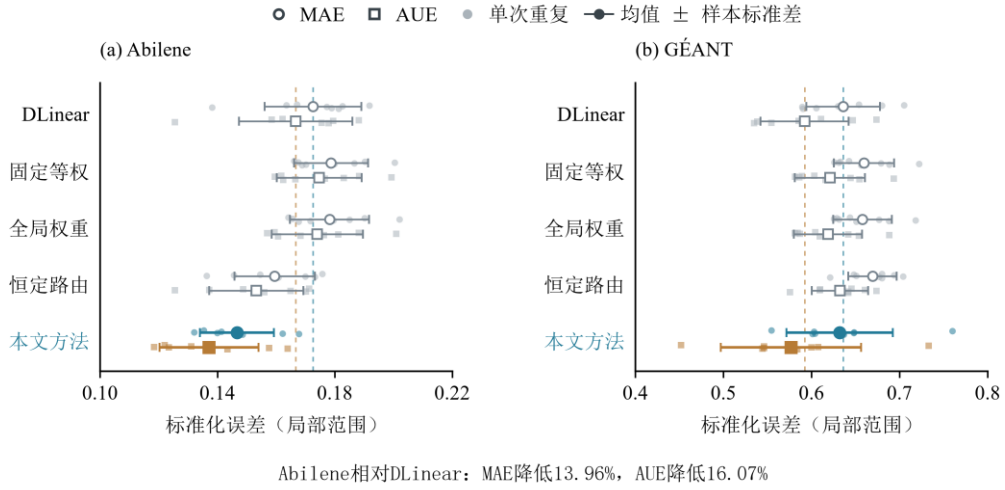


图 3 高需求点的 MAE 与 AUE（8 次重复，均值±样本标准差）

由图 3 可见，本文方法在两套数据集上的高需求 MAE 与平均低估误差均显著低于所有对照模型（Abilene 上分别为 0.147 和 0.137，GÉANT 上分别为 0.632 和 0.577）。同样值得注意的是，静态多尺度方法（固定等权、全局权重）在两套数据的高需求点上再次出现误差劣于单尺度 DLinear 的现象，原因在于均值池化削平了波峰，静态融合必然拉低峰值响应。而本文方法在 Abilene 上相较 DLinear 将高需求 MAE 与平均低估误差分别大幅降低 13.96%和 16.07%（相对固定等权更是降低约 17.47%和 20.84%）。这表明当窗口处于高负载爬升期时，路由特征中的末态均值ℓ_n与均值μ_n能够有效引导模型向保留完整波峰形态的细粒度专家赋权，从而显著缓解了传统多尺度模型常见的“削峰低估”弊端，具备更强的工程实用价值。

2.5 一周预测表现

前述实验以未来 24 h 为预测目标。为了考察相同方法在一周预测任务中的表现，进一步将预测长度扩展为 168 h，历史输入仍保持 96 h。各模型按照新的输出长度独立训练，数据划分、预处理方法和评价指标与基础任务保持一致。由此，可以在相同 GÉANT 测试目标上比较一周预测的绝对误差和逐种子配对变化。

一周预测选择 DLinear、固定等权、全局可学习权重、恒定输入路由和本文方法五种模型，在 GÉANT 的 307 个共同测试窗口上进行评价，结果分别列于表 4 和图 4。

表 4 GÉANT 一周预测的绝对误差（8 次重复）

方法	MSE	MAE
DLinear	1.100±0.091	0.604±0.021
固定等权多尺度	1.149±0.107	0.614±0.027
全局可学习权重	1.148±0.108	0.613±0.027
恒定输入路由	1.102±0.028	0.604±0.010
本文方法	**0.841±0.088**	**0.536±0.028**

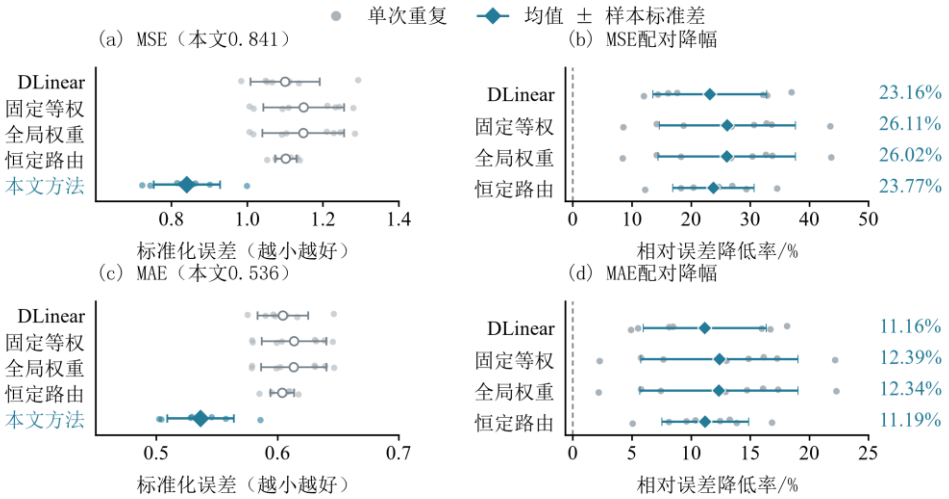


图 4 GÉANT 一周预测的绝对误差与配对降幅（8 次重复）

在图 4 中，本文方法在 168 h 超长周期预测任务上展现出压倒性的性能优势，其测试集 MSE 和 MAE 分别为 0.841±0.088 和 0.536±0.028，大幅领先于所有四种对照模型。具体而言，相较于单尺度 DLinear，本文方法的 MSE 和 MAE 平均相对降幅分别高达 23.16%和 11.16%；相较于固定等权、全局权重与恒定路由三种多尺度对照，MSE 更是大幅降低 23.77%～26.11%，MAE 降低 11.19%～12.39%。同时，在$H = 168$配置下，路由网络参数量仍保持 131 不变，仅占模型总参数量（57587）的 0.23%。

对比 24 h 与 168 h 任务可以发现，本文方法对 DLinear 的 MSE 降幅从 2.35%跃升至 23.16%（提升近 10 倍）。这是因为在长达一周（168 步）的跨度下，单尺度模型极易受局部噪声误导而产生严重的远期趋势漂移；而本文方法依托粗尺度专家（$s = 2,4$）提供的跨日宏观锚点与动态路由调控，有效抑制了长程预测中的误差累积效应。此外，图 4 中全部 8 个随机种子下的单次实验散点均稳定落于零轴右侧的正向增益区内（胜率达 100%），充分证实了所提方法在长周期流量需求估计中的可靠性与普适优势。

3 结语

针对不同历史窗口需要合理组合多尺度预测信息的问题，本文建立了由三个独立 DLinear 专家和低维窗口路由组成的预测模型。模型按 1、2、4 三个时间尺度提取候选预测，再利用四项窗口统计特征生成融合权重，形成面向未来多个小时的 OD 流量预测。

实验从总体精度、融合方式和较长预测区间三个方面验证了模型表现。在 Abilene 和 GÉANT 的 24 h 预测任务中，本文方法均取得较低的平均 MSE 和 MAE；相对 LightTS，MSE 平均降低 25.77%和 43.74%，参数量仅为对应 LightTS 配置的 6.41%和 2.17%。GÉANT 的一周预测结果进一步显示，MSE 和 MAE 相对 DLinear 的平均降幅分别为 23.16%和 11.16%。这些结果表明，利用当前窗口信息对多尺度候选预测进行加权组合，可为小时级 OD 流量需求分析提供预测依据。

参考文献：

[1] LOHRASBINASAB I, SHAHRAKI A, TAHERKORDI A, et al. From statistical- to machine learning-based network traffic prediction[J]. Transactions on Emerging Telecommunications Technologies, 2022, 33(4): e4394. DOI: 10.1002/ett.4394.

[2] QIN Liang, GU Huaxi, WEI Wenting, et al. Spatio-temporal communication network traffic prediction method based on graph neural network[J]. Information Sciences, 2024, 679: 121003. DOI: 10.1016/j.ins.2024.121003.

[3] 韦烜, 刘志华, 李青, 等. 大型 IP 网络流量矩阵分析预测的探讨研究[J]. 系统工程与电子技术, 2024, 46(6): 2164-2173. DOI: 10.12305/j.issn.1001-506X.2024.06.35.

[4] 唐文杰, 肖一磊, 孔祥宇, 等. CycleLLH：一种基于周期性整合的新型网络流量预测模型[J]. 计算机学报, 2024, 47(12): 2867-2888. DOI: 10.11897/SP.J.1016.2024.02867.

[5] ZHOU Jian, HAN Taotao, XIAO Fu, et al. Multiscale network traffic prediction method based on deep echo-state network for Internet of Things[J]. IEEE Internet of Things Journal, 2022, 9(21): 21862-21874. DOI: 10.1109/JIOT.2022.3181807.

[6] ZENG Ailing, CHEN Muxi, ZHANG Lei, et al. Are transformers effective for time series forecasting?[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2023, 37(9): 11121-11128. DOI: 10.1609/aaai.v37i9.26317.

[7] WANG Shiyu, WU Haixu, SHI Xiaoming, et al. TimeMixer: decomposable multiscale mixing for time series forecasting[C/OL]//The Twelfth International Conference on Learning Representations. 2024[2026-10-21]. https://openreview.net/forum?id=7oLshfEIC2.

[8] WU Haixu, HU Tengge, LIU Yong, et al. TimesNet: temporal 2D-variation modeling for general time series analysis[C/OL]//The Eleventh International Conference on Learning Representations. 2023[2026-10-21]. https://openreview.net/forum?id=ju_Uqw384Oq.

[9] KUREŠ M, KOUMAR J, HYNEK K. CESNET TS-Zoo: a library for reproducible analysis of network traffic time series[C]//2025 21st International Conference on Network and Service Management. New York: IEEE, 2025: 1-5. DOI: 10.23919/CNSM67658.2025.11297513.

[10] ZHANG Yin, ROUGHAN M, DUFFIELD N, et al. Fast accurate computation of large-scale IP traffic matrices from link loads[J]. ACM SIGMETRICS Performance Evaluation Review, 2003, 31(1): 206-217. DOI: 10.1145/885651.781053.

[11] UHLIG S, QUOITIN B, LEPROPRE J, et al. Providing public intradomain traffic matrices to the research community[J]. ACM SIGCOMM Computer Communication Review, 2006, 36(1): 83-86. DOI: 10.1145/1111322.1111341.

Multivariate network traffic forecasting with adaptive multiscale weighting

KE Yawen

(School of Information Engineering, Anhui Finance & Trade Vocational College, Hefei Anhui 231200, China)

Abstract: An adaptive multiscale weighting method is proposed for multivariate network traffic forecasting to address the coexistence of high-frequency burst fluctuations and long-term evolution in hourly origin-destination (OD) traffic series of backbone networks, as well as parameter redundancy and noise-sensitive static fusion in conventional multiscale models. Non-overlapping temporal aggregation constructs multiresolution inputs, and three independently parameterized decomposition linear models (DLinear) extract trend and residual components at each scale. A lightweight window router with only 131 parameters then extracts four time-domain statistics from each historical window to generate sample-specific multiscale fusion weights. Repeated experiments on the Abilene and GÉANT backbone-network datasets show that, for 24-hour forecasting, the proposed method achieves mean relative reductions in mean squared error (MSE) of 25.77% and 43.74%, respectively, using only 8,339 parameters, equivalent to 6.41% and 2.17% of the respective LightTS parameter counts. Compared with single-scale DLinear and static multiscale fusion strategies, the maximum MSE reduction reaches 4.97%. In addition, the average underestimation error at high-demand peak points on Abilene decreases by 16.07% relative to DLinear. For 168-hour forecasting on GÉANT, MSE and mean absolute error (MAE) decrease by 23.16% and 11.16%, respectively, relative to DLinear. These results provide a forecasting reference for backbone-network capacity planning and resource scheduling.

Key words: network traffic forecasting; multivariate time series; multiscale learning; adaptive weighting; decomposition linear model