自适应多尺度加权的多变量网络流量预测

柯亚文

（安徽财贸职业学院 信息工程学院，安徽 合肥 231200）

摘要：针对小时级网络流量的多尺度变化，提出自适应加权预测方法。采用三个分解线性模型（DLinear）处理不同时间尺度，并根据四维窗口统计量计算融合权重。在 Abilene 和 GÉANT 上，以 96 h 历史预测未来 24 h，八种子平均均方误差较 DLinear 分别降低 2.77%和 2.35%。模型共含 8339 个参数，其中路由网络为 131 个。结果表明，该方法改善了所设任务的平均预测精度。

关键词：网络流量预测；多变量时间序列；多尺度学习；自适应加权；分解线性模型

Multivariate Network Traffic Forecasting with Adaptive Multiscale Weighting

KE Yawen

(School of Information Engineering, Anhui Finance & Trade Vocational College, Hefei Anhui 231200, China)

Abstract: An adaptive weighting method is proposed to capture multiscale variations in hourly network traffic. Three decomposition linear models (DLinear) process historical sequences at different temporal resolutions, and four window statistics are used to compute their fusion weights. Experiments on Abilene and GÉANT use 96 hours of history to predict the next 24 hours. Across eight random seeds, the mean seed-wise reductions in mean squared error relative to DLinear are 2.77% and 2.35%, respectively. The model contains 8,339 parameters, including 131 routing parameters. The results show improved average forecasting accuracy in the evaluated task.

Key words: network traffic forecasting; multivariate time series; multiscale learning; adaptive weighting; decomposition linear model

中图分类号：TP393　　文献标志码：A

0 引言

骨干网的容量配置与资源管理需要估计未来的通信需求，而源—目的节点对（origin-destination，OD）的流量预测能够为需求分析提供数据依据。小时级 OD 流量既包含局部波动，也呈现较慢的趋势变化；同时，不同变量的量级和变化节奏存在差异。因此，预测模型需要从历史序列中提取不同时间尺度的信息，并将其转化为未来多个时刻的预测结果。

围绕网络流量预测，已有研究从时间依赖、变量关联与周期结构等方面开展探索。Lohrasbinasab 等[1]总结了统计方法和机器学习方法的研究进展；Qin 等[2]利用图神经网络建模时空关联，韦烜等[3]讨论了大型 IP 网络流量矩阵的变量关系与时间变化，唐文杰等[4]则通过周期性整合组织流量信息。这些研究为流量序列的结构建模提供了不同思路。

在时间结构建模方面，Zhou 等[5]通过深度回声状态网络开展多尺度流量预测。分解线性模型（decomposition linear model，DLinear）[6]将趋势项和余项分别映射至预测区间，TimeMixer[7]采用可分解多尺度混合，LightTS[8]则通过采样导向的多层感知器处理多变量序列。随着不同时间分辨率的信息被引入模型，各尺度预测如何根据当前历史窗口进行融合，成为进一步改善预测误差的一个切入点。

基于上述思路，本文提出自适应多尺度加权的网络流量预测方法。首先，通过时间聚合构造三种分辨率的输入，并由独立 DLinear 专家生成候选预测；随后，利用窗口统计量计算尺度权重，完成样本级融合。在 Abilene 和 GÉANT 上，以过去 96 h 预测未来 24 h，通过基线比较、融合消融及周期参照评价该方法的预测效果。

作者简介：柯亚文（1998—），男，助教，硕士，研究方向：计算机软件。电子邮箱：keyawen@afc.edu.cn 。

1 自适应多尺度网络流量预测方法

所提方法由多尺度预测分支和尺度路由分支组成，整体流程如图 1 所示。预测分支提取不同时间分辨率下的趋势与余项，路由分支则根据当前窗口的统计特征分配尺度权重。两条分支共同作用，输出未来 24 h 的逐小时 OD 流量预测。

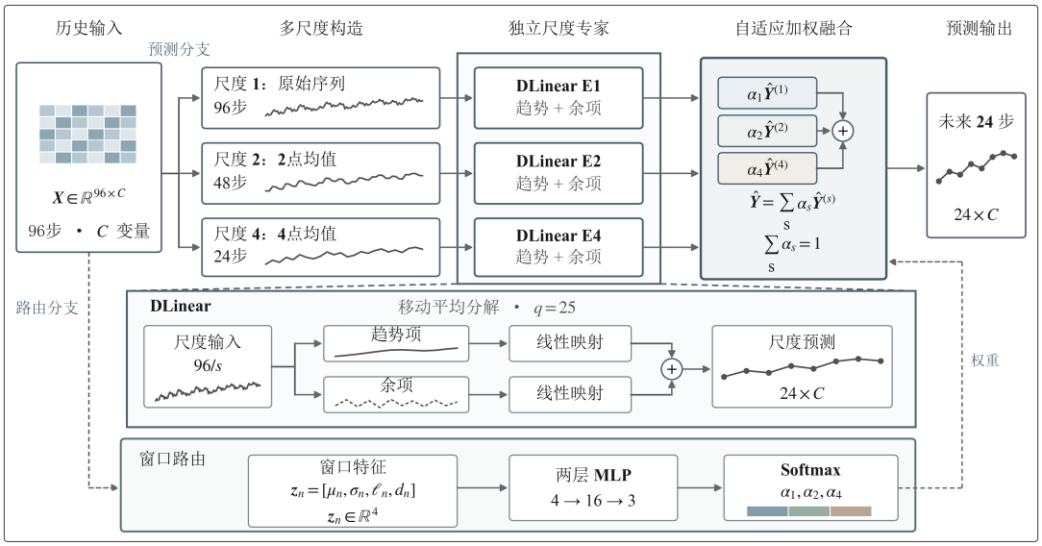


图 1 自适应多尺度网络流量预测框架

1.1 数据表示与预处理

记预处理后的多变量流量向量为 x_t，包含 C 个 OD 变量。沿时间轴构造滑动窗口，第 n 个样本由长度为 L 的历史输入 X_n和其后长度为 H 的目标 Y_n组成。矩阵的行对应时间点，列对应 OD 变量，分别表示为

$$\boldsymbol{X}_n = [\boldsymbol{x}_n, \dots, \boldsymbol{x}_{n+L-1}] \in \mathbb{R}^{L\times C}. \tag{1}$$

$$\boldsymbol{Y}_n = [\boldsymbol{x}_{n+L}, \dots, \boldsymbol{x}_{n+L+H-1}] \in \mathbb{R}^{H\times C}. \tag{2}$$

本文取 L=96、H=24。由于原始流量非负且变量量级不同，先对原始流量进行自然对数变换，再按变量进行标准化：

$$u_{t,c} = \log(1 + v_{t,c}). \tag{3}$$

$$x_{t,c} = \frac{u_{t,c}-\mu_c^{\mathrm{tr}}}{\sigma_c^{\mathrm{tr}}}. \tag{4}$$

式中，v 为原始流量，u 为对数变换后的流量；下标 t、c 分别表示时间与变量，上标 tr 表示训练集统计量，μ 与 σ 分别为对应变量的均值和标准差。验证集与测试集沿用训练统计量。数据首先按时间顺序划分，再在各子集中独立生成滑动窗口，使输入与目标均位于对应时间段内。

1.2 多尺度构造与线性专家

为了在同一历史范围内兼顾局部变化与平滑趋势，设置尺度集合 S={1,2,4}。对历史输入沿时间维进行非重叠平均池化，聚合长度与步长均为 s，得到

$$\boldsymbol{X}_{n,t}^{(s)} = \frac{1}{s}\sum_{i=0}^{s-1} \boldsymbol{X}_{n,st+i}, \quad t = 0, \dots, \frac{L}{s} - 1. \tag{5}$$

式中，s∈S。尺度 1 保留原序列，尺度 2 与尺度 4 分别对相邻 2 个和 4 个时间点取均值，因而形成 96、48 和 24 步的输入。三个尺度使用结构相同、参数独立的 DLinear 专家[6]，并统一输出 H 步预测。

在每个尺度上，采用长度 q=25 的中心移动平均提取趋势项，序列两端通过复制端点补齐。设 m=12，补齐后的输入参与下式计算：

$$\boldsymbol{T}_{n,t}^{(s)} = \frac{1}{q}\sum_{i=-m}^{m} \widetilde{\boldsymbol{X}}_{n,t+i}^{(s)}, \quad q = 2m+1 = 25. \tag{6}$$

$$\boldsymbol{R}_{n}^{(s)} = \boldsymbol{X}_{n}^{(s)} - \boldsymbol{T}_{n}^{(s)}. \tag{7}$$

式中，带波浪号的 X 表示端点补齐序列，T 与 R 分别表示趋势项和余项。随后，两个线性层沿时间维分别完成映射，并将其输出相加，得到尺度 s 的预测：

$$\widehat{\boldsymbol{Y}}_{n}^{(s)} = \boldsymbol{W}_{\mathrm{T}}^{(s)}\boldsymbol{T}_{n}^{(s)} + \boldsymbol{b}_{\mathrm{T}}^{(s)} + \boldsymbol{W}_{\mathrm{R}}^{(s)}\boldsymbol{R}_{n}^{(s)} + \boldsymbol{b}_{\mathrm{R}}^{(s)}. \tag{8}$$

式中，W 与 b 分别为线性层的权重和偏置，下标 T、R 表示对应分量。各权重矩阵的维度为 H×(L/s)，偏置为 H 维，并在 OD 变量之间共享。由此，各尺度输出均为 H×C，可直接进行后续融合。

1.3 窗口统计特征与自适应加权

完成各尺度预测后，路由分支从原始时间分辨率的预处理窗口中提取均值 μ_n、标准差 σ_n、末时刻均值 ℓ_n和平均绝对一阶差分 d_n，组成四维特征向量 z_n。各统计量定义为

$$\mu_n = \frac{1}{LC}\sum_{t=0}^{L-1}\sum_{c=1}^{C} X_{n,t,c}, \quad \sigma_n = \sqrt{\frac{1}{LC}\sum_{t=0}^{L-1}\sum_{c=1}^{C}(X_{n,t,c}-\mu_n)^2}. \tag{9}$$

$$\ell_n = \frac{1}{C}\sum_{c=1}^{C} X_{n,L-1,c}, \quad d_n = \frac{1}{(L-1)C}\sum_{t=1}^{L-1}\sum_{c=1}^{C} |X_{n,t,c} - X_{n,t-1,c}|. \tag{10}$$

均值与标准差概括窗口的整体水平和离散程度，末时刻均值反映近期状态，而平均绝对一阶差分描述相邻时刻的变化幅度。因此，路由网络能够以较低维度接收与当前窗口有关的信息，并据此计算尺度分数：

$$\boldsymbol{a}_n = \boldsymbol{W}_2\mathrm{ReLU}(\boldsymbol{W}_1\boldsymbol{z}_n + \boldsymbol{b}_1) + \boldsymbol{b}_2. \tag{11}$$

式中，第一层将四维特征映射到 16 维隐藏层，经修正线性单元（rectified linear unit，ReLU）激活后，第二层输出三个尺度分数。两层权重矩阵分别为 16×4 和 3×16，偏置分别为 16 维和 3 维。进一步采用 Softmax 归一化，得到

$$\alpha_{n,s} = \frac{\exp(a_{n,s})}{\sum_{j\in S}\exp(a_{n,j})}, \quad \alpha_{n,s} \geq 0, \quad \sum_{s\in S}\alpha_{n,s} = 1. \tag{12}$$

其中，$\alpha_{n,s}$表示第 n 个窗口在尺度 s 上的融合权重。三个非负权重之和为 1，并在当前窗口的全部 OD 变量和预测步之间共享。最终预测为

$$\widehat{\boldsymbol{Y}}_n = \sum_{s\in S}\alpha_{n,s}\widehat{\boldsymbol{Y}}_n^{(s)}. \tag{13}$$

1.4 模型训练与参数规模

尺度专家与路由网络联合训练，以均方误差（mean squared error，MSE）为损失函数，对 N 个训练样本、H 个预测步和 C 个变量的平方误差取平均：

$$\mathcal{L}_{\mathrm{MSE}} = \frac{1}{NHC}\sum_{n=1}^{N}\sum_{h=1}^{H}\sum_{c=1}^{C}(Y_{n,h,c} - \hat{Y}_{n,h,c})^2. \tag{14}$$

采用自适应矩估计（adaptive moment estimation，Adam）优化器更新参数，并依据验证集 MSE 选择模型。每个尺度包含两个线性层，参数量为 2H(L/s+1)；路由网络参数量为 4×16+16+16×3+3=131。因此，当 L=96、H=24 时，模型总参数量为

$$P = \sum_{s \in S} 2H(L/s + 1) + 131 = 8339$$

由于同一尺度的线性映射在变量间共享，所设任务在两套数据上均使用 8339 个参数。预测时，历史输入依次经过预处理、多尺度专家和自适应融合，得到标准化空间中的多步预测结果。

2 实验与结果分析

2.1 数据集与实验设置

实验采用 CESNET TS-Zoo[9]中 1 h 粒度的 Abilene[10]与 GÉANT[11]流量矩阵。两套数据分别按时间顺序以 6:2:2 划分为训练集、验证集和测试集，并独立训练和评价。Abilene 保留 144 个有效 OD 变量；GÉANT 依据训练集标准差剔除恒定或近恒定变量后，保留 524 个变量。数据规模及窗口数见表 1。

表 1 数据集与 24 h 预测任务设置

数据集	时间点数	有效变量数	训练/验证/测试时间点	训练/验证/测试窗口
Abilene	4656	144	2793/931/932	2674/812/813
GÉANT	2849	524	1709/570/570	1590/451/451

各模型均以 96 h 历史预测未来 24 h，批量大小为 16。DLinear 及多尺度模型的学习率为 0.001，最多训练 30 轮，早停耐心值为 6；LightTS 采用公开实现，分块长度为 24、模型维度为 512，学习率为 0.0001，最多训练 50 轮，早停耐心值为 10。各模型均按验证集 MSE 选择检查点。软件环境为 Python 3.11.9 和 PyTorch 2.5.1。

外部基线比较使用 42～44 三个共同随机种子，融合消融与周期比较使用 42～49 八个共同种子。表中学习模型报告种子均值±样本标准差。相对误差降低率按共同种子逐一计算，再取平均；所有种子均参与对应汇总。

2.2 评价指标

采用 MSE、平均绝对误差（mean absolute error，MAE）及均方根误差（root mean squared error，RMSE）评价预测结果，三项指标均在对数变换并逐变量标准化后的空间计算。测试集 MSE 按式（14）计算，样本数取测试窗口数；MAE 与 RMSE 分别为

$$\mathrm{MAE} = \frac{1}{N_{\mathrm{te}} HC} \sum_{n=1}^{N_{\mathrm{te}}} \sum_{h=1}^{H} \sum_{c=1}^{C} \left| Y_{n,h,c} - \hat{Y}_{n,h,c} \right|. \tag{15}$$

$$\mathrm{RMSE} = \sqrt{\mathrm{MSE}}. \tag{16}$$

式中，N_{te}为测试窗口数。MSE 对较大偏差更敏感，MAE 反映平均绝对偏差，RMSE 则以平方误差的均方根表示预测偏差。三项指标的数值越小，表示预测误差越低。

2.3 基线模型比较

选取单尺度 DLinear 和采样导向预测模型 LightTS 作为基线，结果见表 2。两个数据集上，本文方法的平均 MSE 和 MAE 均低于所列基线，说明多尺度候选预测与窗口相关融合相结合，改善了该 24 h 任务的平均预测精度。

表 2 三个共同随机种子的预测结果

数据集	方法	MSE	MAE
Abilene	DLinear	0.194±0.002	0.188±0.009
Abilene	LightTS	0.265±0.011	0.204±0.008
Abilene	**本文方法**	**0.186±0.002**	**0.168±0.001**
GÉANT	DLinear	0.454±0.007	0.383±0.006
GÉANT	LightTS	0.817±0.024	0.523±0.014
GÉANT	**本文方法**	**0.434±0.051**	**0.370±0.031**

按共同种子计算，本文方法相对 DLinear 的平均 MSE 降幅在 Abilene 和 GÉANT 上分别为 4.07%和 4.54%，相对 LightTS 分别为 29.80%和 46.89%。图 2 进一步给出相对 LightTS 的逐种子误差降低率及参数比例，三个共同种子下的 MSE、MAE 和 RMSE 均取得改善。

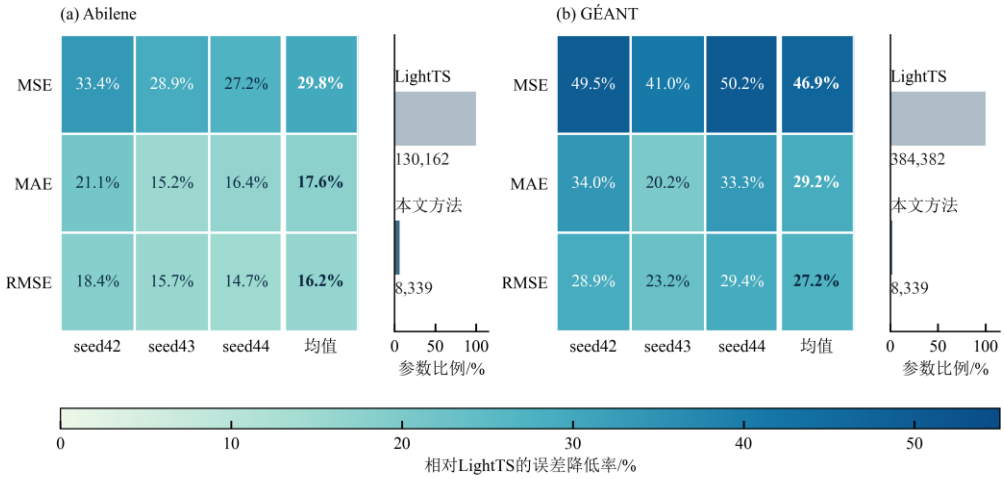


图 2 相对 LightTS 的误差降低率与参数比例

图 2 中，色块表示各指标相对 LightTS 的降低率，最后一列为三个种子的均值；右侧以 LightTS 参数量为 100%表示参数比例。本文方法在两套数据上的参数量分别为对应 LightTS 配置的 6.41%和 2.17%，在保持较低参数规模的同时获得了较低平均预测误差。

2.4 融合方式消融分析

进一步保持三个独立 DLinear 专家及尺度集合不变，对融合方式进行消融。固定等权模型将权重设为 1/3；全局可学习权重模型通过三个可训练分数生成所有窗口共用的权重；恒定输入路由模型保留两层路由网络，但向其输入全零特征。各对照的尺度专家均处理真实历史序列，因此可以在相同多尺度结构下比较融合方式。

表 3 八个共同随机种子的融合消融结果

数据集	方法	MSE	MAE
Abilene	DLinear	0.194±0.002	0.189±0.008
Abilene	固定等权多尺度	0.192±0.002	0.191±0.006
Abilene	全局可学习权重	0.192±0.002	0.190±0.006
Abilene	恒定输入路由	0.192±0.002	0.181±0.006
Abilene	**本文方法**	**0.189±0.003**	**0.173±0.008**
GÉANT	DLinear	0.437±0.016	0.371±0.011
GÉANT	固定等权多尺度	0.447±0.014	0.377±0.009
GÉANT	全局可学习权重	0.446±0.014	0.377±0.009
GÉANT	恒定输入路由	0.449±0.012	0.379±0.007
GÉANT	**本文方法**	**0.426±0.029**	**0.366±0.018**

在八个共同种子的汇总结果中，本文方法在两套数据上的平均 MSE 和 MAE 均低于表 3 所列对照。相对单尺度 DLinear，平均 MSE 分别降低 2.77%和 2.35%；相对固定等权融合，分别降低 1.65%和 4.54%。这表明，在所设 24 h 任务中，引入多尺度输入并学习融合权重能够改善平均误差。

与全局可学习权重相比，本文方法的逐种子平均 MSE 降幅分别为 1.80%和 4.31%；与恒定输入路由相比，分别为 1.80%和 4.97%。两类对照分别提供全局固定权重和等路由结构的参照，而本文方法将当前窗口统计量作为融合依据，在本组重复实验中获得更低的平均预测误差。

2.5 周期基线比较

为评价模型相对周期复制预测的效果，设置日周期与周周期朴素基线，分别采用前 24 h 和前 168 h 对应时刻的观测预测未来 24 h。各方法统一在测试段起点不早于第 168 小时的窗口计分，Abilene 与 GÉANT 分别保留 741 和 379 个共同窗口。日、周周期基线使用 24 h 和 168 h 历史，本文方法使用 96 h 历史，结果见表 4。

表 4 共同测试窗口上的周期基线比较

数据集	方法	历史/h	MSE	MAE
Abilene	日周期朴素	24	0.370	0.231
Abilene	周周期朴素	168	0.390	0.245
Abilene	**本文方法**	**96**	**0.204±0.003**	**0.180±0.009**
GÉANT	日周期朴素	24	0.647	0.404
GÉANT	周周期朴素	168	0.628	0.442
GÉANT	**本文方法**	**96**	**0.442±0.030**	**0.367±0.019**

周期朴素基线为确定性计算，表 4 仅对学习模型报告种子标准差。与日周期基线相比，本文方法在 Abilene 和 GÉANT 上的平均 MSE 分别降低 44.93%和 31.77%；与周周期基线相比，分别降低 47.80%

和 29.69%。同时，两套数据的平均 MAE 也较低，表明根据历史窗口联合提取多尺度信息，在这些共同评价窗口上优于直接复制周期观测。

2.6 模型前向计算耗时

采用八个检查点测量模型前向耗时，批量大小为 16，输入预先载入目标设备并关闭梯度。GPU 在 GTX 1060（6 GB）上以 CUDA 事件计时，每个检查点预热 50 批后，将完整测试集重复 30 次；CPU 在 i7-8750H 上使用单线程，预热 30 批并重复 10 次。按检查点内平均每批耗时计算，再汇总八个检查点的均值与标准差。

Abilene 与 GÉANT 上的 GPU 每批前向耗时分别为 3.28±0.20 ms 和 5.26±2.79 ms，CPU 分别为 40.65±0.19 ms 和 131.35±1.25 ms。该测量对应已载入设备的模型前向过程，为所设规模下的计算需求提供量化参照。

3 结语

本文面向小时级骨干网流量的 24 h 预测任务，构建了由三个独立 DLinear 专家和低维路由网络组成的自适应多尺度模型。通过时间聚合形成不同分辨率的输入，再以四维窗口统计量计算尺度权重，实现多尺度候选预测的融合。

在 Abilene 和 GÉANT 的既定时间划分与完整训练历史下，八种子平均 MSE 相对 DLinear 分别降低 2.77%和 2.35%，相对全局可学习权重分别降低 1.80%和 4.31%；周期比较也取得较低平均误差。模型参数量为 8339，其中尺度路由仅含 131 个参数。上述结果为利用低维窗口特征融合多尺度预测提供了实验依据，可为小时级 OD 流量需求分析提供方法参考。

参考文献

[1] LOHRASBINASAB I, SHAHRAKI A, TAHERKORDI A, et al. From statistical- to machine learning-based network traffic prediction[J]. Transactions on Emerging Telecommunications Technologies, 2022, 33(4): e4394. DOI: 10.1002/ett.4394.

[2] QIN Liang, GU Huaxi, WEI Wenting, et al. Spatio-temporal communication network traffic prediction method based on graph neural network[J]. Information Sciences, 2024, 679: 121003. DOI: 10.1016/j.ins.2024.121003.

[3] 韦烜, 刘志华, 李青, 等. 大型 IP 网络流量矩阵分析预测的探讨研究[J]. 系统工程与电子技术, 2024, 46(6): 2164-2173. DOI: 10.12305/j.issn.1001-506X.2024.06.35.

[4] 唐文杰, 肖一磊, 孔祥宇, 等. CycleLLH：一种基于周期性整合的新型网络流量预测模型[J]. 计算机学报, 2024, 47(12): 2867-2888. DOI: 10.11897/SP.J.1016.2024.02867.

[5] ZHOU Jian, HAN Taotao, XIAO Fu, et al. Multiscale network traffic prediction method based on deep echo-state network for Internet of Things[J]. IEEE Internet of Things Journal, 2022, 9(21): 21862-21874. DOI: 10.1109/JIOT.2022.3181807.

[6] ZENG Ailing, CHEN Muxi, ZHANG Lei, et al. Are transformers effective for time series forecasting?[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2023, 37(9): 11121-11128. DOI: 10.1609/aaai.v37i9.26317.

[7] WANG Shiyu, WU Haixu, SHI Xiaoming, et al. TimeMixer: decomposable multiscale mixing for time series forecasting[C/OL]//International Conference on Learning Representations. 2024[2026-10-03]. https://openreview.net/forum?id=7oLshfEIC2.

[8] ZHANG Tianping, ZHANG Yizhuo, CAO Wei, et al. Less is more: fast multivariate time series forecasting with light sampling-oriented MLP structures[EB/OL]. (2022-07-04)[2026-10-03]. https://arxiv.org/abs/2207.01186. DOI: 10.48550/arXiv.2207.01186.

[9] KUREŠ M, KOUMAR J, HYNEK K. CESNET TS-Zoo: a library for reproducible analysis of network traffic time series[C]//2025 21st International Conference on Network and Service Management. New York: IEEE, 2025: 1-5. DOI: 10.23919/CNSM67658.2025.11297513.

[10] ZHANG Yin, ROUGHAN M, DUFFIELD N, et al. Fast accurate computation of large-scale IP traffic matrices from link loads[J]. ACM SIGMETRICS Performance Evaluation Review, 2003, 31(1): 206-217. DOI: 10.1145/885651.781053.

[11] UHLIG S, QUOITIN B, LEPROPRE J, et al. Providing public intradomain traffic matrices to the research community[J]. ACM SIGCOMM Computer Communication Review, 2006, 36(1): 83-86. DOI: 10.1145/1111322.1111341.