自适应多尺度加权的多变量网络流量预测

收稿日期：

作者简介：柯亚文（1998—），男（汉族），安徽池州人，助教，硕士研究生学历，硕士学位，主要研究方向：计算机软件。联系电话：12345678900；电子邮箱：keyawen@afc.edu.cn。

柯亚文

（安徽财贸职业学院 信息工程学院，安徽 合肥 231200）

摘要：针对小时级网络流量预测，提出自适应多尺度加权方法。以三个分解线性模型（DLinear）处理多尺度输入，通过四维窗口统计量生成融合权重。8 次重复实验中，Abilene 和 GÉANT 的 24 h 预测均方误差较 DLinear 平均降低 2.77%和 2.35%；GÉANT 的 168 h 预测均方误差和平均绝对误差分别降低 23.16%和 11.16%。24 h 模型含 8339 个参数，为流量需求分析提供预测依据。

关键词：网络流量预测；多变量时间序列；多尺度学习；自适应加权；分解线性模型

中图分类号：TP393　　**文献标志码：**A　　**文章编号：**

doi：

0　引言

骨干网的容量配置与资源管理需要估计未来的通信需求，而源—目的节点对（origin-destination，OD）的流量预测能够为需求分析提供数据依据。小时级 OD 流量既包含局部波动，也呈现较慢的趋势变化，而且不同历史窗口的波动幅度与近期变化状态有所不同。因此，预测模型需要提取不同时间尺度的信息，并结合当前窗口的统计特征融合各尺度预测，从而估计未来多个时刻的流量需求。

围绕网络流量预测，已有研究从时间依赖、变量关联与周期结构等方面开展探索。Lohrasbinasab 等[1]总结了统计方法和机器学习方法的研究进展；Qin 等[2]利用图神经网络建模时空关联，韦烜等[3]讨论了大型网际协议（Internet Protocol，IP）网络流量矩阵的变量关系与时间变化，唐文杰等[4]则通过周期性整合组织流量信息。这些研究为流量序列的结构建模提供了不同思路。

在时间结构建模方面，Zhou 等[5]通过深度回声状态网络开展多尺度流量预测。分解线性模型（decomposition linear model，DLinear）[6]将趋势项和余项分别映射至预测区间，TimeMixer[7]采用可分解多尺度混合；TimesNet 公开基准[8]则将基于多层感知机（multilayer perceptron，MLP）的 LightTS 纳入比较。本文关注以低维窗口特征调整不同尺度预测的融合权重。

本文据此将三个独立 DLinear 专家与四维统计特征驱动的尺度路由相结合。时间聚合形成多尺度输入，各专家在 OD 变量间共享时间映射，路由网络则随窗口状态调整融合权重，以较少参数完成样本级融合。在 Abilene 和 GÉANT 上，以过去 96 h 预测未来 24 h，通过基线比较、融合消融与高需求分析评价模型，并在 GÉANT 上考察未来 168 h 的一周预测表现。

1　自适应多尺度网络流量预测方法

所提方法由多尺度预测分支和尺度路由分支组成，图 1 以 24 h 预测任务为例展示整体流程。预测分支提取不同时间分辨率下的趋势与余项，路由分支则根据当前窗口的统计特征分配尺度权重。两条分支共同作用，输出未来 H 个小时的逐小时 OD 流量预测。

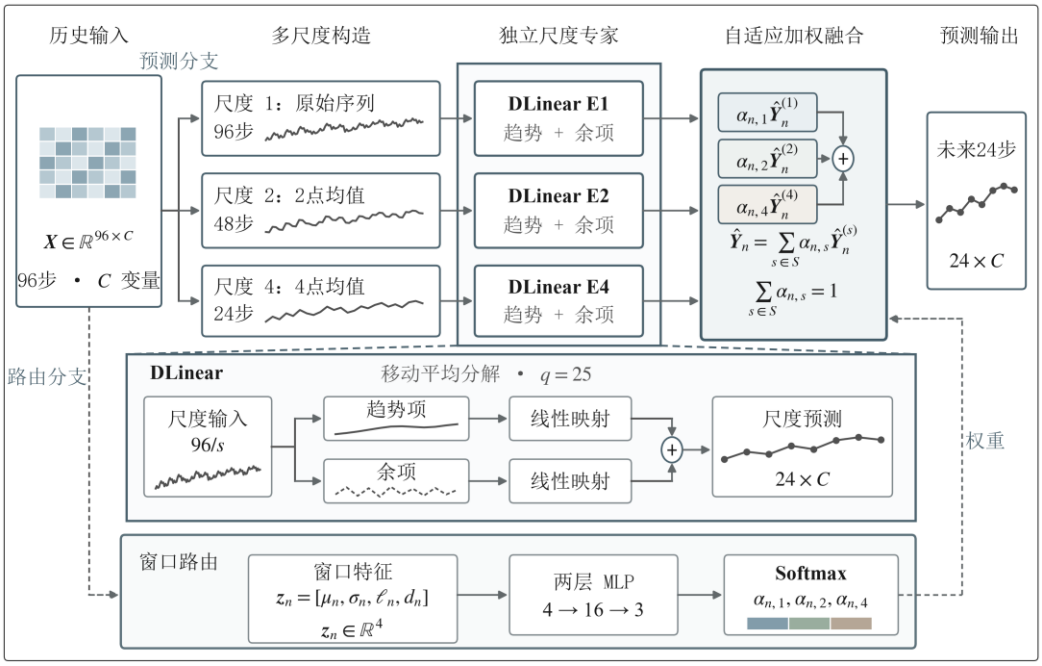


图 1 自适应多尺度网络流量预测框架

1.1 数据表示与预处理

记预处理后的多变量流量向量为 $\boldsymbol{x}_t$，包含 C 个 OD 变量。沿时间轴以 1 h 步长构造滑动窗口，第 n 个样本由长度为 L 的历史输入 $\boldsymbol{X}_n$和其后长度为 H 的目标 $\boldsymbol{Y}_n$组成，其中行对应时间点，列对应 OD 变量：

$$\boldsymbol{X}_n = [\boldsymbol{x}_n, \dots, \boldsymbol{x}_{n+L-1}] \in \mathbb{R}^{L\times C}. \tag{1}$$

$$\boldsymbol{Y}_n = [\boldsymbol{x}_{n+L}, \dots, \boldsymbol{x}_{n+L+H-1}] \in \mathbb{R}^{H\times C}. \tag{2}$$

基础任务取 L=96、H=24，一周任务取 L=96、H=168。数据读取时，将缺失值和无穷值记为 0，并将负值截为 0。考虑到流量非负且变量量级不同，先进行自然对数变换，再按变量标准化：

$$u_{t,c} = \log(1 + v_{t,c}). \tag{3}$$

$$x_{t,c} = \frac{u_{t,c}-\mu_c^{\mathrm{tr}}}{\sigma_c^{\mathrm{tr}}}. \tag{4}$$

式中，v 为原始流量，u 为对数变换后的流量；下标 t、c 分别表示时间与变量，上标 tr 表示训练集统计量，μ 与 σ 分别为对应变量的均值和标准差。验证集与测试集沿用训练统计量。数据首先按时间顺序划分，再在各子集中独立生成滑动窗口，使输入与目标均位于对应时间段内。

1.2 多尺度构造与线性专家

为了在同一历史范围内兼顾局部变化与平滑趋势，设置尺度集合 S={1,2,4}。对历史输入沿时间维进行非重叠平均池化，聚合长度与步长均为 s，得到

$$\boldsymbol{X}_{n,t}^{(s)} = \frac{1}{s}\sum_{i=0}^{s-1}\boldsymbol{X}_{n,st+i}, \quad t = 0, \dots, \frac{L}{s} - 1. \tag{5}$$

式中，$s\in S$，i 为聚合窗口内的时间索引。尺度 1 保留原序列，尺度 2 与尺度 4 分别对相邻 2 个和 4 个时间点取均值，因而形成 96、48 和 24 步的输入。三个尺度使用结构相同、参数独立的 DLinear 专家[6]，并统一输出 H 步预测。

在每个尺度上，采用长度 q=25 的中心移动平均提取趋势项，序列两端通过复制端点补齐。设 m=12，补齐后的输入参与下式计算：

$$\boldsymbol{T}_{n,t}^{(s)} = \frac{1}{q}\sum_{i=-m}^{m}\widetilde{\boldsymbol{X}}_{n,t+i}^{(s)}, \quad q = 2m + 1 = 25. \tag{6}$$

$$\boldsymbol{R}_n^{(s)} = \boldsymbol{X}_n^{(s)} - \boldsymbol{T}_n^{(s)}. \tag{7}$$

式中，带波浪号的 $\boldsymbol{X}$ 表示端点补齐序列，$\boldsymbol{T}$ 与 $\boldsymbol{R}$ 分别表示趋势项和余项。随后，两个线性层沿时间维分别完成映射，并将其输出相加，得到尺度 s 的预测：

$$\widehat{\boldsymbol{Y}}_n^{(s)} = \boldsymbol{W}_{\mathrm{T}}^{(s)}\boldsymbol{T}_n^{(s)} + \boldsymbol{b}_{\mathrm{T}}^{(s)} + \boldsymbol{W}_{\mathrm{R}}^{(s)}\boldsymbol{R}_n^{(s)} + \boldsymbol{b}_{\mathrm{R}}^{(s)}. \tag{8}$$

式中，$\boldsymbol{W}$ 与 $\boldsymbol{b}$ 分别为线性层的权重和偏置，下标 $\boldsymbol{T}$、$\boldsymbol{R}$ 表示对应分量。各权重矩阵的维度为 $H\times(L/s)$，偏置为 H 维，并在 OD 变量之间共享。由此，各尺度输出均为 $H\times C$，可直接进行后续融合。

1.3 窗口统计特征与自适应加权

完成各尺度预测后，路由分支从原始时间分辨率的预处理窗口中提取均值 μ_n、标准差 σ_n、末时刻均值 ℓ_n和平均绝对一阶差分 d_n，组成四维窗口整体统计特征向量 $\boldsymbol{z}_n$。各统计量定义为

$$\mu_n = \frac{1}{LC}\sum_{t=0}^{L-1}\sum_{c=1}^{C} X_{n,t,c}, \quad \sigma_n = \sqrt{\frac{1}{LC}\sum_{t=0}^{L-1}\sum_{c=1}^{C}(X_{n,t,c}-\mu_n)^2}. \tag{9}$$

$$\ell_n = \frac{1}{C}\sum_{c=1}^{C} X_{n,L-1,c}, \quad d_n = \frac{1}{(L-1)C}\sum_{t=1}^{L-1}\sum_{c=1}^{C}|X_{n,t,c}-X_{n,t-1,c}|. \tag{10}$$

均值与标准差概括标准化窗口的整体水平和离散程度，末时刻均值反映窗口末端的整体状态，而平均绝对一阶差分描述相邻时刻的平均变化幅度。因此，路由网络能够以较低维度接收当前窗口的整体变化信息，并据此计算尺度分数：

$$\boldsymbol{a}_n = \boldsymbol{W}_2\mathrm{ReLU}(\boldsymbol{W}_1\boldsymbol{z}_n + \boldsymbol{b}_1) + \boldsymbol{b}_2. \tag{11}$$

式中，$\boldsymbol{a}_n$为尺度分数向量，$\boldsymbol{W}_1$、$\boldsymbol{W}_2$与 $\boldsymbol{b}_1$、$\boldsymbol{b}_2$分别为两层网络的权重矩阵和偏置。第一层将四维特征映射到 16 维隐藏层，经修正线性单元（rectified linear unit，ReLU）激活后，第二层输出三个尺度分数。两层权重矩阵分别为 16×4 和 3×16，偏置分别为 16 维和 3 维。进一步采用归一化指数函数（Softmax），得到

$$\alpha_{n,s} = \frac{\exp(a_{n,s})}{\sum_{j\in S}\exp(a_{n,j})}, \quad \alpha_{n,s}\geq 0, \quad \sum_{s\in S}\alpha_{n,s} = 1. \tag{12}$$

其中，$\alpha_{n,s}$表示第 n 个窗口在尺度 s 上的融合权重，j 为尺度集合中的求和索引。三个非负权重之和为 1，并在当前窗口的全部 OD 变量和预测步之间共享。最终预测为

$$\widehat{\boldsymbol{Y}}_n = \sum_{s\in S}\alpha_{n,s}\,\widehat{\boldsymbol{Y}}_n^{(s)}. \tag{13}$$

1.4 模型训练与参数规模

尺度专家与路由网络联合训练，以均方误差（mean squared error，MSE）为损失函数，对 N 个训练样本、H 个预测步和 C 个变量的平方误差取平均：

$$\mathscr{L}_{\mathrm{MSE}} = \frac{1}{NHC}\sum_{n=1}^{N}\sum_{h=1}^{H}\sum_{c=1}^{C}(Y_{n,h,c}-\hat{Y}_{n,h,c})^2. \tag{14}$$

采用自适应矩估计（adaptive moment estimation，Adam）优化器更新参数，并依据验证集 MSE 选择模型。每个尺度包含两个线性层，参数量为 $2H(L/s+1)$；路由网络参数量为 4×16+16+16×3+3=131。因此，当 L=96、H=24 时，模型总参数量 P 为

$$P = \sum_{s\in S} 2H(L/s+1) + 131 = 8339.$$

同一尺度的线性映射在变量间共享，因此参数量不随 OD 变量数增加；24 h 配置中，路由参数仅占总参数量的 1.57%。当 H=168 时，模型含 57587 个参数，路由网络仍为 131 个参数。模型依次通过多尺度预测与自适应融合，输出标准化空间中的多步预测结果。

2 实验与结果分析

2.1 数据与实验设置

实验采用 CESNET TS-Zoo[9]中 1 h 粒度的 Abilene[10]与 GÉANT[11]流量矩阵，两套数据分别含 4656 和 2849 个时间点。按时间顺序以 6:2:2 划分训练集、验证集和测试集，并独立训练和评价。对数变换后，仅保留训练

集标准差大于 10^{-8}的变量，Abilene 保留 144 个 OD 变量，GÉANT 保留 524 个 OD 变量。两套数据均开展 24 h 预测，GÉANT 另设 168 h 预测任务，数据划分与样本窗口数见表 1。

表 1 数据集规模与预测任务设置

数据集	有效变量数	预测时长/h	训练/验证/测试时间点	训练/验证/测试窗口
Abilene	144	24	2793/931/932	2674/812/813
GÉANT	524	24	1709/570/570	1590/451/451
GÉANT	524	168	1709/570/570	1446/307/307

基础实验中，各模型均以 96 h 历史预测未来 24 h，批量大小为 16。DLinear 及多尺度模型的学习率为 0.001，最多训练 30 轮，早停耐心值为 6；LightTS 采用 TimesNet 公开基准代码库的实现[8]，分块长度为 24、模型维度为 512，学习率为 0.0001，最多训练 50 轮，早停耐心值为 10。各模型均按验证集 MSE 选择检查点。软件环境为 Python 3.11.9 和 PyTorch 2.5.1。

各模型均采用 42～49 八个共同随机种子重复训练。误差报告均值与样本标准差，误差线表示样本标准差；相对降幅按相同种子下的结果计算，再取平均。

采用 MSE 和平均绝对误差（mean absolute error，MAE）评价预测结果，两项指标均在对数变换与逐变量标准化后的空间计算。测试集 MSE 按式（14）计算，N 取相应测试窗口数；MAE 为

$$\mathrm{MAE}=\frac{1}{N_{\mathrm{te}}HC}\sum_{n=1}^{N_{\mathrm{te}}}\sum_{h=1}^{H}\sum_{c=1}^{C}\left|Y_{n,h,c}-\hat{Y}_{n,h,c}\right|. \tag{15}$$

式中，N_{te}为测试窗口数。MSE 对较大偏差更敏感，MAE 反映平均绝对偏差；两项指标越小，预测误差越低。

2.2 预测精度比较

选取单尺度 DLinear 和 LightTS 作为基线，在相同测试窗口上进行比较，结果见表 2。

表 2 基线模型的 24 h 预测误差（8 次重复）

数据集	方法	MSE	MAE
Abilene	DLinear	0.194±0.002	0.189±0.008
Abilene	LightTS	0.255±0.014	0.199±0.008
Abilene	**本文方法**	**0.189±0.003**	**0.173±0.008**
GÉANT	DLinear	0.437±0.016	0.371±0.011
GÉANT	LightTS	0.761±0.056	0.516±0.013
GÉANT	**本文方法**	**0.426±0.029**	**0.366±0.018**

表 2 中，本文方法在两套数据上的平均 MSE 和 MAE 均低于所列基线。图 2 给出相对 LightTS 的误差降幅与参数比例：在 Abilene 和 GÉANT 上，MSE 平均相对降幅分别为 25.77%和 43.74%，MAE 为 12.66%和 29.09%。本文模型均含 8339 个参数，LightTS 两套配置分别含 130162 和 384382 个参数，对应比例为 6.41%和 2.17%。

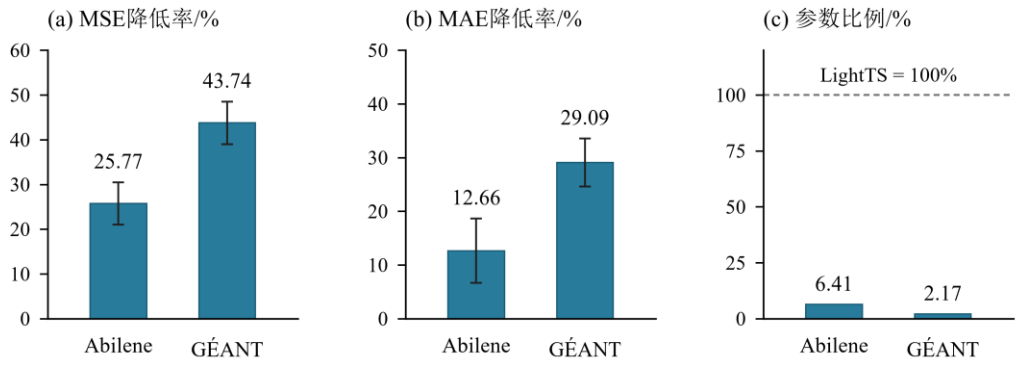


图 2 相对 LightTS 的预测误差降低率与参数比例

图 2(a)、(b)的柱高为八个共同种子的平均相对降幅，误差线为样本标准差；图 2(c)以对应 LightTS 配置的参数量为 100%，给出本文模型的参数比例。该结果表明，在所设 24 h 任务中，多尺度线性预测与低维窗口融合能够兼顾参数规模和预测误差。

2.3 融合方式消融

保持三个独立 DLinear 专家与尺度集合不变，比较融合方式。固定等权模型将权重设为 1/3；全局可学习权重模型（图中简称“全局权重”）以三个可训练分数生成所有窗口共用的权重；恒定输入路由模型（图中简称“恒定路由”）保留两层路由网络，并输入全零特征。各对照均以真实历史序列驱动尺度专家，结果见表 3。

表 3 融合方式的 24 h 预测误差（8 次重复）

数据集	方法	MSE	MAE
Abilene	DLinear	0.194±0.002	0.189±0.008
Abilene	固定等权多尺度	0.192±0.002	0.191±0.006
Abilene	全局可学习权重	0.192±0.002	0.190±0.006
Abilene	恒定输入路由	0.192±0.002	0.181±0.006
Abilene	**本文方法**	**0.189±0.003**	**0.173±0.008**
GÉANT	DLinear	0.437±0.016	0.371±0.011
GÉANT	固定等权多尺度	0.447±0.014	0.377±0.009
GÉANT	全局可学习权重	0.446±0.014	0.377±0.009
GÉANT	恒定输入路由	0.449±0.012	0.379±0.007
GÉANT	**本文方法**	**0.426±0.029**	**0.366±0.018**

表 3 中，本文方法在两套数据上的平均 MSE 和 MAE 均低于所列对照。相对 DLinear，MSE 的平均相对降幅分别为 2.77%和 2.35%；相对全局可学习权重，分别为 1.80%和 4.31%。全局权重在窗口间保持一致，而本文方法以窗口统计量调整尺度组合；结合恒定输入路由的对照，结果支持了在该 24 h 任务中依据窗口信息进行融合预测的设计。

2.4 高需求预测表现

以训练集各 OD 变量的第 90 百分位为高需求阈值，在测试集中超过对应阈值的目标点上计算 MAE 与平均低估误差。后者将低估时的差额计入，其他情况记为 0，再对全部高需求点取平均，结果见图 3。

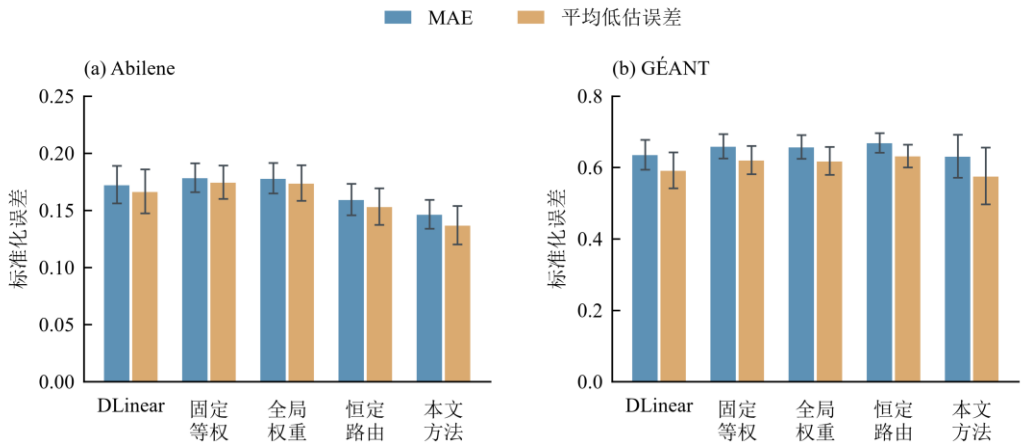


图 3 高需求预测点的 MAE 与平均低估误差（8 次重复）

图 3 中，本文方法在 Abilene 上的 MAE 与平均低估误差分别为 0.147 和 0.137，在 GÉANT 上分别为 0.632 和 0.577，两项均值均低于所列对照。相对 DLinear，Abilene 两项指标的平均相对降幅分别为 13.96%和 16.07%。

MAE 反映总体偏差，平均低估误差侧重于预测需求不足的幅度，二者共同反映了该 24 h 任务中高需求点估计的改善，可为容量需求分析提供参考。

2.5 一周预测表现

为评价较长预测区间的流量需求估计能力，在 GÉANT 上设置 H=168 的任务，并保持小时采样、96 h 输入、数据划分和预处理方式不变。DLinear、固定等权、全局可学习权重、恒定输入路由与本文方法均按 168 h 输出独立训练，沿用 2.1 节中 DLinear 及多尺度模型的训练设置。五种模型在相同的 307 个测试窗口上评价，覆盖全部 168 个预测小时与 524 个 OD 变量，各模型的绝对误差见表 4，相对误差降幅见图 4。

表 4 GÉANT 一周预测的绝对误差（8 次重复）

方法	MSE	MAE
DLinear	1.100±0.091	0.604±0.021
固定等权多尺度	1.149±0.107	0.614±0.027
全局可学习权重	1.148±0.108	0.613±0.027
恒定输入路由	1.102±0.028	0.604±0.010
本文方法	**0.841±0.088**	**0.536±0.028**

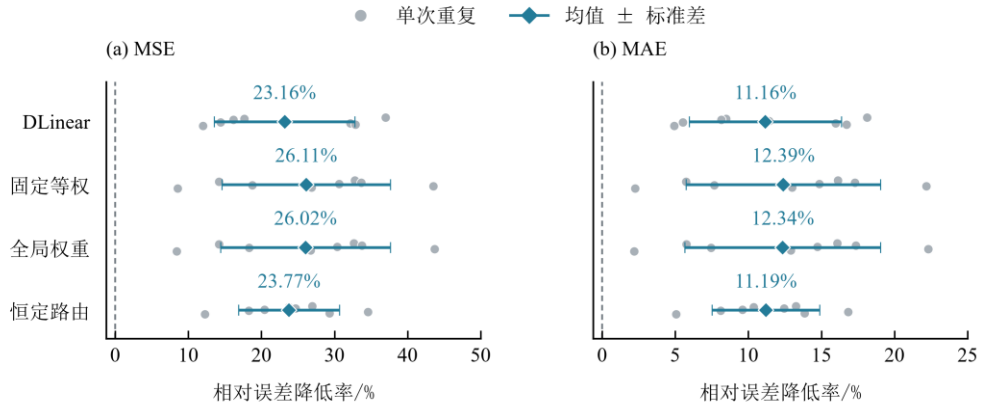


图 4 GÉANT 一周预测中本文方法相对各对照的误差降幅（8 次重复）

表 4 中，本文方法的平均 MSE 和 MAE 均低于四种对照。图 4 进一步给出相同随机种子下的相对降幅：相对 DLinear，两项指标平均降低 23.16%和 11.16%；相对其余三种融合对照，MSE 降低 23.77%～26.11%，MAE 降低 11.19%～12.39%。图中小圆点表示单次相对降幅，菱形及横线表示均值与样本标准差。每种对照下的 8 次重复中，两项误差均降低，体现了该一周任务中优势方向的一致性。

3 结语

本文面向小时级骨干网流量预测，构建了由三个独立 DLinear 专家和低维路由网络组成的自适应多尺度模型。通过时间聚合形成不同分辨率的输入，再以四维窗口统计量计算尺度权重，实现多尺度候选预测的融合。

24 h 任务的基线比较和融合消融表明，本文方法在 Abilene 和 GÉANT 上均取得了较低的平均预测误差。相对 LightTS，MSE 的平均相对降幅分别为 25.77%和 43.74%，参数量分别为对应 LightTS 配置的 6.41%和 2.17%。在 GÉANT 的一周任务中，MSE 与 MAE 相对 DLinear 的平均相对降幅分别为 23.16%和 11.16%。结合高需求点的预测结果，这些实验为利用低维窗口信息融合多尺度预测提供了依据，可为小时级 OD 流量需求分析提供方法参考。

参考文献：

[1] LOHRASBINASAB I, SHAHRAKI A, TAHERKORDI A, et al. From statistical- to machine learning-based network traffic prediction[J]. Transactions on Emerging Telecommunications Technologies, 2022, 33(4): e4394. DOI: 10.1002/ett.4394.

[2] QIN Liang, GU Huaxi, WEI Wenting, et al. Spatio-temporal communication network traffic prediction method based on graph neural network[J]. Information Sciences, 2024, 679: 121003. DOI: 10.1016/j.ins.2024.121003.

[3] 韦烜, 刘志华, 李青, 等. 大型 IP 网络流量矩阵分析预测的探讨研究[J]. 系统工程与电子技术, 2024, 46(6): 2164-2173. DOI: 10.12305/j.issn.1001-506X.2024.06.35.

[4] 唐文杰, 肖一磊, 孔祥宇, 等. CycleLLH：一种基于周期性整合的新型网络流量预测模型[J]. 计算机学报, 2024, 47(12): 2867-2888. DOI: 10.11897/SP.J.1016.2024.02867.

[5] ZHOU Jian, HAN Taotao, XIAO Fu, et al. Multiscale network traffic prediction method based on deep echo-state network for Internet of Things[J]. IEEE Internet of Things Journal, 2022, 9(21): 21862-21874. DOI: 10.1109/JIOT.2022.3181807.

[6] ZENG Ailing, CHEN Muxi, ZHANG Lei, et al. Are transformers effective for time series forecasting?[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2023, 37(9): 11121-11128. DOI: 10.1609/aaai.v37i9.26317.

[7] WANG Shiyu, WU Haixu, SHI Xiaoming, et al. TimeMixer: decomposable multiscale mixing for time series forecasting[C/OL]//The Twelfth International Conference on Learning Representations. 2024[2026-10-21]. https://openreview.net/forum?id=7oLshfEIC2.

[8] WU Haixu, HU Tengge, LIU Yong, et al. TimesNet: temporal 2D-variation modeling for general time series analysis[C/OL]//The Eleventh International Conference on Learning Representations. 2023[2026-10-21]. https://openreview.net/forum?id=ju_Uqw384Oq.

[9] KUREŠ M, KOUMAR J, HYNEK K. CESNET TS-Zoo: a library for reproducible analysis of network traffic time series[C]//2025 21st International Conference on Network and Service Management. New York: IEEE, 2025: 1-5. DOI: 10.23919/CNSM67658.2025.11297513.

[10] ZHANG Yin, ROUGHAN M, DUFFIELD N, et al. Fast accurate computation of large-scale IP traffic matrices from link loads[J]. ACM SIGMETRICS Performance Evaluation Review, 2003, 31(1): 206-217. DOI: 10.1145/885651.781053.

[11] UHLIG S, QUOITIN B, LEPROPRE J, et al. Providing public intradomain traffic matrices to the research community[J]. ACM SIGCOMM Computer Communication Review, 2006, 36(1): 83-86. DOI: 10.1145/1111322.1111341.

Multivariate network traffic forecasting with adaptive multiscale weighting

KE Yawen

(School of Information Engineering, Anhui Finance & Trade Vocational College, Hefei Anhui 231200, China)

Abstract: An adaptive multiscale weighting method is proposed for hourly network traffic forecasting. Three decomposition linear models (DLinear) process multiscale inputs, and four window statistics determine their fusion weights. Across eight training runs with different random seeds, the mean relative reductions in mean squared error against DLinear are 2.77% on Abilene and 2.35% on GÉANT for 24-hour forecasting. For the 168-hour GÉANT task,

the corresponding reductions in mean squared error and mean absolute error are 23.16% and 11.16%. The 24-hour model contains 8,339 parameters, providing a forecasting method for traffic demand analysis.

Key words: network traffic forecasting; multivariate time series; multiscale learning; adaptive weighting; decomposition linear model