自适应多尺度加权的多变量网络流量预测

收稿日期：

作者简介：柯亚文（1998—），男（汉族），安徽池州人，助教，硕士研究生学历，硕士学位，主要研究方向：计算机软件。联系电话：12345678900；电子邮箱：keyawen@afc.edu.cn。

柯亚文

（安徽财贸职业学院 信息工程学院，安徽 合肥 231200）

摘要：提出自适应多尺度加权方法，按窗口统计量融合三个分解线性模型（DLinear）的小时级流量预测。8 次重复中，Abilene 和 GÉANT 的 24 h 均方误差较 LightTS 平均降低 25.77%和 43.74%，参数量为其 6.41%和 2.17%。较 DLinear，Abilene 高需求点平均低估误差降低 16.07%，GÉANT 的 168 h 均方误差和平均绝对误差降低 23.16%和 11.16%，辅助容量需求估计。

关键词：网络流量预测；多变量时间序列；多尺度学习；自适应加权；分解线性模型

中图分类号：TP393　　**文献标志码：**A　　**文章编号：**

doi：

0　引言

骨干网的容量配置与资源管理需要估计未来的通信需求，而源—目的节点对（origin-destination，OD）的流量预测能够为需求分析提供数据依据。小时级 OD 流量既包含局部波动，也呈现较慢的趋势变化，而且不同历史窗口的波动幅度与近期变化状态有所不同。因此，预测模型需要提取不同时间尺度的信息，并结合当前窗口的统计特征融合各尺度预测，从而估计未来多个时刻的流量需求。

围绕网络流量预测，已有研究从时间依赖、变量关联与周期结构等方面开展探索。Lohrasbinasab 等[1]总结了统计方法和机器学习方法的研究进展；Qin 等[2]利用图神经网络建模时空关联，韦烜等[3]讨论了大型网际协议（Internet Protocol，IP）网络流量矩阵的变量关系与时间变化，唐文杰等[4]则通过周期性整合组织流量信息。这些研究为流量序列的结构建模提供了不同思路。

在时间结构建模方面，Zhou 等[5]通过深度回声状态网络开展多尺度流量预测。分解线性模型（decomposition linear model，DLinear）[6]将趋势项和余项分别映射至预测区间，TimeMixer[7]采用可分解多尺度混合；TimesNet 公开基准[8]则将基于多层感知机（multilayer perceptron，MLP）的 LightTS 纳入比较。多尺度信息的提取还需与融合方式相配合。固定等权或全局权重在窗口间共享融合系数，因而不能根据当前窗口的变化状态调整尺度权重。本文关注如何在控制参数规模的同时，利用窗口信息调整尺度权重。

据此，本文将三个独立 DLinear 专家与四维窗口统计特征驱动的尺度路由相结合，构建自适应多尺度加权预测模型。时间聚合形成多分辨率输入，各专家在 OD 变量间共享时间映射，使参数量不随变量数增加；路由网络仅含 131 个参数，根据窗口状态分配尺度权重。在 Abilene 和 GÉANT 上以 96 h 输入开展 24 h 预测、融合消融与高需求点分析，并在 GÉANT 上开展 168 h 预测，评价预测误差与参数规模。

1　自适应多尺度网络流量预测方法

所提方法由多尺度预测分支和尺度路由分支组成，图 1 以 24 h 预测任务为例展示整体流程。预测分支提取不同时间分辨率下的趋势与余项，路由分支则根据当前窗口的统计特征分配尺度权重。两条分支共同作用，输出未来 H 个小时的逐小时 OD 流量预测。

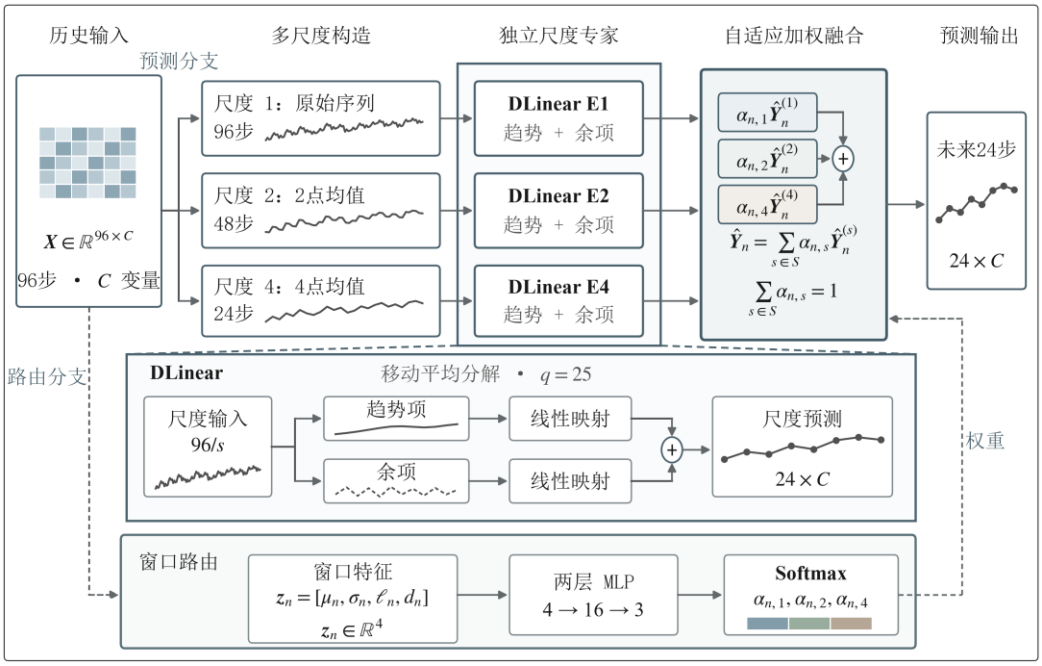


图 1 自适应多尺度网络流量预测框架

1.1 数据表示与预处理

记预处理后的多变量流量向量为 $\boldsymbol{x}_t$，包含 C 个 OD 变量。沿时间轴以 1 h 步长构造滑动窗口，第 n 个样本由长度为 L 的历史输入 $\boldsymbol{X}_n$和其后长度为 H 的目标 $\boldsymbol{Y}_n$组成，其中行对应时间点，列对应 OD 变量：

$$\boldsymbol{X}_n = [\boldsymbol{x}_n, \dots, \boldsymbol{x}_{n+L-1}] \in \mathbb{R}^{L\times C}. \tag{1}$$

$$\boldsymbol{Y}_n = [\boldsymbol{x}_{n+L}, \dots, \boldsymbol{x}_{n+L+H-1}] \in \mathbb{R}^{H\times C}. \tag{2}$$

基础任务取 L=96、H=24，一周任务取 L=96、H=168。数据读取时，将缺失值和无穷值记为 0，并将负值截为 0。考虑到流量非负且变量量级不同，先进行自然对数变换，再按变量标准化：

$$u_{t,c} = \log(1 + v_{t,c}). \tag{3}$$

$$x_{t,c} = \frac{u_{t,c}-\mu_c^{\mathrm{tr}}}{\sigma_c^{\mathrm{tr}}}. \tag{4}$$

式中，v 为原始流量，u 为对数变换后的流量；下标 t、c 分别表示时间与变量，上标 tr 表示训练集统计量，μ 与 σ 分别为对应变量的均值和标准差。验证集与测试集沿用训练统计量。数据首先按时间顺序划分，再在各子集中独立生成滑动窗口，使输入与目标均位于对应时间段内。

1.2 多尺度构造与线性专家

为了在同一历史范围内兼顾局部变化与平滑趋势，设置尺度集合 S={1,2,4}。对历史输入沿时间维进行非重叠平均池化，聚合长度与步长均为 s，得到

$$\boldsymbol{X}_{n,t}^{(s)} = \frac{1}{s}\sum_{i=0}^{s-1}\boldsymbol{X}_{n,st+i}, \quad t = 0, \dots, \frac{L}{s} - 1. \tag{5}$$

式中，$s\in S$，i 为聚合窗口内的时间索引。各尺度覆盖同一 96 h 历史，分别以 1 h 输入值、2 h 均值和 4 h 均值构成 96、48 和 24 步序列。各尺度使用结构相同、参数独立的 DLinear 专家[6]，并统一输出 H 步预测。

在每个尺度上，采用长度 q=25 的中心移动平均提取趋势项，序列两端通过复制端点补齐。设 m=12，补齐后的输入参与下式计算：

$$\boldsymbol{T}_{n,t}^{(s)} = \frac{1}{q}\sum_{i=-m}^{m}\widetilde{\boldsymbol{X}}_{n,t+i}^{(s)}, \quad q = 2m + 1 = 25. \tag{6}$$

$$\boldsymbol{R}_n^{(s)} = \boldsymbol{X}_n^{(s)} - \boldsymbol{T}_n^{(s)}. \tag{7}$$

式中，带波浪号的 $\boldsymbol{X}$ 表示端点补齐序列，$\boldsymbol{T}$ 与 $\boldsymbol{R}$ 分别表示趋势项和余项。随后，两个线性层沿时间维分别完成映射，并将其输出相加，得到尺度 s 的预测：

$$\widehat{\boldsymbol{Y}}_n^{(s)} = \boldsymbol{W}_{\mathrm{T}}^{(s)}\boldsymbol{T}_n^{(s)} + \boldsymbol{b}_{\mathrm{T}}^{(s)} + \boldsymbol{W}_{\mathrm{R}}^{(s)}\boldsymbol{R}_n^{(s)} + \boldsymbol{b}_{\mathrm{R}}^{(s)}. \tag{8}$$

式中，$\boldsymbol{W}$ 与 $\boldsymbol{b}$ 分别为线性层的权重和偏置，下标 $\boldsymbol{T}$、$\boldsymbol{R}$ 表示对应分量。各权重矩阵的维度为 $H\times(L/s)$，偏置为 H 维，并在 OD 变量之间共享。由此，各尺度输出均为 $H\times C$，可直接进行后续融合。

1.3 窗口统计特征与自适应加权

完成各尺度预测后，路由分支从原始时间分辨率的预处理窗口中提取均值 μ_n、标准差 σ_n、末时刻均值 ℓ_n和平均绝对一阶差分 d_n，组成四维窗口整体统计特征向量 $\boldsymbol{z}_n$。各统计量定义为

$$\mu_n = \frac{1}{LC}\sum_{t=0}^{L-1}\sum_{c=1}^{C} X_{n,t,c}, \quad \sigma_n = \sqrt{\frac{1}{LC}\sum_{t=0}^{L-1}\sum_{c=1}^{C}(X_{n,t,c}-\mu_n)^2}. \tag{9}$$

$$\ell_n = \frac{1}{C}\sum_{c=1}^{C} X_{n,L-1,c}, \quad d_n = \frac{1}{(L-1)C}\sum_{t=1}^{L-1}\sum_{c=1}^{C}|X_{n,t,c}-X_{n,t-1,c}|. \tag{10}$$

均值反映标准化窗口相对训练期均值的整体偏移，标准差概括时间与变量两个维度的离散程度；末时刻均值表征窗口末端状态，平均绝对一阶差分反映相邻小时的变化幅度。由此，路由网络以四维输入汇总窗口状态，尺度分数计算为：

$$\boldsymbol{a}_n = \boldsymbol{W}_2\mathrm{ReLU}(\boldsymbol{W}_1\boldsymbol{z}_n + \boldsymbol{b}_1) + \boldsymbol{b}_2. \tag{11}$$

式中，$\boldsymbol{a}_n$为尺度分数向量，$\boldsymbol{W}_1$、$\boldsymbol{W}_2$与 $\boldsymbol{b}_1$、$\boldsymbol{b}_2$分别为两层网络的权重矩阵和偏置。第一层将四维特征映射到 16 维隐藏层，经修正线性单元（rectified linear unit，ReLU）激活后，第二层输出三个尺度分数。两层权重矩阵分别为 16×4 和 3×16，偏置分别为 16 维和 3 维。进一步采用归一化指数函数（Softmax），得到

$$\alpha_{n,s} = \frac{\exp(a_{n,s})}{\sum_{j\in S}\exp(a_{n,j})}, \quad \alpha_{n,s}\geq 0, \quad \sum_{s\in S}\alpha_{n,s} = 1. \tag{12}$$

其中，$\alpha_{n,s}$表示第 n 个窗口在尺度 s 上的融合权重，j 为尺度集合中的求和索引。三个非负权重之和为 1，并在当前窗口的全部 OD 变量和预测步之间共享。最终预测为

$$\widehat{\boldsymbol{Y}}_n = \sum_{s\in S}\alpha_{n,s}\,\widehat{\boldsymbol{Y}}_n^{(s)}. \tag{13}$$

1.4 模型训练与参数规模

尺度专家与路由网络联合训练，以均方误差（mean squared error，MSE）为损失函数，对 N 个训练样本、H 个预测步和 C 个变量的平方误差取平均：

$$\mathscr{L}_{\mathrm{MSE}} = \frac{1}{NHC}\sum_{n=1}^{N}\sum_{h=1}^{H}\sum_{c=1}^{C}(Y_{n,h,c}-\hat{Y}_{n,h,c})^2. \tag{14}$$

采用自适应矩估计（adaptive moment estimation，Adam）优化器更新参数，并依据验证集 MSE 选择模型。每个尺度包含两个线性层，参数量为 $2H(L/s+1)$；路由网络参数量为 4×16+16+16×3+3=131。因此，当 L=96、H=24 时，模型总参数量 P 为

$$P = \sum_{s\in S} 2H(L/s+1) + 131 = 8339.$$

同一尺度的线性映射在变量间共享，因此参数量不随 OD 变量数增加；24 h 配置中，路由参数仅占总参数量的 1.57%。当 H=168 时，模型含 57587 个参数，路由网络仍为 131 个参数。模型依次通过多尺度预测与自适应融合，输出标准化空间中的多步预测结果。

2 实验与结果分析

2.1 数据与实验设置

实验采用 CESNET TS-Zoo[9]中 1 h 粒度的 Abilene[10]与 GÉANT[11]流量矩阵，两套数据分别含 4656 和 2849 个时间点。按时间顺序以 6:2:2 划分训练集、验证集和测试集，并独立训练和评价。对数变换后，仅保留训练

集标准差大于 10^{-8}的变量，Abilene 保留 144 个 OD 变量，GÉANT 保留 524 个 OD 变量。两套数据均开展 24 h 预测，GÉANT 另设 168 h 预测任务，数据划分与样本窗口数见表 1。

表 1 数据集规模与预测任务设置

数据集	有效变量数	预测时长/h	训练/验证/测试时间点	训练/验证/测试窗口
Abilene	144	24	2793/931/932	2674/812/813
GÉANT	524	24	1709/570/570	1590/451/451
GÉANT	524	168	1709/570/570	1446/307/307

基础实验中，各模型均以 96 h 历史预测未来 24 h，批量大小为 16。DLinear 及多尺度模型的学习率为 0.001，最多训练 30 轮，早停耐心值为 6；LightTS 采用 TimesNet 公开基准代码库的实现[8]，分块长度为 24、模型维度为 512，学习率为 0.0001，最多训练 50 轮，早停耐心值为 10。各模型均按验证集 MSE 选择检查点。软件环境为 Python 3.11.9 和 PyTorch 2.5.1。

各模型均采用 42～49 八个共同随机种子重复训练。误差报告均值与样本标准差，误差线表示样本标准差；相对降幅按相同种子下的结果计算，再取平均。

采用 MSE 和平均绝对误差（mean absolute error，MAE）评价预测结果，两项指标均在对数变换与逐变量标准化后的空间计算。测试集 MSE 按式（14）计算，N 取相应测试窗口数；MAE 为

$$\mathrm{MAE}=\frac{1}{N_{\mathrm{te}}HC}\sum_{n=1}^{N_{\mathrm{te}}}\sum_{h=1}^{H}\sum_{c=1}^{C}\left|Y_{n,h,c}-\hat{Y}_{n,h,c}\right|. \tag{15}$$

式中，N_{te}为测试窗口数。MSE 对较大偏差更敏感，MAE 反映平均绝对偏差；两项指标越小，预测误差越低。

2.2 预测精度比较

选取单尺度 DLinear 和 LightTS 作为基线，在相同测试窗口上进行比较，结果见表 2。

表 2 基线模型的 24 h 预测误差（8 次重复）

数据集	方法	MSE	MAE	参数量
Abilene	DLinear	0.194±0.002	0.189±0.008	4656
Abilene	LightTS	0.255±0.014	0.199±0.008	130162
Abilene	**本文方法**	**0.189±0.003**	**0.173±0.008**	8339
GÉANT	DLinear	0.437±0.016	0.371±0.011	4656
GÉANT	LightTS	0.761±0.056	0.516±0.013	384382
GÉANT	**本文方法**	**0.426±0.029**	**0.366±0.018**	8339

表 2 中，本文方法在两套数据上的平均 MSE 与 MAE 均最优。相对 LightTS，Abilene 和 GÉANT 的 MSE 平均降低 25.77%和 43.74%，MAE 降低 12.66%和 29.09%；参数量分别减少 93.59%和 97.83%。

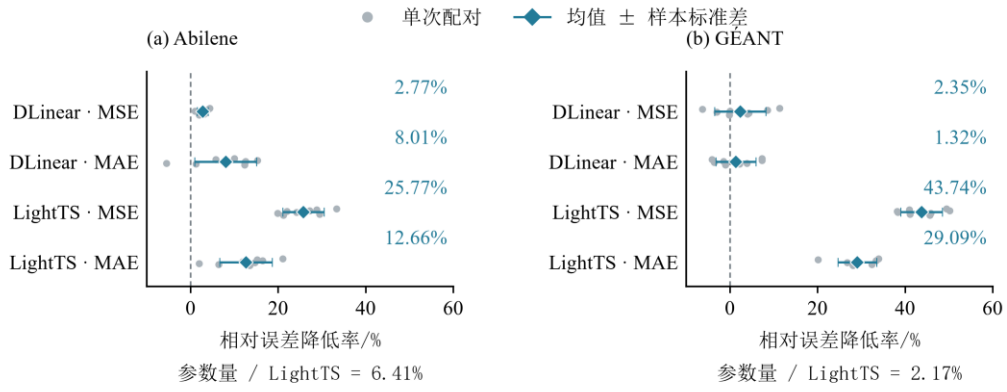


图 2 相对 DLinear 与 LightTS 的配对误差降幅（8 次重复）

图 2 中，点为单次配对结果，菱形及横线为均值与样本标准差；下方为相对 LightTS 的参数比例。

2.3 融合方式消融

保持三个独立 DLinear 专家与尺度集合不变，比较融合方式。固定等权模型将权重设为 1/3；全局可学习权重模型（图中简称“全局权重”）以三个可训练分数生成所有窗口共用的权重；恒定输入路由模型（图中简称“恒定路由”）保留两层路由网络，并输入全零特征。各对照均以真实历史序列驱动尺度专家，结果见表 3。

表 3 融合方式的 24 h 预测误差（8 次重复）

数据集	方法	MSE	MAE
Abilene	DLinear	0.194±0.002	0.189±0.008
Abilene	固定等权多尺度	0.192±0.002	0.191±0.006
Abilene	全局可学习权重	0.192±0.002	0.190±0.006
Abilene	恒定输入路由	0.192±0.002	0.181±0.006
Abilene	**本文方法**	**0.189±0.003**	**0.173±0.008**
GÉANT	DLinear	0.437±0.016	0.371±0.011
GÉANT	固定等权多尺度	0.447±0.014	0.377±0.009
GÉANT	全局可学习权重	0.446±0.014	0.377±0.009
GÉANT	恒定输入路由	0.449±0.012	0.379±0.007
GÉANT	**本文方法**	**0.426±0.029**	**0.366±0.018**

表 3 中，本文方法各项平均误差均最优。相对 DLinear，两套数据的 MSE 平均降低 2.77%和 2.35%；相对全局权重，降低 1.80%和 4.31%。Abilene 的 MAE 较二者降低 8.01%和 8.91%。GÉANT 上，仅本文方法的平均 MSE 低于 DLinear；恒定输入路由保留相同结构和参数量，其误差仍较高，支持窗口统计量驱动的融合设计。

2.4 高需求预测表现

以标准化训练集各 OD 变量的第 90 百分位为阈值τ_c，定义测试集高需求点集$\Omega=\{(n,h,c)|Y_{n,h,c}>\tau_c\}$，在集合内全部目标点上计算 MAE 与平均低估误差（average underestimation error，AUE）：

$$\mathrm{AUE}=\frac{1}{|\Omega|}\sum_{(n,h,c)\in\Omega}\max\left(0,Y_{n,h,c}-\hat{Y}_{n,h,c}\right). \tag{16}$$

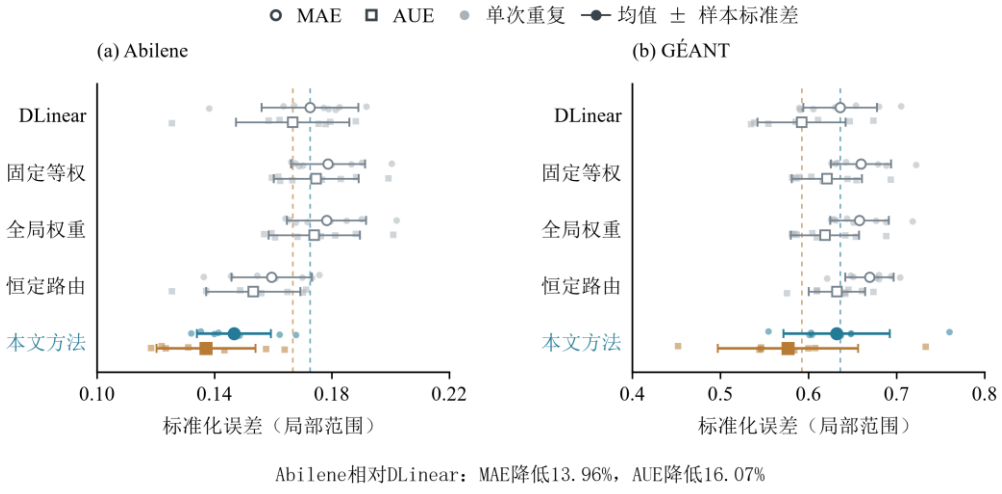


图 3 高需求点的 MAE 与 AUE（8 次重复，均值±样本标准差）

图 3 中，本文方法在 Abilene 上的 MAE 与 AUE 为 0.147 和 0.137，在 GÉANT 上为 0.632 和 0.577，均值均低于所列对照。Abilene 上，相对 DLinear 两项指标平均降低 13.96%和 16.07%，相对固定等权降低 17.47%和 20.84%。横轴为局部范围，虚线为 DLinear 均值。

2.5 一周预测表现

一周预测取 H=168，保持 96 h 输入及原有数据划分与预处理。表 4 所列五种模型均沿用 2.1 节的训练设置，按 168 h 输出独立训练，并在 GÉANT 的全部 307 个测试窗口上评价。

表 4 GÉANT 一周预测的绝对误差（8 次重复）

方法	MSE	MAE
DLinear	1.100±0.091	0.604±0.021
固定等权多尺度	1.149±0.107	0.614±0.027
全局可学习权重	1.148±0.108	0.613±0.027
恒定输入路由	1.102±0.028	0.604±0.010
本文方法	**0.841±0.088**	**0.536±0.028**

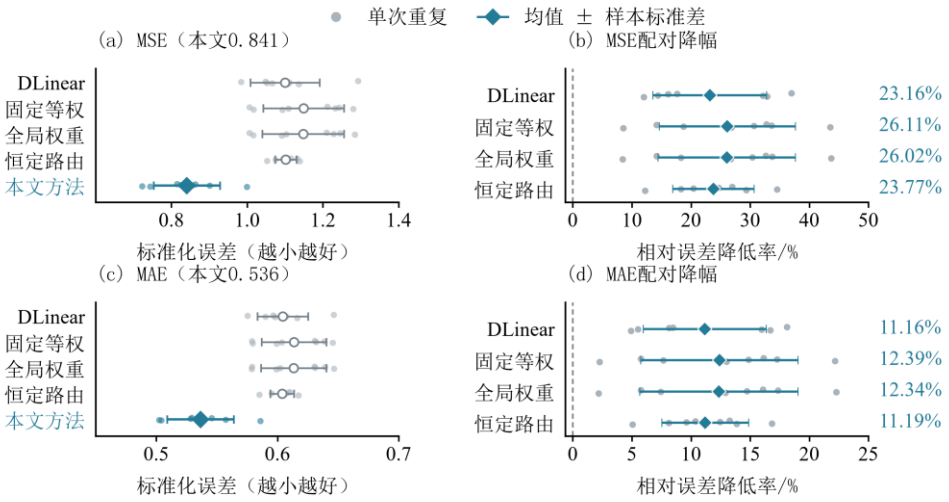


图 4 GÉANT 一周预测的绝对误差与配对降幅（8 次重复）

表 4 中，本文方法的平均 MSE 和 MAE 均最优，较 DLinear 降低 23.16%和 11.16%，较其余融合对照降低 23.77%～26.11%和 11.19%～12.39%。168 h 模型含 57587 个参数，路由网络仍为 131 个，仅占 0.23%。图 4(a)、(c)展示绝对误差，(b)、(d)展示配对降幅；全部 64 个配对降幅均为正值，体现了本组一周预测实验中误差降低的一致性。

3 结语

本文面向小时级骨干网流量预测，构建了由三个独立 DLinear 专家和低维路由网络组成的自适应多尺度模型。通过时间聚合形成不同分辨率的输入，再以四维窗口统计量计算尺度权重，实现多尺度候选预测的融合。

24 h 任务的基线比较和融合消融表明，本文方法在 Abilene 和 GÉANT 上均取得了较低的平均预测误差。相对 LightTS，MSE 的平均相对降幅分别为 25.77%和 43.74%，参数量分别为对应 LightTS 配置的 6.41%和 2.17%。在 GÉANT 的一周任务中，MSE 与 MAE 相对 DLinear 的平均相对降幅分别为 23.16%和 11.16%。结合高需求点的预测结果，这些实验为利用低维窗口信息融合多尺度预测提供了依据，可为小时级 OD 流量需求分析提供方法参考。

参考文献：

[1] LOHRASBINASAB I, SHAHRAKI A, TAHERKORDI A, et al. From statistical- to machine learning-based network traffic prediction[J]. Transactions on Emerging Telecommunications Technologies, 2022, 33(4): e4394. DOI: 10.1002/ett.4394.

[2] QIN Liang, GU Huaxi, WEI Wenting, et al. Spatio-temporal communication network traffic prediction method based on graph neural network[J]. Information Sciences, 2024, 679: 121003. DOI: 10.1016/j.ins.2024.121003.
[3] 韦烜, 刘志华, 李青, 等. 大型 IP 网络流量矩阵分析预测的探讨研究[J]. 系统工程与电子技术, 2024, 46(6): 2164-2173. DOI: 10.12305/j.issn.1001-506X.2024.06.35.
[4] 唐文杰, 肖一磊, 孔祥宇, 等. CycleLLH：一种基于周期性整合的新型网络流量预测模型[J]. 计算机学报, 2024, 47(12): 2867-2888. DOI: 10.11897/SP.J.1016.2024.02867.
[5] ZHOU Jian, HAN Taotao, XIAO Fu, et al. Multiscale network traffic prediction method based on deep echo-state network for Internet of Things[J]. IEEE Internet of Things Journal, 2022, 9(21): 21862-21874. DOI: 10.1109/JIOT.2022.3181807.
[6] ZENG Ailing, CHEN Muxi, ZHANG Lei, et al. Are transformers effective for time series forecasting?[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2023, 37(9): 11121-11128. DOI: 10.1609/aaai.v37i9.26317.
[7] WANG Shiyu, WU Haixu, SHI Xiaoming, et al. TimeMixer: decomposable multiscale mixing for time series forecasting[C/OL]//The Twelfth International Conference on Learning Representations. 2024[2026-10-21]. https://openreview.net/forum?id=7oLshfEIC2.
[8] WU Haixu, HU Tengge, LIU Yong, et al. TimesNet: temporal 2D-variation modeling for general time series analysis[C/OL]//The Eleventh International Conference on Learning Representations. 2023[2026-10-21]. https://openreview.net/forum?id=ju_Uqw384Oq.
[9] KUREŠ M, KOUMAR J, HYNEK K. CESNET TS-Zoo: a library for reproducible analysis of network traffic time series[C]//2025 21st International Conference on Network and Service Management. New York: IEEE, 2025: 1-5. DOI: 10.23919/CNSM67658.2025.11297513.
[10] ZHANG Yin, ROUGHAN M, DUFFIELD N, et al. Fast accurate computation of large-scale IP traffic matrices from link loads[J]. ACM SIGMETRICS Performance Evaluation Review, 2003, 31(1): 206-217. DOI: 10.1145/885651.781053.
[11] UHLIG S, QUOITIN B, LEPROPRE J, et al. Providing public intradomain traffic matrices to the research community[J]. ACM SIGCOMM Computer Communication Review, 2006, 36(1): 83-86. DOI: 10.1145/1111322.1111341.

Multivariate network traffic forecasting with adaptive multiscale weighting

KE Yawen

(School of Information Engineering, Anhui Finance & Trade Vocational College, Hefei Anhui 231200, China)

Abstract: An adaptive multiscale weighting method forecasts hourly traffic by combining three decomposition linear models (DLinear) according to window statistics. Across eight training runs, mean relative reductions in 24-hour mean squared error versus LightTS are 25.77% on Abilene and 43.74% on GÉANT. Parameter counts are 6.41% and 2.17% of the respective LightTS configurations. Relative to DLinear, the mean shortfall at high-demand Abilene points decreases by 16.07%. For 168-hour GÉANT forecasting against DLinear, mean squared error and mean absolute error decrease by 23.16% and 11.16%, respectively. These results support capacity demand estimation using hourly traffic forecasts.

Key words: network traffic forecasting; multivariate time series; multiscale learning; adaptive weighting; decomposition linear model