基于自适应多尺度加权的多变量网络流量预测方法

柯亚文

（安徽财贸职业学院 信息工程学院，合肥 231200）

摘要：小时级骨干网络流量预测需要同时刻画短期波动与长期趋势。针对这一需求，设计一种轻量自适应多尺度预测模型。历史窗口数据按三种时间分辨率输入模型，由独立分解线性专家分别生成预测结果。路由网络从当前窗口提取均值、标准差、末时刻均值和平均绝对一阶差分，再由多层感知器计算融合权重。实验采用 Abilene 和 GÉANT，以 96 步历史输入预测未来 24 步。在 3 个共同随机种子的比较中，单尺度分解线性模型作为对照，本文方法的均方误差分别降低 4.07%和 4.54%；采样导向轻量模型 LightTS 作为对照时，降幅为 29.80%和 46.89%。8 种子消融实验以全局可学习权重和恒定输入路由作对照，Abilene 的逐种子平均改进率均约为 1.80%，GÉANT 的对应改进率分别为 4.31%和 4.97%。多尺度候选预测与低维路由机制配合，在仅引入少量融合参数的条件下获得更低的平均预测误差。输出结果可为次日网络流量需求分析与容量规划提供参考。

关键词：网络流量预测；多变量时间序列；多尺度学习；自适应加权；分解线性模型

中图分类号：TP393　　**文献标志码：**A

A Multivariate Network Traffic Forecasting Method Based on Adaptive Multiscale Weighting

KE Yawen

(School of Information Engineering, Anhui Finance & Trade Vocational College, Hefei 231200, China)

Abstract: Hourly backbone network traffic forecasting requires a representation of both short-term fluctuations and long-term trends. A lightweight adaptive multiscale forecasting model was developed for this purpose. Three temporal resolutions were used to represent historical windows; at each resolution, independent decomposition linear experts generated candidate forecasts. For the current window, a routing network extracted four statistics: the mean, standard deviation, mean at the last time step, and mean absolute first difference. These statistics served as inputs to a multilayer perceptron with two fully connected layers, which calculated fusion weights. On Abilene and GÉANT, experiments used 96 historical steps for predicting the next 24 steps. With three common random seeds, the proposed method reduced mean squared error by 4.07% and 4.54% relative to the single-scale decomposition linear model, respectively. Relative to the sampling-oriented lightweight model LightTS, the corresponding reductions were 29.80% and 46.89%. In ablation experiments across eight random seeds, learned global weights and a constant-input router served as controls for the proposed method. Against both controls, the mean seed-wise improvements on Abilene were approximately 1.80%; on GÉANT, the respective improvements were 4.31% and 4.97%. Lower mean forecasting errors were obtained by combining multiscale candidate forecasts with low-dimensional routing while adding few additional fusion parameters. For next-day network traffic demand analysis and capacity planning, the forecasts can serve as a reference.

Key words: network traffic forecasting; multivariate time series; multiscale learning; adaptive weighting; decomposition linear model

骨干网节点对之间的通信需求以源—目的节点对（origin-destination，OD）流量描述，容量规划则需要掌握各节点对未来的需求变化。本文针对小时级 OD 流量预测未来一天的需求，为高需求时段观察和容量安排提供参考。流量变化的复杂性与云计算、视频业务和数据中心互联所增加的业务迁移与聚集有关。各 OD 变量量级不同，周期变化又与局部波动、突发变化叠加，因此较慢趋势和短时变化均需由预测模型刻画。

收稿日期：[编辑部填写]

第一作者简介：柯亚文（1998—），男，助教，硕士，研究方向：计算机软件。电子邮箱：keyawen@afc.edu.cn 。

Lohrasbinasab 等[1]综述了网络流量预测方法，指出机器学习与深度学习等数据驱动方法的应用不断增加。网络规模扩大后，仅分析单一序列难以覆盖 OD 变量之间的关联。Qin 等[2]采用图神经网络处理空间关联与时间依赖；韦烜等[3]分析大型网际协议（Internet protocol，IP）网络流量矩阵的变量关联及时间变化；唐文杰等[4]在 CycleLLH 中引入周期性信息。这些研究从时间依赖、变量关联和周期结构等角度开展预测。

原始序列中的短时扰动经时间聚合后得到平滑，较慢趋势随之更明显。不同时间分辨率所提供的信息具有互补性。Zhou 等[5]采用深度回声状态网络开展多尺度流量预测。轻量预测方法中，分解线性模型（decomposition linear model，DLinear）[6]将序列分解与线性映射结合使用。TimeMixer[7]进行多尺度混合。LightTS[8]则采用采样导向的多层感知器（multilayer perceptron，MLP）。本文以 DLinear 作为主干，考察不同尺度预测结果的融合方式。

当各尺度专家采用相同结构时，本文考察融合比例随当前窗口状态调整后能否降低预测误差。固定权重能够组合多尺度预测结果，其融合比例却无法随窗口间的状态差异调整。

本文以独立 DLinear 专家处理尺度 1、2 和 4 的序列，用低维窗口统计量驱动路由网络，生成归一化融合权重。尺度专家负责各分辨率的候选预测，路由网络负责尺度间融合，在保留多尺度信息的同时控制参数规模。在 Abilene 和 GÉANT 上，通过基线模型比较、固定融合对照及多随机种子实验评价整体预测精度，并结合预测轨迹和权重分布分析模型行为。

1 自适应多尺度网络流量预测方法

图 1 中预测分支与路由分支共享同一预处理历史窗口，DLinear 专家内部结构通过梯形虚线展开。历史 OD 窗口经对数变换与标准化处理，得到尺度 1、2 和 4 的序列。独立 DLinear 专家将趋势项与余项分别映射，两部分的 24 步预测相加后形成候选预测。尺度路由网络从原始时间分辨率的预处理输入中取得 4 项统计特征，用于计算 Softmax 权重。模型输出由 3 个尺度候选预测加权求和得到。图中曲线和色块仅作示意。

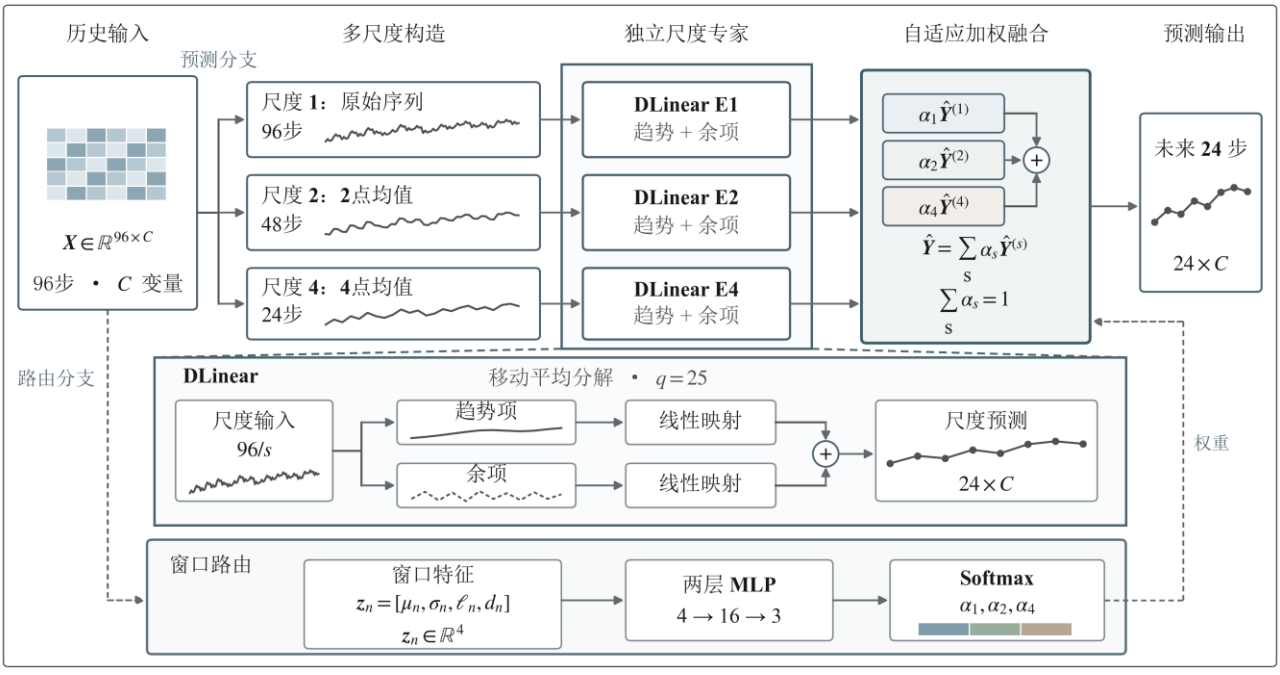


图 1 自适应多尺度预测框架

各尺度的预测彼此独立，均采用相同 DLinear 结构。原始尺度中保留局部波动，较粗尺度经时间聚合突出较慢趋势。融合权重由路由网络按当前窗口特征分配，在统一预测主干上结合多尺度输入与按样本加权。

1.1 预测任务与数据预处理

预处理后的多变量流量序列记为 $\boldsymbol{x}_t \in \mathbb{R}^C$，其中 t 为时间索引，C 为有效 OD 变量数。沿连续序列的时间轴生成滑动窗口，作为监督学习样本。第 n 个样本包含历史窗口$\boldsymbol{X}_n$及预测目标$\boldsymbol{Y}_n$：$\boldsymbol{X}_n$包含连续 L 个时间点，$\boldsymbol{Y}_n$包含其后连续的 H 个时间点。按时间顺序逐行堆叠向量后，矩阵的行与时间点对应，列与 OD 变量对应。第 n 个样本的输入与目标表示为：

$$\boldsymbol{X}_n = [\boldsymbol{x}_n, \dots, \boldsymbol{x}_{n+L-1}] \in \mathbb{R}^{L\times C}. \tag{1}$$

$$\boldsymbol{Y}_n = [\boldsymbol{x}_{n+L}, \dots, \boldsymbol{x}_{n+L+H-1}] \in \mathbb{R}^{H\times C}. \tag{2}$$

输入窗口长度设为 L=96，预测长度设为 H=24，数据中保留的有效 OD 维度数记为 C。历史信息与未来流量之间的预测映射表示为：$\widehat{\boldsymbol{Y}}_n = f_\theta(\boldsymbol{X}_n)$。原始 OD 流量为非负值，不同变量的量级差异较大，因此先对原始流量$v_{t,c}$作对数变换。对数变换后的序列取值范围得到压缩，其中 log 表示自然对数：

$$u_{t,c} = \log(1 + v_{t,c}). \tag{3}$$

再按变量进行标准化：

$$x_{t,c} = \frac{u_{t,c}-\mu_c^{\mathrm{tr}}}{\sigma_c^{\mathrm{tr}}}. \tag{4}$$

其中μ_c^{tr}和σ_c^{tr}由对数变换后的训练集计算，分别表示第 c 个 OD 变量的均值与标准差。这组训练统计量同时用于验证集与测试集。对数变换在压缩取值范围时保留大小关系，逐变量标准化后输入具有相近的数值尺度。数据按时间顺序划分，比例为 6:2:2；滑动窗口在各集合内独立生成，不跨集合边界。

各尺度序列由同一预处理历史窗口构造，分别保留细粒度变化或较平滑的趋势。

96 步历史和 24 步预测，在第 2.1 节的 1 h 聚合数据上分别为过去 96 h 与未来 24 h。这一设置提供未来一天的流量预测，也供小时级需求变化的观察使用。

1.2 多尺度构造与 DLinear 专家

对尺度 s，时间维的非重叠平均池化同时将聚合窗口大小和步长设为该尺度的取值。尺度集合为 S={1,2,4}，各序列按下式构造，其中 s 取自该集合：

$$\boldsymbol{X}_{n,t}^{(s)} = \frac{1}{s}\sum_{i=0}^{s-1} \boldsymbol{X}_{n,st+i}, \quad t = 0, \dots, \frac{L}{s} - 1. \tag{5}$$

非重叠平均池化中没有可训练参数。L=96 时，尺度 1 使用原始 96 步序列。尺度 2 对相邻 2 点取均值后形成 48 步序列。尺度 4 对相邻 4 点取均值后形成 24 步序列。较慢趋势经时间聚合后更明显，局部波动得到平滑。

尺度集合{1,2,4}可将 96 步历史构造成整数长度序列。输入长度随尺度取值增大而缩短，每个尺度配置一个独立专家。在同一尺度内聚合时，每个时间点仅使用一次。

每个 DLinear 专家[6]对本尺度输入作分解，使用长度 q=25 的中心移动平均提取趋势项。输入减去趋势项即可得到余项。为使分解前后的时间长度一致，序列两端采用端点复制填充，补齐后的序列记为$\widetilde{\boldsymbol{X}}^{(s)}$，越界索引对应的值取自最近端点：

$$\boldsymbol{T}_{n,t}^{(s)} = \frac{1}{q}\sum_{i=-m}^{m} \widetilde{\boldsymbol{X}}_{n,t+i}^{(s)}, \quad q = 2m + 1 = 25. \tag{6}$$

$$\boldsymbol{R}_n^{(s)} = \boldsymbol{X}_n^{(s)} - \boldsymbol{T}_n^{(s)}. \tag{7}$$

趋势项$\boldsymbol{T}^{(s)}$和余项$\boldsymbol{R}^{(s)}$沿时间维分别通过线性层映射到预测长度 H：

$$\widehat{\boldsymbol{Y}}_n^{(s)} = \boldsymbol{W}_{\mathrm{T}}^{(s)}\boldsymbol{T}_n^{(s)} + \boldsymbol{b}_{\mathrm{T}}^{(s)} + \boldsymbol{W}_{\mathrm{R}}^{(s)}\boldsymbol{R}_n^{(s)} + \boldsymbol{b}_{\mathrm{R}}^{(s)}. \tag{8}$$

式（6）和式（7）分别给出尺度 s 上的趋势项$\boldsymbol{T}^{(s)}$和余项$\boldsymbol{R}^{(s)}$。局部平滑后的趋势由前者表示，去除趋势后的剩余部分为后者。两者在式（8）中分别作线性映射，再将预测结果相加。长度 96、48 和 24 的输入各由一个专家处理，专家参数独立。两个线性层的权重矩阵均为 $H\times(L/s)$，对应的偏置向量均为 H 维。参数在各 OD 变量之间共享，偏置沿 OD 变量维度广播后，输出为 $H\times C$。

1.3 样本级自适应尺度加权

固定等权融合在三个尺度上均使用 1/3，权重不随当前窗口状态变化。本文通过窗口统计特征学习融合权重，并据此组合三个 DLinear 专家的预测结果。考虑到局部波动与较慢趋势的预测价值可能随窗口变化，从原始时间分辨率的预处理窗口$\boldsymbol{X}_n$中提取统计量，构造四维统计向量$\boldsymbol{z}_n=[\mu_n,\sigma_n,\ell_n,d_n]$，各统计量按下式定义：

$$\mu_n=\frac{1}{LC}\sum_{t=0}^{L-1}\sum_{c=1}^{C}X_{n,t,c},\quad \sigma_n=\sqrt{\frac{1}{LC}\sum_{t=0}^{L-1}\sum_{c=1}^{C}(X_{n,t,c}-\mu_n)^2}. \tag{9}$$

$$\ell_n=\frac{1}{C}\sum_{c=1}^{C}X_{n,L-1,c},\quad d_n=\frac{1}{(L-1)C}\sum_{t=1}^{L-1}\sum_{c=1}^{C}|X_{n,t,c}-X_{n,t-1,c}|. \tag{10}$$

μ_n、σ_n、ℓ_n和d_n分别为输入窗口的均值、标准差、末时刻均值和平均绝对一阶差分。μ_n反映窗口整体流量水平，σ_n刻画观测值的离散程度，ℓ_n为窗口末时刻各 OD 变量的均值，d_n为相邻时间点绝对差值的均值。这 4 个统计量用于计算随输入窗口变化的尺度权重，各尺度专家负责生成预测值。

尺度路由网络以多层感知器实现门控网络，负责生成融合权重；各尺度专家则独立生成 OD 流量预测。多层感知器接收四维统计向量，内部为两层全连接层，16 维隐藏层的输出再映射为 3 个尺度的未归一化分数。该全连接结构构成路由模块，不包含循环网络或注意力编码器。隐藏层采用修正线性单元（rectified linear unit，ReLU）完成激活，尺度分数由下式计算：

$$\boldsymbol{a}_n=\boldsymbol{W}_2\mathrm{ReLU}(\boldsymbol{W}_1\boldsymbol{z}_n+\boldsymbol{b}_1)+\boldsymbol{b}_2. \tag{11}$$

式（11）的两层权重矩阵依次取 16×4 和 3×16，对应偏置向量分别为 16 维和 3 维。3 个尺度分数经 Softmax 归一化后形成 3 个非负权重，其总和为 1。最终预测中各专家的相对贡献以这些权重表示：

$$\alpha_{n,s}=\frac{\exp(a_{n,s})}{\sum_{j\in S}\exp(a_{n,j})},\quad \alpha_{n,s}\geq 0,\quad \sum_{s\in S}\alpha_{n,s}=1. \tag{12}$$

最终预测为

$$\widehat{\boldsymbol{Y}}_n=\sum_{s\in S}\alpha_{n,s}\,\widehat{\boldsymbol{Y}}_n^{(s)}. \tag{13}$$

式（13）给出最终预测$\widehat{\boldsymbol{Y}}_n$。输入窗口决定这一组权重，同一窗口内的全部 OD 变量共用该组取值。

1.4 模型训练与预测输出

采用均方误差（mean squared error，MSE）训练模型，损失为 N 个训练样本、未来 H 个时刻及 C 个 OD 变量上平方误差的平均值。其中 N 为训练样本数，训练目标为

$$\mathcal{L}_{\mathrm{MSE}}=\frac{1}{NHC}\sum_{n=1}^{N}\sum_{h=1}^{H}\sum_{c=1}^{C}(Y_{n,h,c}-\hat{Y}_{n,h,c})^2. \tag{14}$$

模型参数的更新使用自适应矩估计（adaptive moment estimation，Adam）优化器，最终模型依据验证集 MSE 选择。

推理时，输入的历史 OD 窗口按训练阶段的规则处理，各尺度预测由多尺度专家分别生成。路由模块加权融合这些预测，得到未来多步流量预测结果；将结果恢复至原始流量量纲，可供网络需求分析与容量规划参考。

2 实验与结果分析

实验从总体预测性能、融合方式消融、预测与权重行为以及计算开销四方面评价模型。

2.1 数据集与实验设置

实验数据取自 CESNET TS-Zoo[9]中的 1 h 粒度聚合流量矩阵 Abilene[10]和 GÉANT[11]。两套数据采用相同的 L=96、H=24 设置，表 1 列出其规模及窗口数。Abilene 包含 144 维有效 OD 变量，覆盖 4656 个时间点。GÉANT 共有 2849 个时间点，按训练集标准差剔除恒定或近恒定变量后保留 524 个有效 OD 变量。训练、验证、测试集按时间以 6:2:2 划分，数据预处理依照第 1.1 节执行。

表 1 数据集与预测任务设置

数据集	时间点	有效变量 C	训练/验证/测试时间点	训练/验证/测试窗口	L/H
Abilene	4656	144	2793/931/932	2674/812/813	96/24
GÉANT	2849	524	1709/570/570	1590/451/451	96/24

对比设置包括单尺度 DLinear、独立轻量基线 LightTS、固定等权多尺度、全局可学习权重、恒定输入路由及本文方法。四种多尺度模型采用相同的 DLinear 主干和尺度集合{1,2,4}，比较不同融合方式。

本实验定义三类融合对照：固定等权模型将各尺度权重设为 1/3；全局权重模型用 3 个由等权初始化的可训练参数，经 Softmax 生成全局固定权重；恒定输入路由保留本文方法的路由网络，训练与推理均输入全零特征向量，使所有窗口共用融合权重。三类对照的专家均接收真实历史窗口，用于区分多尺度信息、非等权融合与输入相关分配的作用。

数据划分、输入长度、预测长度及评价指标在各模型间保持一致，批量大小均设为 16，统一使用 Adam 优化器。超参数配置预先固定，不对各模型分别进行超参数搜索。多尺度模型的专家与可训练融合参数联合优化，以验证集 MSE 确定模型后进行测试集评价。DLinear 及各多尺度模型使用 0.001 的学习率，训练上限为 30 轮。验证集 MSE 连续 6 轮未下降即执行早停。LightTS 以 0.0001 的学习率训练，轮数上限为 50 轮，早停等待轮数设为 10 轮。

LightTS 使用清华大学软件学院机器学习组公开的实现，分块长度设为 24，模型维度参数设为 512。DLinear 及各尺度专家依照文献[6]实现，移动平均窗口长度取 25，路由隐藏层维度取 16。Python 3.11.9 和 PyTorch 2.5.1 是本实验使用的软件版本。

基线模型比较使用随机种子 42～44 共 3 个共同随机种子；消融实验使用 42～49 共 8 个共同随机种子，比较 DLinear、三类固定融合对照及本文方法，并以随机种子作为配对统计单位。

均方误差（MSE）、平均绝对误差（mean absolute error，MAE）及均方根误差（root mean squared error，RMSE）作为预测性能的评价指标。测试集 MSE 的计算沿用式（14）的平均规则，样本数为测试窗口数。式（15）中的 N_{te} 表示测试样本数，MAE 和 RMSE 按下式定义

$$\mathrm{MAE}=\frac{1}{N_{\mathrm{te}}HC}\sum_{n=1}^{N_{\mathrm{te}}}\sum_{h=1}^{H}\sum_{c=1}^{C}\left|Y_{n,h,c}-\hat{Y}_{n,h,c}\right|. \tag{15}$$

$$\mathrm{RMSE}=\sqrt{\mathrm{MSE}}. \tag{16}$$

评价指标均在标准化空间内计算，以较小数值表示较低误差。较大误差会使 MSE 变化更明显，MAE 表示平均绝对偏差，RMSE 则与标准化后的预测值具有相同数值尺度。表 2、表 3 分别采用种子 42～44、42～49 的均值±样本标准差汇总结果，以标准差描述种子间波动。共同种子配对后，以对照模型与本文方法的误差之差除以对照误差计算改进率，再求平均；计算不使用表内四舍五入值。八种子配对改进率的 95% 置信区间由均值、标准误及自由度为 7 的 t 分布计算。标准误取种子间样本标准差除以√8。

2.2 总体预测性能与基线比较

3 个共同随机种子的总体基线结果列于表 2，本文方法在 Abilene 和 GÉANT 上的 MSE 分别为 0.186 和 0.434。按种子逐一计算，相对 DLinear 分别降低 4.07%和 4.54%，相对 LightTS 分别降低 29.80%和 46.89%；MAE 也呈相同方向变化。本文方法与 LightTS 的逐种子、多指标结果及参数规模在图 2 中进一步比较，参数比例以各数据集的 LightTS 参数量为参照。

表 2 三随机种子基线模型比较（均值±标准差）

数据集	模型	参数量	MSE	MAE
Abilene	DLinear	4656	0.194±0.002	0.188±0.009
Abilene	LightTS	130162	0.265±0.011	0.204±0.008
Abilene	本文方法	8339	0.186±0.002	0.168±0.001
GÉANT	DLinear	4656	0.454±0.007	0.383±0.006
GÉANT	LightTS	384382	0.817±0.024	0.523±0.014
GÉANT	本文方法	8339	0.434±0.051	0.370±0.031

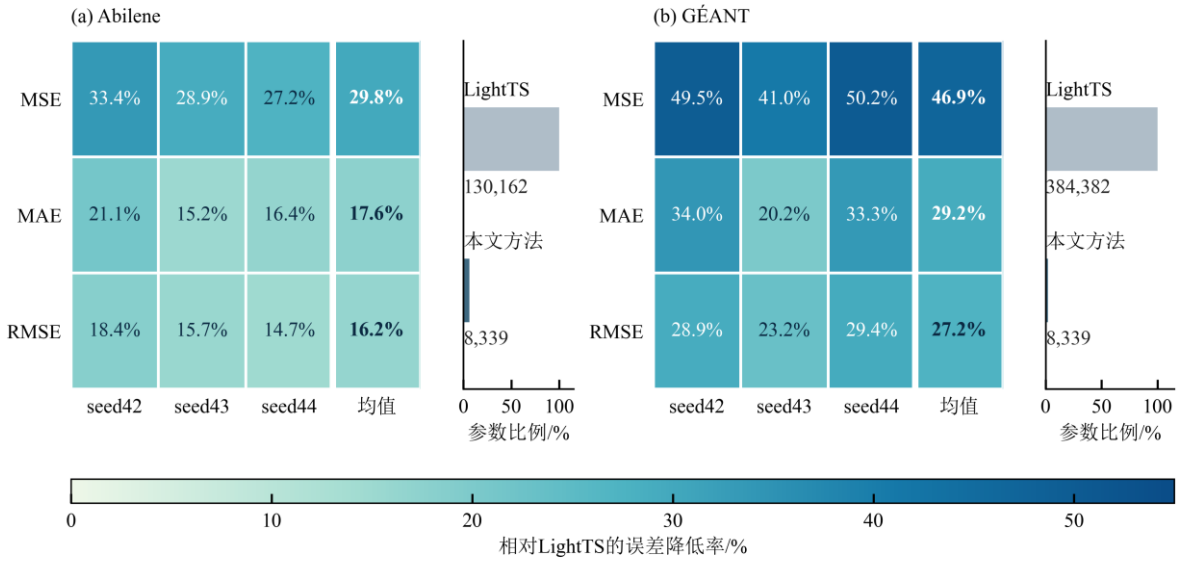


图 2 相对 LightTS 的误差降低率与参数规模

MSE、MAE 和 RMSE 的平均降幅在 Abilene 上为 29.80%、17.57%和 16.23%，在 GÉANT 上为 46.89%、29.15%和 27.18%。逐种子检查这三项指标，两个数据集的 3 个共同随机种子均有改善。本文方法的 8339 个参数，约为 LightTS 在 Abilene 和 GÉANT 上参数量的 6.41%和 2.17%；LightTS 的对应参数量分别为 130162 和 384382。

本文方法在 OD 规模不同的两套数据上均优于 LightTS，GÉANT 的 MSE 降幅更高。下节以相同多尺度专家检验融合方式。

2.3 八随机种子消融实验与稳定性

表 3 汇总随机种子 42～49 的 8 次消融实验，列出五种模型的参数量、MSE 和 MAE。

表 3 八随机种子消融实验结果（均值±标准差）

数据集	模型	参数量	MSE	MAE
Abilene	DLinear	4656	0.194±0.002	0.189±0.008
Abilene	固定等权多尺度	8208	0.192±0.002	0.191±0.006
Abilene	全局可学习权重	8211	0.192±0.002	0.190±0.006
Abilene	恒定输入路由	8339	0.192±0.002	0.181±0.006
Abilene	本文方法	8339	0.189±0.003	0.173±0.008
GÉANT	DLinear	4656	0.437±0.016	0.371±0.011
GÉANT	固定等权多尺度	8208	0.447±0.014	0.377±0.009
GÉANT	全局可学习权重	8211	0.446±0.014	0.377±0.009
GÉANT	恒定输入路由	8339	0.449±0.012	0.379±0.007
GÉANT	本文方法	8339	0.426±0.029	0.366±0.018

相对全局可学习权重和恒定输入路由，本文方法在 Abilene 上的逐种子平均 MSE 改进均约 1.80%，在 GÉANT 上分别为 4.31%和 4.97%，两类对照下分别均有 6/8 和 7/8 个种子的 MSE 更低。相对恒定输入路由的 95%置信区间分别为[0.49%,3.11%]和[−1.62%,11.56%]，相对全局权重则为[0.01%,3.58%]和[−2.51%,11.13%]；GÉANT 两项区间均跨零。

图 3 展示本文方法相对 DLinear 和固定等权多尺度模型的逐种子改进分布。单个种子的改进率以散点表示，均值以黑色菱形标出，横向误差线对应 95%置信区间。

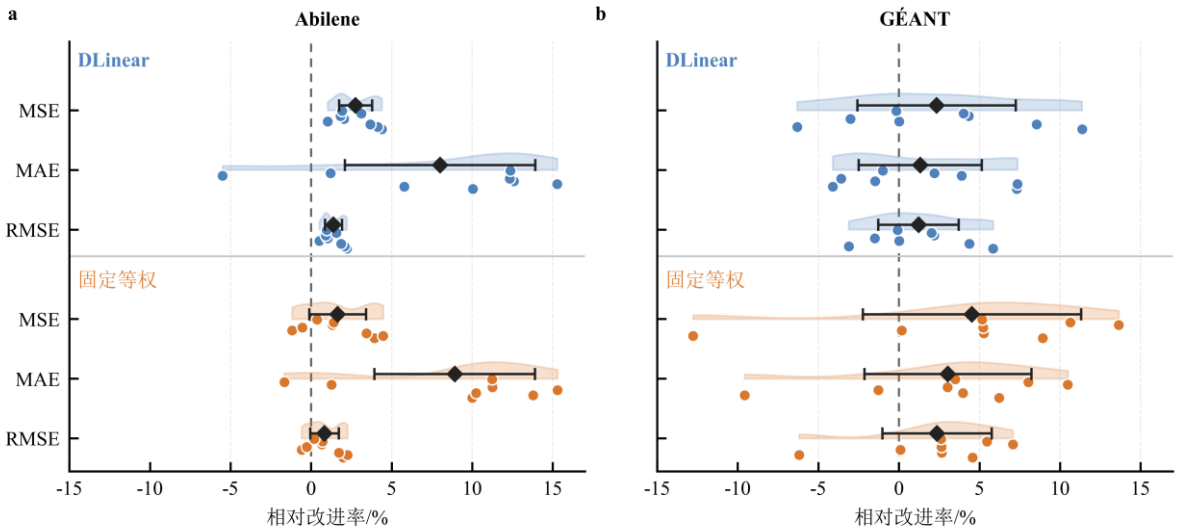


图 3 相对两类基线的多指标改进分布

图 3 所列的不同随机种子改进率中，两类基线下三个指标的平均改进率均为正。以 DLinear 为对照，Abilene 的 MSE、MAE、RMSE 平均改进率依次为 2.77%、8.01%、1.40%，MSE 和 RMSE 在 8 次实验中均有改善。GÉANT 的三项对应平均改进率为 2.35%、1.32%、1.22%，负改进率涉及更多种子，种子间波动

也较大。改用固定等权模型作为对照后，按相同指标顺序，Abilene 的平均改进率为 1.65%、8.92%、0.84%，GÉANT 上则为 4.54%、3.05%、2.37%。

本文方法在表 3 八次重复实验中的平均 MSE 较全局可学习权重与恒定输入路由两类对照低，不过 GÉANT 种子 43 相对恒定输入路由的 MSE 仍增加 12.78%。图 4 以全测试点的预测偏差和按真实序列波动选取的典型轨迹补充平均误差比较，观察模型的预测行为。

2.4 预测行为与尺度权重分析

图 4（a、b）使用 8 个种子的全测试预测点，按真实值分位点划分为最多 40 组，并绘制分组平均预测；种子间±1 个标准差以浅色带表示。图 4（c～f）取种子 42 的预测结果，依据真实序列选择标准差接近第 75 百分位的 OD 通道，窗口的平均绝对一阶差分则接近中位数、第 90 百分位。

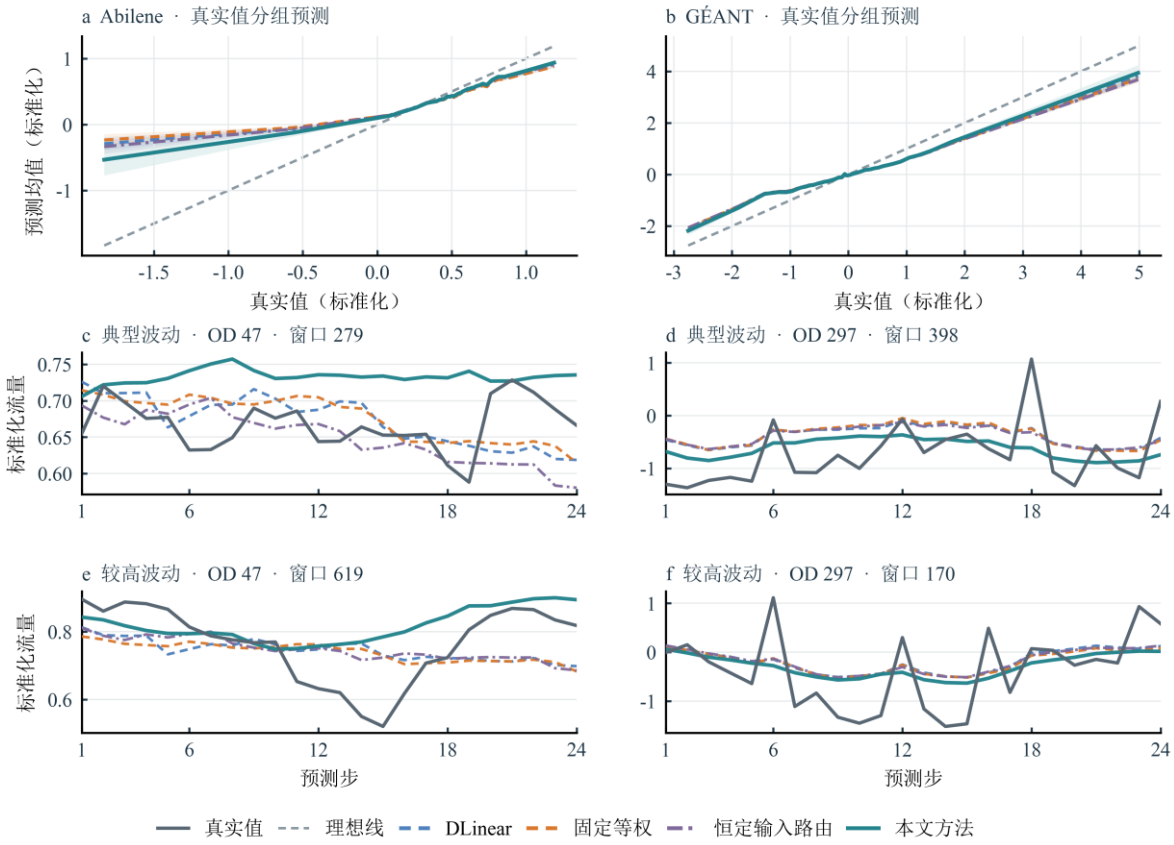


图 4 真实值分组预测与典型窗口轨迹

四种模型在图 4 的高真实值区间均有分组预测低于真实值的现象，本文方法的平均偏差较小。四例典型轨迹中，本文方法在三例上的 24 步均方误差低于 DLinear、固定等权和恒定输入路由模型；在 Abilene 典型波动窗口这一例中，本文方法的结果较差。整体误差比较见表 3。

图 5 汇总 8 个种子的测试窗口权重。各随机种子的窗口平均权重用彩色点表示；黑色菱形及误差线标出这些均值的均值±1 个标准差。短横线标出汇总分布中位数，水平虚线对应固定等权 1/3。

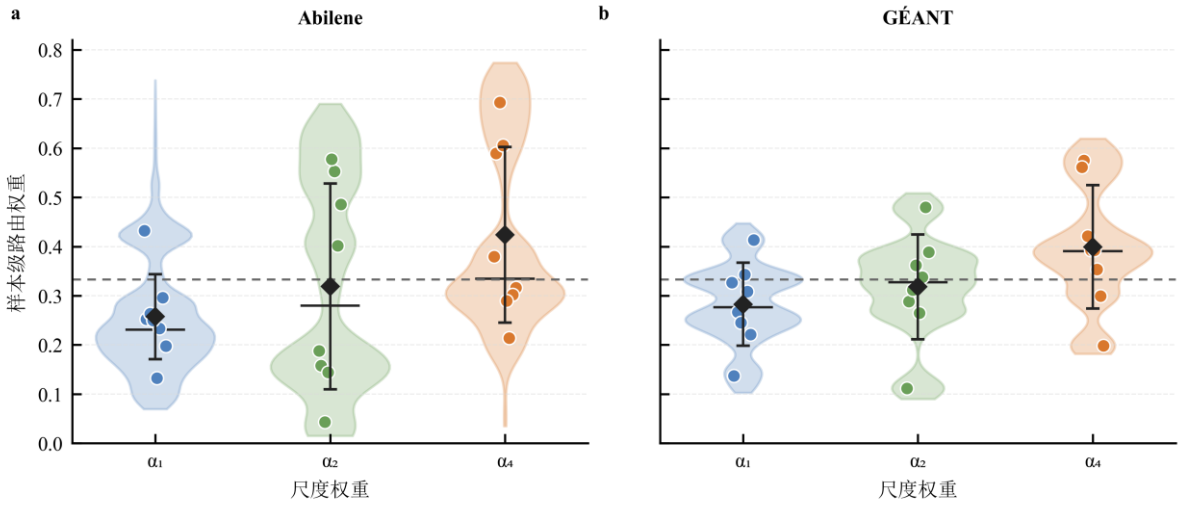


图 5 尺度权重分布与种子均值

Abilene 的三个尺度汇总平均权重依次取 0.257、0.319 和 0.424；GÉANT 的对应取值为 0.283、0.318 和 0.399。各取值均偏离固定等权的 1/3。按来源划分汇总权重方差后，GÉANT 三个尺度约有 96.2%、95.8%和 97.7%来自种子间差异，Abilene 的对应比例为 48.7%、86.1%和 80.6%。GÉANT 在同一种子内部仅有较小的窗口间权重变化。图 5 同时呈现不同尺度的总体权重分配及随机种子间的差异。

测试窗口以训练阶段窗口波动强度的三分位数划分为低、中、高三组，用于考察不同波动水平下模型的表现；波动强度采用平均绝对一阶差分度量。以全局权重模型作对照时，Abilene 三组的逐种子平均 MSE 改进率依次为 4.43%、1.90%、1.69%，相应的样本窗口数为 15、406、392 个。GÉANT 按相同训练阈值划分后，测试集中没有低波动窗口。中、高波动组分别有 76、375 个窗口，其对应改进率为 5.85%、4.06%。Abilene 高波动组的尺度 1 平均权重超过中波动组，误差优势却未随权重增加而增强。GÉANT 的中、高波动组权重取值近似相同，误差改善幅度仍存在差异。因此，误差变化与权重调整之间并非简单的对应关系。

2.5 计算开销与网络管理应用讨论

单尺度 DLinear 包含 4656 个可训练参数，使用三个尺度专家的固定等权模型含 8208 个参数。在固定等权结构上加入三个全局权重参数后，参数总数为 8211 个；样本级路由和恒定输入路由的参数总数均为 8339 个。与固定等权及全局权重模型相比，路由网络分别增加 131 个和 128 个参数。恒定输入路由虽然保留样本级路由的网络结构，恒为零的输入却使首层输入权重不参与有效计算。

种子 42～49 的 8 个模型检查点用于测量前向耗时，预测长度设为 24，批量大小设为 16。关闭梯度计算并将测试张量预先载入显存后，各检查点预热 20 个批次，再对完整测试集重复计时 10 次。每次测量以总耗时除以批次数，随后对 10 次测量取平均，再对 8 个检查点取平均。Abilene 与 GÉANT 上，本文方法测得的平均每批前向耗时分别为 2.65 ms、2.61 ms，固定等权模型为 2.38 ms、2.10 ms，DLinear 为 0.77 ms、0.70 ms。上述测量不包含数据读取与传输开销。

小时级网络管理中，全部有效 OD 变量未来 24 h 的逐小时需求预测由模型一次输出。观测更新后，各 OD 最近 96 h 的流量按训练预处理规则构成历史窗口，预测结果按时间与节点对组织，供需求分析使用。

实际需求分析使用的预测结果需由标准化空间还原到原始流量量纲。利用训练阶段保存的逐 OD 统计量做逆标准化后，进行逆对数变换，并将结果截断至非负范围。结合网络拓扑与路由关系，各 OD 的预测需求可汇总到对应链路上；比较链路预测需求与可用容量，可为容量调度与扩容决策提供参考。

训练集各 OD 的第 90 百分位用作高需求阈值，超过对应阈值的真实值所在测试预测点才参与评价。种子 42～49 的 24 步预测在标准化空间内统计 MAE 及低估误差均值。对后者，真实值减预测值仅取正值部分，再在全部高需求预测点上平均。高需求预测点在 Abilene 占 13.61%，在 GÉANT 占 13.00%。

按 8 个种子的均值±标准差汇总，本文方法在 Abilene 上的高需求 MAE 和低估误差均值分别为 0.147±0.013、0.137±0.017，相对全局可学习权重的逐种子平均降幅为 17.22%、20.49%，8 个种子均改善。GÉANT 两项指标为 0.632±0.060、0.577±0.080，平均降幅为 3.59%、6.30%，均有 6/8 个种子改善。

高需求预测点上的 MAE 和低估误差均值较低，这与图 4 较高真实值区间的预测结果相符。Abilene 在不同随机种子下的改善较为一致；GÉANT 两项配对改进率的 95%置信区间均包含零，各随机种子下的改善有所不同。上述结果可供高需求时段的流量监测与容量规划参考。

3 结语

独立分解线性专家生成预测结果，基于窗口统计特征的尺度路由网络以自适应多尺度加权协调各尺度输出，在较小参数规模下完成小时级骨干网流量预测。两套数据的重复实验中，平均误差均低于所设单尺度与固定融合对照。预测输出可供未来一天需求分析参考，后续将在更多网络数据和预测长度下检验模型适用性。

参考文献

[1] LOHRASBINASAB I, SHAHRAKI A, TAHERKORDI A, et al. From statistical- to machine learning-based network traffic prediction[J]. Transactions on Emerging Telecommunications Technologies, 2022, 33(4): e4394. DOI: 10.1002/ett.4394.

[2] QIN Liang, GU Huaxi, WEI Wenting, et al. Spatio-temporal communication network traffic prediction method based on graph neural network[J]. Information Sciences, 2024, 679: 121003. DOI: 10.1016/j.ins.2024.121003.

[3] 韦烜, 刘志华, 李青, 等. 大型 IP 网络流量矩阵分析预测的探讨研究[J]. 系统工程与电子技术, 2024, 46(6): 2164-2173. DOI: 10.12305/j.issn.1001-506X.2024.06.35.

[4] 唐文杰, 肖一磊, 孔祥宇, 等. CycleLLH：一种基于周期性整合的新型网络流量预测模型[J]. 计算机学报, 2024, 47(12): 2867-2888. DOI: 10.11897/SP.J.1016.2024.02867.

[5] ZHOU Jian, HAN Taotao, XIAO Fu, et al. Multiscale network traffic prediction method based on deep echo-state network for Internet of Things[J]. IEEE Internet of Things Journal, 2022, 9(21): 21862-21874. DOI: 10.1109/JIOT.2022.3181807.

[6] ZENG Ailing, CHEN Muxi, ZHANG Lei, et al. Are transformers effective for time series forecasting?[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2023, 37(9): 11121-11128. DOI: 10.1609/aaai.v37i9.26317.

[7] WANG Shiyu, WU Haixu, SHI Xiaoming, et al. TimeMixer: decomposable multiscale mixing for time series forecasting[C/OL]//International Conference on Learning Representations. 2024[2026-10-03]. https://openreview.net/forum?id=7oLshfEIC2.

[8] ZHANG Tianping, ZHANG Yizhuo, CAO Wei, et al. Less is more: fast multivariate time series forecasting with light sampling-oriented MLP structures[EB/OL]. (2022-07-04)[2026-10-03]. https://arxiv.org/abs/2207.01186. DOI: 10.48550/arXiv.2207.01186.

[9] KUREŠ M, KOUMAR J, HYNEK K. CESNET TS-Zoo: a library for reproducible analysis of network traffic time series[C]//2025 21st International Conference on Network and Service Management. New York: IEEE, 2025: 1-5. DOI: 10.23919/CNSM67658.2025.11297513.

[10] ZHANG Yin, ROUGHAN M, DUFFIELD N, et al. Fast accurate computation of large-scale IP traffic matrices from link loads[J]. ACM SIGMETRICS Performance Evaluation Review, 2003, 31(1): 206-217. DOI: 10.1145/885651.781053.

[11] UHLIG S, QUOITIN B, LEPROPRE J, et al. Providing public intradomain traffic matrices to the research community[J]. ACM SIGCOMM Computer Communication Review, 2006, 36(1): 83-86. DOI: 10.1145/1111322.1111341.