基于自适应多尺度加权的多变量网络流量预测方法

柯亚文

（安徽财贸职业学院 信息工程学院，合肥 231200）

摘要：面向小时级骨干网络流量预测，设计一种轻量自适应多尺度预测模型，以同时刻画短期波动与长期趋势。三种时间分辨率的历史窗口数据分别交由独立分解线性专家预测。当前窗口的均值、标准差、末时刻均值和平均绝对一阶差分由路由网络提取，多层感知器据此给出融合权重。以 Abilene 和 GÉANT 检验模型，历史输入为 96 步，预测目标为未来 24 步。3 个共同随机种子的实验中，相比单尺度分解线性模型，本文方法的均方误差在两套数据上分别降低 4.07%和 4.54%；相比采样导向轻量模型 LightTS，对应降幅为 29.80%和 46.89%。在 8 种子消融实验中，与全局可学习权重和恒定输入路由比较，Abilene 的逐种子平均改进率均约为 1.80%，GÉANT 上分别为 4.31%和 4.97%。实验中，多尺度候选预测结合低维路由机制，在增加少量融合参数的条件下获得更低的平均预测误差，所得预测可为次日网络流量需求分析与容量规划提供参考。

关键词：网络流量预测；多变量时间序列；多尺度学习；自适应加权；分解线性模型

中图分类号：TP393　　**文献标志码：**A

A Multivariate Network Traffic Forecasting Method Based on Adaptive Multiscale Weighting

KE Yawen

(School of Information Engineering, Anhui Finance & Trade Vocational College, Hefei 231200, China)

Abstract: A lightweight adaptive multiscale forecasting model was developed for hourly backbone network traffic forecasting to represent short-term fluctuations and long-term trends. Historical windows were represented at three temporal resolutions, with independent decomposition linear experts generating candidate forecasts at each resolution. A routing network extracted the mean, standard deviation, mean at the last time step, and mean absolute first difference from the current window. A multilayer perceptron with two fully connected layers calculated fusion weights from these four statistics. Experiments on Abilene and GÉANT used an input length of 96 historical steps and a forecast length of 24 steps. Across three common random seeds, mean squared error decreased by 4.07% and 4.54% relative to the single-scale decomposition linear model, respectively. The corresponding reductions relative to the sampling-oriented lightweight model LightTS were 29.80% and 46.89%. Ablation experiments across eight random seeds compared the proposed method with learned global weights and a constant-input router. Mean seed-wise improvements over both controls were approximately 1.80% on Abilene; on GÉANT, they were 4.31% and 4.97%. Combining multiscale candidate forecasts with low-dimensional routing achieved lower mean forecasting errors with few additional fusion parameters. The forecasts can provide a reference for next-day network traffic demand analysis and capacity planning.

Key words: network traffic forecasting; multivariate time series; multiscale learning; adaptive weighting; decomposition linear model

骨干网节点对之间的通信需求以源—目的节点对（origin-destination，OD）流量描述，掌握各节点对未来的需求变化是容量规划的依据。本文以小时级 OD 流量预测未来一天的需求，供高需求时段观察和容量安排参考。云计算、视频业务和数据中心互联增加了业务迁移与聚集，流量变化的复杂性与此有关。OD 变量之间存在量级差异，周期变化中又叠加局部波动与突发变化，预测模型需同时刻画较慢趋势和短时变化。

Lohrasbinasab 等[1]在网络流量预测方法综述中指出，机器学习与深度学习等数据驱动方法的应用不断增加。随网络规模扩大，OD 变量之间的关联难以仅由单一序列分析覆盖。Qin 等[2]通过图神经网络处理空

收稿日期：[编辑部填写]

第一作者简介：柯亚文（1998—），男，助教，硕士，研究方向：计算机软件。电子邮箱：keyawen@afc.edu.cn 。

间关联与时间依赖；韦烜等[3]分析大型网际协议（Internet protocol，IP）网络流量矩阵的变量关联及时间变化；唐文杰等[4]在 CycleLLH 中引入周期性信息。上述预测研究分别涉及时间依赖、变量关联及周期结构。

时间聚合平滑了原始序列中的短时扰动，使较慢趋势更易观察；不同时间分辨率由此提供互补信息。Zhou 等[5]以深度回声状态网络进行多尺度流量预测。在轻量预测方法中，分解线性模型（decomposition linear model，DLinear）[6]结合序列分解与线性映射。TimeMixer[7]使用多尺度混合，LightTS[8]采用采样导向的多层感知器（multilayer perceptron，MLP）。不同尺度预测结果的融合方式是本文的研究对象，预测主干采用 DLinear。

本文在各尺度专家结构相同的条件下，考察按当前窗口状态调整融合比例能否降低预测误差。固定权重可组合多尺度预测结果，但不同窗口使用同一融合比例，无法体现窗口间的状态差异。

本文以独立 DLinear 专家处理尺度 1、2 和 4 的序列，用低维窗口统计量驱动路由网络，生成归一化融合权重。尺度专家负责各分辨率的候选预测，路由网络负责尺度间融合，在保留多尺度信息的同时控制参数规模。在 Abilene 和 GÉANT 上，通过基线模型比较、固定融合对照及多随机种子实验评价整体预测精度，并结合预测轨迹和权重分布分析模型行为。

1 自适应多尺度网络流量预测方法

图 1 给出预测分支和路由分支，两者共享同一预处理历史窗口；梯形虚线表示 DLinear 专家内部结构的展开。历史 OD 窗口完成对数变换与标准化后构造尺度 1、2 和 4 的序列。每个独立 DLinear 专家分别映射趋势项与余项，两部分的 24 步预测相加构成候选预测。尺度路由网络使用原始时间分辨率预处理输入的 4 项统计特征计算 Softmax 权重。模型随后按这些权重对 3 个尺度候选预测加权求和，得到输出。曲线与色块在图中仅作示意。

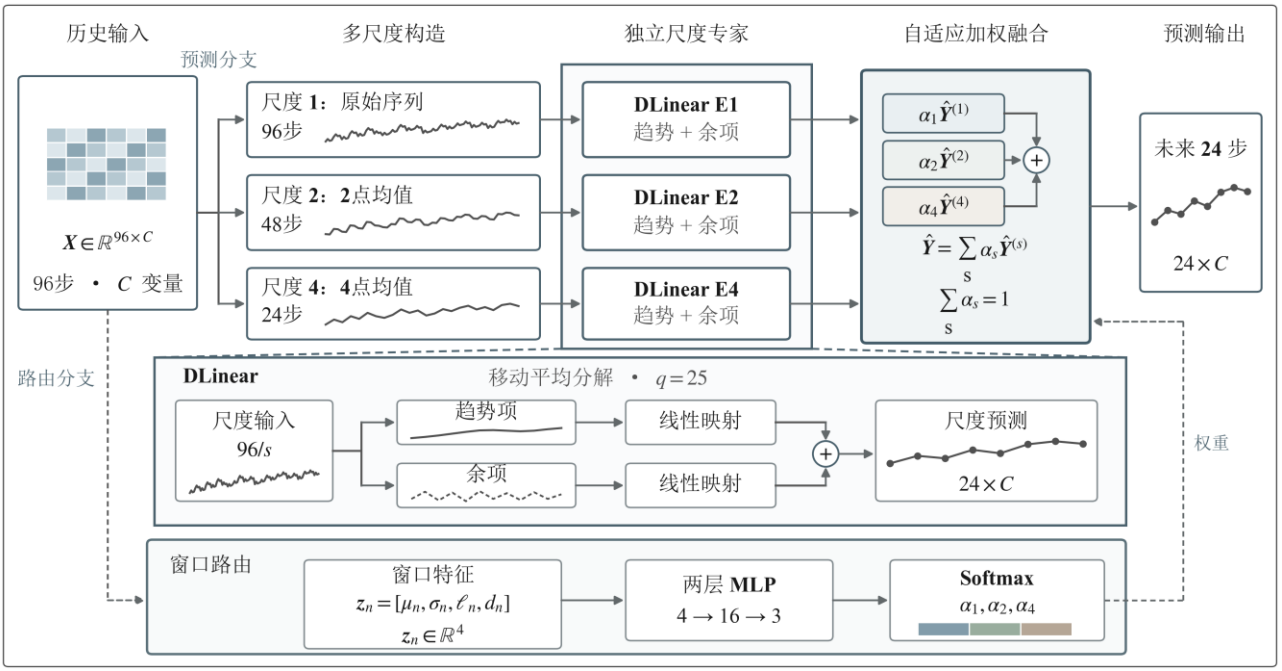


图 1 自适应多尺度预测框架

相同 DLinear 结构用于各尺度，预测由各专家独立完成。原始尺度保留局部波动，时间聚合后的较粗尺度突出较慢趋势。路由网络依据当前窗口特征分配融合权重，使统一预测主干结合多尺度输入与按样本加权。

1.1 预测任务与数据预处理

将预处理后的多变量流量序列表示为 $\boldsymbol{x}_t \in \mathbb{R}^C$；$t$ 表示时间索引，C 表示有效 OD 变量数。监督学习样本由沿连续序列时间轴生成的滑动窗口构成。第 n 个样本包含历史窗口$\boldsymbol{X}_n$及预测目标$\boldsymbol{Y}_n$：$\boldsymbol{X}_n$包含连续 L 个时间点，$\boldsymbol{Y}_n$包含其后连续的 H 个时间点。向量按时间顺序逐行堆叠为矩阵，矩阵行对应时间点，列对应 OD 变量。第 n 个样本的输入与目标可写为：

$$\boldsymbol{X}_n = [\boldsymbol{x}_n, \dots, \boldsymbol{x}_{n+L-1}] \in \mathbb{R}^{L\times C}. \tag{1}$$

$$\boldsymbol{Y}_n = [\boldsymbol{x}_{n+L}, \dots, \boldsymbol{x}_{n+L+H-1}] \in \mathbb{R}^{H\times C}. \tag{2}$$

输入窗口长度取 L=96，预测长度取 H=24，保留的有效 OD 维度数用 C 表示。由历史信息预测未来流量的映射为：$\widehat{\boldsymbol{Y}}_n = f_\theta(\boldsymbol{X}_n)$。原始 OD 流量均为非负值，变量之间存在较大量级差异。预处理时先对原始流量$v_{t,c}$作对数变换，以压缩序列的取值范围；这里的 log 表示自然对数：

$$u_{t,c} = \log(1 + v_{t,c}). \tag{3}$$

再按变量进行标准化：

$$x_{t,c} = \frac{u_{t,c}-\mu_c^{\mathrm{tr}}}{\sigma_c^{\mathrm{tr}}}. \tag{4}$$

其中μ_c^{tr}和σ_c^{tr}分别表示第 c 个 OD 变量的均值与标准差，两者均从对数变换后的训练集计算得到；验证集与测试集使用同一组训练统计量。经对数变换，取值范围得以压缩而大小关系不变。逐变量标准化使输入具有相近的数值尺度。按时间顺序以 6:2:2 划分数据后，仅在各集合内部独立生成滑动窗口，所有窗口均不跨越集合边界。

各尺度序列由同一预处理历史窗口构造，分别保留细粒度变化或较平滑的趋势。

96 步历史和 24 步预测，在第 2.1 节的 1 h 聚合数据上分别为过去 96 h 与未来 24 h。这一设置提供未来一天的流量预测，也供小时级需求变化的观察使用。

1.2 多尺度构造与 DLinear 专家

对尺度 s，时间维的非重叠平均池化同时将聚合窗口大小和步长设为该尺度的取值。尺度集合为 S={1,2,4}，各序列按下式构造，其中 s 取自该集合：

$$\boldsymbol{X}_{n,t}^{(s)} = \frac{1}{s}\sum_{i=0}^{s-1} \boldsymbol{X}_{n,st+i}, \quad t = 0, \dots, \frac{L}{s} - 1. \tag{5}$$

非重叠平均池化不含可训练参数。对于 L=96，尺度 1 直接使用原始 96 步序列；尺度 2 的输入由相邻 2 点均值组成，为 48 步序列；尺度 4 由相邻 4 点均值组成 24 步序列。时间聚合平滑局部波动，使较慢趋势更为明显。

尺度集合{1,2,4}能够将 96 步历史分别构造成整数长度序列。各尺度均配置独立专家，其输入长度随尺度取值增大而缩短。同一尺度内，每个时间点仅参与一次聚合。

每个 DLinear 专家[6]仅分解本尺度输入：长度 q=25 的中心移动平均用于提取趋势项，原输入减去趋势项得到余项。序列两端先作端点复制填充，使分解前后的时间长度一致。补齐后的序列记为$\widetilde{\boldsymbol{X}}^{(s)}$，对越界索引，取最近端点的值：

$$\boldsymbol{T}_{n,t}^{(s)} = \frac{1}{q}\sum_{i=-m}^{m} \widetilde{\boldsymbol{X}}_{n,t+i}^{(s)}, \quad q = 2m + 1 = 25. \tag{6}$$

$$\boldsymbol{R}_n^{(s)} = \boldsymbol{X}_n^{(s)} - \boldsymbol{T}_n^{(s)}. \tag{7}$$

趋势项$\boldsymbol{T}^{(s)}$和余项$\boldsymbol{R}^{(s)}$沿时间维分别通过线性层映射到预测长度 H：

$$\widehat{\boldsymbol{Y}}_n^{(s)} = \boldsymbol{W}_{\mathrm{T}}^{(s)}\boldsymbol{T}_n^{(s)} + \boldsymbol{b}_{\mathrm{T}}^{(s)} + \boldsymbol{W}_{\mathrm{R}}^{(s)}\boldsymbol{R}_n^{(s)} + \boldsymbol{b}_{\mathrm{R}}^{(s)}. \tag{8}$$

根据式（6）和式（7），尺度 s 分解所得的趋势项$\boldsymbol{T}^{(s)}$和余项$\boldsymbol{R}^{(s)}$分别表示局部平滑后的趋势和去除趋势后的剩余部分。式（8）对这两部分各作线性映射，并将各自预测相加。长度 96、48 和 24 的输入分别交

由不同专家，各专家的参数独立。每个专家的两个线性层均采用 $H\times(L/s)$权重矩阵和 H 维偏置向量；各 OD 变量共享这组参数。沿 OD 变量维度广播偏置后，得到 $H\times C$ 输出。

1.3 样本级自适应尺度加权

固定等权融合为三个尺度均分配 1/3 权重，融合比例因而不随当前窗口状态变化。本文以窗口统计特征为依据学习融合权重，再组合三个 DLinear 专家的预测结果。局部波动和较慢趋势的预测价值可能随窗口而异，因此从原始时间分辨率的预处理窗口$\boldsymbol{X}_n$中提取统计量，以构成四维统计向量$\boldsymbol{z}_n=[\mu_n,\sigma_n,\ell_n,d_n]$，各统计量按下式定义：

$$\mu_n=\frac{1}{LC}\sum_{t=0}^{L-1}\sum_{c=1}^{C}X_{n,t,c},\quad \sigma_n=\sqrt{\frac{1}{LC}\sum_{t=0}^{L-1}\sum_{c=1}^{C}(X_{n,t,c}-\mu_n)^2}. \tag{9}$$

$$\ell_n=\frac{1}{C}\sum_{c=1}^{C}X_{n,L-1,c},\quad d_n=\frac{1}{(L-1)C}\sum_{t=1}^{L-1}\sum_{c=1}^{C}|X_{n,t,c}-X_{n,t-1,c}|. \tag{10}$$

μ_n、σ_n、ℓ_n和d_n分别为输入窗口的均值、标准差、末时刻均值和平均绝对一阶差分。μ_n反映窗口整体流量水平，σ_n刻画观测值的离散程度，ℓ_n为窗口末时刻各 OD 变量的均值，d_n为相邻时间点绝对差值的均值。这 4 个统计量用于计算随输入窗口变化的尺度权重，各尺度专家负责生成预测值。

OD 流量预测仍由各尺度专家独立生成；尺度路由网络中的门控网络由多层感知器实现，仅生成融合权重。多层感知器由两层全连接层构成，四维统计向量经 16 维隐藏层映射为 3 个尺度的未归一化分数。路由模块采用该全连接结构，未设置循环网络或注意力编码器。修正线性单元（rectified linear unit，ReLU）用于隐藏层激活，尺度分数的计算式为：

$$\boldsymbol{a}_n=\boldsymbol{W}_2\mathrm{ReLU}(\boldsymbol{W}_1\boldsymbol{z}_n+\boldsymbol{b}_1)+\boldsymbol{b}_2. \tag{11}$$

式（11）中，两层分别使用 16×4 和 3×16 的权重矩阵，偏置向量则依次为 16 维和 3 维。将 3 个尺度分数经 Softmax 归一化，得到 3 个非负权重，权重总和为 1。这组权重表示各专家对最终预测的相对贡献：

$$\alpha_{n,s}=\frac{\exp(a_{n,s})}{\sum_{j\in S}\exp(a_{n,j})},\quad \alpha_{n,s}\geq 0,\quad \sum_{s\in S}\alpha_{n,s}=1. \tag{12}$$

最终预测为

$$\widehat{\boldsymbol{Y}}_n=\sum_{s\in S}\alpha_{n,s}\,\widehat{\boldsymbol{Y}}_n^{(s)}. \tag{13}$$

式（13）给出最终预测$\widehat{\boldsymbol{Y}}_n$。输入窗口决定这一组权重，同一窗口内的全部 OD 变量共用该组取值。

1.4 模型训练与预测输出

采用均方误差（mean squared error，MSE）训练模型，损失为 N 个训练样本、未来 H 个时刻及 C 个 OD 变量上平方误差的平均值。其中 N 为训练样本数，训练目标为

$$\mathcal{L}_{\mathrm{MSE}}=\frac{1}{NHC}\sum_{n=1}^{N}\sum_{h=1}^{H}\sum_{c=1}^{C}(Y_{n,h,c}-\hat{Y}_{n,h,c})^2. \tag{14}$$

自适应矩估计（adaptive moment estimation，Adam）优化器更新模型参数；最终模型的选择以验证集 MSE 为依据。

推理输入仍为历史 OD 窗口，其处理规则沿用训练阶段。多尺度专家分别生成各尺度预测。这些预测经路由模块加权融合，形成未来多步流量预测结果。网络需求分析与容量规划可参考恢复至原始流量量纲后的结果。

2 实验与结果分析

实验从总体预测性能、融合方式消融、预测与权重行为以及计算开销四方面评价模型。

2.1 数据集与实验设置

实验采用 CESNET TS-Zoo[9]提供的 1 h 粒度聚合流量矩阵 Abilene[10]和 GÉANT[11]。L=96、H=24 在两套数据上统一使用，数据规模与窗口数列于表 1。Abilene 在 144 维有效 OD 变量上共有 4656 个时间点。

GÉANT 具有 2849 个时间点；以训练集标准差为依据，剔除恒定或近恒定变量，得到 524 个有效 OD 变量。数据按时间顺序以 6:2:2 划分为训练、验证、测试集，预处理采用第 1.1 节的步骤。

表 1 数据集与预测任务设置

数据集	时间点	有效变量 C	训练/验证/测试时间点	训练/验证/测试窗口	L/H
Abilene	4656	144	2793/931/932	2674/812/813	96/24
GÉANT	2849	524	1709/570/570	1590/451/451	96/24

对比设置包括单尺度 DLinear、独立轻量基线 LightTS、固定等权多尺度、全局可学习权重、恒定输入路由及本文方法。四种多尺度模型采用相同的 DLinear 主干和尺度集合{1,2,4}，比较不同融合方式。

本实验定义三类融合对照：固定等权模型将各尺度权重设为 1/3；全局权重模型用 3 个由等权初始化的可训练参数，经 Softmax 生成全局固定权重；恒定输入路由保留本文方法的路由网络，训练与推理均输入全零特征向量，使所有窗口共用融合权重。三类对照的专家均接收真实历史窗口，用于区分多尺度信息、非等权融合与输入相关分配的作用。

各模型使用同一数据划分，输入长度、预测长度与评价指标也保持一致；批量大小统一为 16，优化器均为 Adam。超参数配置预先固定，未按模型分别开展超参数搜索。多尺度模型联合优化专家参数与可训练融合参数，依据验证集 MSE 选择模型，再在测试集评价。DLinear 及各多尺度模型的学习率为 0.001，最多训练 30 轮；若验证集 MSE 连续 6 轮未下降，则执行早停。LightTS 采用 0.0001 的学习率，训练不超过 50 轮，早停等待轮数为 10 轮。

LightTS 使用清华大学软件学院机器学习组公开的实现，分块长度设为 24，模型维度参数设为 512。DLinear 及各尺度专家依照文献[6]实现，移动平均窗口长度取 25，路由隐藏层维度取 16。Python 3.11.9 和 PyTorch 2.5.1 是本实验使用的软件版本。

基线模型比较使用随机种子 42～44 共 3 个共同随机种子；消融实验使用 42～49 共 8 个共同随机种子，比较 DLinear、三类固定融合对照及本文方法，并以随机种子作为配对统计单位。

预测性能采用均方误差（MSE）、平均绝对误差（mean absolute error，MAE）及均方根误差（root mean squared error，RMSE）评价。在测试集上计算 MSE 时，式（14）的平均规则保持不变，样本数取测试窗口数。式（15）用 N_{te} 表示测试样本数，MAE 和 RMSE 的定义为

$$\mathrm{MAE}=\frac{1}{N_{\mathrm{te}}HC}\sum_{n=1}^{N_{\mathrm{te}}}\sum_{h=1}^{H}\sum_{c=1}^{C}\left|Y_{n,h,c}-\hat{Y}_{n,h,c}\right|. \tag{15}$$

$$\mathrm{RMSE}=\sqrt{\mathrm{MSE}}. \tag{16}$$

标准化空间中的评价指标越小，表示预测误差越低。对较大误差，MSE 更为敏感；MAE 给出平均绝对偏差，RMSE 与标准化后的预测值处于相同数值尺度。表 2、表 3 分别汇总种子 42～44、42～49 所得结果，以均值±样本标准差报告，种子间波动由标准差描述。改进率按共同种子逐一配对计算：以对照模型与本文方法的误差之差除以对照误差，再取配对改进率的平均值；计算所用数值未经表内四舍五入。八种子配对改进率的 95%置信区间使用均值和标准误，并采用自由度为 7 的 t 分布计算。将种子间样本标准差除以√8，得到标准误。

2.2 总体预测性能与基线比较

3 个共同随机种子的总体基线结果列于表 2，本文方法在 Abilene 和 GÉANT 上的 MSE 分别为 0.186 和 0.434。按种子逐一计算，相对 DLinear 分别降低 4.07%和 4.54%，相对 LightTS 分别降低 29.80%和 46.89%；MAE 也呈相同方向变化。本文方法与 LightTS 的逐种子、多指标结果及参数规模在图 2 中进一步比较，参数比例以各数据集的 LightTS 参数量为参照。

表 2 三随机种子基线模型比较（均值±标准差）

数据集	模型	参数量	MSE	MAE
Abilene	DLinear	4656	0.194±0.002	0.188±0.009
Abilene	LightTS	130162	0.265±0.011	0.204±0.008
Abilene	本文方法	8339	0.186±0.002	0.168±0.001
GÉANT	DLinear	4656	0.454±0.007	0.383±0.006
GÉANT	LightTS	384382	0.817±0.024	0.523±0.014
GÉANT	本文方法	8339	0.434±0.051	0.370±0.031

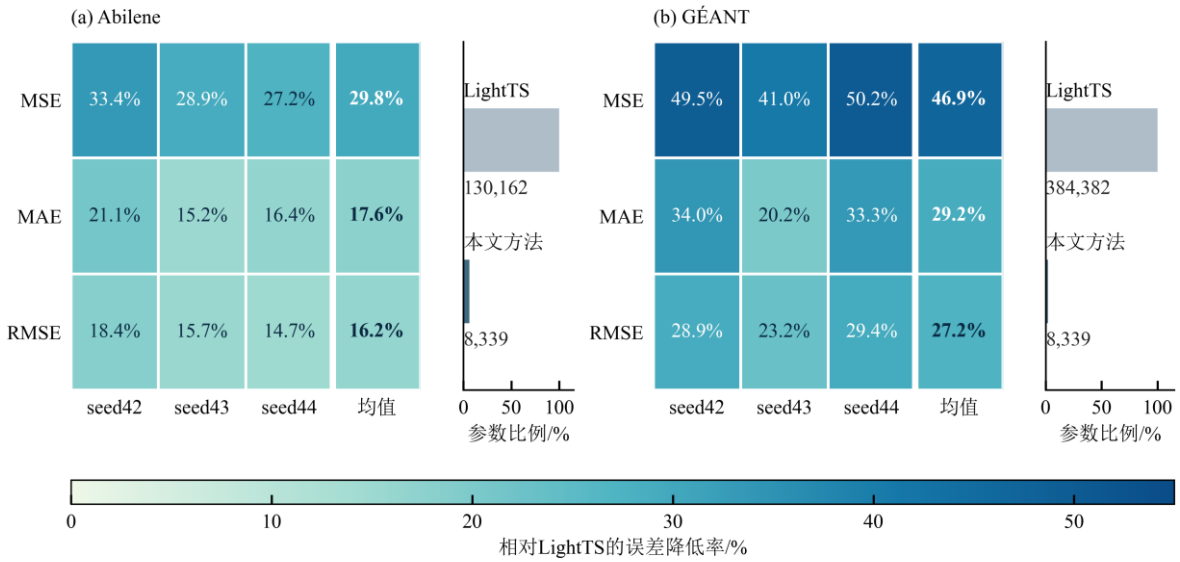


图 2 相对 LightTS 的误差降低率与参数规模

MSE、MAE 和 RMSE 的平均降幅在 Abilene 上为 29.80%、17.57%和 16.23%，在 GÉANT 上为 46.89%、29.15%和 27.18%。逐种子检查这三项指标，两个数据集的 3 个共同随机种子均有改善。本文方法的 8339 个参数，约为 LightTS 在 Abilene 和 GÉANT 上参数量的 6.41%和 2.17%；LightTS 的对应参数量分别为 130162 和 384382。

本文方法在 OD 规模不同的两套数据上均优于 LightTS，GÉANT 的 MSE 降幅更高。下节以相同多尺度专家检验融合方式。

2.3 八随机种子消融实验与稳定性

表 3 汇总随机种子 42～49 的 8 次消融实验，列出五种模型的参数量、MSE 和 MAE。

表 3 八随机种子消融实验结果（均值±标准差）

数据集	模型	参数量	MSE	MAE
Abilene	DLinear	4656	0.194±0.002	0.189±0.008
Abilene	固定等权多尺度	8208	0.192±0.002	0.191±0.006
Abilene	全局可学习权重	8211	0.192±0.002	0.190±0.006
Abilene	恒定输入路由	8339	0.192±0.002	0.181±0.006
Abilene	本文方法	8339	0.189±0.003	0.173±0.008
GÉANT	DLinear	4656	0.437±0.016	0.371±0.011
GÉANT	固定等权多尺度	8208	0.447±0.014	0.377±0.009
GÉANT	全局可学习权重	8211	0.446±0.014	0.377±0.009
GÉANT	恒定输入路由	8339	0.449±0.012	0.379±0.007
GÉANT	本文方法	8339	0.426±0.029	0.366±0.018

相对全局可学习权重和恒定输入路由，本文方法在 Abilene 上的逐种子平均 MSE 改进均约 1.80%，在 GÉANT 上分别为 4.31%和 4.97%，两类对照下分别均有 6/8 和 7/8 个种子的 MSE 更低。相对恒定输入路由的 95%置信区间分别为[0.49%,3.11%]和[−1.62%,11.56%]，相对全局权重则为[0.01%,3.58%]和[−2.51%,11.13%]；GÉANT 两项区间均跨零。

图 3 给出本文方法相对 DLinear 和固定等权多尺度模型的逐种子改进分布。散点对应单个种子的改进率，黑色菱形给出均值，横向误差线给出 95%置信区间。

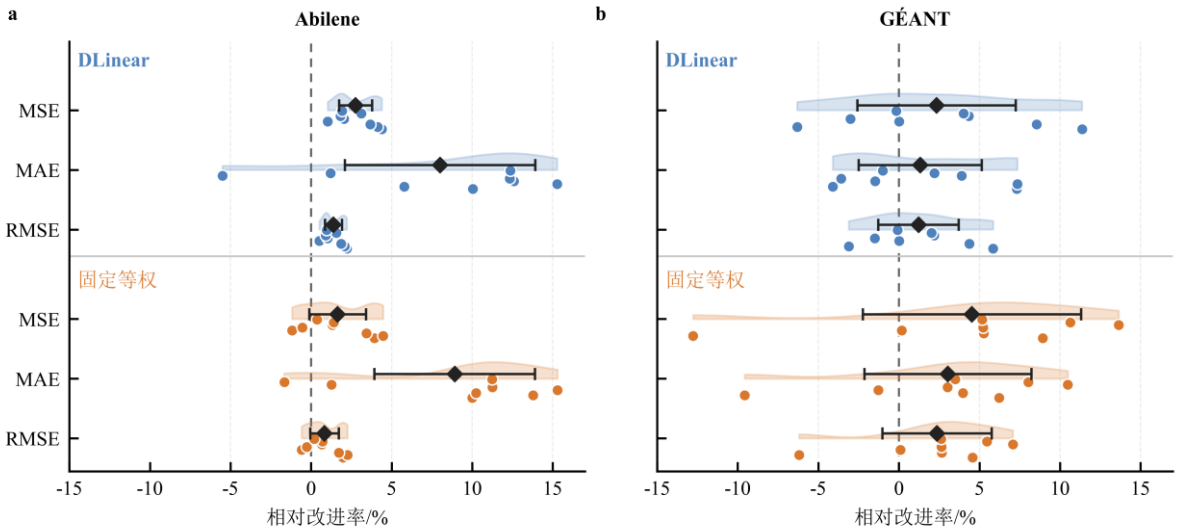


图 3 相对两类基线的多指标改进分布

图 3 中，相对两类基线的三个指标平均改进率均为正。DLinear 作为对照时，Abilene 的 MSE、MAE、RMSE 的平均改进率分别为 2.77%、8.01%、1.40%，MSE 和 RMSE 均在 8 次实验中改善。同样三个指标在 GÉANT 上的平均改进率为 2.35%、1.32%、1.22%，出现负改进率的种子更多，种子间波动较大。固定

等权模型作为对照时，仍按上述指标顺序，Abilene 的平均改进率为 1.65%、8.92%、0.84%，GÉANT 的对应值为 4.54%、3.05%、2.37%。

本文方法在表 3 八次重复实验中的平均 MSE 较全局可学习权重与恒定输入路由两类对照低，不过 GÉANT 种子 43 相对恒定输入路由的 MSE 仍增加 12.78%。图 4 以全测试点的预测偏差和按真实序列波动选取的典型轨迹补充平均误差比较，观察模型的预测行为。

2.4 预测行为与尺度权重分析

图 4（a、b）的统计覆盖 8 个种子的全测试预测点。按真实值分位点将这些预测点分成最多 40 组，分别绘出分组平均预测，浅色带对应种子间±1 个标准差。图 4（c～f）采用种子 42 的预测结果，选取真实序列标准差接近第 75 百分位的 OD 通道，再选平均绝对一阶差分接近中位数、第 90 百分位的窗口。

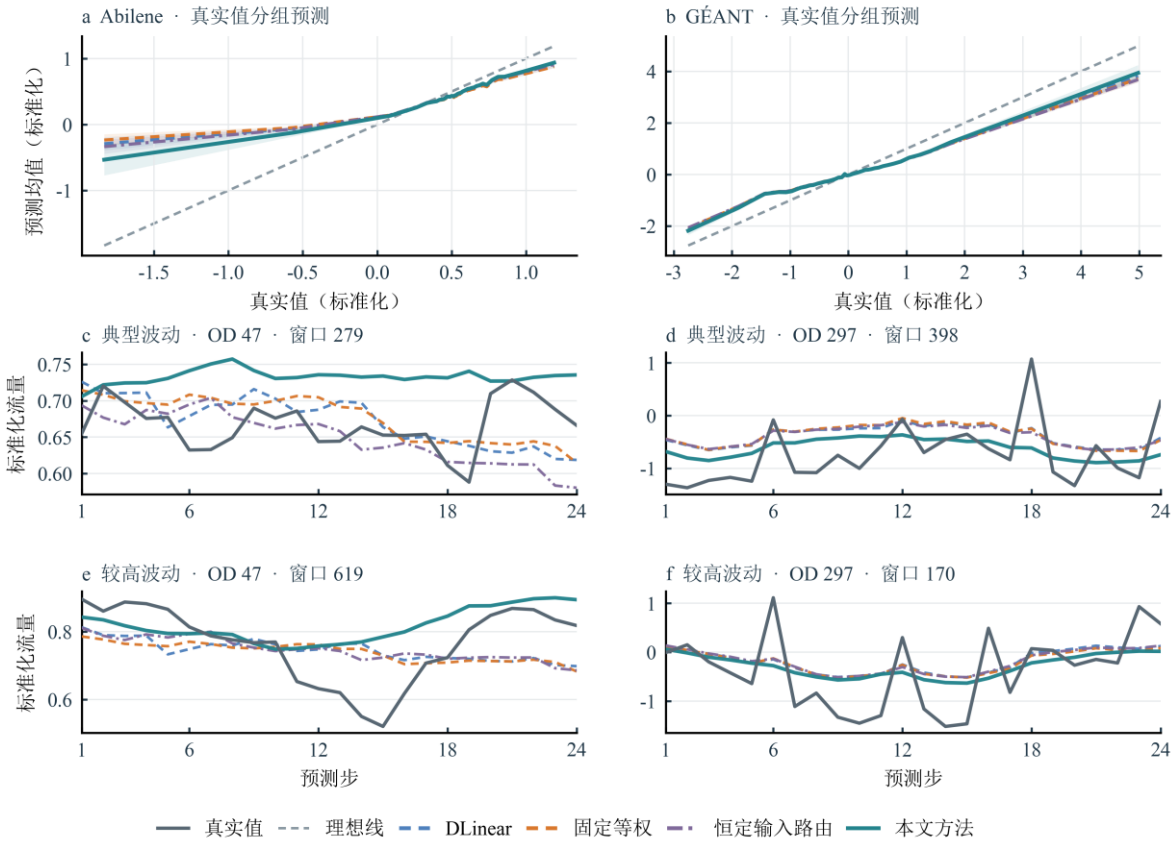


图 4 真实值分组预测与典型窗口轨迹

四种模型在图 4 的高真实值区间均有分组预测低于真实值的现象，本文方法的平均偏差较小。四例典型轨迹中，本文方法在三例上的 24 步均方误差低于 DLinear、固定等权和恒定输入路由模型；在 Abilene 典型波动窗口这一例中，本文方法的结果较差。整体误差比较见表 3。

图 5 汇总 8 个种子的测试窗口权重，彩色点分别给出各随机种子的窗口平均权重。对这些均值再求均值±1 个标准差，以黑色菱形及误差线表示。汇总分布中位数由短横线标出，水平虚线标出固定等权 1/3。

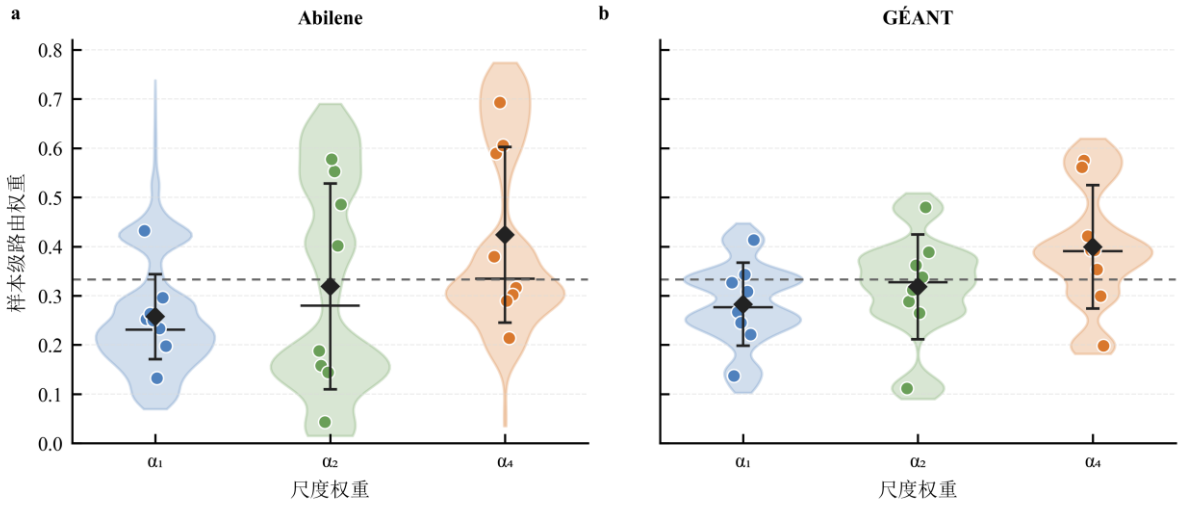


图 5 尺度权重分布与种子均值

Abilene 三个尺度的汇总平均权重分别为 0.257、0.319 和 0.424；相同尺度顺序下，GÉANT 的取值为 0.283、0.318 和 0.399。这些取值均偏离固定等权的 1/3。将汇总权重方差按来源分解，GÉANT 三个尺度中约 96.2%、95.8%和 97.7%的方差来自种子间差异，Abilene 的对应比例为 48.7%、86.1%和 80.6%。在 GÉANT 的同一种子内，权重随窗口的变化较小。总体尺度权重分配和随机种子间差异在图 5 中同时呈现。

为考察不同波动水平下的预测表现，依据训练阶段窗口波动强度的三分位数，将测试窗口划为低、中、高三组；平均绝对一阶差分用于度量波动强度。与全局权重模型比较，Abilene 三组的逐种子平均 MSE 改进率分别为 4.43%、1.90%、1.69%，对应的样本窗口数为 15、406、392 个。GÉANT 测试窗口按相同训练阈值划分，没有窗口进入低波动组。中、高波动组的窗口数分别为 76、375 个，相应改进率为 5.85%、4.06%。Abilene 高波动组的尺度 1 平均权重高于中波动组，误差优势并未随之增强；GÉANT 中、高波动组的权重近似相同，误差改善幅度却不同。这些分组结果表明，权重调整与误差变化并非简单对应。

2.5 计算开销与网络管理应用讨论

单尺度 DLinear 的可训练参数为 4656 个，三个尺度专家构成的固定等权模型共含 8208 个参数。固定等权结构加入三个全局权重参数后，总参数量为 8211 个；样本级路由与恒定输入路由均含 8339 个参数。路由网络比固定等权及全局权重模型分别多 131 个和 128 个参数。样本级路由的网络结构仍保留在恒定输入路由中，但输入恒为零，首层输入权重因此不参与有效计算。

前向耗时按种子 42～49 的 8 个模型检查点分别测量，预测长度为 24，批量大小为 16。测试张量预先载入显存，计时过程关闭梯度计算。各检查点先预热 20 个批次，完整测试集随后重复计时 10 次。以每次总耗时除以批次数得到每批耗时，先平均 10 次测量结果，再平均 8 个检查点的结果。在 Abilene 与 GÉANT 上测得，本文方法的平均每批前向耗时分别为 2.65 ms、2.61 ms，固定等权模型为 2.38 ms、2.10 ms，DLinear 为 0.77 ms、0.70 ms。数据读取与传输开销未计入上述测量。

模型在小时级网络管理中一次给出全部有效 OD 变量未来 24 h 的逐小时需求预测。更新观测后，按训练预处理规则将各 OD 最近 96 h 的流量构成历史窗口；需求分析使用的预测结果按时间与节点对组织。

用于实际需求分析时，预测结果须恢复原始流量量纲。先根据训练阶段保存的逐 OD 统计量对标准化空间内的结果做逆标准化，随后进行逆对数变换，并截断至非负范围。各 OD 的预测需求可依照网络拓扑与路由关系汇总至对应链路，链路预测需求与可用容量的比较可供容量调度与扩容决策参考。

训练集各 OD 的第 90 百分位用作高需求阈值，超过对应阈值的真实值所在测试预测点才参与评价。种子 42～49 的 24 步预测在标准化空间内统计 MAE 及低估误差均值。对后者，真实值减预测值仅取正值部分，再在全部高需求预测点上平均。高需求预测点在 Abilene 占 13.61%，在 GÉANT 占 13.00%。

按 8 个种子的均值±标准差汇总，本文方法在 Abilene 上的高需求 MAE 和低估误差均值分别为 0.147±0.013、0.137±0.017，相对全局可学习权重的逐种子平均降幅为 17.22%、20.49%，8 个种子均改善。GÉANT 两项指标为 0.632±0.060、0.577±0.080，平均降幅为 3.59%、6.30%，均有 6/8 个种子改善。

高需求预测点上较低的 MAE 和低估误差均值，与图 4 较高真实值区间的预测结果相符。Abilene 的改善在不同随机种子下较为一致；GÉANT 两项配对改进率的 95%置信区间均包含零，改善幅度随随机种子而异。高需求时段的流量监测与容量规划可参考这些结果。

3 结语

本文以独立分解线性专家生成预测结果，基于窗口统计特征的尺度路由网络通过自适应多尺度加权融合各尺度输出，以较小参数规模完成小时级骨干网流量预测。两套数据重复实验的平均误差均低于所设单尺度与固定融合对照，预测可供未来一天需求分析参考。后续将在更多网络数据和预测长度下检验模型适用性。

参考文献

[1] LOHRASBINASAB I, SHAHRAKI A, TAHERKORDI A, et al. From statistical- to machine learning-based network traffic prediction[J]. Transactions on Emerging Telecommunications Technologies, 2022, 33(4): e4394. DOI: 10.1002/ett.4394.

[2] QIN Liang, GU Huaxi, WEI Wenting, et al. Spatio-temporal communication network traffic prediction method based on graph neural network[J]. Information Sciences, 2024, 679: 121003. DOI: 10.1016/j.ins.2024.121003.

[3] 韦烜, 刘志华, 李青, 等. 大型 IP 网络流量矩阵分析预测的探讨研究[J]. 系统工程与电子技术, 2024, 46(6): 2164-2173. DOI: 10.12305/j.issn.1001-506X.2024.06.35.

[4] 唐文杰, 肖一磊, 孔祥宇, 等. CycleLLH：一种基于周期性整合的新型网络流量预测模型[J]. 计算机学报, 2024, 47(12): 2867-2888. DOI: 10.11897/SP.J.1016.2024.02867.

[5] ZHOU Jian, HAN Taotao, XIAO Fu, et al. Multiscale network traffic prediction method based on deep echo-state network for Internet of Things[J]. IEEE Internet of Things Journal, 2022, 9(21): 21862-21874. DOI: 10.1109/JIOT.2022.3181807.

[6] ZENG Ailing, CHEN Muxi, ZHANG Lei, et al. Are transformers effective for time series forecasting?[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2023, 37(9): 11121-11128. DOI: 10.1609/aaai.v37i9.26317.

[7] WANG Shiyu, WU Haixu, SHI Xiaoming, et al. TimeMixer: decomposable multiscale mixing for time series forecasting[C/OL]//International Conference on Learning Representations. 2024[2026-10-03]. https://openreview.net/forum?id=7oLshfEIC2.

[8] ZHANG Tianping, ZHANG Yizhuo, CAO Wei, et al. Less is more: fast multivariate time series forecasting with light sampling-oriented MLP structures[EB/OL]. (2022-07-04)[2026-10-03]. https://arxiv.org/abs/2207.01186. DOI: 10.48550/arXiv.2207.01186.

[9] KUREŠ M, KOUMAR J, HYNEK K. CESNET TS-Zoo: a library for reproducible analysis of network traffic time series[C]//2025 21st International Conference on Network and Service Management. New York: IEEE, 2025: 1-5. DOI: 10.23919/CNSM67658.2025.11297513.

[10] ZHANG Yin, ROUGHAN M, DUFFIELD N, et al. Fast accurate computation of large-scale IP traffic matrices from link loads[J]. ACM SIGMETRICS Performance Evaluation Review, 2003, 31(1): 206-217. DOI: 10.1145/885651.781053.

[11] UHLIG S, QUOITIN B, LEPROPRE J, et al. Providing public intradomain traffic matrices to the research community[J]. ACM SIGCOMM Computer Communication Review, 2006, 36(1): 83-86. DOI: 10.1145/1111322.1111341.