基于自适应多尺度加权的多变量网络流量预测方法

柯亚文

（安徽财贸职业学院 信息工程学院，合肥 231200）

摘要：为兼顾小时级骨干网络流量预测中的短期波动与长期趋势，设计一种轻量自适应多尺度预测模型。模型在三种时间分辨率上输入历史窗口数据，分别经由独立分解线性专家生成预测结果，再由路由网络从当前窗口提取均值、标准差、末时刻均值和平均绝对一阶差分，多层感知器据此计算融合权重。以 Abilene 和 GÉANT 为实验数据，均以 96 步历史输入预测未来 24 步。在 3 个共同随机种子下，与单尺度分解线性模型相比，方法的均方误差分别降低 4.07%和 4.54%；相对采样导向轻量模型 LightTS，降幅达到 29.80%和 46.89%。进一步的 8 种子消融实验中，相对全局可学习权重和恒定输入路由，在 Abilene 上逐种子平均改进率均约为 1.80%，GÉANT 分别为 4.31%和 4.97%。结果表明，多尺度候选预测配合低维路由机制，仅引入少量融合参数即可获得更低的平均预测误差，输出结果可为次日网络流量需求分析与容量规划提供参考。

关键词：网络流量预测；多变量时间序列；多尺度学习；自适应加权；分解线性模型

中图分类号：TP393　　**文献标志码：**A

A Multivariate Network Traffic Forecasting Method Based on Adaptive Multiscale Weighting

KE Yawen

(School of Information Engineering, Anhui Finance & Trade Vocational College, Hefei 231200, China)

Abstract: A lightweight adaptive multiscale forecasting model was developed to account for short-term fluctuations and long-term trends in hourly backbone network traffic forecasting. Historical windows were represented at three temporal resolutions, and independent decomposition linear experts generated candidate forecasts. A routing network extracted four statistics from the current window: the mean, standard deviation, mean at the last time step, and mean absolute first difference. A multilayer perceptron with two fully connected layers used these statistics to calculate fusion weights. Experiments on Abilene and GÉANT used 96 historical steps to predict the next 24 steps. Across three common random seeds, the proposed method reduced mean squared error by 4.07% and 4.54% relative to the single-scale decomposition linear model, respectively. The corresponding reductions relative to the sampling-oriented lightweight model LightTS were 29.80% and 46.89%. Further ablation experiments across eight random seeds compared the proposed method with learned global weights and a constant-input router. On Abilene, the mean seed-wise improvements over both controls were approximately 1.80%; on GÉANT, they were 4.31% and 4.97%, respectively. The results show that combining multiscale candidate forecasts with low-dimensional routing achieves lower mean forecasting errors with few additional fusion parameters. The forecasts can provide a reference for next-day network traffic demand analysis and capacity planning.

Key words: network traffic forecasting; multivariate time series; multiscale learning; adaptive weighting; decomposition linear model

骨干网节点对之间的通信需求以源—目的节点对（origin-destination，OD）流量描述，容量规划则需要掌握各节点对未来的需求变化。本文针对小时级 OD 流量预测未来一天的需求，为高需求时段观察和容量安排提供参考。流量变化的复杂性与云计算、视频业务和数据中心互联所增加的业务迁移与聚集有关。各 OD 变量量级不同，周期变化又与局部波动、突发变化叠加，因此较慢趋势和短时变化均需由预测模型刻画。

Lohrasbinasab 等[1]在综述中系统梳理了网络流量预测方法，指出其中机器学习与深度学习等数据驱动

收稿日期：[编辑部填写]

第一作者简介：柯亚文（1998—），男，助教，硕士，研究方向：计算机软件。电子邮箱：keyawen@afc.edu.cn 。

方法的应用占比持续增加。由于网络规模扩大后，仅分析单一序列难以捕捉 OD 变量之间的内在关联。Qin 等[2]采用图神经网络来处理空间关联与时间依赖；韦烜等[3]分析大型网际协议（Internet protocol，IP）网络流量矩阵中的变量关联及时间变化；唐文杰等[4]在 CycleLLH 中引入周期性信息。总体来看，上述工作分别从时间依赖、变量关联与周期结构等不同方面推进了网络流量预测研究。

时间聚合可平滑原始序列中的短时扰动，使较慢趋势更明显；不同时间分辨率提供互补信息。Zhou 等[5]以深度回声状态网络进行多尺度流量预测。在轻量预测方向上，分解线性模型（decomposition linear model，DLinear）[6]结合序列分解与线性映射；TimeMixer[7]采用多尺度混合；LightTS[8]使用采样导向的多层感知器（multilayer perceptron，MLP）。本文以 DLinear 为主干，研究不同尺度预测结果的融合方式。

当各尺度专家共享同一结构时，需要进一步考虑的问题是：融合权重能否依据当前窗口状态进行动态调整，从而进一步降低预测误差。固定权重虽能组合多个尺度的预测结果，但却无法利用窗口间的状态差异调整融合比例。

为此，本文以相互独立的 DLinear 专家分别处理尺度 1、2 和 4 的序列，并用低维窗口统计量驱动路由网络，生成归一化后的融合权重。其中，尺度专家负责各分辨率上的候选预测，路由网络计算尺度融合权重，模型据此组合各尺度候选预测，这样可以在保留多尺度信息的同时控制参数规模。实验在 Abilene 和 GÉANT 上进行，通过基线模型比较、固定融合对照，以及多随机种子实验来评价整体预测精度，并结合预测轨迹和权重分布，对模型行为进一步分析。

1 自适应多尺度网络流量预测方法

图 1 包含共享同一预处理历史窗口的预测分支与路由分支，梯形虚线展开 DLinear 专家内部结构。历史 OD 窗口完成对数变换与标准化后，生成尺度 1、2 和 4 的序列；独立 DLinear 专家分别映射趋势项与余项，把两部分的 24 步预测相加，形成候选预测。尺度路由网络根据原始时间分辨率预处理输入的 4 项统计特征计算 Softmax 权重；模型随后对 3 个尺度候选预测加权求和，得到最终输出。图中曲线和色块仅作示意。

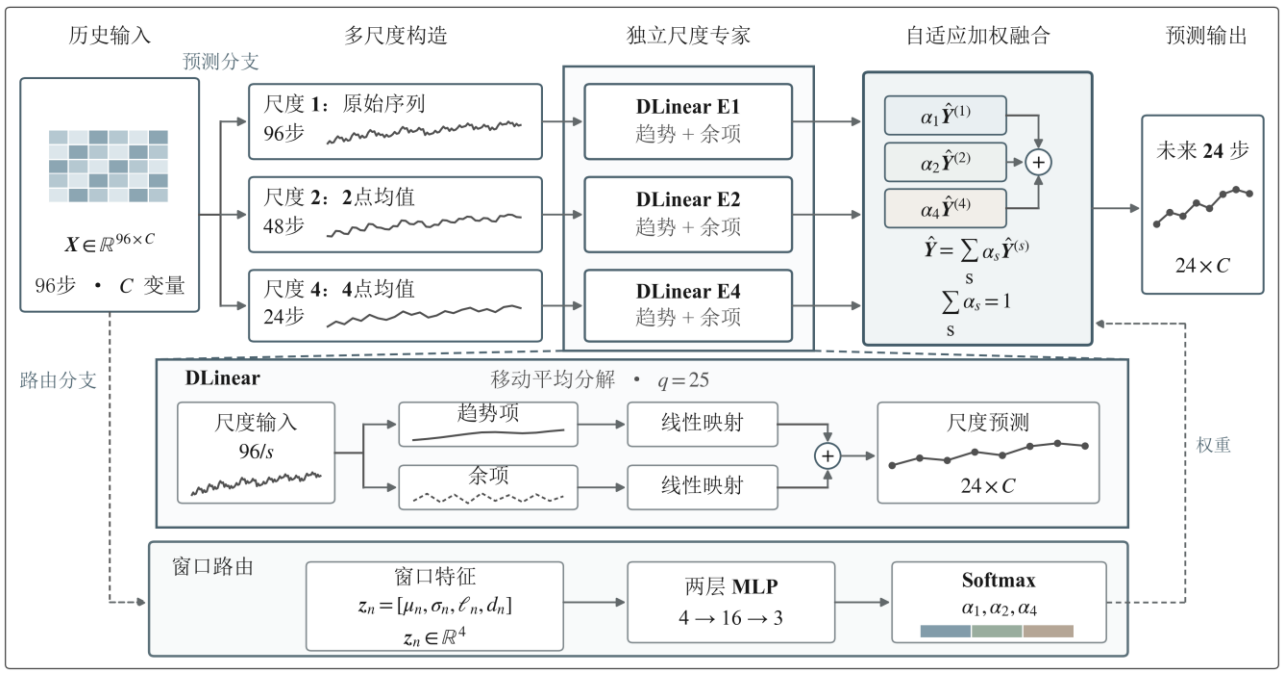


图 1 自适应多尺度预测框架

各尺度采用相同 DLinear 结构并独立预测。原始尺度保留局部波动，时间聚合后的较粗尺度突出较慢趋势；路由网络根据当前窗口特征分配融合权重。模型由此在统一预测主干上结合多尺度输入与按样本加权。

1.1 预测任务与数据预处理

记预处理后的多变量流量序列为 $\boldsymbol{x}_t \in \mathbb{R}^C$，其中 t 为时间索引，C 为有效 OD 变量数。监督学习样本由连续序列沿时间轴生成的滑动窗口构成；第 n 个样本由历史窗口$\boldsymbol{X}_n$及预测目标$\boldsymbol{Y}_n$组成：$\boldsymbol{X}_n$覆盖连续 L 个时间点，$\boldsymbol{Y}_n$覆盖其后连续的 H 个时间点。向量按时间顺序逐行堆叠，矩阵行对应时间点，列对应 OD 变量。第 n 个样本的输入与目标表示为：

$$\boldsymbol{X}_n = [\boldsymbol{x}_n, \dots, \boldsymbol{x}_{n+L-1}] \in \mathbb{R}^{L\times C}. \tag{1}$$

$$\boldsymbol{Y}_n = [\boldsymbol{x}_{n+L}, \dots, \boldsymbol{x}_{n+L+H-1}] \in \mathbb{R}^{H\times C}. \tag{2}$$

取输入窗口长度 L=96、预测长度 H=24，数据中保留的有效 OD 维度数记为 C。由此，历史信息到未来流量的预测映射可写为：$\widehat{\boldsymbol{Y}}_n = f_\theta(\boldsymbol{X}_n)$。原始 OD 流量非负且变量间量级差异较大，先对原始流量$v_{t,c}$作对数变换压缩其取值范围，得到对数变换后的序列，其中 log 表示自然对数：

$$u_{t,c} = \log(1 + v_{t,c}). \tag{3}$$

再按变量进行标准化：

$$x_{t,c} = \frac{u_{t,c}-\mu_c^{\mathrm{tr}}}{\sigma_c^{\mathrm{tr}}}. \tag{4}$$

其中μ_c^{tr}和σ_c^{tr}分别为对数变换后训练集上第 c 个 OD 变量的均值与标准差，验证集和测试集直接沿用训练统计量，不再单独估计。对数变换可以在压缩非负流量数值范围的同时保留大小关系，从而减小量级差异。训练集、验证集和测试集按时间先后顺序以 6:2:2 比例划分后，在各集合内独立生成滑动窗口，并使所有窗口保持在集合边界内。

各尺度序列由同一预处理历史窗口构造，分别保留细粒度变化或较平滑的趋势。

96 步历史和 24 步预测，在第 2.1 节的 1 h 聚合数据上分别为过去 96 h 与未来 24 h。这一设置提供未来一天的流量预测，也供小时级需求变化的观察使用。

1.2 多尺度构造与 DLinear 专家

对尺度 s，时间维的非重叠平均池化同时将聚合窗口大小和步长设为该尺度的取值。尺度集合为 S={1,2,4}，各序列按下式构造，其中 s 取自该集合：

$$\boldsymbol{X}_{n,t}^{(s)} = \frac{1}{s}\sum_{i=0}^{s-1} \boldsymbol{X}_{n,st+i}, \quad t = 0, \dots, \frac{L}{s} - 1. \tag{5}$$

非重叠平均池化不引入可训练参数。L=96 时，尺度 1 保留原始 96 步序列；尺度 2 对相邻 2 点取均值，得到 48 步序列；尺度 4 对相邻 4 点取均值，得到 24 步序列。时间聚合平滑局部波动，使较慢趋势更明显。

尺度集合{1,2,4}使 96 步历史得到整数长度序列。尺度取值越大，对应输入越短；三个尺度分别配置一个独立专家。同一尺度内，每个时间点仅参与一次聚合。

每个 DLinear 专家[6]处理本尺度输入，通过长度 q=25 的中心移动平均提取趋势项，余项由输入减去趋势项得到。序列两端采用端点复制填充，保证分解前后时间长度不变；补齐后的序列记为$\widetilde{\boldsymbol{X}}^{(s)}$。越界索引取最近端点的值：

$$\boldsymbol{T}_{n,t}^{(s)} = \frac{1}{q}\sum_{i=-m}^{m} \widetilde{\boldsymbol{X}}_{n,t+i}^{(s)}, \quad q = 2m + 1 = 25. \tag{6}$$

$$\boldsymbol{R}_n^{(s)} = \boldsymbol{X}_n^{(s)} - \boldsymbol{T}_n^{(s)}. \tag{7}$$

趋势项$\boldsymbol{T}^{(s)}$和余项$\boldsymbol{R}^{(s)}$沿时间维分别通过线性层映射到预测长度 H：

$$\hat{\boldsymbol{Y}}_n^{(s)} = \boldsymbol{W}_{\mathrm{T}}^{(s)}\boldsymbol{T}_n^{(s)} + \boldsymbol{b}_{\mathrm{T}}^{(s)} + \boldsymbol{W}_{\mathrm{R}}^{(s)}\boldsymbol{R}_n^{(s)} + \boldsymbol{b}_{\mathrm{R}}^{(s)}. \tag{8}$$

由式（6）和式（7）可得到尺度 s 上的趋势项$\boldsymbol{T}^{(s)}$和余项$\boldsymbol{R}^{(s)}$。前者表示局部平滑后的趋势，后者为去除趋势后的剩余部分。式（8）对两者分别作线性映射，将预测结果相加。三个专家分别处理长度 96、48 和 24 的输入，参数独立。两个线性层的权重矩阵均为 $H\times(L/s)$，偏置向量均为 H 维；各 OD 变量共享参数，偏置沿 OD 变量维度广播，输出为 $H\times C$。

1.3 样本级自适应尺度加权

固定等权融合对三个尺度均取 1/3，与当前窗口状态无关。本文根据窗口统计特征学习融合权重，组合三个 DLinear 专家的预测结果。局部波动与较慢趋势的预测价值可能随窗口变化，因此从原始时间分辨率的预处理窗口$\boldsymbol{X}_n$中构造四维统计向量$\boldsymbol{z}_n = [\mu_n, \sigma_n, \ell_n, d_n]$，各统计量定义如下：

$$\mu_n = \frac{1}{LC}\sum_{t=0}^{L-1}\sum_{c=1}^{C} X_{n,t,c}\,, \quad \sigma_n = \sqrt{\frac{1}{LC}\sum_{t=0}^{L-1}\sum_{c=1}^{C}(X_{n,t,c} - \mu_n)^2}. \tag{9}$$

$$\ell_n = \frac{1}{C}\sum_{c=1}^{C} X_{n,L-1,c}\,, \quad d_n = \frac{1}{(L-1)C}\sum_{t=1}^{L-1}\sum_{c=1}^{C} |X_{n,t,c} - X_{n,t-1,c}|. \tag{10}$$

μ_n、σ_n、ℓ_n和d_n分别为输入窗口的均值、标准差、末时刻均值和平均绝对一阶差分。μ_n反映窗口整体流量水平，σ_n刻画观测值的离散程度，ℓ_n为窗口末时刻各 OD 变量的均值，d_n为相邻时间点绝对差值的均值。这 4 个统计量用于计算随输入窗口变化的尺度权重，各尺度专家负责生成预测值。

尺度路由网络是用于生成融合权重的门控网络，由多层感知器实现。各尺度专家独立生成候选预测，模型根据归一化权重对候选预测加权求和，得到最终 OD 流量预测。多层感知器由两层全连接层组成，接收四维统计向量，通过 16 维隐藏层输出 3 个尺度的未归一化分数。由于状态向量本身维数较低、隐藏层规模也较小，路由模块引入的参数量相当有限；整个过程中不再额外接入循环网络或注意力机制等时序编码器。其中隐藏层采用修正线性单元（rectified linear unit，ReLU）进行激活，尺度分数计算如下：

$$\boldsymbol{a}_n = \boldsymbol{W}_2\mathrm{ReLU}(\boldsymbol{W}_1\boldsymbol{z}_n + \boldsymbol{b}_1) + \boldsymbol{b}_2. \tag{11}$$

式（11）中，两层权重矩阵依次为 16×4 和 3×16，偏置向量分别为 16 维和 3 维。对 3 个尺度分数作 Softmax 归一化，得到 3 个总和为 1 的非负权重；各专家在最终预测中的相对贡献由这些权重表示：

$$\alpha_{n,s} = \frac{\exp(a_{n,s})}{\sum_{j\in S}\exp(a_{n,j})}, \quad \alpha_{n,s} \geq 0, \quad \sum_{s\in S}\alpha_{n,s} = 1. \tag{12}$$

最终预测为

$$\hat{\boldsymbol{Y}}_n = \sum_{s\in S}\alpha_{n,s}\,\hat{\boldsymbol{Y}}_n^{(s)}. \tag{13}$$

式（13）给出最终预测$\hat{\boldsymbol{Y}}_n$。输入窗口决定这一组权重，同一窗口内的全部 OD 变量共用该组取值。

1.4 模型训练与预测输出

采用均方误差（mean squared error，MSE）训练模型，损失为 N 个训练样本、未来 H 个时刻及 C 个 OD 变量上平方误差的平均值。其中 N 为训练样本数，训练目标为

$$\mathcal{L}_{\mathrm{MSE}} = \frac{1}{NHC}\sum_{n=1}^{N}\sum_{h=1}^{H}\sum_{c=1}^{C}(Y_{n,h,c} - \hat{Y}_{n,h,c})^2. \tag{14}$$

模型参数采用自适应矩估计（adaptive moment estimation，Adam）优化器进行更新，以验证集 MSE 作为选择依据。

在推理阶段，先以与训练时一致的规则处理输入的历史 OD 窗口，随后由多尺度专家分别给出各尺度预测，再根据路由网络计算的权重进行加权融合，得到未来多步流量预测结果，将其恢复至原始流量量纲后，可用于网络需求分析与容量规划参考。

2 实验与结果分析

实验从总体预测性能、融合方式消融、预测与权重行为以及计算开销四方面评价模型。

2.1 数据集与实验设置

本实验选用 CESNET TS-Zoo[9]中的 1 h 粒度聚合流量矩阵 Abilene[10]和 GÉANT[11]。两套数据均采用 L=96、H=24 的设置，规模及窗口数参见表 1。其中，Abilene 的 144 维有效 OD 变量覆盖 4656 个时间点；GÉANT 在 2849 个时间点上按训练集标准差剔除恒定或近恒定变量后，剩余 524 个有效 OD 变量。训练、验证、测试集的时间划分比例为 6:2:2，数据预处理按第 1.1 节所述执行。

表 1 数据集与预测任务设置

数据集	时间点	有效变量 C	训练/验证/测试时间点	训练/验证/测试窗口	L/H
Abilene	4656	144	2793/931/932	2674/812/813	96/24
GÉANT	2849	524	1709/570/570	1590/451/451	96/24

对比设置包括单尺度 DLinear、独立轻量基线 LightTS、固定等权多尺度、全局可学习权重、恒定输入路由及本文方法。四种多尺度模型采用相同的 DLinear 主干和尺度集合{1,2,4}，对不同融合方式进行比较。

本实验对三类融合进行对照：固定等权模型中各尺度权重设为 1/3；全局权重模型使用 3 个由等权初始化的可训练参数，由 Softmax 生成全局固定权重；恒定输入路由保留本文方法的路由网络，训练与推理均输入全零特征向量，使所有窗口共用融合权重。三类对照的专家均接收真实历史窗口数据，用于区分多尺度信息、非等权融合与输入相关分配的作用。

为统一标准，各模型在相同的数据划分、输入与预测长度以及评价指标下进行训练，批量大小统一取 16，优化器均使用 Adam，各模型采用预先固定的超参数配置，未分别开展超参数搜索。对具有可训练融合参数的多尺度模型，尺度专家与融合参数共同优化；各模型均根据验证集 MSE 选择模型检查点，再在测试集上评价。DLinear 及各多尺度模型均以 0.001 的学习率训练至多 30 轮；若验证集 MSE 连续 6 轮不再下降则提前终止。LightTS 使用 0.0001 的学习率，训练上限放宽至 50 轮，早停耐心值相应调整为 10 轮。

LightTS 采用清华大学软件学院机器学习组的公开实现，分块长度为 24，模型维度参数为 512。DLinear 及各尺度专家按文献[6]实现，移动平均窗口长度为 25，路由隐藏层维度设为 16。Python 3.11.9 和 PyTorch 2.5.1 为本实验的软件版本。

外部基线比较使用 42～44 共 3 个共同随机种子；核心消融使用 42～49 共 8 个共同随机种子，比较 DLinear、三类固定融合对照以及本文方法，并以随机种子作为配对统计单位。

均方误差（MSE）、平均绝对误差（mean absolute error，MAE）及均方根误差（root mean squared error，RMSE）用于评价预测性能。测试集 MSE 按式（14）计算，样本数取测试窗口数；式（15）中的 N_{te} 为测试样本数。MAE 和 RMSE 定义如下

$$\mathrm{MAE}=\frac{1}{N_{\mathrm{te}}HC}\sum_{n=1}^{N_{\mathrm{te}}}\sum_{h=1}^{H}\sum_{c=1}^{C}\left|Y_{n,h,c}-\hat{Y}_{n,h,c}\right|. \tag{15}$$

$$\mathrm{RMSE}=\sqrt{\mathrm{MSE}}. \tag{16}$$

所有指标在标准化空间计算，数值越小，误差越低。MSE 对较大误差更敏感；MAE 反映平均绝对偏差；RMSE 与标准化后的预测值处于同一数值尺度。表 2、表 3 分别汇总种子 42～44、42～49 的均值±样本标准差，标准差反映种子间波动。改进率为对照模型与本文方法的误差之差除以对照误差，按共同种子配对计算后求平均，不使用表内四舍五入值。八种子配对改进率的 95%置信区间采用均值、标准误及自由度为 7 的 t 分布计算，标准误为种子间样本标准差除以√8。

2.2 总体预测性能与基线比较

3 个共同随机种子的总体基线结果列于表 2，本文方法在 Abilene 和 GÉANT 上的 MSE 分别为 0.186 和

0.434。按种子逐一计算，相对 DLinear 分别降低 4.07%和 4.54%，相对 LightTS 分别降低 29.80%和 46.89%；MAE 也呈相同方向变化。本文方法与 LightTS 的逐种子、多指标结果及参数规模在图 2 中进一步比较，参数比例以各数据集的 LightTS 参数量为参照。

表 2 三随机种子基线模型比较（均值±标准差）

数据集	模型	参数量	MSE	MAE
Abilene	DLinear	4656	0.194±0.002	0.188±0.009
Abilene	LightTS	130162	0.265±0.011	0.204±0.008
Abilene	本文方法	8339	0.186±0.002	0.168±0.001
GÉANT	DLinear	4656	0.454±0.007	0.383±0.006
GÉANT	LightTS	384382	0.817±0.024	0.523±0.014
GÉANT	本文方法	8339	0.434±0.051	0.370±0.031

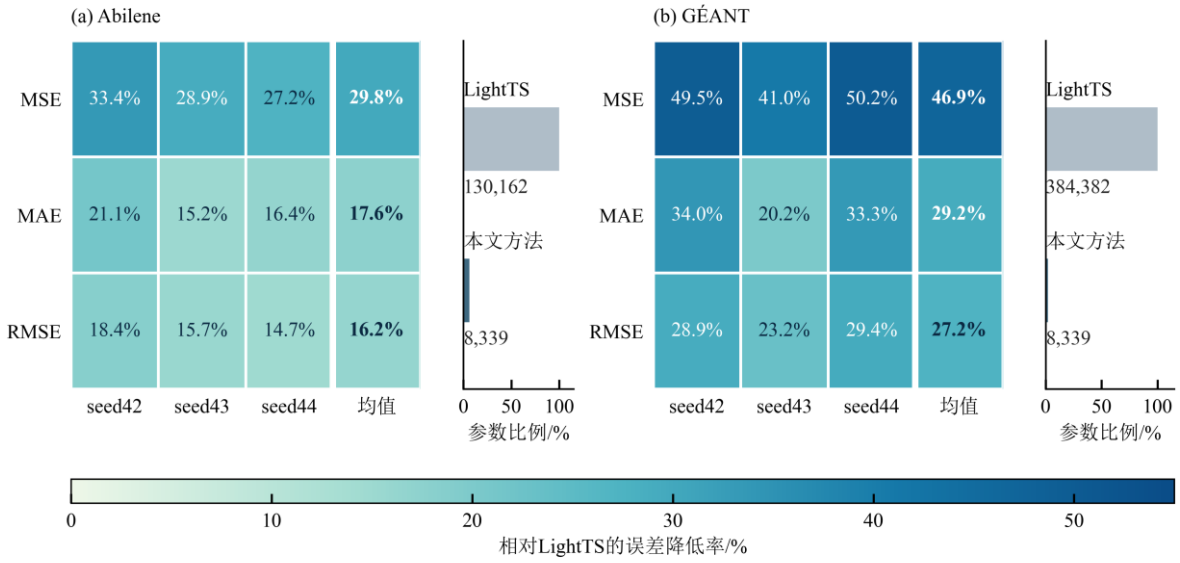


图 2 相对 LightTS 的误差降低率与参数规模

MSE、MAE 和 RMSE 的平均降幅在 Abilene 上为 29.80%、17.57%和 16.23%，在 GÉANT 上为 46.89%、29.15%和 27.18%。逐种子检查这三项指标，两个数据集的 3 个共同随机种子均有改善。本文方法的 8339 个参数，约为 LightTS 在 Abilene 和 GÉANT 上参数量的 6.41%和 2.17%；LightTS 的对应参数量分别为 130162 和 384382。

本文方法在 OD 规模不同的两套数据上均优于 LightTS，GÉANT 的 MSE 降幅更高。下节以相同多尺度专家检验融合方式。

2.3 八随机种子消融实验与稳定性

表 3 汇总随机种子 42～49 的 8 次消融实验，列出五种模型的参数量、MSE 和 MAE。

表 3 八随机种子消融实验结果（均值±标准差）

数据集	模型	参数量	MSE	MAE
Abilene	DLinear	4656	0.194±0.002	0.189±0.008
Abilene	固定等权多尺度	8208	0.192±0.002	0.191±0.006
Abilene	全局可学习权重	8211	0.192±0.002	0.190±0.006
Abilene	恒定输入路由	8339	0.192±0.002	0.181±0.006
Abilene	本文方法	8339	0.189±0.003	0.173±0.008
GÉANT	DLinear	4656	0.437±0.016	0.371±0.011
GÉANT	固定等权多尺度	8208	0.447±0.014	0.377±0.009
GÉANT	全局可学习权重	8211	0.446±0.014	0.377±0.009
GÉANT	恒定输入路由	8339	0.449±0.012	0.379±0.007
GÉANT	本文方法	8339	0.426±0.029	0.366±0.018

相对全局可学习权重和恒定输入路由两个模型，本文方法在 Abilene 上的逐种子平均 MSE 改进均约为 1.80%，在 GÉANT 上这一数据分别为 4.31%和 4.97%，两类对照下分别均有 6/8 和 7/8 个种子的 MSE 更低。相对恒定输入路由模型的 95%置信区间分别为[0.49%,3.11%]和[−1.62%,11.56%]，相对全局权重模型则为[0.01%,3.58%]和[−2.51%,11.13%]；在 GÉANT 上的两项区间均跨零。

图 3 进一步展示了本文方法相对 DLinear 和固定等权多尺度模型的逐种子改进分布。散点为单个种子的改进率，黑色菱形及横向误差线则分别为均值和 95%置信区间。

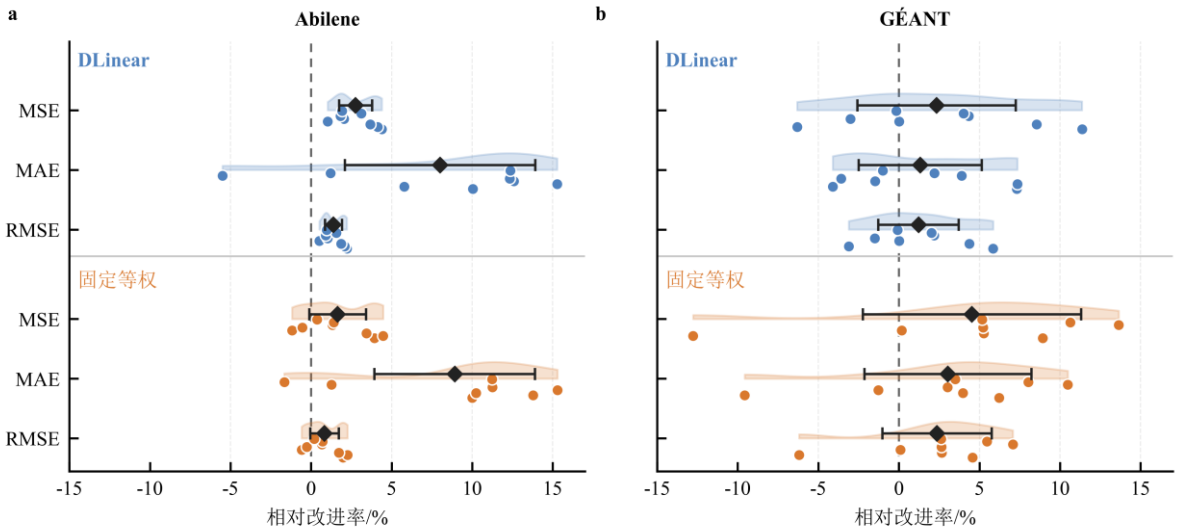


图 3 相对两类基线的多指标改进分布

图 3 给出了不同随机种子下改进率的分布情况；在两类基线上，三个指标的平均改进率均为正。与 DLinear 相比，Abilene 上的 MSE、MAE、RMSE 平均改进率依次为 2.77%、8.01%、1.40%，其中 MSE 和 RMSE 在 8 次实验中均得到了改善。GÉANT 上对应的三项平均改进率为 2.35%、1.32%、1.22%，但负改

进率的种子更多，种子间波动较大。相对固定等权模型，按相同指标顺序，Abilene 的平均改进率为 1.65%、8.92%、0.84%，GÉANT 上则为 4.54%、3.05%、2.37%。

本文方法在表 3 八次重复实验中的平均 MSE 较全局可学习权重与恒定输入路由两类对照低，不过 GÉANT 种子 43 相对恒定输入路由的 MSE 仍增加 12.78%。图 4 以全测试点的预测偏差和按真实序列波动选取的典型轨迹补充平均误差比较，观察模型的预测行为。

2.4 预测行为与尺度权重分析

图 4（a、b）将 8 个种子的全测试预测点按真实值分位点分为最多 40 组，展示分组平均预测，浅色带表示种子间±1 个标准差。图 4（c～f）使用种子 42，按真实序列选取标准差接近第 75 百分位的 OD 通道，以及平均绝对一阶差分接近中位数、第 90 百分位的窗口。

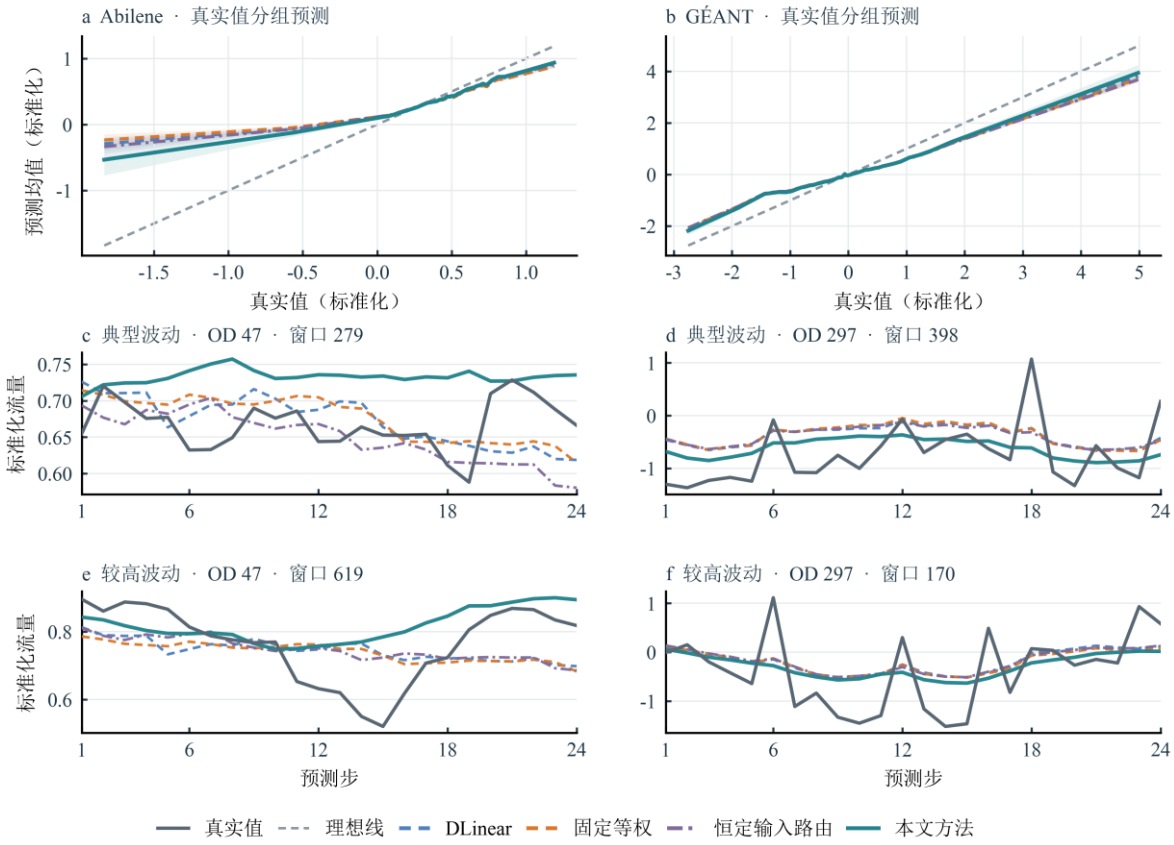


图 4 真实值分组预测与典型窗口轨迹

四种模型在图 4 的高真实值区间均有分组预测低于真实值的现象，本文方法的平均偏差较小。四例典型轨迹中，本文方法在三例上的 24 步均方误差低于 DLinear、固定等权和恒定输入路由模型；在 Abilene 典型波动窗口这一例中，本文方法的结果较差。整体误差比较见表 3。

图 5 汇总 8 个种子的测试窗口权重，彩色点为各随机种子的窗口平均权重，黑色菱形及误差线为这些均值的均值±1 个标准差；短横线表示汇总分布中位数，水平虚线表示固定等权 1/3。

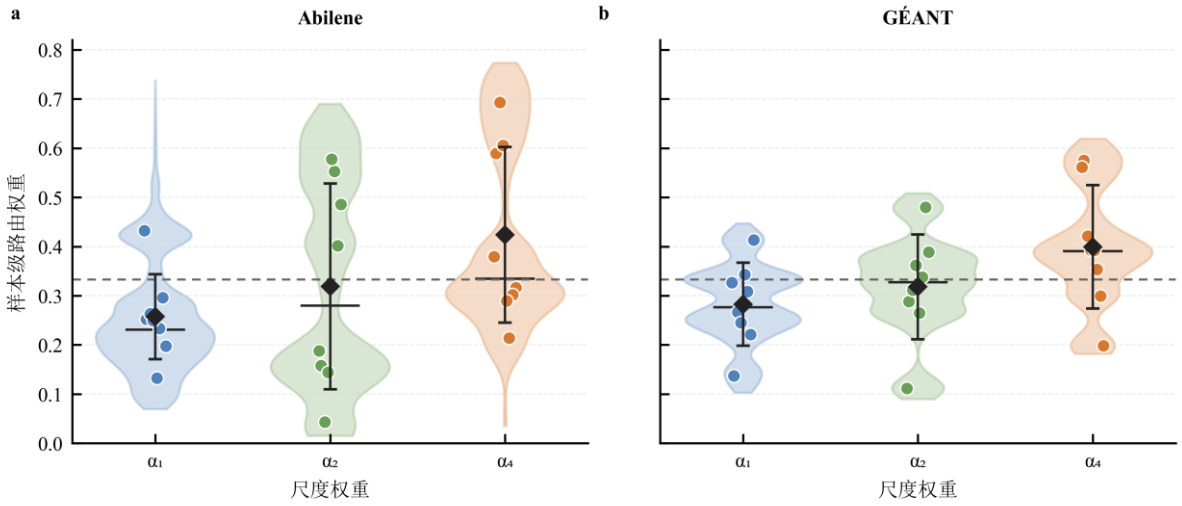


图 5 尺度权重分布与种子均值

Abilene 三个尺度的汇总平均权重依次为 0.257、0.319 和 0.424，GÉANT 对应为 0.283、0.318 和 0.399，均偏离固定等权的 1/3。将汇总权重方差按来源区分，GÉANT 三个尺度中约 96.2%、95.8%和 97.7%来自种子间差异；Abilene 对应比例为 48.7%、86.1%和 80.6%。在 GÉANT 同一种子内部，权重随窗口的变化较小。图 5 所呈现的是不同尺度的总体权重分配，以及其在随机种子间的差异。

为进一步考察模型在不同波动水平下的表现，本文按训练阶段窗口波动强度的三分位数将测试窗口划分为低、中、高三组；波动强度以平均绝对一阶差分进行度量。以全局权重模型为对照，Abilene 上实验的三组逐种子平均 MSE 改进率依次为 4.43%、1.90%、1.69%，样本窗口数相应为 15、406、392 个。而在 GÉANT 上，按相同训练阈值划分时，测试集未出现低波动窗口；相应划分出的中、高波动组分别包含 76、375 个窗口，对应改进率为 5.85%、4.06%。Abilene 的高波动组中，尺度 1 的平均权重高于中波动组，但其误差改善优势却未随权重升高而加强。而在 GÉANT 上，中、高波动组的权重取值近似相同，误差改善幅度却仍有差异，这说明了误差变化与权重调整之间并非简单的对应关系。

2.5 计算开销与网络管理应用讨论

单尺度 DLinear 包含 4656 个可训练参数，使用三个尺度专家的固定等权模型包含 8208 个参数。在固定等权结构上加入三个全局权重参数后，参数总数为 8211 个；样本级路由和恒定输入路由模型的参数总数均为 8339 个。与固定等权及全局权重模型相比，路由网络的参数分别增加 131 个和 128 个。恒定输入路由虽然保留了样本级路由的网络结构，但恒为零的输入却使首层输入权重不参与有效计算。

使用种子 42～49 的 8 个模型检查点测量前向耗时，预测长度为 24，批量大小为 16。计时前关闭梯度计算，测试张量预先载入显存；各检查点预热 20 个批次后，对完整测试集重复计时 10 次。每次总耗时除以批次数，先对 10 次测量取平均，再对 8 个检查点取平均。Abilene 与 GÉANT 上，本文方法的平均每批前向耗时分别为 2.65 ms、2.61 ms，固定等权模型为 2.38 ms、2.10 ms，DLinear 为 0.77 ms、0.70 ms。测量不包含数据读取与传输开销。

在小时级网络管理中，模型一次输出全部有效 OD 变量未来 24 h 的逐小时需求预测。观测更新后，按训练预处理规则将各 OD 最近 96 h 的流量构成历史窗口，再按时间与节点对组织预测结果，供需求分析使用。

在将预测结果投入实际需求分析之前，还需将其从标准化空间还原到原始流量量纲，具体步骤为：先利用训练阶段保存的逐 OD 均值与标准差，对标准化预测值进行逆标准化，再进行逆对数变换，并将结果截断至非负范围。在此基础上，结合网络拓扑与路由关系，将各 OD 的预测需求进一步汇总到对应链路上；通过比较链路预测需求与可用容量，即可为容量调度与扩容决策提供参考。

训练集各 OD 的第 90 百分位用作高需求阈值，超过对应阈值的真实值所在测试预测点才参与评价。种子 42～49 的 24 步预测在标准化空间内统计 MAE 及低估误差均值。对后者，真实值减预测值仅取正值部分，再在全部高需求预测点上平均。高需求预测点在 Abilene 占 13.61%，在 GÉANT 占 13.00%。

按 8 个种子的均值±标准差汇总，本文方法在 Abilene 上的高需求 MAE 和低估误差均值分别为 0.147±0.013、0.137±0.017，相对全局可学习权重的逐种子平均降幅为 17.22%、20.49%，8 个种子均改善。GÉANT 两项指标为 0.632±0.060、0.577±0.080，平均降幅为 3.59%、6.30%，均有 6/8 个种子改善。

高需求预测点上的 MAE 和低估误差均值较低，与图 4 较高真实值区间的预测结果一致。Abilene 不同随机种子下的改善较为一致；GÉANT 两项配对改进率的 95%置信区间均包含零，不同随机种子下的改善并不完全一致。上述结果可为高需求时段的流量监测与容量规划提供参考。

3 结语

本文结合独立分解线性专家与基于窗口统计特征的尺度路由网络，采用自适应多尺度加权协调各尺度输出，以较小参数规模完成小时级骨干网流量预测。重复实验在两套数据上得到的平均误差均低于所设单尺度与固定融合对照，预测输出可作为未来一天需求分析的参考。后续将在更多网络数据和预测长度下检验模型适用性。

参考文献

[1] LOHRASBINASAB I, SHAHRAKI A, TAHERKORDI A, et al. From statistical- to machine learning-based network traffic prediction[J]. Transactions on Emerging Telecommunications Technologies, 2022, 33(4): e4394. DOI: 10.1002/ett.4394.

[2] QIN Liang, GU Huaxi, WEI Wenting, et al. Spatio-temporal communication network traffic prediction method based on graph neural network[J]. Information Sciences, 2024, 679: 121003. DOI: 10.1016/j.ins.2024.121003.

[3] 韦烜, 刘志华, 李青, 等. 大型 IP 网络流量矩阵分析预测的探讨研究[J]. 系统工程与电子技术, 2024, 46(6): 2164-2173. DOI: 10.12305/j.issn.1001-506X.2024.06.35.

[4] 唐文杰, 肖一磊, 孔祥宇, 等. CycleLLH：一种基于周期性整合的新型网络流量预测模型[J]. 计算机学报, 2024, 47(12): 2867-2888. DOI: 10.11897/SP.J.1016.2024.02867.

[5] ZHOU Jian, HAN Taotao, XIAO Fu, et al. Multiscale network traffic prediction method based on deep echo-state network for Internet of Things[J]. IEEE Internet of Things Journal, 2022, 9(21): 21862-21874. DOI: 10.1109/JIOT.2022.3181807.

[6] ZENG Ailing, CHEN Muxi, ZHANG Lei, et al. Are transformers effective for time series forecasting?[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2023, 37(9): 11121-11128. DOI: 10.1609/aaai.v37i9.26317.

[7] WANG Shiyu, WU Haixu, SHI Xiaoming, et al. TimeMixer: decomposable multiscale mixing for time series forecasting[C/OL]//International Conference on Learning Representations. 2024[2026-10-03]. https://openreview.net/forum?id=7oLshfEIC2.

[8] ZHANG Tianping, ZHANG Yizhuo, CAO Wei, et al. Less is more: fast multivariate time series forecasting with light sampling-oriented MLP structures[EB/OL]. (2022-07-04)[2026-10-03]. https://arxiv.org/abs/2207.01186. DOI: 10.48550/arXiv.2207.01186.

[9] KUREŠ M, KOUMAR J, HYNEK K. CESNET TS-Zoo: a library for reproducible analysis of network traffic time series[C]//2025 21st International Conference on Network and Service Management. New York: IEEE, 2025: 1-5. DOI: 10.23919/CNSM67658.2025.11297513.

[10] ZHANG Yin, ROUGHAN M, DUFFIELD N, et al. Fast accurate computation of large-scale IP traffic matrices from link loads[J]. ACM SIGMETRICS Performance Evaluation Review, 2003, 31(1): 206-217. DOI: 10.1145/885651.781053.

[11] UHLIG S, QUOITIN B, LEPROPRE J, et al. Providing public intradomain traffic matrices to the research community[J]. ACM SIGCOMM Computer Communication Review, 2006, 36(1): 83-86. DOI: 10.1145/1111322.1111341.