

基于自适应多尺度加权的多变量网络流量预测方法

[请填写作者姓名]

([请填写单位全称], [省市邮编])

摘要: 为提高骨干网源—目的节点对流量短期预测的尺度适应能力, 提出一种基于样本级自适应多尺度加权的轻量预测方法。该方法将长度为 96 的输入窗口按尺度 1、2 和 4 进行非重叠平均池化, 构造三种时间分辨率视图; 分别采用独立 DLinear 专家分解趋势项与余项并预测未来 24 个时刻; 再由窗口均值、标准差、末时刻均值和平均绝对一阶差分驱动两层路由器, 生成 Softmax 权重并融合三路 144 维预测。同时设置可学习低频门控及不同频率保留比例, 用于检验频域平滑的作用边界。在 CESNET TS-Zoo 公开 Abilene 数据集上完成 48 次正式训练。结果表明, 无频域门控模型的均方误差 (MSE) 和平均绝对误差 (MAE) 分别为 0.186099 和 0.168203, 较单尺度 DLinear 分别降低 4.06% 和 10.52%; 在尺度及专家结构相同条件下, MSE 较固定等权融合降低 3.95%。频率保留比例由 0.25 增至 0.75 时, 含门控模型误差逐步下降, 但仍未优于无频域主模型。结果说明, 样本级自适应尺度加权能够利用不同时间分辨率的互补信息, 是性能提升的主要来源; 低频门控适合作为依赖数据特征的辅助机制。

关键词: 网络流量预测; 多变量时间序列; 多尺度学习; 自适应加权; 线性分解预测; 频域分析

中图分类号: TP393 **文献标志码:** A

A Multivariate Network Traffic Forecasting Method Based on Adaptive

Multiscale Weighting

[Author Name]

([Affiliation], [City] [Postcode], China; Corresponding author: [Name], E-mail: [E-mail])

Abstract: To improve scale adaptability in short-term backbone origin-destination traffic forecasting, a lightweight method based on sample-wise adaptive multiscale weighting was developed. Input windows of 96 time steps were transformed into three temporal views by non-overlapping average pooling at scales 1, 2, and 4. Independent DLinear experts decomposed each view into trend and residual components and predicted the next 24 time steps. A two-layer router used the window mean, standard deviation, mean at the latest time step, and mean absolute first difference to generate Softmax weights for fusing three 144-variable forecasts. Learnable low-frequency gates with different frequency-retention ratios were also evaluated. Forty-eight training runs were conducted on the public Abilene dataset from CESNET TS-Zoo. The ungated adaptive multiscale model achieved a mean squared error (MSE) of 0.186099 and a mean absolute error (MAE) of 0.168203, reducing the two errors by 4.06% and 10.52%, respectively, relative to single-scale DLinear. With identical scales and expert structures, adaptive weighting reduced MSE by 3.95% relative to fixed equal weighting. Increasing the retention ratio from 0.25 to 0.75 reduced errors in gated models, but none outperformed the ungated model. Sample-wise adaptive weighting is therefore the main source of improvement, whereas low-frequency gating serves as a data-dependent auxiliary mechanism.

Key words: network traffic forecasting; multivariate time series; multiscale learning; adaptive weighting; linear decomposition forecasting; frequency-domain analysis

引言

骨干网络中的源—目的节点对 (origin-destination, OD) 流量刻画入口与出口之间的传输需求, 短期预测可服务容量规划、拥塞预警、流量工程和资源调度。现有方法涵盖统计、机器学习和深度学习[1-2],

收稿日期: [待填写]

基金项目: [基金来源] ([基金项目编号]); 如无基金项目请填写“无”。

第一作者简介: [姓名] ([出生年]—), [性别], [职称], [学位], 研究方向: [请填写]。

通信作者简介: [姓名] ([出生年]—), [性别], [职称], [学位], 研究方向: [请填写], 电子邮箱: [请填写]。

并从特征交互、拓扑传播、多尺度动态及非平稳性等方面改善预测[3-6]。这些研究表明，网络流量具有多变量关联和多时间尺度变化。

细粒度观测保留突发变化，粗尺度平滑噪声并突出趋势。固定尺度或固定融合比例难以随当前流量状态调整预测依据；图卷积和复杂 Transformer 又增加参数、训练成本及拓扑要求。因此，本研究检验轻量线性主干配合样本级尺度选择，能否在不引入复杂拓扑建模时获得稳定收益。

分解线性模型（Decomposition-Linear, DLinear）以移动平均分离趋势和余项并进行线性预测，是轻量基线[7]；iTransformer 显式学习变量关系[8]。频率增强分解 Transformer（Frequency Enhanced Decomposed Transformer, FEDformer）、频率插值时间序列分析基线（Frequency Interpolation Time Series Analysis Baseline, FITS）及频域多层感知机（multilayer perceptron, MLP）分别利用频域增强、插值或 MLP 提取周期结构[9-11]。TimeMixer、Pathformer、TimesNet 和 OneNet 通过多尺度混合、自适应路径、频谱周期或在线组合处理尺度变化[12-15]。这些工作支持多尺度互补与输入相关组合，但并非专为骨干网 OD 矩阵设计。

低频通常对应趋势和主要周期，但突发与状态切换可能位于中高频，过强低通会删除预测信息。因此，频率保留比例仅作为敏感性因素。与面向蜂窝网格、结合频域 MLP 和多尺度注意力的时空多层感知机（a frequency-domain multilayer perceptron with multiscale attention network for spatial-temporal traffic prediction, STMLP）[16]不同，本研究面向 Abilene 的 144 维 OD 矩阵，采用 DLinear 专家和四统计量路由器，不使用二维卷积、复杂注意力或网络拓扑。

主要工作包括：1）构建尺度 1、2 和 4 的三支 DLinear 专家；2）以窗口均值、波动、最近状态和变化强度生成样本级非负归一化权重，并设置固定等权对照；3）在 Abilene 上完成 48 次训练，覆盖基础模型、组件消融、频率敏感性和路由分布；4）如实报告频域门控未超过无频域主模型。结论仅适用于既定数据划分、预测任务和三个随机种子。

1 相关工作

1.1 网络流量预测

网络流量预测对象包括链路负载、节点业务和 OD 矩阵。传统统计模型解释性较好，深度模型更能表示高维非线性关系，但需权衡精度、成本与可解释性[1-2]。特征交互模型[3]、图卷积与多头注意力[4]以及动态扩散卷积交互图网络[18]可建模时空依赖，适合拓扑明确的场景，但结构和先验要求较高。

周期性与多尺度性是另一研究重点。多尺度回声状态网络捕获物联网流量的跨尺度依赖[5]，层次化平稳过程描述长期 5G 业务的非平稳变化[6]。运营级互联网协议（Internet Protocol, IP）网络研究验证了 OD 预测的运维价值[17]，CycleLLH 利用周期整合和轻量预测头[19]。本研究据此设计随窗口变化的尺度权重，并用固定等权组检验路由贡献。

1.2 轻量多变量时间序列预测

DLinear 把趋势和余项分别映射为多步预测[7]，参数少且训练稳定，适合作为轻量主干。iTransformer 把变量作为标记学习变量相关性[8]。本研究使用共享时间映射处理 144 个 OD 变量，聚焦时间尺度融合，不把结果解释为已充分建模 OD 拓扑。

国内研究以基于离散傅里叶变换（discrete Fourier transform, DFT）的双分支 Transformer[20]、多尺度特征融合与双注意力[21]和统计特征搜索[22]扩展尺度建模。本研究的四个统计量仅作为路由信号，控制三个尺度专家组合，不参与模型搜索或直接预测。

1.3 频域建模与自适应多尺度融合

傅里叶变换表征不同频率的幅值与相位。FEDformer 结合分解与频域增强[9]；FITS 用复数线性层进行频域插值[10]；面向时间序列预测的频域多层感知机（Frequency-domain MLPs for Time Series forecasting, FreTS）学习时间维和变量维依赖[11]。本研究仅执行标准化、实数输入快速傅里叶变换（real-input fast Fourier transform, RFFT）、低频保留和可学习门控，用于构造可控变量，不复现 FITS 的复数插值层。

TimeMixer、Pathformer、TimesNet 和 OneNet 分别通过下采样混合、自适应路径、频谱周期和在线组合利用多尺度信息[12-15]。本文仅保留三条线性专家及两层路由器。最近邻工作 STMLP 将频域 MLP 和多尺度注意力用于二维蜂窝网格[16]，而本文面向公开骨干网 OD 矩阵，以统计量驱动样本级尺度加权，并用固定等权对照直接检验动态权重收益。

2 自适应多尺度网络流量预测方法

本文方法由预处理、多尺度构造、尺度专家、统计路由和预测融合五部分组成。无频域自适应多尺度结构作为主模型；可学习低频门控作为辅助模块，仅用于分析频率保留比例。整体流程如图 1 所示。




图 1 自适应多尺度预测框架

2.1 问题定义与数据预处理

设预处理后的多变量流量序列为 $x_t \in \mathbb{R}^{C \times 1}$ ，其中 t 为时间索引， C 为 OD 变量数。第 n 个样本的输入和目标分别为

$$X_n = [x_n, \dots, x_{n+L-1}] \in \mathbb{R}^{L \times C}, \quad (1)$$

$$Y_n = [x_{n+L}, \dots, x_{n+L+H-1}] \in \mathbb{R}^{H \times C}. \quad (2)$$

本文取输入长度 $L=96$ 、预测长度 $H=24$ 、变量数 $C=144$ ，学习映射 $\hat{Y}_n = f_\theta(X_n)$ 。原始非负流量 $v_{\{t,c\}}$ 先作对数变换

$$u_{\{t,c\}} = \log(1 + v_{\{t,c\}}), \quad (3)$$

再按变量进行标准化：

$$x_{\{t,c\}} = \frac{u_{\{t,c\}} - \mu_c^{\{tr\}}}{\sigma_c^{\{tr\}}}. \quad (4)$$

其中 $\mu_c^{\{tr\}}$ 和 $\sigma_c^{\{tr\}}$ 只由训练集计算，再用于验证集和测试集，避免未来信息进入训练过程。时间点按 6:2:2 顺序划分，不随机打乱原始时间位置；每个集合内部独立构造滑动窗口，避免跨边界使用数据。

2.2 多尺度序列构造

设尺度集合 $S=\{1,2,4\}$ 。对尺度 s ，使用窗口大小和步长均为 s 的非重叠平均池化：

$$X_{\{n,t\}}^{\{(s)\}} = \left(\frac{1}{s}\right) \Sigma_{\{i=0\}}^{\{(s-1)\}X} X_{\{n,t+i\}}, \quad t = 0, \dots, \frac{L}{s} - 1. \quad (5)$$

三个尺度的输入长度依次为 96、48 和 24。尺度 1 保留逐小时细节，尺度 2 和 4 逐步平滑局部扰动并扩大单个表示对应的时间范围。由于 L 能被各尺度整除，池化不需要补零或裁剪。平均池化本身不增加可训练参数，也使三条支路的含义明确。

2.3 DLinear 尺度专家

每个尺度配置一个独立 DLinear 专家[7]。对尺度 s 的输入，以长度 q=25 的中心移动平均提取趋势项，序列两端采用端点复制以保持长度：

$$T_{\{n,t\}}^{\{(s)\}} = \left(\frac{1}{q}\right) \Sigma_{\{i=-m\}}^{\{m\}\bar{X}_{\{n,t+i\}}^{\{(s)\}}}, \quad q = 2m + 1 = 25, \quad (6)$$

$$R_n^{\{(s)\}} = X_n^{\{(s)\}} - T_n^{\{(s)\}}. \quad (7)$$

趋势项 $T^{\{(s)\}}$ 和余项 $R^{\{(s)\}}$ 沿时间维分别通过线性层映射到预测长度 H：

$$\hat{Y}_n^{\{(s)\}} = W_T^{\{(s)\}} T_n^{\{(s)\}} + b_T^{\{(s)\}} + W_R^{\{(s)\}} R_n^{\{(s)\}} + b_R^{\{(s)\}}. \quad (8)$$

同一尺度内的 144 个变量共享时间映射权重，三个尺度使用不同参数。共享权重显著控制参数量，但不会显式学习 OD 变量间的拓扑关系。三个专家观察不同分辨率的输入，因此即使主干结构相同，也会形成互补预测。

2.4 样本级自适应尺度加权

固定平均默认三个尺度对每个窗口同等重要，难以反映流量状态差异。本文从原始输入 X_n 提取四维统计向量 $z_n = [\mu_n, \sigma_n, \ell_n, d_n]$ ，其中

$$\mu_n = \left(\frac{1}{LC}\right) \Sigma_{\{t,c\}} X_{\{n,t,c\}}, \quad \sigma_n = \sqrt{\left(\frac{1}{LC}\right) \Sigma_{\{t,c\}}^2 (X_{\{n,t,c\}} - \mu_n)^2}, \quad (9)$$

$$\ell_n = \left(\frac{1}{C}\right) \Sigma_{\{t,c\}} X_{\{n,t,c\}}, \quad d_n = \left(\frac{1}{(L-1)C}\right) \Sigma_{\{t=1\}}^{\{(L-1)\}X} \left| X_{\{n,t,c\}} - X_{\{n,t-1,c\}} \right|. \quad (10)$$

μ_n 描述窗口总体水平， σ_n 描述离散程度， ℓ_n 描述最近时刻状态， d_n 描述平均变化强度。四维向量经隐藏维数为 16 的两层感知器得到三个尺度分数：

$$a_n = W_{2ReLU}(W_{1z_n} + b_1) + b_2. \quad (11)$$

Softmax 将分数转换为非负、和为 1 的权重：

$$\alpha_{\{n,s\}} = \frac{\exp(a_{\{n,s\}})}{\Sigma_{\{j \in S\}} \exp(a_{\{n,j\}})}, \quad \alpha_{\{n,s\}} \geq 0, \quad \Sigma_s \alpha_{\{n,s\}} = 1. \quad (12)$$

最终预测为

$$\hat{Y}_n = \Sigma_{\{s \in S\}} \alpha_{\{n,s\}} \hat{Y}_n^{\{(s)\}}. \quad (13)$$

每个样本单独生成一组权重，同一样本的全部 OD 变量共享该组权重。这是一种样本级而不是变量级路由，可控制复杂度并便于解释。固定等权消融令 $\alpha_{\{n,s\}} = 1/3$ ，其他结构和训练过程完全不变，因此固定组与自适应组的误差差异主要反映权重生成方式。

2.5 辅助频域门控

对长度 $L_s = L/s$ 的尺度输入，先按样本和变量沿时间维计算均值与标准差，得到标准化序列：

$$\bar{X}_n^{\{(s)\}} = \frac{X_n^{\{(s)\}} - \mu_n^{\{(s)\}}}{\max(\sigma_n^{\{(s)\}}, 10^{-5})}. \quad (14)$$

沿时间维执行实数快速傅里叶变换：

$$F_{\{n,k,c\}}^{\{(s)\}} = \sum_{\{t=0\}}^{\{L_s-1\}} \tilde{X}_{\{n,t,c\}}^{\{(s)\}} \exp\left(-\frac{j2\pi kt}{L_s}\right). \quad (15)$$

RFFT 共有 $L_s/2+1$ 个非负频率。按比例 r 保留低频个数

$$K_s = \max\left(2, \left\lceil r \left(\frac{L_s}{2} + 1\right) \right\rceil\right), \quad (16)$$

并对保留频率施加可学习门控：

$$\hat{F}_{\{n,k,c\}}^{\{(s)\}} = \text{sigmoid}\left(g_k^{\{(s)\}}\right) F_{\{n,k,c\}}^{\{(s)\}}, k < K_s; \quad \hat{F}_{\{n,k,c\}}^{\{(s)\}} = 0, k \geq K_s. \quad (17)$$

门控参数在同一尺度内按频率共享给所有 OD 变量。逆实数输入快速傅里叶变换 (inverse real-input fast Fourier transform, IRFFT) 将信号恢复到时域，再还原窗口均值与标准差。实验比较 $r \in \{0.25, 0.50, 0.75\}$ 。该设计把频域处理限定为可控低通和衰减，不将其等同于 FITS[10]的复数频率插值。

2.6 训练目标与复杂度

模型以所有样本、预测时刻和 OD 变量上的均方误差为目标：

$$L_{\{MSE\}} = \left(\frac{1}{NHC}\right) \sum_{\{n=1\}}^{\{N\}} \sum_{\{h=1\}}^{\{H\}} \sum_{\{c=1\}}^{\{C\}} \left(Y_{\{n,h,c\}} - \hat{Y}_{\{n,h,c\}}\right)^2. \quad (18)$$

使用 Adam 优化器更新参数，模型选择只依据验证集 MSE。无频域自适应多尺度模型含 8339 个可训练参数；加入频域门控后，参数量随保留频率数变化， $r=0.50$ 和 $r=0.75$ 时分别为 8381 和 8402。其参数增加主要来自尺度专家和门控，不涉及大型注意力矩阵。依据消融结果，无频域版本作为主要方法，频域版本作为敏感性分析对象。

3 实验与结果分析

3.1 数据集与运行环境

实验使用 CESNET TS-Zoo 公开的 Abilene 骨干网 1 h 聚合流量矩阵，从字段 `matrix_avg_realOD` 提取 144 维有效 OD 序列，共 4656 个时间点。训练集、验证集和测试集按时间顺序分别包含 2793、931 和 932 个时间点。在 $L=96$ 、 $H=24$ 的条件下，三个集合分别形成 2674、812 和 813 个滑动窗口。数据执行 $\log(1+x)$ 变换，再使用训练集逐变量统计量标准化。

实验运行环境为 Windows 64 位操作系统、Python 3.11.9、PyTorch 2.5.1+cu118、统一计算设备架构 (compute unified device architecture, CUDA) 11.8、NumPy 2.4.6、pandas 2.3.3 和 SciPy 1.17.1。模型采用自适应矩估计 (adaptive moment estimation, Adam) 优化器，学习率 0.001，批量大小 16，最多训练 30 轮；验证集 MSE 连续 6 轮未改善时提前停止，并保留验证误差最低的参数。每个配置使用随机种子 42、43 和 44 独立训练。实验档案共含 48 次正式训练，每次保存评价指标、最佳检查点和预测数组，多尺度模型另保存测试窗口的路由权重。

3.2 评价指标与统计方法

预测性能在标准化空间中评价。设测试集有 N_{te} 个窗口，平均绝对误差和均方根误差分别为

$$MAE = \left(\frac{1}{N_{te}HC}\right) \sum_{\{n,h,c\}} |Y_{\{n,h,c\}} - \hat{Y}_{\{n,h,c\}}|, \quad (19)$$

$$RMSE = \sqrt{MSE}. \quad (20)$$

MSE、MAE 和均方根误差 (root mean squared error, RMSE) 均越小越好。由于 RMSE 是 MSE 的单调变换，正文表格主要列出 MSE 和 MAE。每个配置以三个随机种子的均值 $\pm$ 样本标准差报告。统计推断的独立重复单位为随机种子，即每个配置 $n=3$ ，不能把 813 个测试窗口当作 813 次独立重复。固定权重与

自适应权重使用相同种子进行双侧配对 t 检验，并报告配对差的 95%置信区间（confidence interval, CI）及 Cohen's d_z。在 r=0.50 下的两项预设权重比较使用 Holm 法校正。由于 n=3 无法可靠检验正态性，显著性结果仅作为均值、标准差和效应方向的补充。

3.3 基础模型与组件消融

表 1 比较五种基础配置。所有模型使用相同划分、输入输出长度、预处理和早停规则。DLinear+自适应多尺度取得最低平均误差，MSE 为 0.186099，较单尺度 DLinear 降低 4.06%；MAE 为 0.168203，降低 10.52%。这表明三种分辨率与样本级融合的组合能够为当前 Abilene 短期预测提供互补信息。随机种子分布及均值见图 2。

表 1 基础模型消融结果

模型	参数量	MSE	MAE
DLinear	4656	0.193983±0.001567	0.187988±0.009422
FITS	750	0.202230±0.001972	0.198299±0.003818
DLinear+频域门控 (r=0.50)	4680	0.197181±0.000655	0.191756±0.007712
DLinear+自适应多尺度	8339	0.186099±0.001996	0.168203±0.000583
频域门控+自适应多尺度 (r=0.50)	8381	0.192432±0.005766	0.173438±0.000813




图 2 基础模型消融结果

频域相关模型没有呈现同等收益。FITS 和 DLinear+频域门控的 MSE 分别比 DLinear 高 4.25%和 1.65%；

在自适应多尺度模型上增加 $r=0.50$ 的频域门控后, MSE 由 0.186099 升至 0.192432。完整模型仍比 DLinear 低 0.80%, 但该差异不能证明频域模块单独有效。由表 1 和图 2 可见, 基础实验中的主要增益来自自适应多尺度, 不来自低频门控。

3.4 自适应权重消融与路由行为

为分离多尺度结构和权重生成方式的影响, 表 2 在尺度集合与专家结构完全相同的条件下比较固定等权和自适应权重。无频域时, 自适应模型相对固定等权模型 MSE 降低 3.95%, MAE 降低 11.38%。按种子计算的 MSE 平均配对差为 0.007651, 95% CI 为[0.005238, 0.010064], $t(2)=13.642$, Holm 校正后 $p=0.01066$, Cohen's $d_z=7.876$ 。该结果在三个种子上方向一致, 但效应量和置信区间建立在很少的算法重复上, 应谨慎解释。同种子配对变化见图 3。

表 2 权重方式消融结果

频域设置	权重方式	MSE	MAE
无频域	固定等权	0.193750±0.001103	0.189802±0.005236
无频域	自适应	0.186099±0.001996	0.168203±0.000583
$r=0.50$	固定等权	0.200384±0.002176	0.195155±0.005022
$r=0.50$	自适应	0.192432±0.005766	0.173438±0.000813
$r=0.75$	固定等权	0.196809±0.001457	0.192722±0.005338
$r=0.75$	自适应	0.189447±0.005119	0.170543±0.000729




图 3 自适应权重消融结果

在 $r=0.50$ 时, 自适应权重相对固定等权降低 MSE 3.97%, 但配对差 95% CI 为[-0.001193, 0.017096], Holm 校正后 $p=0.06460$; 在探索性 $r=0.75$ 设置下, MSE 和 MAE 分别降低 3.74%和 11.51%, 配对差 95% CI 为[-0.001770, 0.016493], $t(2)=3.469$, $p=0.07401$, Cohen's $d_z=2.003$ 。后两项区间跨越 0, 只能称为改善趋势。图 3 把同一种子的结果连接, 可避免把总体均值差异误读为大量独立样本带来的显著性。路由权重的样本变化与总体分布见图 4。




图 4 路由权重分布

图 4 显示路由权重并非恒定 1/3，且在测试窗口之间存在分布差异，说明路由器没有退化为固定平均。三个随机种子的平均尺度偏好并不完全一致，因此结果只支持“权重会随样本变化”，不能把某一个尺度固定解释为所有场景中最重要业务尺度。更稳妥的机制解释是：路由器根据窗口统计状态改变专家组合，从而降低固定融合的约束。

3.5 频率保留比例敏感性

表 3 给出 $r \in \{0.25, 0.50, 0.75\}$ 的频率敏感性结果。对 DLinear+频域门控和频域门控+自适应多尺度两类模型，保留比例从 0.25 增加到 0.75 时平均 MSE 均逐步下降。该趋势与“过强低通可能删除重要变化”的认识一致[9]，但实验没有直接定位误差对应的具体频带，因此只能作为与结果相符的解释。各随机种子的敏感性轨迹见图 5。

表 3 频率保留比例敏感性

模型	r	MSE	MAE
DLinear+频域门控	0.25	0.200367±0.002349	0.193320±0.005065
DLinear+频域门控	0.50	0.197181±0.000655	0.191756±0.007712
DLinear+频域门控	0.75	0.195478±0.001138	0.190041±0.008711
频域门控+自适应多尺度	0.25	0.201774±0.006798	0.182381±0.002075
频域门控+自适应多尺度	0.50	0.192432±0.005766	0.173438±0.000813
频域门控+自适应多尺度	0.75	0.189447±0.005119	0.170543±0.000729




图 5 频率保留比例敏感性

完整模型在三个候选比例中的最低 MSE 为 0.189447。与 DLlinear 相比， $r=0.75$ 的完整模型将 MSE 和 MAE 分别降低 2.34% 和 9.28%；但与无频域自适应多尺度模型相比，其 MSE 和 MAE 仍分别高 1.80% 和 1.39%。因此，0.75 只能称为已测试候选值中的探索性较优比例，不能称为在独立验证上确定的最优超参数。频域门控的价值主要体现在揭示截断边界：低频保留过少会损失信息，而保留更多频率虽能缓解损失，仍未超过不截断的主模型。

3.6 代表性预测与应用含义

为直观观察预测曲线，图 6 使用预先规定的中位规则选取测试窗口和 OD 通道：先在种子 42 的自适应模型中选择 MAE 最接近 813 个测试窗口中位数的窗口，再在该窗口选择真实序列标准差最接近非恒定 OD 变量中位数的通道。该过程避免仅展示效果最好的样本。




图 6 代表性窗口预测结果

从应用角度看，预测输出可作为容量与拥塞管理的辅助输入。例如，网络管理系统可用未来 24 h 的 OD 流量估计识别可能持续上升的业务对，提前调整链路容量、路由权重或巡检优先级；在资源编排中，可根据预测需求安排带宽和计算资源。本文实验评价的是标准化空间误差，并未直接模拟路由控制或服务提升，因此不能把误差下降等同于确定的吞吐量提升。更准确的表述是：在相同数据和评价规则下，较低预测误差为后续决策提供了更准确的需求估计。

3.7 讨论与局限性

三层证据支持主要结论：主模型优于单尺度 DLlinear；在尺度和专家相同条件下，自适应权重优于固定等权；路由权重随窗口变化。因此，收益主要来自样本级尺度组合，但实验未分别检验四个统计量的因果贡献。

较高频率保留比例优于较低比例，提示中高频信息对 Abilene 短期预测有用；但含门控模型未超过无频域主模型，因此频域门控不能作为精度创新。该边界与低频截断风险的相关研究一致[9-10,20]。

结论受三点限制：仅使用一个骨干网数据集，跨网络迁移性尚未验证[17-19]；每个配置只有三个随机种子，统计推断应以均值、标准差、置信区间和方向一致性为主；模型未使用 OD 拓扑或显式变量注意力，不能据此否定相关路线[4,8,18]。后续需在第二个公开数据集和 12、48、96 等预测长度上复核固定/自适应消融；频域模块可尝试残差旁路或分频带选择。

4 结论

本文提出一种基于样本级自适应多尺度加权的多变量网络流量预测方法。模型将长度 96 的输入窗口构造成尺度 1、2 和 4 三种时间视图，使用独立 DLinear 专家预测未来 24 个时刻，再由四个窗口统计量驱动的两层路由器生成 Softmax 权重。该结构保持参数量较小，且可通过权重分布观察不同输入窗口的融合行为。

Abilene 公开数据上的三随机种子实验表明，无频域自适应多尺度模型相对 DLinear 将 MSE 和 MAE 分别降低 4.06%和 10.52%，相对固定等权模型将 MSE 降低 3.95%。固定/自适应配对结果和路由分布共同支持样本级尺度融合是主要改进来源。频率敏感性实验显示，保留更多频率可减少低通造成的误差，但含频域门控的模型仍未超过无频域主模型。因此，本文的有效创新应定位于轻量多尺度专家与统计路由的组合，频域门控仅提供关于信息保留边界的辅助结论。

研究结论限于 Abilene 单一数据集、固定输入输出长度和三个随机种子。尽管如此，完整的组件消融、固定等权对照、频率敏感性和逐样本权重记录，使主要结论具备可检查的证据链。该方法可为容量规划、拥塞预警和资源调度提供短期 OD 需求估计；跨数据集、跨预测长度与更细粒度的频带选择是下一步验证其适用范围的重点。

参考文献

- [1] LOHRASBINASAB I, KESHAVARZ A, AMIN-NEJAD S, et al. From statistical- to machine learning-based network traffic prediction[J]. Transactions on Emerging Telecommunications Technologies, 2022, 33(4): e4394. DOI: 10.1002/ett.4394.
- [2] WANG X, WANG Z, YANG K, et al. A survey on deep learning for cellular traffic prediction[J]. Intelligent Computing, 2024, 3: 0054. DOI: 10.34133/icomputing.0054.
- [3] LU Y, NING Q, HUANG L, et al. A network traffic prediction model based on reinforced staged feature interaction and fusion[J]. Computer Networks, 2023, 227: 109719. DOI: 10.1016/j.comnet.2023.109719.
- [4] QIN L, GU H, WEI W, et al. Spatio-temporal communication network traffic prediction method based on graph neural network[J]. Information Sciences, 2024, 679: 121003. DOI: 10.1016/j.ins.2024.121003.
- [5] ZHOU J, HAN T, XIAO F, et al. Multiscale network traffic prediction method based on deep echo-state network for Internet of Things[J]. IEEE Internet of Things Journal, 2022, 9(21): 21862-21874. DOI: 10.1109/JIOT.2022.3181807.
- [6] YANG Y, GENG S, ZHANG B, et al. Long term 5G network traffic forecasting via modeling non-stationarity with deep learning[J]. Communications Engineering, 2023, 2: 33. DOI: 10.1038/s44172-023-00081-4.
- [7] ZENG A, CHEN M, ZHANG L, et al. Are transformers effective for time series forecasting?[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2023, 37(9): 11121-11128. DOI: 10.1609/aaai.v37i9.26317.
- [8] LIU Y, HU T, ZHANG H, et al. iTransformer: inverted transformers are effective for time series forecasting[C]//International Conference on Learning Representations. 2024.
- [9] ZHOU T, MA Z, WEN Q, et al. FEDformer: frequency enhanced decomposed transformer for long-term series forecasting[C]//Proceedings of the 39th International Conference on Machine Learning. 2022: 27268-27286.
- [10] XU Z, ZENG A, XU Q. FITS: modeling time series with 10k parameters[C]//International Conference on Learning Representations. 2024.

- [11] YI K, ZHANG Q, FAN W, et al. Frequency-domain MLPs are more effective learners in time series forecasting[C]//Advances in Neural Information Processing Systems. 2023, 36.
- [12] WANG S, WU H, SHI X, et al. TimeMixer: decomposable multiscale mixing for time series forecasting[C]//International Conference on Learning Representations. 2024.
- [13] CHEN P, ZHANG Y, CHENG Y, et al. Pathformer: multi-scale transformers with adaptive pathways for time series forecasting[C]//International Conference on Learning Representations. 2024.
- [14] WU H, HU T, LIU Y, et al. TimesNet: temporal 2D-variation modeling for general time series analysis[C]//International Conference on Learning Representations. 2023.
- [15] ZHANG Y, WEN Q, WANG X, et al. OneNet: enhancing time series forecasting models under concept drift by online ensembling[C]//Advances in Neural Information Processing Systems. 2023, 36: 69949-69980. DOI: 10.52202/075280-3066.
- [16] TANG C, LU J, YANG W, et al. A frequency-domain multilayer perceptron with multiscale attention network for cellular traffic prediction[J]. Computer Networks, 2025, 271: 111593. DOI: 10.1016/j.comnet.2025.111593.
- [17] 韦烜, 刘志华, 李青, 等. 大型 IP 网络流量矩阵分析预测的探讨研究[J]. 系统工程与电子技术, 2024, 46(6): 2164-2173. DOI: 10.12305/j.issn.1001-506X.2024.06.35.
- [18] 王菁, 文晓东, 王春枝. 基于动态扩散卷积交互图神经网络的网络流量预测[J]. 计算机应用研究, 2023, 40(1): 97-101. DOI: 10.19734/j.issn.1001-3695.2022.05.0255.
- [19] 唐文杰, 肖一磊, 孔祥宇, 等. CycleLLH: 一种基于周期性整合的新型网络流量预测模型[J]. 计算机学报, 2024, 47(12): 2867-2888. DOI: 10.11897/SP.J.1016.2024.02867.
- [20] 任烈弘, 黄铝文, 田旭, 等. 基于 DFT 的频率敏感双分支 Transformer 多变量长时间序列预测方法[J]. 计算机应用, 2024, 44(9): 2739-2746. DOI: 10.11772/j.issn.1001-9081.2023091320.
- [21] 韩璐, 霍纬纲, 张永会, 等. 基于多尺度特征融合与双注意力机制的多元时间序列预测[J]. 计算机工程, 2023, 49(9): 99-108. DOI: 10.19678/j.issn.1000-3428.0065846.
- [22] 潘金伟, 等. 基于统计特征搜索的多元时间序列预测方法[J]. 电子与信息学报, 2024, 46(8): 3276-3284. DOI: 10.11999/JEIT231264.