

基于自适应多尺度加权的多变量网络流量预测方法

[请填写作者姓名]

[[请填写工作单位][请填写部门], [省 市 邮编]]

摘要: 为提高骨干网络源—目的节点对短期流量预测对不同时间尺度变化的适应能力, 构建一种样本级自适应多尺度轻量预测方法。采用尺度 1、2 和 4 的非重叠平均池化生成多分辨率序列, 由独立 DLinear 专家预测; 提取窗口均值、标准差、末时刻均值和平均绝对一阶差分, 经轻量路由网络生成 Softmax 权重, 对各尺度结果动态融合。在 Abilene 和 GÉANT 数据集上, 以 DLinear、LightTS 及固定等权多尺度模型为对比。共同 3 个随机种子下, 所建方法 MSE 较 DLinear 分别降低 4.06% 和 4.43%, 较 LightTS 分别降低 29.89% 和 46.83%; 8 个随机种子的核心消融结果显示, 相较固定等权融合, 两数据集 MSE 分别降低 1.67% 和 4.68%, 其中 GÉANT 跨种子波动更大。结果表明, 样本级动态尺度加权能够以较小参数增量利用不同时间分辨率的互补信息, 但跨数据集稳定性仍需提升。

关键词: 网络流量预测; 多变量时间序列; 多尺度学习; 自适应加权; DLinear

中图分类号: TP393 **文献标志码:** A

A Multivariate Network Traffic Forecasting Method Based on Adaptive Multiscale Weighting

[Author Name]

[[Affiliation] [Department], [City] [Postcode], China; Corresponding author: [Name], E-mail: [E-mail]]

Abstract: A lightweight forecasting method based on sample-wise adaptive multiscale weighting was developed to improve the adaptability of short-term backbone origin-destination (OD) traffic forecasting to variations at different temporal scales. Non-overlapping average pooling at scales 1, 2, and 4 was used to construct multiresolution sequences, which were processed by independent DLinear experts. The window mean, standard deviation, mean at the latest time step, and mean absolute first difference were extracted and fed into a lightweight routing network to generate Softmax weights for dynamic fusion of the scale-wise forecasts. Experiments were conducted on the Abilene and GÉANT datasets, with DLinear, LightTS, and a fixed equal-weight multiscale model as baselines. Under three common random seeds, the proposed method reduced MSE by 4.06% and 4.43% relative to DLinear, and by 29.89% and 46.83% relative to LightTS on Abilene and GÉANT, respectively. In the eight-seed core ablation, MSE was reduced by 1.67% and 4.68% compared with fixed equal weighting, while GÉANT exhibited larger cross-seed variability. These results indicate that sample-wise adaptive scale weighting can exploit complementary temporal-resolution information with only a small parameter increase, although robustness across datasets remains to be improved.

Key words: network traffic forecasting; multivariate time series; multiscale learning; adaptive weighting; DLinear

随着云计算、视频业务和数据中心互联等网络应用持续发展, 骨干网络业务需求呈现明显的时变性、突发性和多时间尺度特征。源—目的节点对 (origin-destination, OD) 流量能够刻画网络入口与出口之间的业务需求, 其短期预测结果可为容量规划、拥塞预警、流量工程和资源调度提供依据。网络流量预测方法已由传统统计模型逐步发展到机器学习和深度学习[1]。针对通信网络中的时空相关性, Qin 等[2]采用图神经网络建模空间依赖关系; 韦烜等[10]对大型互联网协议 (Internet Protocol, IP) 网络流量矩阵的分析

收稿日期: [请填写, 格式 YYYY-MM-DD]

基金项目: [基金来源] ([基金项目编号])

第一作者简介: [姓名] ([出生年]—), [性别] (民族, 汉族可省略), [职称], [学位 (若在读请注明)], 研究方向: [方向 1]; [方向 2]。

通信作者简介: [姓名] ([出生年]—), [性别] (民族, 汉族可省略), [职称], [学位 (若在读请注明)], 研究方向: [方向 1]; [方向 2], 电子邮箱: [邮箱]。

预测进行了研究。这类方法拓展了流量预测的建模能力，但对于仅利用历史 OD 流量、强调结构简洁和参数规模受控的应用场景，仍有必要探索更轻量的时序建模方式。

网络流量在不同时间尺度上包含互补信息：细粒度序列保留局部变化，较粗粒度序列有助于突出相对平滑的趋势。Zhou 等[3]利用多尺度回声状态网络提取不同时间尺度的流量特征；TimeMixer 通过可分解多尺度混合实现不同分辨率信息交互[5]；CycleLLH 从周期性整合角度改进网络流量预测[11]。在轻量时间序列预测方面，DLinear 通过趋势项与余项分解配合线性映射实现多步预测[4]；LightTS 采用连续采样和间隔采样配合多层感知机结构，以较低计算开销建模多变量时间序列[6]。这些研究说明，多尺度表征与简洁预测结构均具有应用潜力，也为在参数规模受控条件下进一步研究尺度融合提供了基础。

现有研究分别从拓扑关联、多尺度表征和轻量序列建模等角度提升预测能力，但在不显式依赖网络拓扑的历史 OD 序列预测场景中，如何根据当前输入窗口的状态动态确定不同时间尺度的重要性，仍值得进一步研究。为此，本文构建基于 DLinear 尺度专家的样本级自适应多尺度预测方法：采用尺度 1、2 和 4 构造多分辨率序列，由独立尺度专家生成候选预测，再从输入窗口提取均值、标准差、末时刻均值和平均绝对一阶差分，通过轻量路由网络生成 Softmax 权重，实现样本级动态融合。实验在 Abilene 和 GÉANT 两个骨干网数据集上开展，并引入 DLinear、LightTS 和固定等权多尺度模型进行比较；同时使用 8 个随机种子分析核心机制的稳定性，以检验性能改善是否来自样本级自适应尺度加权。

1 自适应多尺度网络流量预测方法

本文方法由数据预处理、多尺度序列构造、DLinear 尺度专家、样本级统计路由和自适应预测融合五部分组成。输入窗口经尺度 1、2 和 4 构造不同时间分辨率，由三个独立 DLinear 专家分别预测；路由器依据原始窗口统计状态生成 Softmax 尺度权重，对专家输出进行样本级动态加权。整体流程如图 1 所示。




图 1 自适应多尺度网络流量预测方法框架

1.1 问题定义与数据预处理

设预处理后的多变量流量序列为 $x_t \in \mathbb{R}^C$ ，其中 t 为时间索引， C 为 OD 变量数。第 n 个样本的输入和目标分别为

$$\mathbf{X}_n = [x_n, \dots, x_{n+L-1}] \in \mathbf{R}^{L \times C}, \quad (1)$$

$$\mathbf{Y}_n = [x_{n+L}, \dots, x_{n+L+H-1}] \in \mathbf{R}^{H \times C}. \quad (2)$$

本文取输入长度 $L=96$ 、预测长度 $H=24$ 、变量数 C 随具体数据集的有效 OD 维度确定, 学习映射 $\hat{\mathbf{Y}}_n = f_\theta(\mathbf{X}_n)$ 。

原始非负流量 $v_{t,c}$ 先作对数变换

$$u_{\{t,c\}} = \log(1 + v_{\{t,c\}}), \quad (3)$$

再按变量进行标准化:

$$x_{\{t,c\}} = \frac{u_{\{t,c\}} - \mu_c^{\{\text{tr}\}}}{\sigma_c^{\{\text{tr}\}}}. \quad (4)$$

其中 μ_c^{tr} 和 σ_c^{tr} 只由训练集计算, 再用于验证集和测试集, 避免未来信息进入训练过程。时间点按 6:2:2 顺序划分, 不随机打乱原始时间位置; 每个集合内部独立构造滑动窗口, 避免跨边界使用数据。

1.2 多尺度序列构造

设尺度集合 $S=\{1,2,4\}$ 。对尺度 s , 使用窗口大小和步长均为 s 的非重叠平均池化:

$$\mathbf{X}_{\{n,t\}}^{\{(s)\}} = \left(\frac{1}{s}\right) \Sigma_{\{i=0\}_{\{n, st+i\}}^{\{s-1\}X}}, \quad t = 0, \dots, \frac{L}{s} - 1. \quad (5)$$

三个尺度的输入长度依次为 96、48 和 24。尺度 1 保留逐小时细节, 尺度 2 和 4 逐步平滑局部扰动并扩大单个表示对应的时间范围。由于 L 能被各尺度整除, 池化不需要补零或裁剪。平均池化本身不增加可训练参数, 也使三条支路的含义明确。

1.3 DLinear 尺度专家

每个尺度配置一个独立 DLinear 专家[4]。对尺度 s 的输入, 以长度 $q=25$ 的中心移动平均提取趋势项, 序列两端采用端点复制以保持长度:

$$\mathbf{T}_{\{n,t\}}^{\{(s)\}} = \left(\frac{1}{q}\right) \Sigma_{\{i=-m\}}^{\{m\}} \bar{\mathbf{X}}_{\{n,t+i\}}^{\{(s)\}}, \quad q = 2m + 1 = 25, \quad (6)$$

$$\mathbf{R}_n^{\{(s)\}} = \mathbf{X}_n^{\{(s)\}} - \mathbf{T}_n^{\{(s)\}}. \quad (7)$$

趋势项 $\mathbf{T}^{(s)}$ 和余项 $\mathbf{R}^{(s)}$ 沿时间维分别通过线性层映射到预测长度 H :

$$\hat{\mathbf{Y}}_n^{\{(s)\}} = \mathbf{W}_T^{\{(s)\}} \mathbf{T}_n^{\{(s)\}} + \mathbf{b}_T^{\{(s)\}} + \mathbf{W}_R^{\{(s)\}} \mathbf{R}_n^{\{(s)\}} + \mathbf{b}_R^{\{(s)\}}. \quad (8)$$

式中, 趋势项线性层和余项线性层分别具有独立的时间映射权重与偏置参数。同一尺度内的 C 个变量共享时间映射权重, 三个尺度使用不同参数。共享权重显著控制参数量, 但不会显式学习 OD 变量间的拓扑关系。三个专家观察不同分辨率的输入, 因此即使主干结构相同, 也会形成互补预测。

1.4 样本级自适应尺度加权

固定平均默认三个尺度对每个窗口同等重要, 难以反映流量状态差异。本文从原始输入 $\mathbf{X}_n$ 提取四维统

计向量 $\mathbf{z}_n = [\mu_n, \sigma_n, \ell_n, d_n]$ ，其中

$$\mu_n = \left(\frac{1}{LC}\right) \Sigma_{\{t,c\}} X_{\{n,t,c\}}, \quad \sigma_n = \sqrt{\left(\frac{1}{LC}\right) \Sigma_{\{t,c\}}^2 (X_{\{n,t,c\}} - \mu_n)^2}, \quad (9)$$

$$\ell_n = \left(\frac{1}{C}\right) \Sigma_c X_{\{n,L-1,c\}}, \quad d_n = \left(\frac{1}{(L-1)C}\right) \Sigma_{\{t=1\}^{(L-1)\Sigma}} \left| X_{\{n,t,c\}} - X_{\{n,t-1,c\}} \right|. \quad (10)$$

μ_n 描述窗口总体水平， σ_n 描述离散程度， ℓ_n 描述最近时刻状态， d_n 描述平均变化强度。四维向量经隐藏维数为 16 的两层感知器得到三个尺度分数：

$$\mathbf{a}_n = \mathbf{W}_{2\text{ReLU}}(\mathbf{w}_{1\mathbf{z}_n} + \mathbf{b}_1) + \mathbf{b}_2. \quad (11)$$

式中，两层感知器各自包含权重矩阵和偏置，输出为三个尺度的得分向量。Softmax 将分数转换为非负、和为 1 的权重：

$$\alpha_{\{n,s\}} = \frac{\exp(a_{\{n,s\}})}{\Sigma_{\{j \in S\}} \exp(a_{\{n,j\}})}, \quad \alpha_{\{n,s\}} \geq 0, \quad \Sigma_s \alpha_{\{n,s\}} = 1. \quad (12)$$

最终预测为

$$\hat{\mathbf{Y}}_n = \Sigma_{\{s \in S\}} \alpha_{\{n,s\}} \mathbf{y}_n^{\{(s)\}}. \quad (13)$$

每个样本单独生成一组权重，同一样本的全部 OD 变量共享该组权重。这是一种样本级而不是变量级路由，可控制复杂度并便于解释。固定等权消融令 $\alpha_{n,s} = 1/3$ ，其他结构和训练过程完全不变，因此固定组与自适应组的误差差异主要反映权重生成方式。

1.5 训练目标与模型复杂度

模型以所有样本、预测时刻和 OD 变量上的均方误差为目标：

$$L_{\{\text{MSE}\}} = \left(\frac{1}{NHC}\right) \Sigma_{\{n=1\}}^{\{N\} \Sigma_{\{h=1\}}^{\{H\} \Sigma_{\{c=1\}}^{\{C\}}} (\mathbf{y}_{\{n,h,c\}} - \hat{\mathbf{y}}_{\{n,h,c\}})^2. \quad (14)$$

式中，N 为训练样本数，损失函数表示训练样本、预测时刻和 OD 变量上的平均平方误差。使用 Adam 优化器更新参数，模型选择只依据验证集均方误差。单尺度 DLinear、固定等权多尺度和自适应多尺度模型分别含 4656、8208 和 8339 个可训练参数，其中样本级路由器相对固定等权版本仅增加 131 个参数。模型不包含大型注意力矩阵或显式拓扑模块，结构复杂度主要来自三个尺度专家。

2 实验与结果分析

2.1 数据集与实验设置

实验选用 CESNET TS-Zoo[7]中的 Abilene[8]和 GÉANT[9]骨干网 1 h 聚合流量矩阵。Abilene 从 matrix_avg_realOD 提取 144 维有效 OD 流量，共 4656 个时间点；GÉANT 从 matrix_avg_bandwidth_kbps 读取 529 维矩阵，去除 5 个恒定通道后保留 524 维有效变量，共 2849 个时间点。两数据集均按时间顺序以 6:2:2 划分训练集、验证集和测试集，并分别在各集合内部构造滑动窗口，避免跨集合泄漏。输入长度 L=96，

预测长度 $H=24$ ；预处理与第 1.1 节一致，先进行 $\log(1+x)$ 变换，再仅使用训练集统计量逐变量标准化。数据规模见表 1。

表 1 数据集与预测任务设置

数据集	时间点	有效变量 C	训练/验证/测试时间点	训练/验证/测试窗口	L/H
Abilene	4656	144	2793/931/932	2674/812/813	96/24
GÉANT	2849	524	1709/570/570	1590/451/451	96/24

所有模型均通过统一训练接口完成，并采用 Adam 优化器和批量大小 16。DLinear、固定等权多尺度和自适应多尺度模型的学习率为 0.001，最多训练 30 轮，验证集 MSE 连续 6 轮未改善时提前停止；LightTS 采用固定外部基线设置，学习率为 0.0001，最多训练 50 轮，早停耐心为 10。所有模型均以验证集 MSE 最低的参数进行测试。为避免不同重复次数造成统计口径混用，外部基线比较统一采用各模型共同完成的随机种子 42—44；三个核心模型进一步采用 42—49 共 8 个随机种子进行机制稳定性分析。

2.2 对比模型与评价指标

对比模型包括单尺度 DLinear、外部轻量基线 LightTS、固定等权多尺度模型和本文自适应多尺度模型。其中，LightTS 采用 Time-Series-Library 中固定版本的原始模型逻辑，并通过适配器接入与其他模型相同的数据划分、预处理和训练接口；固定等权多尺度与本文方法使用相同的尺度集合 {1,2,4} 和 DLinear 专家，仅将三个尺度权重固定为 1/3，用于隔离样本级动态加权的贡献。

采用均方误差（mean squared error, MSE）、平均绝对误差（mean absolute error, MAE）和均方根误差（root mean squared error, RMSE）评价预测性能。MSE 按式（14）计算；设测试集包含 N_{te} 个窗口，则 MAE 和 RMSE 分别为

$$MAE = \left(\frac{1}{N_{\{te\}HC}} \right) \sum_{\{n,h,c\}} |Y_{\{n,h,c\}} - \hat{Y}_{\{n,h,c\}}|, \tag{15}$$

$$RMSE = \sqrt{MSE}. \tag{16}$$

上述指标均在标准化空间中计算，数值越小表示预测误差越低。由于 RMSE 是 MSE 的单调变换，正文表格主要报告 MSE 和 MAE。外部基线比较以 3 个共同随机种子的均值±样本标准差表示；核心机制分析以 8 个随机种子的均值±样本标准差表示，并对相同随机种子下的模型结果进行双侧配对 t 检验和 95% 置信区间分析。测试窗口仅用于计算误差，不作为独立统计重复。

2.3 两数据集外部基线比较

为保证外部模型比较的重复次数一致，表 2 仅统计随机种子 42、43 和 44。在 Abilene 上，本文方法的 MSE 和 MAE 分别为 0.186 ± 0.002 和 0.168 ± 0.001 ，相较 DLinear 分别降低 4.06% 和 10.52%，相较 LightTS 分别降低 29.89% 和 17.65%。在 GÉANT 上，本文方法的 MSE 和 MAE 分别为 0.434 ± 0.051 和 0.370 ± 0.031 ，相较 DLinear 分别降低 4.43% 和 3.46%，相较 LightTS 分别降低 46.83% 和 29.29%。

表 2 三随机种子外部基线比较

数据集	模型	参数量	MSE	MAE
Abilene	DLinear	4656	0.194±0.002	0.188±0.009
Abilene	LightTS	130162	0.265±0.011	0.204±0.008
Abilene	本文方法	8339	0.186±0.002	0.168±0.001
GÉANT	DLinear	4656	0.454±0.007	0.383±0.006
GÉANT	LightTS	384382	0.817±0.024	0.523±0.014
GÉANT	本文方法	8339	0.434±0.051	0.370±0.031

两数据集的平均结果均表明，自适应多尺度融合能够在统一的数据划分、预处理和预测任务设置下降低预测误差。同时，本文方法仅含 8339 个可训练参数，明显少于当前适配下的 LightTS；但参数量仅反映模型规模，不等同于训练或推理速度。此外，GÉANT 上的标准差明显高于 Abilene，因此外部基线结果用于说明当前统一实验协议下的相对表现，不据此推断本文方法在其他任务上普遍优于 LightTS。

2.4 八随机种子核心消融与稳定性

表 3 进一步使用随机种子 42—49 比较 DLinear、固定等权多尺度和自适应多尺度。在 Abilene 上，本文方法相较 DLinear 的 MSE 和 MAE 分别降低 2.77%和 8.23%，相较固定等权多尺度分别降低 1.67%和 9.04%；在 GÉANT 上，相应降幅分别为 2.37%、1.35%以及 4.68%、3.14%。固定等权模型含 8208 个参数，而本文方法含 8339 个参数，说明样本级路由仅增加 131 个参数。

表 3 八随机种子核心模型结果

数据集	模型	参数量	MSE	MAE
Abilene	DLinear	4656	0.194±0.002	0.189±0.008
Abilene	固定等权多尺度	8208	0.192±0.002	0.191±0.006
Abilene	本文方法	8339	0.189±0.003	0.173±0.008
GÉANT	DLinear	4656	0.437±0.016	0.371±0.011
GÉANT	固定等权多尺度	8208	0.447±0.014	0.377±0.009
GÉANT	本文方法	8339	0.426±0.029	0.366±0.018

同种子配对结果及配对差值分布见图 2。图 2 上排灰线连接同一随机种子下固定等权与自适应权重模型 MSE，黑色菱形及误差线表示 8 个随机种子的均值±标准差；下排以 $\Delta\text{MSE}=\text{固定等权}-\text{自适应权重}$ 表示效应方向，圆点表示各随机种子的配对差值，半小提琴表示差值分布，黑色圆点及误差线表示平均 ΔMSE 及其 95%置信区间，其中 $\Delta\text{MSE}>0$ 表示自适应权重模型的 MSE 更低。Abilene 中，自适应模型在 8 个种子中的 6 个取得更低 MSE，平均 ΔMSE 为 0.00320，95%置信区间为[-0.00020,0.00660]，配对 t 检验 $p=0.061$ ；GÉANT 中为 7 个，平均 ΔMSE 为 0.02094，95%置信区间为[-0.00958,0.05146]， $p=0.149$ 。两数据集的平均差值均为正，说明样本级自适应加权在平均意义上降低了 MSE；但相对固定等权的 95%置信区间均跨越 0，因此不能表述为两数据集均达到统计显著。结合表 3 可见，Abilene 上的跨种子波动较小，而 GÉANT 仍存在更明显的稳定性提升空间。




图 2 固定等权与自适应权重的八随机种子配对 MSE 及配对差值分布

2.5 路由行为与适用范围

为从总体统计视角分析样本级路由器对不同时间尺度的权重分配，图 3 汇总了 Abilene 和 GÉANT 数据集在随机种子 42—49 下全部测试窗口的三尺度路由权重。图中小提琴轮廓表示样本级权重分布，彩色圆点表示各随机种子的平均权重，黑色菱形及误差线表示 8 个随机种子均值及标准差，灰色虚线为固定等权权基准 1/3。




图 3 八随机种子下样本级自适应路由权重分布

从图 3 可以看出，两数据集的三尺度权重均呈非退化分布，并未长期固定在 1/3。按 8 个随机种子的平均权重计算，Abilene 的 α_1 、 α_2 和 α_4 分别为 0.257、0.319 和 0.424，GÉANT 分别为 0.283、0.318 和

0.399；两个数据集上尺度 4 的平均权重均最高，尺度 1 最低，尺度 2 整体接近等权基准。与此同时，不同随机种子的平均权重仍存在明显差异，其中 Abilene 的尺度 2 和尺度 4 离散程度更大。该结果说明路由器并非学习到单一固定尺度，而是在总体尺度偏好基础上保留了随训练初始化和输入样本变化的自适应调节能力。

为进一步观察权重在具体测试样本上的动态变化，图 4 固定选取随机种子 42，展示两个数据集测试集前 150 个窗口的三尺度权重。该选择规则在两数据集间保持一致，仅用于机制可视化，不参与模型优劣的统计比较。




图 4 两数据集样本级路由权重变化（随机种子 42，灰色点线为等权基准 1/3）

图 4 中三个尺度权重均随测试窗口发生变化，并未长期固定在 1/3 附近，与图 3 的总体分布结果相互印证，说明路由器能够依据输入窗口统计状态动态调整尺度组合。以随机种子 42 为例，两数据集均表现出较明显的尺度偏好变化；但不同随机种子的平均权重并不完全一致，因此不能将某一尺度解释为所有网络场景下持续占优的固定尺度。

综合表 2、表 3 和图 2—图 4 可见，样本级自适应尺度加权的平均收益已在 Abilene 和 GÉANT 两个骨干网数据集上得到验证，路由权重的总体分布与局部动态也表明模型确实在不同时间尺度之间进行自适应调节；但 GÉANT 上的跨种子方差更大，稳定性仍有提升空间。当前实验仅考察 $L=96$ 、 $H=24$ 的单一预测设置，未显式建模网络拓扑，外部模型也仅包含 LightTS 一种轻量基线；同时，“轻量”主要指参数规模，而非训练时间最短。因此，后续仍需在更多网络、预测长度和拓扑约束条件下进一步检验泛化性。

2.6 代表性窗口预测结果

图 5 固定随机种子 42，在两个数据集中选择本文方法窗口 MAE 最接近测试集中位数的窗口，并选择真实值波动接近非恒定 OD 通道中位水平的通道。该规则选择典型而非最佳案例，不按相对 DLinear 优势筛选；流量采用标准化值。




图 5 Abilene 与 GÉANT 代表性预测窗口的真实值与预测值对比（随机种子 42）

Abilene 代表窗口中，本文方法 MAE 为 0.0680，低于 DLinear 的 0.1057；GÉANT 中两者分别为 0.2094 和 0.2087，差异很小。两个面板显示主要趋势能够被跟随，但突发峰值存在平滑现象。图 5 仅作直观展示，不替代多随机种子总体比较。

3 结论

两数据集实验表明，样本级自适应多尺度加权可在较小参数增量下改善固定等权融合，并降低相对 DLinear 和 LightTS 的平均预测误差。代表性窗口显示模型能够跟随主要趋势，但对突发峰值仍存在平滑偏差；GÉANT 跨种子波动较大。后续将扩展更多网络、预测长度及拓扑约束，进一步检验稳定性与泛化能力。

参考文献

- [1] LOHRASBINASAB I, KESHAVERZ A, AMIN-NEJAD S, et al. From statistical- to machine learning-based network traffic prediction[J]. Transactions on Emerging Telecommunications Technologies, 2022, 33(4): e4394. DOI: 10.1002/ett.4394.
- [2] QIN L, GU H, WEI W, et al. Spatio-temporal communication network traffic prediction method based on graph neural network[J]. Information Sciences, 2024, 679: 121003. DOI: 10.1016/j.ins.2024.121003.
- [3] ZHOU J, HAN T, XIAO F, et al. Multiscale network traffic prediction method based on deep echo-state network for Internet of Things[J]. IEEE Internet of Things Journal, 2022, 9(21): 21862-21874. DOI: 10.1109/JIOT.2022.3181807.
- [4] ZENG A, CHEN M, ZHANG L, et al. Are transformers effective for time series forecasting?[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2023, 37(9): 11121-11128. DOI: 10.1609/aaai.v37i9.26317.
- [5] WANG S, WU H, SHI X, et al. TimeMixer: decomposable multiscale mixing for time series forecasting[C]//International Conference on Learning Representations. 2024.
- [6] ZHANG T, ZHANG Y, CAO W, et al. Less is more: fast multivariate time series forecasting with light sampling-oriented MLP structures[EB/OL]. (2022-07-04)[2026-09-20]. <https://arxiv.org/abs/2207.01186>. DOI: 10.48550/arXiv.2207.01186.
- [7] KUREŠ M, KOUMAR J, HYNEK K. CESNET TS-Zoo: a library for reproducible analysis of network traffic time series[C]//2025 21st International Conference on Network and Service Management. 2025. DOI: 10.23919/CNSM67658.2025.11297513.
- [8] ZHANG Y, ROUGHAN M, DUFFIELD N, et al. Fast accurate computation of large-scale IP traffic matrices from link loads[J]. ACM SIGMETRICS Performance Evaluation Review, 2003, 31(1): 206-217. DOI: 10.1145/885651.781053.
- [9] UHLIG S, QUOTIN B, LEPROPRE J, et al. Providing public intradomain traffic matrices to the research community[J]. ACM SIGCOMM Computer Communication Review, 2006, 36(1): 83-86. DOI: 10.1145/1111322.1111341.
- [10] 韦烜, 刘志华, 李青, 等. 大型 IP 网络流量矩阵分析预测的探讨研究[J]. 系统工程与电子技术, 2024, 46(6): 2164-2173. DOI: 10.12305/j.issn.1001-506X.2024.06.35.
- [11] 唐文杰, 肖一磊, 孔祥宇, 等. CycleLLH: 一种基于周期性整合的新型网络流量预测模型[J]. 计算机学报, 2024, 47(12): 2867-2888. DOI: 10.11897/SPJ.1016.2024.02867.