

基于自适应多尺度加权的多变量网络流量预测方法

[请填写作者姓名]

([请填写工作单位] [请填写部门], [省市 邮编])

摘要: 针对骨干网络 OD 流量的多时间尺度变化, 提出一种样本级自适应多尺度预测方法。采用尺度 1、2 和 4 的非重叠平均池化构造多分辨率序列, 由 DLinear 尺度专家分别预测; 基于窗口均值、标准差、未时刻均值和平均绝对一阶差分生成 Softmax 尺度权重, 实现动态融合。在 Abilene 和 GÉANT 数据集上, 与 DLinear、LightTS 及固定等权多尺度模型比较。共同 3 个随机种子下, 本文方法 MSE 较 DLinear 分别降低 4.06% 和 4.43%, 较 LightTS 分别降低 29.89% 和 46.83%; 8 个随机种子的核心消融中, 较固定等权融合分别降低 1.67% 和 4.68%。结果表明, 样本级动态尺度加权能够以较小参数增量有效利用多时间尺度信息。

关键词: 网络流量预测; 多变量时间序列; 多尺度学习; 自适应加权; DLinear

中图分类号: TP393 **文献标志码:** A

A Multivariate Network Traffic Forecasting Method Based on Adaptive Multiscale Weighting

[Author Name]

([Affiliation] [Department], [City] [Postcode], China; Corresponding author: [Name], E-mail: [E-mail])

Abstract: A sample-wise adaptive multiscale forecasting method is proposed for backbone origin-destination (OD) traffic. Multiresolution sequences at scales 1, 2, and 4 are constructed by non-overlapping average pooling and predicted by DLinear experts. Window mean, standard deviation, latest-step mean, and mean absolute first difference are used to generate Softmax scale weights for dynamic fusion. Experiments on Abilene and GÉANT compare the method with DLinear, LightTS, and fixed equal-weight multiscale fusion. Under three common random seeds, MSE is reduced by 4.06% and 4.43% versus DLinear and by 29.89% and 46.83% versus LightTS. In the eight-seed core ablation, MSE is reduced by 1.67% and 4.68% versus fixed equal weighting. The results show that sample-wise scale weighting effectively exploits multiscale temporal information with a small parameter increase.

Key words: network traffic forecasting; multivariate time series; multiscale learning; adaptive weighting; DLinear

随着云计算、视频业务和数据中心互联的发展, 骨干网络流量呈现明显的时变性和多时间尺度特征。OD 流量预测可为容量规划、拥塞预警和流量工程提供依据。现有方法已由统计模型发展到机器学习和深度学习[1], 并进一步利用图神经网络等结构建模网络关联[2,10]。对于仅依赖历史 OD 序列且强调结构简洁的场景, 仍有必要研究参数规模受控的时序预测方法。

不同时间尺度包含互补流量信息: 细粒度序列保留局部变化, 粗粒度序列突出趋势。已有研究通过多尺度回声状态网络[3]、TimeMixer[5]和 CycleLLH[11]提升多尺度建模能力; DLinear[4]和 LightTS[6]则说明简洁结构也能获得较好的时间序列预测性能。这为在轻量结构中进一步研究自适应尺度融合提供了基础。

现有方法多侧重拓扑关联、多尺度表征或轻量序列建模, 而对“如何依据当前输入状态动态调整不

收稿日期: [请填写, 格式 YYYY-MM-DD]

基金项目: [基金来源] ([基金项目编号])

第一作者简介: [姓名] ([出生年]—), [性别] ([民族, 汉族可省略]), [职称], [学位 (若在读请注明)], 研究方向: [方向 1]; [方向 2]。

通信作者简介: [姓名] ([出生年]—), [性别] ([民族, 汉族可省略]), [职称], [学位 (若在读请注明)], 研究方向: [方向 1]; [方向 2], 电子邮箱: [邮箱]。

同时间尺度的重要性”关注不足。本文采用尺度 1、2 和 4 构造多分辨率序列，以 DLinear 作为尺度专家，并由窗口统计特征驱动轻量路由器生成 Softmax 权重，实现样本级动态融合；在 Abilene 和 GÉANT 上通过外部基线、固定等权消融和 8 随机种子实验验证其有效性。

1 自适应多尺度网络流量预测方法

本文方法由多尺度序列构造、DLinear 尺度专家和样本级自适应融合组成。输入窗口在尺度 1、2 和 4 上形成多分辨率序列，各尺度专家独立预测，路由器根据窗口统计特征生成 Softmax 权重并融合结果，整体流程见图 1。




图 1 自适应多尺度网络流量预测方法框架

1.1 问题定义与数据预处理

设预处理后的多变量流量序列为 $x_t \in \mathbb{R}^C$ ，其中 t 为时间索引， C 为 OD 变量数。第 n 个样本的输入和目标分别为

$$X_n = [x_n, \dots, x_{n+L-1}] \in \mathbb{R}^{L \times C}, \quad (1)$$

$$Y_n = [x_{n+L}, \dots, x_{n+L+H-1}] \in \mathbb{R}^{H \times C}. \quad (2)$$

本文取输入长度 $L=96$ 、预测长度 $H=24$ 、变量数 C 随具体数据集的有效 OD 维度确定，学习映射 $\hat{Y}_n = f_\theta(X_n)$ 。原始非负流量 $v_{t,c}$ 先作对数变换

$$u_{t,c} = \log(1 + v_{t,c}), \quad (3)$$

再按变量进行标准化：

$$x_{[t,c]} = \frac{u_{[t,c]} - \mu_c^{[tr]}}{\sigma_c^{[tr]}}. \quad (4)$$

其中 μ_{ctr} 和 σ_{ctr} 仅由训练集计算，并用于验证集和测试集；数据按时间顺序以 6:2:2 划分，各集合内部独立构造滑动窗口。

1.2 多尺度序列构造

设尺度集合 $S=\{1,2,4\}$ 。对尺度 s ，使用窗口大小和步长均为 s 的非重叠平均池化：

$$X_{[n,t]}^{[s]} = \left(\frac{1}{s} \right) \sum_{i=0}^{\lfloor \frac{s-1}{s} X \rfloor} x_{[n, st+i]}, t=0, \dots, \frac{L}{s}-1. \quad (5)$$

三个尺度的输入长度依次为 96、48 和 24。尺度 1 保留细粒度变化，尺度 2 和 4 逐步平滑局部扰动；平均池化不引入额外可训练参数。

1.3 DLinear 尺度专家

每个尺度配置一个独立 DLinear 专家[4]。对尺度 s 的输入，以长度 $q=25$ 的中心移动平均提取趋势项，序列两端采用端点复制以保持长度：

$$T_{[n,t]}^{[s]} = \left(\frac{1}{q} \right) \sum_{i=-m}^m x_{[n, t+i]}^{[s]}, q=2m+1=25, \quad (6)$$

$$R_n^{[s]} = X_n^{[s]} - T_n^{[s]}. \quad (7)$$

趋势项 $T^{(s)}$ 和余项 $R^{(s)}$ 沿时间维分别通过线性层映射到预测长度 H ：

$$\hat{Y}_n^{[s]} = W_T^{[s]} T_n^{[s]} + b_T^{[s]} + W_R^{[s]} R_n^{[s]} + b_R^{[s]}. \quad (8)$$

同一尺度内各变量共享时间映射参数，不同尺度使用独立参数。

1.4 样本级自适应尺度加权

固定等权无法反映不同输入窗口的状态差异。本文从原始输入 X_n 提取四维统计向量 $zn=[\mu_n, \sigma_n, \ell_n, d_n]$ ，其中

$$\mu_n = \left(\frac{1}{LC} \right) \sum_{[t,c]} x_{[n,t,c]}, \sigma_n = \sqrt{\left(\frac{1}{LC} \right) \sum_{[t,c]} (x_{[n,t,c]} - \mu_n)^2}, \quad (9)$$

$$l_n = \left(\frac{1}{C} \right) \Sigma_c X_{[n, L-1, c]}, d_n = \left(\frac{1}{(L-1)C} \right) \Sigma_{[t=1]_{[c]}}^{\lfloor \frac{L-1}{C} \rfloor} |X_{[n, t, c]} - X_{[n, t-1, c]}|. \quad (10)$$

μ_n 、 σ_n 、 ℓ_n 和 d_n 分别描述窗口总体水平、离散程度、最近状态和平均变化强度。四维向量经隐藏维数为16 的两层感知器得到三个尺度分数：

$$a_n = W_{2ReLU(W_{1x_n} + b_1)} + b_2. \quad (11)$$

Softmax 将三个尺度分数转换为非负且和为 1 的权重：

$$\alpha_{[n, s]} = \frac{\exp(a_{[n, s]})}{\Sigma_{[j \in S]} \exp(a_{[n, j]})}, \alpha_{[n, s]} \geq 0, \Sigma_s \alpha_{[n, s]} = 1. \quad (12)$$

最终预测为

$$\hat{Y}_n = \Sigma_{[s \in S]} \alpha_{[n, s]} \hat{Y}_{n,s}. \quad (13)$$

每个样本生成一组共享于全部 OD 变量的尺度权重。固定等权消融将 $\alpha_{n,s}$ 设为 1/3，其余结构与训练过程保持一致。

1.5 训练目标与模型复杂度

模型以所有样本、预测时刻和 OD 变量上的均方误差为目标：

$$L_{[MSE]} = \left(\frac{1}{NHC} \right) \Sigma_{[n=1]}^N \Sigma_{[h=1]}^H \Sigma_{[c=1]}^C |Y_{[n, h, c]} - \hat{Y}_{[n, h, c]}|^2. \quad (14)$$

模型采用 Adam 优化并按验证集 MSE 选择参数。DLinear、固定等权多尺度和本文模型分别含 4656、8208 和 8339 个可训练参数，样本级路由器仅增加 131 个参数。

2 实验与结果分析

2.1 数据集与实验设置

实验采用 CESNET TS-Zoo[7]中的 Abilene[8]和 GÉANT[9] 1 h 聚合流量矩阵。Abilene 保留 144 维有效 OD 流量，GÉANT 去除恒定通道后保留 524 维。两数据集均按时间顺序以 6:2:2 划分，输入长度 L=96、预测长度 H=24，并采用第 1.1 节的预处理方式，具体规模见表 1。

表 1 数据集与预测任务设置

数据集	时间点	有效变量 C	训练/验证/测试时间点	训练/验证/测试窗口	L/H
Abilene	4656	144	2793/931/932	2674/812/813	96/24
GÉANT	2849	524	1709/570/570	1590/451/451	96/24

所有模型采用统一数据划分和训练接口，批量大小为 16，并按验证集 MSE 选择最优参数。DLinear、固定等权多尺度和本文模型最多训练 30 轮，LightTS 最多训练 50 轮。外部基线比较使用共同随机种子 42—44，核心模型进一步使用 42—49 共 8 个随机种子。

2.2 对比模型与评价指标

对比模型包括 DLinear、LightTS、固定等权多尺度模型和本文方法。固定等权多尺度与本文方法采用相同尺度集合 {1,2,4} 和 DLinear 专家，仅将尺度权重固定为 1/3，用于检验自适应加权的贡献。

采用均方误差（MSE）、平均绝对误差（MAE）和均方根误差（RMSE）评价预测性能。MSE 按式（14）计算，MAE 和 RMSE 分别为

$$MAE = \left(\frac{1}{N_{|te|_{HC}}} \right) \sum_{|n,h,c|} |Y_{|n,h,c|} - \hat{Y}_{|n,h,c|}|, \tag{15}$$

$$RMSE = \sqrt{MSE}. \tag{16}$$

上述指标均在标准化空间计算，数值越小表示误差越低。正文主要报告 MSE 和 MAE；表 2 采用 3 个共同随机种子的均值±标准差，表 3 采用 8 个随机种子的均值±标准差。

2.3 两数据集外部基线比较

表 2 给出了随机种子 42—44 的外部基线结果。本文方法在 Abilene 和 GÉANT 上的 MSE 分别较 DLinear 降低 4.06% 和 4.43%，较 LightTS 降低 29.89% 和 46.83%；MAE 也均低于两类基线。

表 2 三随机种子外部基线比较

数据集	模型	参数量	MSE	MAE
Abilene	DLinear	4656	0.194±0.002	0.188±0.009
Abilene	LightTS	130162	0.265±0.011	0.204±0.008
Abilene	本文方法	8339	0.186±0.002	0.168±0.001
GÉANT	DLinear	4656	0.454±0.007	0.383±0.006
GÉANT	LightTS	384382	0.817±0.024	0.523±0.014
GÉANT	本文方法	8339	0.434±0.051	0.370±0.031

逐随机种子结果见图 2。Abilene 上，本文方法相对 DLinear 的 MSE 和 MAE 均为 3/3 次降低，相对 LightTS 也均为 3/3 次降低；GÉANT 相对 DLinear 为 2/3 次降低，相对 LightTS 为 3/3 次降低。结合表 2 可见，本文方法在两个数据集上均取得更低的平均误差，其中相对 LightTS 的优势更为明显。




图 2 Abilene 与 GÉANT 上三随机种子外部基线配对结果

2.4 八随机种子核心消融与稳定性

表 3 使用随机种子 42—49 比较 DLinear、固定等权多尺度和本文方法。相较 DLinear，本文方法在 Abilene 和 GÉANT 上的 MSE 分别降低 2.77% 和 2.37%；相较固定等权多尺度分别降低 1.67% 和 4.68%，说明自适应加权能够进一步改善多尺度融合。

表 3 八随机种子核心模型结果

数据集	模型	参数量	MSE	MAE
Abilene	DLinear	4656	0.194±0.002	0.189±0.008
Abilene	固定等权多尺度	8208	0.192±0.002	0.191±0.006
Abilene	本文方法	8339	0.189±0.003	0.173±0.008
GÉANT	DLinear	4656	0.437±0.016	0.371±0.011
GÉANT	固定等权多尺度	8208	0.447±0.014	0.377±0.009
GÉANT	本文方法	8339	0.426±0.029	0.366±0.018

同种子配对结果见图 3。Abilene 中本文方法在 6/8 个随机种子上取得更低 MSE，GÉANT 为 7/8；两数据集的平均 Δ MSE 均为正，与表 3 的均值结果一致。




图 3 固定等权与自适应权重的八随机种子配对 MSE 及配对差值分布

2.5 路由权重分析

图 4 汇总了随机种子 42—49 下全部测试窗口的三尺度路由权重，用于观察整体尺度偏好。




图 4 八随机种子下样本级自适应路由权重分布

图 4 显示，两数据集的权重均未固定在 $1/3$ 。Abilene 的 α_1 、 α_2 和 α_4 平均为 0.257、0.319 和 0.424，GÉANT 分别为 0.283、0.318 和 0.399，均表现为尺度 4 权重最高、尺度 1 最低。

综合表 2、表 3 和图 2—图 4，本文方法在两个骨干网数据集上均取得更低的平均预测误差，自适应权重相对固定等权进一步改善结果；图 4 的权重分布表明模型能够根据输入样本调整不同尺度的贡献。

3 结论

两数据集实验表明, 样本级自适应多尺度加权能够以较小参数增量改善固定等权融合, 并降低相对 DLinear 和 LightTS 的平均预测误差。路由权重分析表明模型能够依据输入状态动态调整尺度组合。后续将进一步研究更多网络、预测长度和拓扑信息。

参考文献

- [1] LOHRASBINASAB I, KESHAVERZ A, AMIN-NEJAD S, et al. From statistical- to machine learning-based network traffic prediction[J]. Transactions on Emerging Telecommunications Technologies, 2022, 33(4): e4394. DOI: 10.1002/ett.4394.
- [2] QIN L, GU H, WEI W, et al. Spatio-temporal communication network traffic prediction method based on graph neural network[J]. Information Sciences, 2024, 679: 121003. DOI: 10.1016/j.ins.2024.121003.
- [3] ZHOU J, HAN T, XIAO F, et al. Multiscale network traffic prediction method based on deep echo-state network for Internet of Things[J]. IEEE Internet of Things Journal, 2022, 9(21): 21862-21874. DOI: 10.1109/JIOT.2022.3181807.
- [4] ZENG A, CHEN M, ZHANG L, et al. Are transformers effective for time series forecasting?[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2023, 37(9): 11121-11128. DOI: 10.1609/aaai.v37i9.26317.
- [5] WANG S, WU H, SHI X, et al. TimeMixer: decomposable multiscale mixing for time series forecasting[C]//International Conference on Learning Representations. 2024.
- [6] ZHANG T, ZHANG Y, CAO W, et al. Less is more: fast multivariate time series forecasting with light sampling-oriented MLP structures[EB/OL]. (2022-07-04)[2026-09-20]. <https://arxiv.org/abs/2207.01186>. DOI: 10.48550/arXiv.2207.01186.
- [7] KUREŠ M, KOUMAR J, HYNEK K. CESNET TS-Zoo: a library for reproducible analysis of network traffic time series[C]//2025 21st International Conference on Network and Service Management. 2025. DOI: 10.23919/CNSM67658.2025.11297513.
- [8] ZHANG Y, ROUGHAN M, DUFFIELD N, et al. Fast accurate computation of large-scale IP traffic matrices from link loads[J]. ACM SIGMETRICS Performance Evaluation Review, 2003, 31(1): 206-217. DOI: 10.1145/885651.781053.
- [9] UHLIG S, QUOTIN B, LEPROPRE J, et al. Providing public intradomain traffic matrices to the research community[J]. ACM SIGCOMM Computer Communication Review, 2006, 36(1): 83-86. DOI: 10.1145/1111322.1111341.
- [10] 韦烜, 刘志华, 李青, 等. 大型 IP 网络流量矩阵分析预测的探讨研究[J]. 系统工程与电子技术, 2024, 46(6): 2164-2173. DOI: 10.12305/j.issn.1001-506X.2024.06.35.
- [11] 唐文杰, 肖一磊, 孔祥宇, 等. CycleLLH: 一种基于周期性整合的新型网络流量预测模型[J]. 计算机学报, 2024, 47(12): 2867-2888. DOI: 10.11897/SPJ.1016.2024.02867.