

基于自适应多尺度加权的多变量网络流量预测方法

[请填写作者姓名]

([请填写工作单位] [请填写部门], [省市 邮编])

摘要: 针对骨干网络源一目的节点对流量具有明显时变性和多时间尺度特征、固定尺度模型难以根据当前状态调整信息利用方式的问题,提出一种样本级自适应多尺度预测方法。采用尺度 1、2 和 4 的非重叠平均池化构造多分辨率序列,并以 DLinear 作为各尺度预测专家;进一步提取窗口均值、标准差、末时刻均值和平均绝对一阶差分,经轻量路由网络生成 Softmax 尺度权重,实现多尺度预测结果的动态融合。在 Abilene 和 GÉANT 两个骨干网流量数据集上进行实验,并与 DLinear、LightTS 及固定等权多尺度模型比较。共同 3 个随机种子下,所提方法 MSE 相对 DLinear 分别降低 4.06% 和 4.43%,相对 LightTS 分别降低 29.89% 和 46.83%;8 个随机种子的核心消融中,相对固定等权融合分别降低 1.67% 和 4.68%。结果表明,该方法能够以较小参数增量有效利用不同时间尺度的互补信息,提高多变量网络流量预测精度。

关键词: 网络流量预测; 多变量时间序列; 多尺度学习; 自适应加权; DLinear

中图分类号: TP393 **文献标志码:** A

A Multivariate Network Traffic Forecasting Method Based on Adaptive Multiscale Weighting

[Author Name]

([Affiliation] [Department], [City] [Postcode], China; Corresponding author: [Name], E-mail: [E-mail])

Abstract: Backbone origin-destination (OD) traffic exhibits pronounced temporal variation and multiscale characteristics, while fixed-scale models cannot adapt their information use to the current traffic state. A sample-wise adaptive multiscale forecasting method is therefore proposed. Non-overlapping average pooling at scales 1, 2, and 4 is used to construct multiresolution sequences, and DLinear is employed as the forecasting expert at each scale. Four window statistics, including the mean, standard deviation, latest-step mean, and mean absolute first difference, are further fed into a lightweight routing network to generate Softmax scale weights for dynamic fusion. Experiments are conducted on the Abilene and GÉANT backbone traffic datasets against DLinear, LightTS, and fixed equal-weight multiscale fusion. Under three common random seeds, the proposed method reduces MSE by 4.06% and 4.43% over DLinear and by 29.89% and 46.83% over LightTS on the two datasets, respectively. In the eight-seed core ablation, MSE is reduced by 1.67% and 4.68% over fixed equal weighting. These results indicate that sample-wise scale weighting can effectively exploit complementary temporal information at different resolutions with only a small parameter increase.

Key words: network traffic forecasting; multivariate time series; multiscale learning; adaptive weighting; DLinear

随着云计算、视频业务、数据中心互联及智能网络应用的持续发展,骨干网络承载的业务类型与流量规模不断增加,OD 流量在小时级尺度上表现出明显的时变性、突发性和周期性。准确预测未来一段时间的 OD 流量,可为容量规划、拥塞预警、资源调度和流量工程提供先验依据,因此网络流量预测一直是

收稿日期: [请填写, 格式 YYYY-MM-DD]

基金项目: [基金来源] ([基金项目编号])

第一作者简介: [姓名] ([出生年]—), [性别] ([民族, 汉族可省略]), [职称], [学位 (若在读请注明)], 研究方向: [方向 1]; [方向 2]。

通信作者简介: [姓名] ([出生年]—), [性别] ([民族, 汉族可省略]), [职称], [学位 (若在读请注明)], 研究方向: [方向 1]; [方向 2], 电子邮箱: [邮箱]。

网络管理与智能运维中的重要研究问题。

网络流量预测方法已由传统统计模型逐步发展到机器学习和深度学习方法。Lohrasbinasab 等[1]系统梳理了网络流量预测从统计方法向机器学习方法的演进，指出数据驱动模型在复杂流量模式建模方面具有更强的表达能力。Qin 等[2]利用图神经网络联合建模通信网络的空间关联与时间依赖；韦烜等[10]围绕大型 IP 网络流量矩阵的分析与预测开展研究，说明 OD 维度间关联和时间演化对预测性能具有重要影响。针对网络流量中的周期特征，唐文杰等[11]提出 CycleLLH 模型，通过周期性信息整合增强流量变化规律的建模能力。

除拓扑关联与周期规律外，多时间尺度建模也是提升预测性能的重要路径。Zhou 等[3]提出基于深度回声状态网络的多尺度网络流量预测方法，通过不同时间分辨率捕获互补变化模式。DLinear[4]采用时间序列分解与线性映射构建简洁预测结构，表明在长期预测任务中较低复杂度模型同样具有较强竞争力；TimeMixer[5]通过可分解的多尺度混合机制联合利用不同分辨率信息；LightTS[6]则以采样导向的 MLP 结构实现快速多变量时间序列预测。这些研究表明，多尺度信息与轻量预测结构具有良好的结合潜力，但多数方法仍采用预设的尺度组合或统一的融合方式。

在实际骨干网络中，不同输入窗口的流量水平、波动幅度和短期变化状态并不相同，固定尺度或固定融合比例难以始终匹配当前预测样本。基于此，提出一种样本级自适应多尺度网络流量预测方法：首先在尺度 1、2 和 4 上构造多分辨率序列，以 DLinear 作为尺度专家；随后利用窗口统计特征驱动轻量路由器，为每个样本生成动态尺度权重并完成预测融合。实验在 Abilene 和 GÉANT 两个公开骨干网数据集上展开，并通过外部基线比较、固定等权消融、8 随机种子重复实验以及路由权重分析验证方法的预测效果与自适应融合机制。

1 自适应多尺度网络流量预测方法

本文方法由数据预处理、多尺度序列构造、DLinear 尺度专家和样本级自适应融合组成，整体流程如图 1 所示。核心思想是先在不同时间分辨率上形成具有互补信息的候选预测，再由轻量路由器根据当前输入窗口的统计状态动态调整各尺度贡献，使模型同时利用细粒度局部变化与较粗粒度趋势信息。




图 1 自适应多尺度网络流量预测方法框架

1.1 问题定义与数据预处理

设预处理后的多变量流量序列为 $x_t \in \mathbb{R}^C$ ，其中 t 为时间索引， C 为 OD 变量数。第 n 个样本的输入和目标分别为

$$X_n = [x_n, \dots, x_{n+L-1}] \in \mathbb{R}^{L \times C}, \quad (1)$$

$$Y_n = [x_{n+L}, \dots, x_{n+L+H-1}] \in \mathbb{R}^{H \times C}. \quad (2)$$

本文取输入长度 $L=96$ 、预测长度 $H=24$ 、变量数 C 随具体数据集的有效 OD 维度确定，学习映射 $\hat{Y}_n = f_\theta(X_n)$ 。原始非负流量 $v_{t,c}$ 先作对数变换

$$u_{t,c} = \log(1 + v_{t,c}), \quad (3)$$

再按变量进行标准化：

$$x_{t,c} = \frac{u_{t,c} - \mu_c^{tr}}{\sigma_c^{tr}}. \quad (4)$$

其中 μ^{tr} 和 σ^{tr} 仅由训练集计算，并统一用于验证集和测试集，以避免测试信息参与归一化过程。对原始非负流量采用 $\log(1+x)$ 变换，可压缩不同 OD 流量之间较大的数值动态范围；随后按变量标准化，使各维流量在相近尺度上参与模型训练。数据按时间顺序以 6:2:2 划分，各集合内部独立构造滑动窗口。

1.2 多尺度序列构造

设尺度集合 $S=\{1,2,4\}$ 。对尺度 s ，使用窗口大小和步长均为 s 的非重叠平均池化：

$$X_{[n,t]}^{[s]} = \left(\frac{1}{s} \right) \sum_{i=0}^{\lfloor \frac{s-1}{s} X \rfloor} X_{[n, st+i]}^{[s]}, t=0, \dots, \frac{L}{s}-1. \quad (5)$$

三个尺度的输入长度依次为 96、48 和 24，分别对应原始分辨率、2 点平均和 4 点平均。尺度 1 完整保留短时波动，尺度 2 在平滑局部扰动的同时保持较高时间分辨率，尺度 4 进一步突出较慢变化趋势。采用非重叠平均池化无需引入额外可训练参数，也便于不同尺度专家保持统一的输入构造方式。

1.3 DLinear 尺度专家

每个尺度配置一个独立 DLinear 专家[4]。对尺度 s 的输入，以长度 $q=25$ 的中心移动平均提取趋势项，序列两端采用端点复制以保持长度：

$$T_{[n,t]}^{[s]} = \left(\frac{1}{q} \right) \sum_{i=-m}^m X_{[n, t+i]}^{[s]}, q=2m+1=25, \quad (6)$$

$$R_n^{[s]} = X_n^{[s]} - T_n^{[s]}. \quad (7)$$

趋势项 $T^{(s)}$ 和余项 $R^{(s)}$ 沿时间维分别通过线性层映射到预测长度 H ：

$$\hat{Y}_n^{[s]} = W_T^{[s]} T_n^{[s]} + b_T^{[s]} + W_R^{[s]} R_n^{[s]} + b_R^{[s]}. \quad (8)$$

同一尺度内各变量共享时间映射参数，不同尺度使用独立专家参数。DLinear 先通过移动平均将输入分为趋势项与余项，再分别进行线性映射，这种结构参数规模较小，适合作为多尺度框架中的基础专家不同尺度专家独立学习，可避免将不同时间分辨率下的变化模式强制映射到同一组参数中。

1.4 样本级自适应尺度加权

固定等权融合默认所有预测窗口始终采用相同的尺度比例，难以反映流量状态随时间变化的特点。为此，从原始输入 X_n 提取四维统计向量 $z_n=[\mu_n, \sigma_n, \ell_n, d_n]$ ，其中

$$\mu_n = \left(\frac{1}{LC} \right) \sum_{t,c} X_{[n,t,c]}, \sigma_n = \sqrt{\left(\frac{1}{LC} \right) \sum_{t,c} (X_{[n,t,c]} - \mu_n)^2}, \quad (9)$$

$$l_n = \left(\frac{1}{C} \right) \sum_c X_{[n,L-1,c]}, d_n = \left(\frac{1}{(L-1)C} \right) \sum_{t=1}^{\lfloor \frac{L-1}{L} \rfloor} \sum_c |X_{[n,t,c]} - X_{[n,t-1,c]}|. \quad (10)$$

μ_n 、 σ_n 、 ℓ_n 和 d_n 分别描述窗口总体水平、离散程度、最近状态和平均变化强度，能够以较低维度概

括当前输入的整体状态。四维向量经隐藏维数为 16 的两层感知器映射为三个尺度分数，在不引入复杂特征提取网络的情况下，为尺度选择提供样本相关信息：

$$a_n = W_{2ReLU(W_{1x_n} + b_1)} + b_2. \quad (11)$$

Softmax 将三个尺度分数转换为非负且和为 1 的权重：

$$\alpha_{|n,s|} = \frac{\exp(a_{|n,s|})}{\sum_{|j \in S|} \exp(a_{|n,j|})}, \alpha_{|n,s|} \geq 0, \sum_s \alpha_{|n,s|} = 1. \quad (12)$$

最终预测为

$$\hat{Y}_n = \sum_{|s \in S|} \alpha_{|n,s|} \hat{Y}_{n,s}. \quad (13)$$

每个样本生成一组共享于全部 OD 变量的尺度权重，使同一时间窗口内的各 OD 流量采用一致的时间尺度组合，并避免路由参数量随变量数显著增加。为检验动态权重的作用，固定等权消融将 $\alpha_{n,s}$ 统一设为 1/3，其尺度集合、专家结构及训练过程均保持不变。

1.5 训练目标与模型复杂度

模型以所有样本、预测时刻和 OD 变量上的均方误差为目标：

$$L_{|MSE|} = \left(\frac{1}{NHC} \right) \sum_{|n=1|}^{|N|} \sum_{|h=1|}^{|H|} \sum_{|c=1|}^{|C|} \sum_{|a,b \in \mathcal{O}|} \hat{y}_{n,h,c} - y_{n,h,c}^2. \quad (14)$$

模型采用 Adam 优化，并根据验证集 MSE 选择最优参数。DLinear、固定等权多尺度和本文模型分别含 4656、8208 和 8339 个可训练参数，其中自适应路由器在固定等权多尺度模型基础上仅增加 131 个参数。由此，模型性能提升主要通过尺度组织与动态融合获得，而无需显著扩大参数规模。

2 实验与结果分析

2.1 数据集与实验设置

实验采用 CESNET TS-Zoo[7]中的 Abilene[8]和 GÉANT[9] 1 h 聚合流量矩阵。Abilene 包含较长时间序列并保留 144 维有效 OD 流量，GÉANT 去除恒定通道后保留 524 维，变量规模明显更高。两个数据集在网络规模和流量分布上具有差异，可用于从不同骨干网场景考察模型的适用性。两者均按时间顺序以 6:2:2 划分，输入长度 L=96、预测长度 H=24，并采用第 1.1 节的预处理方式，具体规模见表 1。

表 1 数据集与预测任务设置

数据集	时间点	有效变量 C	训练/验证/测试时间点	训练/验证/测试窗口	L/H
Abilene	4656	144	2793/931/932	2674/812/813	96/24
GÉANT	2849	524	1709/570/570	1590/451/451	96/24

所有模型采用统一的数据划分、输入长度和评价流程，批量大小为 16，并按验证集 MSE 选择最优模型。DLinear、固定等权多尺度和本文模型最多训练 30 轮，LightTS 最多训练 50 轮。外部基线比较使用共同随机种子 42—44，以保证各模型重复次数一致；对核心模型进一步扩展到 42—49 共 8 个随机种子，用于观察多尺度机制在重复实验中的总体表现。

2.2 对比模型与评价指标

对比模型包括单尺度 DLinear、轻量多变量预测模型 LightTS、固定等权多尺度模型和本文方法。DLinear 用于衡量多尺度结构相对单尺度线性预测的增益，LightTS 作为外部轻量时间序列基线；固定等权模型与本文方法采用完全相同的尺度集合 {1,2,4} 和 DLinear 专家，仅将三个尺度权重固定为 1/3，从而直接检验样本级自适应加权的贡献。

采用均方误差（MSE）、平均绝对误差（MAE）和均方根误差（RMSE）评价预测性能。MSE 按式 (14) 计算，MAE 和 RMSE 分别为

$$MAE = \left(\frac{1}{N_{|te|_{HC}}} \right) \sum_{|n,h,c|} |Y_{|n,h,c|} - \hat{Y}_{|n,h,c|}|, \tag{15}$$

$$RMSE = \sqrt{MSE}. \tag{16}$$

上述指标均在标准化空间计算，数值越小表示预测误差越低。其中 MSE 对较大预测偏差更敏感，MAE 反映平均绝对偏差，RMSE 与原始误差量纲形式一致。正文主要结合 MSE 和 MAE 分析模型差异；表 2 报告 3 个共同随机种子的均值±标准差，表 3 报告 8 个随机种子的均值±标准差。

2.3 两数据集外部基线比较

表 2 给出了随机种子 42—44 的外部基线结果。本文方法在 Abilene 和 GÉANT 上的 MSE 分别为 0.186 和 0.434，均低于 DLinear 和 LightTS；相对 DLinear 分别降低 4.06%和 4.43%，相对 LightTS 分别降低 29.89%和 46.83%。MAE 同样保持较低水平，说明自适应多尺度结构在两个不同规模的骨干网数据集上均能提升平均预测精度。

表 2 三随机种子外部基线比较

数据集	模型	参数量	MSE	MAE
Abilene	DLinear	4656	0.194±0.002	0.188±0.009
Abilene	LightTS	130162	0.265±0.011	0.204±0.008
Abilene	本文方法	8339	0.186±0.002	0.168±0.001
GÉANT	DLinear	4656	0.454±0.007	0.383±0.006
GÉANT	LightTS	384382	0.817±0.024	0.523±0.014
GÉANT	本文方法	8339	0.434±0.051	0.370±0.031

逐随机种子结果见图 2。Abilene 上，本文方法相对 DLinear 和 LightTS 的 MSE、MAE 均在 3 个随机

种子下保持较低误差；GÉANT 上，相对 LightTS 同样表现出一致优势，相对 DLinear 的平均误差仍更低。结合表 2 与图 2 可以看出，多尺度动态融合不仅改善了单尺度 DLinear 的预测结果，在统一实验设置下相较 LightTS 也具有明显的误差优势。




图 2 Abilene 与 GÉANT 上三随机种子外部基线配对结果

2.4 八随机种子核心消融与稳定性

为进一步验证核心结构，表 3 将 DLinear、固定等权多尺度和本文方法扩展到随机种子 42—49 共 8 次重复实验。相较 DLinear，本文方法在 Abilene 和 GÉANT 上的平均 MSE 分别降低 2.77% 和 2.37%；相较固定等权多尺度分别降低 1.67% 和 4.68%。固定等权模型已引入相同的多尺度专家，因此该结果进一步说明，在多尺度表征基础上根据输入样本动态调整尺度权重能够继续带来预测增益。

表 3 八随机种子核心模型结果

数据集	模型	参数量	MSE	MAE
Abilene	DLinear	4656	0.194±0.002	0.189±0.008
Abilene	固定等权多尺度	8208	0.192±0.002	0.191±0.006
Abilene	本文方法	8339	0.189±0.003	0.173±0.008
GÉANT	DLinear	4656	0.437±0.016	0.371±0.011
GÉANT	固定等权多尺度	8208	0.447±0.014	0.377±0.009
GÉANT	本文方法	8339	0.426±0.029	0.366±0.018

同种子配对结果见图 3。Abilene 中本文方法在 6/8 个随机种子上取得更低 MSE，GÉANT 为 7/8；两个数据集的平均 Δ MSE 均为正，与表 3 的均值结果一致。相较单纯比较总体均值，配对结果进一步表明自适应加权的收益在多数重复实验中能够得到体现。




图3 固定等权与自适应权重的八随机种子配对 MSE 及配对差值分布

2.5 路由权重分析

为观察路由器对不同时间尺度的实际分配情况，图 4 汇总随机种子 42—49 下全部测试窗口的三尺度权重分布。固定等权情况下三个尺度权重均为 1/3，而自适应模型允许权重随输入样本变化，因此其分布可以反映模型学习到的总体尺度偏好。




图4 八随机种子下样本级自适应路由权重分布

图 4 显示，两数据集的路由权重均形成了明显的非等权分布。Abilene 的 α_1 、 α_2 和 α_4 平均为 0.257、0.319 和 0.424，GÉANT 分别为 0.283、0.318 和 0.399，两个数据集均表现为尺度 4 权重最高、尺度 1 最低。说明在当前 24 步预测任务中，较粗时间尺度提供的平滑趋势信息具有较高贡献，同时尺度 1

和尺度 2 仍保留稳定权重，从而形成多时间尺度的联合预测。

综合表 2、表 3 和图 2—图 4 可以看出，本文方法在两个骨干网数据集上均取得更低的平均预测误差；固定等权消融进一步验证了动态尺度权重的有效性，路由权重分布则从模型内部行为角度表明三个尺度并非简单平均，而是形成了与输入样本相关的差异化贡献。

3 结论

两数据集实验表明，样本级自适应多尺度加权能够有效融合不同时间分辨率的信息，在较小参数增量下提升多变量网络流量预测精度；相对 DLinear、LightTS 和固定等权多尺度模型均取得更低的平均误差。路由权重结果进一步验证了动态尺度分配机制的作用。后续将面向更多网络场景和预测长度扩展验证。

参考文献

- [1] LOHRASBINASAB I, KESHAVARZ A, AMIN-NEJAD S, et al. From statistical- to machine learning-based network traffic prediction[J]. Transactions on Emerging Telecommunications Technologies, 2022, 33(4): e4394. DOI: 10.1002/ett.4394.
- [2] QIN L, GU H, WEI W, et al. Spatio-temporal communication network traffic prediction method based on graph neural network[J]. Information Sciences, 2024, 679: 121003. DOI: 10.1016/j.ins.2024.121003.
- [3] ZHOU J, HAN T, XIAO F, et al. Multiscale network traffic prediction method based on deep echo-state network for Internet of Things[J]. IEEE Internet of Things Journal, 2022, 9(21): 21862-21874. DOI: 10.1109/JIOT.2022.3181807.
- [4] ZENG A, CHEN M, ZHANG L, et al. Are transformers effective for time series forecasting?[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2023, 37(9): 11121-11128. DOI: 10.1609/aaai.v37i9.26317.
- [5] WANG S, WU H, SHI X, et al. TimeMixer: decomposable multiscale mixing for time series forecasting[C]//International Conference on Learning Representations. 2024.
- [6] ZHANG T, ZHANG Y, CAO W, et al. Less is more: fast multivariate time series forecasting with light sampling-oriented MLP structures[EB/OL]. (2022-07-04)[2026-09-20]. <https://arxiv.org/abs/2207.01186>. DOI: 10.48550/arXiv.2207.01186.
- [7] KUREŠ M, KOUMAR J, HYNEK K. CESNET TS-Zoo: a library for reproducible analysis of network traffic time series[C]//2025 21st International Conference on Network and Service Management. 2025. DOI: 10.23919/CNSM67658.2025.11297513.
- [8] ZHANG Y, ROUGHAN M, DUFFIELD N, et al. Fast accurate computation of large-scale IP traffic matrices from link loads[J]. ACM SIGMETRICS Performance Evaluation Review, 2003, 31(1): 206-217. DOI: 10.1145/885651.781053.
- [9] UHLIG S, QUOITIN B, LEPROPRE J, et al. Providing public intradomain traffic matrices to the research community[J]. ACM SIGCOMM Computer Communication Review, 2006, 36(1): 83-86. DOI: 10.1145/1111322.1111341.
- [10] 韦烜, 刘志华, 李青, 等. 大型 IP 网络流量矩阵分析预测的探讨研究[J]. 系统工程与电子技术, 2024, 46(6): 2164-2173. DOI: 10.12305/j.issn.1001-506X.2024.06.35.
- [11] 唐文杰, 肖一磊, 孔祥宇, 等. CycleLLH: 一种基于周期性整合的新型网络流量预测模型[J]. 计算机学报, 2024, 47(12): 2867-2888. DOI: 10.11897/SPJ.1016.2024.02867.