

基于自适应多尺度加权的多变量网络流量预测方法

[请填写作者姓名]

([请填写工作单位] [请填写部门], [省市 邮编])

摘要：骨干网络源一目的节点对流量在时间上并非稳定变化，短时波动、突发变化和较慢趋势往往同时存在。固定尺度模型使用单一时间分辨率，难以随当前流量状态调整不同时间尺度信息的利用方式。为此，提出一种样本级自适应多尺度预测方法。采用尺度 1、2 和 4 的非重叠平均池化得到多分辨率序列，并分别输入 DLinear 专家；同时提取输入窗口的均值、标准差、末时刻均值和平均绝对一阶差分，通过轻量路由网络计算 Softmax 尺度权重，完成 3 个尺度预测结果的融合。在 Abilene 和 GÉANT 两个骨干网流量数据集上进行实验。3 个共同随机种子下，所提方法 MSE 相对 DLinear 分别降低 4.06% 和 4.43%，相对 LightTS 分别降低 29.89% 和 46.83%；8 个随机种子的消融实验中，相对固定等权融合分别降低 1.67% 和 4.68%。在仅增加少量参数的情况下，不同时间尺度的信息可以按照输入样本重新分配权重两个数据集上的平均预测误差均得到改善。

关键词：网络流量预测；多变量时间序列；多尺度学习；自适应加权；DLinear

中图分类号：TP393 **文献标志码：**A

A Multivariate Network Traffic Forecasting Method Based on Adaptive Multiscale Weighting

[Author Name]

([Affiliation] [Department], [City] [Postcode], China; Corresponding author: [Name], E-mail: [E-mail])

Abstract: Backbone origin-destination (OD) traffic does not evolve at a single temporal pace. Short-term fluctuations, abrupt changes, and slower trends may appear in the same traffic sequence, whereas a fixed-scale model always uses one temporal resolution. A sample-wise adaptive multiscale forecasting method is therefore proposed. Non-overlapping average pooling at scales 1, 2, and 4 is applied to obtain multiresolution sequences, which are processed by separate DLinear experts. The mean, standard deviation, latest-step mean, and mean absolute first difference of each input window are also extracted and fed into a lightweight routing network. Softmax weights produced by the router are used to combine the three forecasts. Experiments are carried out on the Abilene and GÉANT backbone traffic datasets. With three common random seeds, the proposed method reduces MSE by 4.06% and 4.43% compared with DLinear and by 29.89% and 46.83% compared with LightTS. In the eight-seed ablation experiment, the MSE reductions over fixed equal weighting are 1.67% and 4.68%, respectively. The results on both datasets show that the relative contribution of different temporal scales can be adjusted for each input sample with only a small increase in model parameters.

Key words: network traffic forecasting; multivariate time series; multiscale learning; adaptive weighting; DLinear

随着云计算、视频业务、数据中心互联及智能网络应用的发展，骨干网络承载的数据量不断增加，业务流量的变化也更加复杂。源一目的节点对（origin-destination，OD）流量既会受到日常周期的影响，也可能在较短时间内出现明显波动。对于网络管理而言，若能提前获得后一时段的 OD 流量估计，可为容

收稿日期：[请填写，格式 YYYY-MM-DD]

基金项目：[基金来源] ([基金项目编号])

第一作者简介：[姓名] ([出生年]—)，[性别]（民族，汉族可省略），[职称]，[学位（若在读请注明）]，研究方向：[方向 1]；[方向 2]。

通信作者简介：[姓名] ([出生年]—)，[性别]（民族，汉族可省略），[职称]，[学位（若在读请注明）]，研究方向：[方向 1]；[方向 2]，电子邮箱：[邮箱]。

量规划、拥塞预警、资源调度和流量工程提供数据依据。因此，OD 流量预测不仅要求模型刻画长期变化，还要保留对局部波动的响应能力。

早期网络流量预测主要采用统计模型，随后逐渐转向机器学习和深度学习方法。Lohrasbinasab 等[1]对这一发展过程进行了综述，指出数据驱动方法在复杂流量模式下具有更强的建模能力。Qin 等[2]把图神经网络用于通信网络流量预测，将空间关联和时间依赖同时纳入模型；韦烜等[10]针对大型 IP 网络流量矩阵开展分析与预测，强调了 OD 变量之间关联关系的影响。对于周期性较明显的流量，唐文杰等[11]提出 CycleLLH 模型，将周期信息纳入预测过程。已有研究分别从变量关联、时间依赖和周期变化等方面改进了预测模型。

除了上述特征外，网络流量还具有明显的多时间尺度特性。原始分辨率序列能够反映较细的波动，但其中也包含较多局部扰动；时间尺度变粗后，短时波动被部分平滑，整体趋势会更加突出。Zhou 等[3]采用深度回声状态网络进行多尺度网络流量预测。DLinear[4]通过时间序列分解和线性映射完成预测，模型结构相对简单；TimeMixer[5]利用多尺度混合机制处理不同分辨率序列；LightTS[6]则通过采样导向的 MLP 结构进行快速多变量时间序列预测。由此，多尺度信息与轻量预测结构之间具有进一步结合的空间。

从实际流量序列看，不同输入窗口的波动程度并不一致。有些时段以局部变化为主，有些时段则表现出更明显的平滑趋势，此时 3 个时间尺度的作用很难长期保持相同。固定尺度或固定融合比例不能随这种状态变化调整。本文据此在尺度 1、2 和 4 上构造多分辨率序列，由 DLinear 分别完成预测，再根据当前输入窗口的统计特征生成样本级尺度权重。实验采用 Abilene 和 GÉANT 两个公开骨干网数据集，并设置基线比较、固定等权消融、8 个随机种子重复实验和路由权重分析。

1 自适应多尺度网络流量预测方法

图 1 给出了本文方法的整体流程。原始 OD 流量首先完成对数变换和标准化处理，随后在尺度 1、2 和 4 上形成 3 组输入序列。每组序列对应一个 DLinear 专家，各自输出长度为 H 的预测结果。与此同时，轻量路由网络根据当前输入窗口的统计量给出 3 个尺度权重，最终预测由 3 个专家输出加权得到。




图 1 自适应多尺度网络流量预测方法框架

1.1 问题定义与数据预处理

设预处理后的多变量流量序列为 $x_t \in R^C$ ，其中 t 为时间索引， C 为 OD 变量数。第 n 个样本的输入和目标分别为

$$X_n = [x_n, \dots, x_{n+L-1}] \in R^{[L \times C]}, \quad (1)$$

$$Y_n = [x_{n+L}, \dots, x_{n+L+H-1}] \in R^{[H \times C]}. \quad (2)$$

本文取输入长度 $L=96$ 、预测长度 $H=24$ 、变量数 C 随具体数据集的有效 OD 维度确定，学习映射 $\hat{Y}_n = f_\theta(X_n)$ 。原始非负流量 $v_{t,c}$ 先作对数变换

$$u_{[t,c]} = \log(1 + v_{[t,c]}), \quad (3)$$

再按变量进行标准化：

$$x_{[t,c]} = \frac{u_{[t,c]} - \mu_c^{[tr]}}{\sigma_c^{[tr]}}. \quad (4)$$

其中 μ_{ctr} 和 σ_{ctr} 只在训练集上计算，验证集和测试集直接使用训练阶段得到的参数。由于不同 OD 变量的流量量级差异较大，原始非负流量先进行 $\log(1+x)$ 变换，再按变量标准化。数据仍按时间顺序以 6:2:2 划分为训练集、验证集和测试集，各集合内部独立生成滑动窗口。

1.2 多尺度序列构造

设尺度集合 $S=\{1,2,4\}$ 。对尺度 s ，使用窗口大小和步长均为 s 的非重叠平均池化：

$$X_{[n,t]}^{[s]} = \left(\frac{1}{s} \right) \sum_{i=0}^{s-1} x_{[n, st+i]}, t=0, \dots, \frac{L}{s}-1. \quad (5)$$

尺度集合取 $S=\{1,2,4\}$ 。尺度 1 对应原始 96 步输入，不做时间压缩；尺度 2 经过 2 点非重叠平均后得到 48 步序列；尺度 4 得到 24 步序列。这样处理后，尺度 1 保留更多短时变化，尺度 2 和尺度 4 逐渐削弱局部扰动。由于采用平均池化，多尺度构造本身不增加可训练参数。

1.3 DLinear 尺度专家

每个尺度配置一个独立 DLinear 专家[4]。对尺度 s 的输入，以长度 $q=25$ 的中心移动平均提取趋势项，序列两端采用端点复制以保持长度：

$$T_{[n,t]}^{[s]} = \left(\frac{1}{q} \right) \sum_{i=-m}^m X_{n,t+i}^{[s]}, q=2m+1=25, \quad (6)$$

$$R_n^{[s]} = X_n^{[s]} - T_n^{[s]}. \quad (7)$$

趋势项 $T^{(s)}$ 和余项 $R^{(s)}$ 沿时间维分别通过线性层映射到预测长度 H :

$$\hat{Y}_n^{[s]} = W_T^{[s]} T_n^{[s]} + b_T^{[s]} + W_R^{[s]} R_n^{[s]} + b_R^{[s]}. \quad (8)$$

3 个尺度分别配置 DLinear 专家[4]。对每个尺度的输入，先用长度 $q=25$ 的中心移动平均得到趋势项，再由原序列与趋势项之差得到余项，二者沿时间维分别进行线性映射。不同尺度使用独立参数，同一尺度内的 OD 变量共享时间映射参数。这样设置后，每个专家只需学习本尺度下的时间变化，而不必共用一套时间映射。

1.4 样本级自适应尺度加权

3 个 DLinear 专家输出后，融合权重由当前输入样本决定。若直接取 1/3 等权，流量平稳时和波动明显时采用的尺度比例完全相同。本文从原始输入 X_n 提取四维统计向量 $z_n=[\mu_n, \sigma_n, \ell_n, d_n]$ ，其中

$$\mu_n = \left(\frac{1}{LC} \right) \sum_{t,c} X_{n,t,c}, \sigma_n = \sqrt{\left(\frac{1}{LC} \right) \sum_{t,c} (X_{n,t,c} - \mu_n)^2}, \quad (9)$$

$$l_n = \left(\frac{1}{C} \right) \sum_c X_{n,L-1,c}, d_n = \left(\frac{1}{(L-1)C} \right) \sum_{t=1}^{L-1} \sum_c |X_{n,t,c} - X_{n,t-1,c}|. \quad (10)$$

μ_n 、 σ_n 、 ℓ_n 和 d_n 分别表示输入窗口的总体水平、离散程度、最近状态和平均变化强度。4 个统计量输入隐藏维数为 16 的两层感知器，输出 3 个尺度分数。该路由器只处理低维统计量，没有再叠加额外的时序编码模块。

$$a_n = W_{2ReLU(W_{1z_n} + b_1)} + b_2. \quad (11)$$

Softmax 将三个尺度分数转换为非负且和为 1 的权重：

$$\alpha_{[n,s]} = \frac{\exp(a_{[n,s]})}{\sum_{j \in S} \exp(a_{[n,j]})}, \alpha_{[n,s]} \geq 0, \sum_s \alpha_{[n,s]} = 1. \quad (12)$$

最终预测为

$$\hat{Y}_n = \sum_{s \in S} \alpha_{[n,s]} \hat{Y}_n^{[s]}. \quad (13)$$

3 个尺度分数经过 Softmax 后转化为非负且和为 1 的权重。每个输入样本对应一组权重，并在该窗口

内由全部 OD 变量共享。固定等权消融模型直接令 3 个权重均为 1/3，除此之外，尺度集合、DLinear 专家和训练过程与本文方法一致。

1.5 训练目标与模型复杂度

模型以所有样本、预测时刻和 OD 变量上的均方误差为目标：

$$L_{|MSE|} = \left(\frac{1}{NHC} \right) \sum_{n=1}^N \sum_{h=1}^H \sum_{c=1}^C |Y_{n,h,c} - \hat{Y}_{n,h,c}|^2. \quad (14)$$

训练采用 Adam 优化，以验证集 MSE 选择模型。DLinear、固定等权多尺度模型和本文方法的可训练参数量分别为 4656、8208 和 8339。与固定等权模型相比，加入样本级路由后增加 131 个参数，参数规模基本保持在同一量级。

2 实验与结果分析

2.1 数据集与实验设置

实验数据来自 CESNET TS-Zoo[7]，选取其中的 Abilene[8]和 GÉANT[9] 1 h 聚合流量矩阵。Abilene 保留 144 维有效 OD 流量；GÉANT 去除恒定通道后保留 524 维，OD 变量数量更大。两个数据集分别按时间顺序以 6:2:2 划分，输入长度 L=96，预测长度 H=24，数据预处理与第 1.1 节相同。表 1 给出了具体数据规模和预测任务设置。

表 1 数据集与预测任务设置

数据集	时间点	有效变量 C	训练/验证/测试时间点	训练/验证/测试窗口	L/H
Abilene	4656	144	2793/931/932	2674/812/813	96/24
GÉANT	2849	524	1709/570/570	1590/451/451	96/24

所有对比模型使用相同的数据划分、输入长度和评价指标，批量大小均为 16。DLinear、固定等权多尺度模型和本文方法最多训练 30 轮，LightTS 最多训练 50 轮，各模型均以验证集 MSE 选择结果。外部基线比较使用随机种子 42—44；核心模型另外在 42—49 共 8 个随机种子下重复训练。

2.2 对比模型与评价指标

实验设置 3 类对比模型：单尺度 DLinear、LightTS 以及固定等权多尺度模型。前两者用于观察本文方法与现有轻量预测结构的差异。固定等权多尺度模型使用尺度集合 {1,2,4} 和相同的 DLinear 专家，但不经过路由网络，3 个尺度始终按 1/3 融合。

采用均方误差（MSE）、平均绝对误差（MAE）和均方根误差（RMSE）评价预测性能。MSE 按式 (14) 计算，MAE 和 RMSE 分别为

$$MAE = \left(\frac{1}{N_{|te|HC}} \right) \sum_{n,h,c} |Y_{n,h,c} - \hat{Y}_{n,h,c}|, \quad (15)$$

$$RMSE = \sqrt{MSE}. \quad (16)$$

评价指标为 MSE、MAE 和 RMSE，均在标准化空间中计算。MSE 按式（14）计算，MAE 和 RMSE 分别见式（15）和式（16）。正文主要讨论 MSE 和 MAE；表 2 统计随机种子 42—44 的均值±标准差，表 3 统计随机种子 42—49 的均值±标准差。

2.3 两数据集外部基线比较

由表 2 可知，本文方法在 Abilene 上的 MSE 为 0.186，在 GÉANT 上为 0.434。相对于 DLinear，两者分别降低 4.06%和 4.43%；相对于 LightTS，降幅分别为 29.89%和 46.83%。MAE 的变化方向与 MSE 一致。两个数据集的结果都显示，加入多尺度输入和样本级融合后，平均预测误差低于对应基线。

表 2 三随机种子外部基线比较

数据集	模型	参数量	MSE	MAE
Abilene	DLinear	4656	0.194±0.002	0.188±0.009
Abilene	LightTS	130162	0.265±0.011	0.204±0.008
Abilene	本文方法	8339	0.186±0.002	0.168±0.001
GÉANT	DLinear	4656	0.454±0.007	0.383±0.006
GÉANT	LightTS	384382	0.817±0.024	0.523±0.014
GÉANT	本文方法	8339	0.434±0.051	0.370±0.031

图 2 进一步列出了 3 个随机种子的单次结果。Abilene 的 3 次实验中，本文方法的 MSE 和 MAE 均低于 DLinear 和 LightTS。GÉANT 中，本文方法相对 LightTS 仍保持较低误差；与 DLinear 相比有个别随机种子波动，但 3 次结果取平均后仍低于 DLinear。




图 2 Abilene 与 GÉANT 上三随机种子外部基线配对结果

2.4 八随机种子核心消融与稳定性

表 3 把核心模型的重复实验扩展到 8 个随机种子。相对 DLinear，本文方法在 Abilene 和 GÉANT 上的平均 MSE 分别降低 2.77%和 2.37%。固定等权模型已经包含相同的 3 个 DLinear 尺度专家，因此更能直接反映路由权重的影响；在该模型基础上，本文方法 MSE 继续降低 1.67%和 4.68%。

表 3 八随机种子核心模型结果

数据集	模型	参数量	MSE	MAE
Abilene	DLinear	4656	0.194±0.002	0.189±0.008
Abilene	固定等权多尺度	8208	0.192±0.002	0.191±0.006
Abilene	本文方法	8339	0.189±0.003	0.173±0.008
GÉANT	DLinear	4656	0.437±0.016	0.371±0.011
GÉANT	固定等权多尺度	8208	0.447±0.014	0.377±0.009
GÉANT	本文方法	8339	0.426±0.029	0.366±0.018

图 3 按相同随机种子比较固定等权模型与本文方法。Abilene 的 8 个随机种子中有 6 个随机种子取得更低 MSE，GÉANT 中为 7 个。两个数据集的平均 Δ MSE 均为正，与表 3 给出的均值差异相符。




图 3 固定等权与自适应权重的八随机种子配对 MSE 及配对差值分布

2.5 路由权重分析

图 4 汇总了随机种子 42—49 下全部测试窗口的尺度权重。与固定的 1/3 权重不同，路由网络输出会随输入窗口变化，因此这里统计的是各尺度在测试集上的整体分布。




图4 八随机种子下样本级自适应路由权重分布

Abilene 中 α_1 、 α_2 和 α_4 的平均权重分别为 0.257、0.319 和 0.424；GÉANT 中分别为 0.283、0.318 和 0.399。两个数据集都表现为尺度 4 的平均权重最高，尺度 1 最低。对于本文设置的 24 步预测任务，较粗尺度的趋势信息占比较大，但另外两个尺度并未被路由器舍弃。

表 2 和图 2 反映了本文方法与外部基线的误差差异，表 3 与图 3 则比较了固定等权和自适应加权。两组结果的变化方向基本一致。结合图 4 可见，3 个尺度在测试样本中并非保持相同占比，路由器会改变各尺度参与最终预测的程度。

3 结论

本文针对骨干网络 OD 流量的多时间尺度变化，构建了样本级自适应多尺度预测方法。尺度 1、2 和 4 的序列分别由 DLinear 专家预测，轻量路由网络根据输入窗口统计量给出融合权重。Abilene 和 GÉANT 上的结果显示，相比 DLinear、LightTS 和固定等权多尺度模型，本文方法的平均预测误差更低。路由权重在 3 个尺度间呈现不同分布，说明固定等权并非唯一的融合方式。整个路由模块仅增加 131 个参数，可在较小模型增量下实现多尺度预测结果的动态融合。

参考文献

- [1] LOHRASBINASAB I, KESHAVARZ A, AMIN-NEJAD S, et al. From statistical- to machine learning-based network traffic prediction[J]. Transactions on Emerging Telecommunications Technologies, 2022, 33(4): e4394. DOI: 10.1002/ett.4394.
- [2] QIN L, GU H, WEI W, et al. Spatio-temporal communication network traffic prediction method based on graph neural network[J]. Information Sciences, 2024, 679: 121003. DOI: 10.1016/j.ins.2024.121003.
- [3] ZHOU J, HAN T, XIAO F, et al. Multiscale network traffic prediction method based on deep echo-state network for Internet of Things[J]. IEEE Internet of Things Journal, 2022, 9(21): 21862-21874. DOI: 10.1109/JIOT.2022.3181807.
- [4] ZENG A, CHEN M, ZHANG L, et al. Are transformers effective for time series forecasting?[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2023, 37(9): 11121-11128. DOI: 10.1609/aaai.v37i9.26317.
- [5] WANG S, WU H, SHI X, et al. TimeMixer: decomposable multiscale mixing for time series forecasting[C]//International Conference on Learning Representations. 2024.
- [6] ZHANG T, ZHANG Y, CAO W, et al. Less is more: fast multivariate time series forecasting with light sampling-oriented MLP structures[EB/OL]. (2022-07-04)[2026-09-20]. <https://arxiv.org/abs/2207.01186>. DOI: 10.48550/arXiv.2207.01186.

- [7] KUREŠ M, KOUMAR J, HYNEK K. CESNET TS-Zoo: a library for reproducible analysis of network traffic time series[C]//2025 21st International Conference on Network and Service Management. 2025. DOI: 10.23919/CNSM67658.2025.11297513.
- [8] ZHANG Y, ROUGHAN M, DUFFIELD N, et al. Fast accurate computation of large-scale IP traffic matrices from link loads[J]. ACM SIGMETRICS Performance Evaluation Review, 2003, 31(1): 206-217. DOI: 10.1145/885651.781053.
- [9] UHLIG S, QUOTIN B, LEPROPRE J, et al. Providing public intradomain traffic matrices to the research community[J]. ACM SIGCOMM Computer Communication Review, 2006, 36(1): 83-86. DOI: 10.1145/1111322.1111341.
- [10] 韦烜, 刘志华, 李青, 等. 大型 IP 网络流量矩阵分析预测的探讨研究[J]. 系统工程与电子技术, 2024, 46(6): 2164-2173. DOI: 10.12305/j.issn.1001-506X.2024.06.35.
- [11] 唐文杰, 肖一磊, 孔祥宇, 等. CycleLLH: 一种基于周期性整合的新型网络流量预测模型[J]. 计算机学报, 2024, 47(12): 2867-2888. DOI: 10.11897/SPJ.1016.2024.02867.