

基于自适应多尺度加权的多变量网络流量预测方法

[请填写作者姓名]

([请填写工作单位] [请填写部门], [省市 邮编])

摘要: 骨干网络中的源—目的节点对流量随时间持续变化, 同一序列中既能观察到短时起伏, 也存在突发变化和较慢的趋势成分。若始终在单一时间分辨率上进行预测, 不同流量状态下的信息利用会受到限制。基于这一问题, 本文构建样本级自适应多尺度预测方法。尺度 1、2 和 4 的序列由非重叠平均池化得到, 并分别交由 DLinear 专家处理; 输入窗口的均值、标准差、末时刻均值和平均绝对一阶差分用于生成 Softmax 尺度权重, 再据此组合 3 个尺度的预测结果。实验采用 Abilene 和 GÉANT 两个骨干网流量数据集。3 个共同随机种子下, 所提方法的 MSE 相对 DLinear 分别降低 4.06% 和 4.43%, 相对 LightTS 分别降低 29.89% 和 46.83%; 8 个随机种子的消融实验中, 相对固定等权融合分别降低 1.67% 和 4.68%。从两个数据集的结果看, 在参数只小幅增加的情况下, 按样本调整尺度权重能够降低平均预测误差。

关键词: 网络流量预测; 多变量时间序列; 多尺度学习; 自适应加权; DLinear

中图分类号: TP393 **文献标志码:** A

A Multivariate Network Traffic Forecasting Method Based on Adaptive

Multiscale Weighting

[Author Name]

([Affiliation] [Department], [City] [Postcode], China; Corresponding author: [Name], E-mail: [E-mail])

Abstract: Backbone origin-destination (OD) traffic does not evolve at a single temporal pace. Short-term fluctuations, abrupt changes, and slower trends may appear in the same traffic sequence, whereas a fixed-scale model always uses one temporal resolution. A sample-wise adaptive multiscale forecasting method is therefore proposed. Non-overlapping average pooling at scales 1, 2, and 4 is applied to obtain multiresolution sequences, which are processed by separate DLinear experts. The mean, standard deviation, latest-step mean, and mean absolute first difference of each input window are also extracted and fed into a lightweight routing network. Softmax weights produced by the router are used to combine the three forecasts. Experiments are carried out on the Abilene and GÉANT backbone traffic datasets. With three common random seeds, the proposed method reduces MSE by 4.06% and 4.43% compared with DLinear and by 29.89% and 46.83% compared with LightTS. In the eight-seed ablation experiment, the MSE reductions over fixed equal weighting are 1.67% and 4.68%, respectively. The results on both datasets show that the relative contribution of different temporal scales can be adjusted for each input sample with only a small increase in model parameters.

Key words: network traffic forecasting; multivariate time series; multiscale learning; adaptive weighting; DLinear

随着云计算、视频业务、数据中心互联及智能网络应用不断扩展, 骨干网络承载的数据规模持续增长, 业务流量在时间上的变化也更加复杂。源—目的节点对 (origin-destination, OD) 流量描述网络中不同节点对之间的通信需求, 其变化能够反映业务在网络内部的迁移和聚集情况。对于容量规划、拥塞预警、资源调度和流量工程等任务而言, 若能够提前获得后一时段的 OD 流量估计, 网络管理系统就可以在

收稿日期: [请填写, 格式 YYYY-MM-DD]

基金项目: [基金来源] ([基金项目编号])

第一作者简介: [姓名] ([出生年]—), [性别] ([民族, 汉族可省略]), [职称], [学位 (若在读请注明)], 研究方向: [方向 1]; [方向 2]。

通信作者简介: [姓名] ([出生年]—), [性别] ([民族, 汉族可省略]), [职称], [学位 (若在读请注明)], 研究方向: [方向 1]; [方向 2], 电子邮箱: [邮箱]。

业务变化发生前进行相应调整。与相对平稳的单变量序列不同，OD 流量通常同时包含周期变化、局部波动和突发变化，不同 OD 变量的数值范围也存在明显差异。因此，网络流量预测不仅需要描述较长时间范围内的变化趋势，还要保留对短时状态变化的响应能力。

围绕网络流量的时间变化规律，相关研究经历了从统计模型到机器学习、深度学习方法的发展。Lohrasbinasab 等[1]对网络流量预测方法进行了系统梳理，说明数据驱动方法已成为复杂流量预测的重要研究方向。随着网络规模扩大，仅从单一序列的时间变化进行建模已难以覆盖 OD 变量之间的关联关系。Qin 等[2]将图神经网络用于通信网络流量预测，把空间关联和时间依赖纳入同一模型；韦炬等[10]围绕大型 IP 网络流量矩阵开展分析与预测，进一步讨论了不同 OD 变量之间的关联及其随时间变化的特点。除变量关联外，周期规律也是网络流量中的重要信息，唐文杰等[11]提出 CycleLLH 模型，将周期性信息引入预测过程。上述工作分别从时间依赖、变量关联和周期结构等角度改进了网络流量预测，为后续从更细的时间结构分析流量变化提供了基础。

除变量关联和周期特征外，同一段网络流量在不同时间分辨率下呈现出的信息也并不完全相同。原始分辨率序列保留了较多细节，更容易反映短时起伏；经过一定时间聚合后，局部扰动被削弱，较慢的变化趋势则更加突出。针对这类多时间尺度特征，Zhou 等[3]利用深度回声状态网络开展多尺度网络流量预测，通过不同时间分辨率提取互补信息。与此同时，一些研究开始关注预测模型的结构复杂度 DLinear[4]采用时间序列分解和线性映射完成预测，结构相对简洁；TimeMixer[5]通过多尺度混合机制处理不同分辨率序列；LightTS[6]利用采样导向的 MLP 结构进行快速多变量时间序列预测。可以看到，多尺度建模和轻量时间序列预测分别从信息利用方式和模型结构两个方向提供了改进思路。对于骨干网络 OD 流量，如果能够在较小模型开销下同时使用不同时间尺度的信息，就有可能兼顾局部变化与整体趋势。


现有多尺度方法通常需要先确定若干时间尺度，但尺度建立之后，不同尺度在融合阶段往往采用预先设定的组合方式。实际流量序列中，各输入窗口的状态差异较大：有的窗口短时波动明显，有的窗口则主要呈现较平缓的趋势。当输入状态发生变化时，尺度 1、2 和 4 所包含的信息价值也可能随之变化。如果始终采用单一尺度，容易遗漏其他时间分辨率中的有效信息；如果对多个尺度长期使用固定比例，又难以反映不同窗口之间的状态差异。由此，本文关注的问题不只是如何构造多个时间尺度，还包括如何根据当前输入样本改变不同尺度在最终预测中的参与程度。

基于上述考虑，本文构建一种样本级自适应多尺度网络流量预测方法。首先，在原始输入窗口上采用尺度 1、2 和 4 构造多分辨率序列，并使用结构简洁的 DLinear 作为各尺度预测专家，使不同时间分辨率分别形成候选预测结果；随后，从当前输入窗口提取能够反映总体水平、离散程度、最近状态和变化强度的统计量，经轻量路由网络生成 Softmax 尺度权重，再对各尺度预测结果进行融合。该设计将“各尺度如何预测”和“当前样本更需要哪个尺度”两个问题分开处理，使路由模块不必重新承担完整的时序预测任务。实验在 Abilene 和 GÉANT 两个公开骨干网数据集上进行，并通过 DLinear、LightTS 外部基线、固定等权多尺度消融、多个随机种子重复实验以及路由权重分析，对模型的预测结果和尺度分配行为进行验证。

1 自适应多尺度网络流量预测方法

图 1 给出了自适应多尺度网络流量预测方法的整体流程。本文没有直接使用一个复杂模型同时完成多尺度特征提取和预测，而是将任务拆分为两个相对独立的部分：一部分负责在不同时间分辨率下完成预测，另一部分负责判断当前输入窗口中各尺度结果应占多大比重。原始 OD 流量经过对数变换和标准化后，在尺度 1、2 和 4 上形成 3 组输入序列，分别交由独立的 DLinear 专家处理；与此同时，轻量路由网络只读取当前窗口的统计特征，为 3 个尺度生成样本级权重。最终预测由 3 个专家输出按权重组合得到。这样的结构使多尺度预测和尺度选择各自承担明确功能，也便于后续通过固定等权模型单独考察自适应权重的

作用。



这一设计的出发点是，不同时间分辨率对同一流量窗口的描述侧重点不同。原始尺度保留的局部变化较多，较粗尺度则通过时间聚合削弱部分短时扰动，更容易呈现整体变化。若只保留其中一个尺度，其他时间分辨率的信息将不会进入预测过程；若简单固定多个尺度的融合比例，又无法随输入状态变化。基于此，本文保留 3 个尺度的独立预测结果，再把尺度组合问题交给路由网络处理。DLinear 结构较为简洁，可在控制模型规模的同时作为不同尺度上的预测专家，使方法的重点放在多尺度构造和样本级融合机制上。

图 1 自适应多尺度网络流量预测方法框架

1.1 问题定义与数据预处理

记预处理后的多变量流量序列为 $x_t \in \mathbb{R}^C$ ，其中 t 表示时间索引， C 表示有效 OD 变量数。对连续序列按时间滑动得到监督学习样本，第 n 个样本由一段历史窗口和其后的预测区间组成。历史窗口记为 X_n ，包含连续 L 个时间点；预测目标记为 Y_n ，包含紧随其后的 H 个时间点。因而，模型学习的实质是利用多个 OD 变量在过去 L 步中的联合变化，估计这些变量未来 H 步的取值。第 n 个样本对应的输入与目标定义为

$$X_n = [x_n, \dots, x_{n+L-1}] \in \mathbb{R}^{L \times C}, \quad (1)$$

$$Y_n = [x_{n+L}, \dots, x_{n+L+H-1}] \in \mathbb{R}^{H \times C}. \quad (2)$$

本文取输入长度 $L=96$ 、预测长度 $H=24$ ，变量数 C 由具体数据集保留的有效 OD 维度决定，学习映射记为 $\hat{Y}_n = f_\theta(X_n)$ 。 L 决定模型每次能够观察到的历史范围， H 则对应一次需要连续预测的未来长度。由于

原始 OD 流量为非负值，且不同 OD 变量之间的流量量级可能存在明显差异，若直接使用原始数值训练，较大的数值范围会使不同变量处于不一致的尺度。为减小这种数值跨度，首先对原始流量 $v_{t,c}$ 作对数变换

$$u_{[t,c]} = \log(1 + v_{[t,c]}), \quad (3)$$

再按变量进行标准化：

$$x_{[t,c]} = \frac{u_{[t,c]} - \mu_c^{[tr]}}{\sigma_c^{[tr]}}. \quad (4)$$

其中 μ_{ctr} 和 σ_{ctr} 分别表示第 c 个 OD 变量在训练集上的均值和标准差，只由训练数据计算，验证集和测试集均沿用训练阶段得到的统计量。 $\log(1+x)$ 变换用于压缩非负流量的数值范围，同时保留流量大小关系；随后进行按变量标准化，使不同 OD 维度以相近的数值尺度进入模型。两步处理承担的作用并不相同：前者主要缓和原始流量量级差异，后者使各变量在统一尺度下参与损失计算和参数更新。数据仍按时间顺序以 6:2:2 划分为训练集、验证集和测试集，各集合内部独立生成滑动窗口，避免窗口跨越不同数据划分边界。

经过上述处理后，每个输入样本仍保持原始时间分辨率。为了让后续专家同时观察细粒度变化和较平滑的趋势，需要进一步从同一历史窗口构造不同时间尺度的表示。

1.2 多尺度序列构造

设尺度集合 $S=\{1,2,4\}$ 。尺度 s 表示沿时间维进行聚合时使用的窗口大小。对于任一尺度 s ，采用窗口大小为 s 、步长也为 s 的非重叠平均池化：

$$X_{[n,t]}^{[s]} = \left(\frac{1}{s} \right) \sum_{i=0}^{s-1} x_{[n, st+i]}, t=0, \dots, \frac{L}{s}-1. \quad (5)$$

本文使用尺度集合 $S=\{1,2,4\}$ 。在输入长度 $L=96$ 时，尺度 1 保留原始 96 步序列；尺度 2 将相邻 2 个时间点取平均，得到 48 步序列；尺度 4 按 4 个时间点进行平均，得到 24 步序列。三者分别对应原始、中等和平滑程度更高的时间表示。尺度 1 不压缩时间轴，因此保留较完整的短时起伏；尺度 2 对局部变化进行适度平滑；尺度 4 进一步削弱短时间内的低频变化，使较慢的变化趋势更突出。这里采用平均池化而不是新增可训练的尺度变换模块，是为了在构造多分辨率输入时不额外增加模型参数。

尺度集合采用 1、2 和 4，主要是为了在 96 步历史窗口内形成三个层次清晰且长度均为整数的时间分辨率，同时控制专家数量。尺度继续增加虽然可以产生更粗的序列，但也会继续缩短有效时间长度并增加新的专家分支。本文并不将 $\{1,2,4\}$ 作为经过穷举得到的最优尺度组合，而是把它作为兼顾细粒度信息、趋势信息和模型规模的一组固定设计。采用非重叠池化还使每个原始时间点只参与一次同尺度聚合，尺度变化的含义较为直接。

为直观说明式 (5) 的尺度变换，图 2 选取 Abilene 训练集中一个非恒定 OD 变量的 96 步历史窗口。

该变量和窗口均按波动程度的中位水平确定，选择过程不使用模型预测误差。图 2(a)~(c)分别给出尺度 1、2 和 4 下的实际序列，图 2(d)给出非重叠平均池化的对应关系。




图 2 Abilene 单个 OD 变量的多尺度序列构造与平均池化示意

尺度 1 保留原始 96 步输入；尺度 2 对相邻 2 点取平均后得到 48 步序列；尺度 4 对相邻 4 点取平均后得到 24 步序列。核对源数据可知，尺度 2 和尺度 4 分别与尺度 1 的 2 点、4 点非重叠平均结果一致。随着尺度增大，局部波动逐渐被平滑，但整体变化趋势仍被保留，从而为后续 3 个 DLinear 专家提供侧重点不同的时间分辨率输入。

1.3 DLinear 尺度专家

尺度 1、2 和 4 分别配置一个 DLinear 专家[4]，每个专家只处理本尺度对应的输入序列。DLinear 的核心思路是先将序列拆分为变化较慢的趋势项和围绕趋势变化的余项，再分别完成时间映射。对尺度 s 的输入，本文使用长度 $q=25$ 的中心移动平均提取趋势项。移动平均相当于在局部时间邻域内进行平滑，为避免序列两端因窗口不足而缩短，边界位置采用端点复制方式补齐，从而保持分解前后的时间长度一致：

$$T_{n,t}^{[s]} = \left(\frac{1}{q} \right) \sum_{i=-m}^m \bar{X}_{n,t+i}^{[s]}, q=2m+1=25, \quad (6)$$

$$R_n^{[s]} = X_n^{[s]} - T_n^{[s]}. \quad (7)$$

趋势项 $T^{(s)}$ 和余项 $R^{(s)}$ 沿时间维分别通过线性层映射到预测长度 H ：

$$\hat{Y}_n^{[s]} = W_T^{[s]} T_n^{[s]} + b_T^{[s]} + W_R^{[s]} R_n^{[s]} + b_R^{[s]}. \quad (8)$$

由式（6）和式（7）可得到尺度 s 上的趋势项 $T(s)$ 和余项 $R(s)$ 。趋势项表示经过局部平滑后保留下来的较慢变化部分，余项则由原序列减去趋势项得到，保留未被移动平均解释的局部变化。式（8）分别对两部分沿时间维进行线性映射，并把二者的预测结果相加形成该尺度的候选预测。3 个尺度使用独立 DLinear 专家，是因为尺度 1、2 和 4 的输入长度分别为 96、48 和 24，对应的时间分辨率和时间映射关系并不相同；若强制共用一组尺度间参数，会把不同长度、不同平滑程度的序列约束到同一映射中。同一尺度内部，各 OD 变量共享时间映射参数，模型学习的是这一时间尺度下通用的时间映射形式，而不是为每个 OD 变量分别建立一套线性层。

选择 DLinear 作为尺度专家还有一个考虑：本文需要比较“单尺度预测”“固定等权多尺度”和“样本级自适应多尺度”之间的差异。如果尺度专家本身使用结构过于复杂的网络，最终误差变化会同时受到预测主干和尺度融合机制的影响。DLinear 参数结构较清晰，因此可以在保持预测能力的同时，把实验关注点更多放在多尺度输入和权重分配方式上。

1.4 样本级自适应尺度加权

经过 3 个 DLinear 专家后，同一样本会得到 3 组预测结果。下一步需要确定这些结果在最终预测中的比例。最直接的方式是令 3 个尺度均取 1/3，但这种处理默认所有输入窗口的尺度需求完全相同。实际上，某些窗口的局部波动较明显，细粒度信息可能更值得保留；另一些窗口变化较平稳，较粗尺度中的趋势信息可能更有参考价值。因此，本文不直接固定融合比例，而是从原始输入 X_n 中提取四维统计向量 $zn=[\mu_n, \sigma_n, \ell_n, d_n]$ ，用这些统计量描述当前窗口状态，其中

$$\mu_n = \left(\frac{1}{LC} \right) \Sigma_{[t, c] X_{[n, t, c]}}, \sigma_n = \sqrt{\left(\frac{1}{LC} \right) \Sigma_{[t, c] (X_{[n, t, c]} - \mu_n)^2}}, \quad (9)$$

$$\ell_n = \left(\frac{1}{C} \right) \Sigma_c X_{[n, L-1, c]}, d_n = \left(\frac{1}{(L-1)C} \right) \Sigma_{[t=1]_{[c]} \frac{1}{L-1} \Sigma_{[X_{[n, t, c]} - X_{[n, t-1, c]}]}}. \quad (10)$$

μ_n 、 σ_n 、 ℓ_n 和 d_n 分别表示输入窗口的总体水平、离散程度、最近状态和平均变化强度。 μ_n 用于概括当前窗口整体处于较高还是较低的流量水平； σ_n 反映窗口内部各观测值的离散程度，可用于描述整体波动大小； ℓ_n 对应窗口末时刻的平均状态，为路由器提供最接近预测起点的信息； d_n 由相邻时间点的一阶变化构造，用于补充窗口内部变化速度的信息。这 4 个统计量分别从水平、波动、最近状态和局部变化四个角度概括输入窗口。它们并不直接承担未来流量预测，而是作为尺度选择的依据。

$$a_n = W_{2 \text{ReLU}(W_{1x_n} + b_1)} + b_2. \quad (11)$$

四维向量输入隐藏维数为 16 的两层感知器，输出 3 个尺度对应的未归一化分数。这里没有再使用额外的循环网络、注意力网络或其他完整时序编码器，原因是路由器的任务不是重新学习一遍 OD 流量预测，而只是根据已经提取的窗口状态判断三个尺度的相对重要程度。低维统计量和较小隐藏层可以把路由模块的参数规模限制在较低水平。其尺度分数计算为

式 (11) 得到的 3 个尺度分数仍是未归一化值。为使这些分数可以直接解释为各专家在最终预测中的相对贡献，使用 Softmax 进行归一化。经 Softmax 处理后，每个权重均为非负值，并且 3 个权重之和为 1：

$$\alpha_{|n,s|} = \frac{\exp(a_{|n,s|})}{\sum_{|j \in S|} \exp(a_{|n,j|})}, \alpha_{|n,s|} \geq 0, \sum_s \alpha_{|n,s|} = 1. \quad (12)$$

最终预测为

$$\hat{Y}_n = \sum_{|s \in S|} \alpha_{|n,s|} \hat{Y}_n^{(s)}. \quad (13)$$

式 (13) 利用上述权重对 3 个 DLinear 专家的预测结果进行加权求和，得到最终预测 $\hat{Y}_n$ 。这里的权重是样本级而不是全局固定参数，即不同输入窗口可以得到不同的尺度组合；同一个输入窗口内，该组权重由全部 OD 变量共享。这样处理可以避免为每个 OD 变量单独设置路由器，从而控制参数量。为了区分“使用多尺度”与“使用自适应权重”两部分作用，固定等权消融模型直接把 3 个尺度权重设为 1/3，其尺度集合、DLinear 专家、数据收集和训练过程均保持一致。

1.5 训练目标与模型复杂度

模型训练以均方误差作为优化目标。误差在训练样本、未来 H 个预测时刻以及全部 C 个 OD 变量上共同计算，因此每次参数更新同时考虑不同预测步和不同 OD 维度的偏差。对应训练目标为

$$L_{|MSE|} = \left(\frac{1}{NHC} \right) \sum_{|n=1|}^{|N|} \sum_{|h=1|}^{|H|} \sum_{|c=1|}^{|C|} \frac{1}{2} \left(\hat{y}_{n,h,c} - y_{n,h,c} \right)^2. \quad (14)$$

参数训练使用 Adam 优化器，并以验证集 MSE 选择最终模型。单尺度 DLinear 包含 4656 个可训练参数；扩展为 3 个尺度专家后，固定等权多尺度模型包含 8208 个参数；加入样本级路由网络后，本文方法共有 8339 个参数。由 8208 增加到 8339 的 131 个参数即来自路由模块，这部分相对于多尺度专家主体所占比例较小。因而，从固定等权多尺度模型到本文方法的变化主要是融合方式由常数权重变为样本相关权重，而不是通过大幅增加预测主干规模获得额外容量。

综上，本文方法先利用平均池化把同一输入窗口转换为 3 个时间分辨率，再由独立 DLinear 专家分别形成候选预测；随后，路由网络根据原始窗口的 4 个统计量计算样本级尺度权重，完成预测融合。多尺度序列解决“从哪些时间分辨率观察历史流量”的问题，DLinear 专家负责“各尺度分别如何预测”，路由网络则处理“当前样本应如何组合这些尺度”。三个模块的功能相互区分，后续实验也据此设置单尺度

基线、固定等权多尺度模型和本文方法进行比较。

2 实验与结果分析

实验部分围绕三个问题展开。首先，通过 DLinear 和 LightTS 两个外部基线，观察本文方法在统一数据划分和预测任务下的整体误差水平；其次，将固定等权多尺度模型与本文方法进行比较，在保持尺度集合和 DLinear 专家一致的条件下，考察样本级尺度权重带来的变化；最后，结合多个随机种子的重复实验和路由权重分布，观察这种变化是否只出现在个别初始化条件下，以及模型在测试阶段实际如何分配三个尺度。

2.1 数据集与实验设置

实验数据来自 CESNET TS-Zoo[7]，选取 Abilene[8]和 GÉANT[9]两个 1 h 聚合的骨干网流量矩阵。Abilene 共有 4656 个时间点，保留 144 维有效 OD 流量；GÉANT 共有 2849 个时间点，去除恒定通道后保留 524 维有效 OD 流量。两个数据集在序列长度和变量规模上存在明显差异：Abilene 时间点更多，而 GÉANT 包含更多 OD 变量。因而，在相同预测流程下同时使用这两个数据集，可以观察模型在不同变量规模和样本数量条件下的表现。两者均按时间顺序以 6:2:2 划分为训练集、验证集和测试集，输入长度 $L=96$ ，预测长度 $H=24$ ，预处理方式与第 1.1 节保持一致。表 1 列出了具体的数据规模和窗口数量。

表 1 数据集与预测任务设置

数据集	时间点	有效变量 C	训练/验证/测试时间点	训练/验证/测试窗口	L/H
Abilene	4656	144	2793/931/932	2674/812/813	96/24
GÉANT	2849	524	1709/570/570	1590/451/451	96/24

所有对比模型采用相同的数据划分、输入长度、预测长度和评价指标，批量大小统一设为 16。这样设置的目的是不是比较不同模型各自的最佳超参数，而是在统一预测任务下控制数据条件的一致性。DLinear、固定等权多尺度模型和本文方法最多训练 30 轮，LightTS 最多训练 50 轮，训练过程中均根据验证集 MSE 选择用于测试的模型参数，而不是直接使用最后一轮结果。验证集在这里承担模型选择作用，测试集只用于最终性能统计。

随机种子的设置分为两组。外部基线比较使用 42—44 共 3 个共同随机种子，使 DLinear、LightTS 和本文方法能够在相同初始化编号下进行重复比较；核心消融进一步扩展到 42—49 共 8 个随机种子，只比较 DLinear、固定等权多尺度模型和本文方法。前一组用于给出与外部基线的统一比较，后一组则增加重复次数，以便更充分地观察多尺度结构和样本级加权在不同初始化下的结果变化。

2.2 对比模型与评价指标

实验中的对比对象包括 3 类：单尺度 DLinear、LightTS 和固定等权多尺度模型。三类模型承担的对比作用并不相同。DLinear 与本文各尺度专家采用相同的基础预测结构，可作为单尺度基线，用于观察从单一时间分辨率扩展到多尺度后的变化；LightTS 是独立的轻量多变量时间序列预测模型，用于提供外部结构基线；固定等权多尺度模型与本文方法使用完全相同的尺度集合 {1,2,4} 和 DLinear 专家，但取消样本级路由，3 个尺度始终以 1/3 权重融合。因此，从 DLinear 到固定等权模型主要增加多尺度信息，而从固定等权模型到本文方法只改变尺度融合方式。

预测性能采用均方误差（MSE）、平均绝对误差（MAE）和均方根误差（RMSE）评价。MSE 按式 (14) 计算，MAE 和 RMSE 分别定义为

$$MAE = \left(\frac{1}{N_{|te|HC}} \right) \sum_{|n,h,c|} |Y_{|n,h,c|} - \hat{Y}_{|n,h,c|}|, \quad (15)$$

$$RMSE = \sqrt{MSE}. \quad (16)$$

MSE、MAE 和 RMSE 均在标准化空间中计算，数值越小表示预测结果与真实值之间的偏差越小。三项指标的侧重点有所不同：MSE 对较大的预测误差更敏感，MAE 直接统计绝对误差的平均水平，RMSE 则在均方误差基础上开方，便于从另一种尺度观察整体偏差。正文以 MSE 和 MAE 作为主要比较指标，RMSE 用于补充评价。表 2 统计随机种子 42—44 的均值±标准差，表 3 统计随机种子 42—49 的均值±标准差，从而同时保留平均水平和不同重复实验之间的波动信息。

2.3 两数据集外部基线比较

表 2 给出了 3 个共同随机种子下的外部基线结果。本文方法在 Abilene 上的 MSE 为 0.186，在 GÉANT 上为 0.434。相对于 DLinear，两项 MSE 分别降低 4.06% 和 4.43%；相对于 LightTS，分别降低 29.89% 和 46.83%。MAE 的变化方向与 MSE 一致。由比较幅度可以看到，本文方法相对 DLinear 的改进较为接近，而相对 LightTS 的差距更大，这说明在当前两个数据集和既定参数设置下，DLinear 本身已经是更接近本文方法的强基线。本文的改进是在这一基础上进一步引入多尺度输入和样本级融合获得的。

表 2 三随机种子外部基线比较

数据集	模型	参数量	MSE	MAE
Abilene	DLinear	4656	0.194±0.002	0.188±0.009
Abilene	LightTS	130162	0.265±0.011	0.204±0.008
Abilene	本文方法	8339	0.186±0.002	0.168±0.001
GÉANT	DLinear	4656	0.454±0.007	0.383±0.006
GÉANT	LightTS	384382	0.817±0.024	0.523±0.014
GÉANT	本文方法	8339	0.434±0.051	0.370±0.031

图 3 进一步给出了随机种子 42—44 的单次实验结果，用于观察表 2 中的平均值由哪些重复实验构成。Abilene 上，本文方法在 3 次实验中的 MSE 和 MAE 均低于 DLinear 和 LightTS。GÉANT 上，相对 LightTS 的 3 次结果同样保持较低误差；与 DLinear 相比则存在个别随机种子的波动，但 3 次结果取平均后仍低于 DLinear。由此可见，表 2 中的平均改善并非完全来自某一个随机种子的异常结果，尤其在 Abilene 上，3 次重复实验的变化方向较一致。




图3 Abilene 与 GÉANT 上三随机种子外部基线配对结果

两个数据集上的相对降幅并不完全相同。GÉANT 的 OD 变量数明显多于 Abilene，而本文方法相对 LightTS 在 GÉANT 上的 MSE 降幅也更大；不过，这一现象只能说明在当前数据集和实验设置下两种模型之间的差距不同，不能据此把误差变化简单归因于变量规模。更直接的判断仍需要依赖后续固定等权消融，因为该模型与本文方法共享相同的多尺度专家结构。

平均指标能够反映整体误差水平，但不容易展示 24 步预测过程中预测轨迹与真实序列之间的局部差异。因此，图 4 给出随机种子 42 下的代表性测试窗口，并在下方同时绘制逐步绝对误差。样本选择不依据本文方法相对 DLinear 的提升幅度，而是先选择本文方法绝对误差接近全部测试窗口中位数的窗口，再选择该窗口中真实值波动程度接近通道中位数的非恒定 OD 变量，以避免只展示最有利案例。




图4 Abilene 与 GÉANT 代表性测试窗口的 24 步预测及逐步绝对误差

图 4(a)、(b)展示真实值、DLinear 和本文方法在 24 个预测步上的轨迹，图 4(c)、(d)给出对应的标准化绝对误差。Abilene 示例中，本文方法在多数预测步上与真实值更接近；GÉANT 示例中，两种方法的误差更为接近，不同预测步各有偏差。该图用于补充说明单个典型窗口中的预测形态，整体性能判断仍以表 2 和表 3 在全部测试样本、多个随机种子上的统计结果为准。

2.4 八随机种子核心消融与稳定性

为进一步区分多尺度结构和自适应权重各自带来的影响，表 3 把核心模型扩展到随机种子 42—49 共 8 次重复实验。这里可以按两步理解结果。第一步比较 DLinear 与本文方法：Abilene 和 GÉANT 上的平均 MSE 分别降低 2.77%和 2.37%，说明完整模型相对单尺度 DLinear 保持较低的平均误差。第二步比较固定等权多尺度模型与本文方法：两者拥有相同的尺度集合和 3 个 DLinear 专家，区别只在融合权重是否随样本变化。在这一更严格的结构对照下，本文方法的平均 MSE 仍分别降低 1.67%和 4.68%。因此，表 3 把性能变化分成了“引入多尺度信息”和“进一步改变尺度融合方式”两个层次。

表 3 八随机种子核心模型结果

数据集	模型	参数量	MSE	MAE
Abilene	DLinear	4656	0.194±0.002	0.189±0.008
Abilene	固定等权多尺度	8208	0.192±0.002	0.191±0.006
Abilene	本文方法	8339	0.189±0.003	0.173±0.008
GÉANT	DLinear	4656	0.437±0.016	0.371±0.011
GÉANT	固定等权多尺度	8208	0.447±0.014	0.377±0.009
GÉANT	本文方法	8339	0.426±0.029	0.366±0.018

图 5 按照相同随机种子对固定等权模型和本文方法进行配对比较，以避免把不同随机初始化之间的自然波动混入模型差异。Abilene 的 8 个随机种子中，本文方法有 6 次取得更低 MSE；GÉANT 中有 7 次取得更低 MSE。两个数据集的平均 Δ MSE 均为正，与表 3 中的均值结果一致。换言之，自适应权重带来的平均改善并不只由少数单次实验推动，而是在多数共同随机种子下都能观察到同方向变化。




图 5 固定等权与自适应权重的八随机种子配对 MSE 及配对差值分布

从 DLinear、固定等权多尺度模型到本文方法，模型结构逐步增加了两个因素：先加入多个时间尺度，再把固定权重替换为样本级权重。表 3 与图 5 共同说明，在已经具备多尺度专家的前提下，尺度融合方式仍会影响预测结果。这也是后续分析路由权重分布的原因：如果路由器始终输出接近 1/3 的权重，那么自适应模块与固定等权模型实际上不会形成明显区别。

2.5 路由权重分析

图 6 统计随机种子 42—49 下全部测试窗口的尺度权重，用于观察路由网络在测试阶段是否真正形成

了不同于固定 $1/3$ 的尺度分配。固定等权模型在所有样本上都使用同一组权重，而本文方法的权重由每个输入窗口的统计特征计算，因此测试集中的权重分布能够直接反映路由器对 3 个尺度的总体偏好及其变化范围。




图 6 八随机种子下样本级自适应路由权重分布

Abilene 中 α_1 、 α_2 和 α_4 的平均权重依次为 0.257、0.319 和 0.424；GÉANT 中依次为 0.283、0.318 和 0.399。两个数据集都表现为尺度 4 的平均权重最高，尺度 1 最低，且三个尺度的平均值明显不同于固定等权的 $1/3$ 。对于本文设置的 24 步预测任务，路由器整体上给予较粗尺度更高的权重，说明经过更强时间平滑后的趋势信息在最终融合中占有较大比例；与此同时，尺度 1 和尺度 2 仍保留非零权重，表明最终预测并不是只依赖单一粗尺度，而是继续组合不同时间分辨率的信息。

综合表 2、表 3 和图 3—图 6 可以形成一条较清晰的实验链。表 2 和图 3 用于比较本文方法与外部轻量基线的总体误差水平；图 4 补充展示代表性测试窗口中的 24 步预测轨迹和逐步绝对误差；表 3 和图 5 进一步控制专家结构，考察固定等权与样本级权重之间的差异；图 6 则从模型内部的尺度分配结果说明路由器在测试样本上形成了非等权的融合方式。各部分分别对应总体性能、局部预测形态、核心结构消融和内部权重行为，与第 1 节提出的多尺度专家和样本级路由设计相互对应。

3 结论

本文围绕骨干网络 OD 流量的多时间尺度变化开展预测。尺度 1、2 和 4 分别由 DLinear 专家处理，轻量路由网络根据输入窗口统计量确定融合权重。Abilene 和 GÉANT 实验中，本文方法相对 DLinear、LightTS 和固定等权多尺度模型取得了更低的平均预测误差；3 个尺度的路由权重也呈现不同分布。路由模块只增加 131 个参数，在模型规模变化较小的情况下完成多尺度预测结果的样本级融合。

参考文献

- [1] LOHRASBINASAB I, KESHAVARZ A, AMIN-NEJAD S, et al. From statistical- to machine learning-based network traffic prediction[J]. Transactions on Emerging Telecommunications Technologies, 2022, 33(4): e4394. DOI: 10.1002/ett.4394.
- [2] QIN L, GU H, WEI W, et al. Spatio-temporal communication network traffic prediction method based on graph neural network[J]. Information Sciences, 2024, 679: 121003. DOI: 10.1016/j.ins.2024.121003.
- [3] ZHOU J, HAN T, XIAO F, et al. Multiscale network traffic prediction method based on deep echo-state network for Internet of Things[J]. IEEE Internet of Things Journal, 2022, 9(21): 21862-21874. DOI: 10.1109/JIOT.2022.3181807.

- [4] ZENG A, CHEN M, ZHANG L, et al. Are transformers effective for time series forecasting?[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2023, 37(9): 11121-11128. DOI: 10.1609/aaai.v37i9.26317.
- [5] WANG S, WU H, SHI X, et al. TimeMixer: decomposable multiscale mixing for time series forecasting[C]//International Conference on Learning Representations. 2024.
- [6] ZHANG T, ZHANG Y, CAO W, et al. Less is more: fast multivariate time series forecasting with light sampling-oriented MLP structures[EB/OL]. (2022-07-04)[2026-09-20]. <https://arxiv.org/abs/2207.01186>. DOI: 10.48550/arXiv.2207.01186.
- [7] KUREŠ M, KOUMAR J, HYNEK K. CESNET TS-Zoo: a library for reproducible analysis of network traffic time series[C]//2025 21st International Conference on Network and Service Management. 2025. DOI: 10.23919/CNSM67658.2025.11297513.
- [8] ZHANG Y, ROUGHAN M, DUFFIELD N, et al. Fast accurate computation of large-scale IP traffic matrices from link loads[J]. ACM SIGMETRICS Performance Evaluation Review, 2003, 31(1): 206-217. DOI: 10.1145/885651.781053.
- [9] UHLIG S, QUOTIN B, LEPROPRE J, et al. Providing public intradomain traffic matrices to the research community[J]. ACM SIGCOMM Computer Communication Review, 2006, 36(1): 83-86. DOI: 10.1145/1111322.1111341.
- [10] 韦烜, 刘志华, 李青, 等. 大型 IP 网络流量矩阵分析预测的探讨研究[J]. 系统工程与电子技术, 2024, 46(6): 2164-2173. DOI: 10.12305/j.issn.1001-506X.2024.06.35.
- [11] 唐文杰, 肖一磊, 孔祥宇, 等. CycleLLH: 一种基于周期性整合的新型网络流量预测模型[J]. 计算机学报, 2024, 47(12): 2867-2888. DOI: 10.11897/SP.J.1016.2024.02867.