

基于自适应多尺度加权的多变量网络流量预测方法

[请填写作者姓名]

([请填写工作单位] [请填写部门], [省市 邮编])

摘要：骨干网络中的源一目的节点对流量在同一时间序列中常同时出现短时起伏、突发变化和较慢趋势，固定时间分辨率难以完整利用这些变化信息。针对这一特点，本文设计样本级自适应多尺度预测方法。历史窗口经非重叠平均池化形成尺度 1、2 和 4 的输入，分别由 3 个 DLinear 专家完成预测；路由网络根据输入窗口的均值、标准差、末时刻均值和平均绝对一阶差分计算 Softmax 尺度权重，再融合 3 个尺度的预测结果。实验采用 Abilene 和 GÉANT 两个骨干网流量数据集。3 个共同随机种子下，所提方法 MSE 相对 DLinear 分别降低 4.06% 和 4.43%，相对 LightTS 分别降低 29.89% 和 46.83%；8 个随机种子的消融实验中，相对固定等权融合分别降低 1.67% 和 4.68%。路由模块只带来较小参数增量，但两个数据集上的平均预测误差仍进一步降低。

关键词：网络流量预测；多变量时间序列；多尺度学习；自适应加权；DLinear

中图分类号：TP393 **文献标志码：**A

A Multivariate Network Traffic Forecasting Method Based on Adaptive Multiscale Weighting

[Author Name]

([Affiliation] [Department], [City] [Postcode], China; Corresponding author: [Name], E-mail: [E-mail])

Abstract: Backbone origin-destination (OD) traffic does not evolve at a single temporal pace. Short-term fluctuations, abrupt changes, and slower trends may appear in the same traffic sequence, whereas a fixed-scale model always uses one temporal resolution. A sample-wise adaptive multiscale forecasting method is therefore proposed. Non-overlapping average pooling at scales 1, 2, and 4 is applied to obtain multiresolution sequences, which are processed by separate DLinear experts. The mean, standard deviation, latest-step mean, and mean absolute first difference of each input window are also extracted and fed into a lightweight routing network. Softmax weights produced


比, OD 流量中往往同时存在周期变化、局部波动和突发变化, 不同 OD 变量的数值范围也有明显差异, 因此预测模型既要描述较长时间范围内的变化趋势, 也要保留对短时状态变化的响应。

网络流量预测已经从传统统计模型逐步扩展到机器学习和深度学习方法。Lohrasbinasab 等[1]对相关方法进行了系统梳理, 并指出数据驱动方法在复杂流量预测中的应用不断增加。网络规模扩大后, 仅分析单一序列的时间变化已不足以覆盖 OD 变量之间的关联。Qin 等[2]把图神经网络引入通信网络流量预测, 在同一模型中处理空间关联和时间依赖; 韦烜等[10]针对大型 IP 网络流量矩阵开展分析与预测, 讨论了不同 OD 变量之间的关联及其时间变化。唐文杰等[11]则在 CycleLLH 模型中引入周期性信息。现有工作已经涉及时间依赖、变量关联和周期结构等多个方面, 也为进一步分析不同时间分辨率下的流量变化提供了基础。

同一段网络流量在不同时间分辨率下呈现的特征并不一致。原始分辨率保留更多局部细节, 短时起伏表现得更明显; 时间聚合会削弱部分局部扰动, 使较慢的变化趋势更容易观察。Zhou 等[3]利用深度回声状态网络进行多尺度网络流量预测, 通过不同时间分辨率提取互补信息。另一方面, 模型结构开销也需要考虑。DLinear[4]采用时间序列分解和线性映射完成预测; TimeMixer[5]利用多尺度混合机制处理不同分辨率序列; LightTS[6]采用采样导向的 MLP 结构进行快速多变量时间序列预测。本文在这些工作的基础上, 把关注点放在多时间尺度信息的利用与模型规模控制之间的平衡。

多尺度方法通常先给定若干时间尺度, 再把各尺度结果按既定方式融合。问题在于, 不同输入窗口的流量状态并不相同: 某些窗口以短时波动为主, 另一些窗口则表现为更平缓的趋势。输入状态变化时尺度 1、2 和 4 对预测的作用也可能发生变化。只使用单一尺度会舍弃其他时间分辨率的信息, 而长期采用固定融合比例又难以体现窗口之间的状态差异。基于这一现象, 本文不仅构造多个时间尺度, 还让各尺度在最终预测中的参与程度随当前输入样本变化。

本文采用样本级自适应多尺度结构处理上述问题。历史窗口按尺度 1、2 和 4 构造多分辨率序列, 每个尺度由一个 DLinear 专家给出候选预测。路由网络不重新编码完整时序, 而是读取当前输入窗口的总体水平、离散程度、最近状态和变化强度等统计量, 生成 Softmax 尺度权重, 并据此融合三个专家的结果。这样可以把尺度内



$$u_{[t,c]} = \log(1 + v_{[t,c]}), \quad (3)$$

再按变量进行标准化：

$$x_{[t,c]} = \frac{u_{[t,c]} - \mu_c^{[tr]}}{\sigma_c^{[tr]}}. \quad (4)$$

其中 μ_{ctr} 和 σ_{ctr} 分别为第 c 个 OD 变量在训练集上的均值和标准差，验证集和测试集均使用训练阶段得到的统计量。 $\log(1+x)$ 先压缩非负流量的数值范围，同时保留流量大小关系；随后按变量标准化，使不同 OD 维度在相近的数值尺度上参与训练。前一步主要缓和原始流量的量级差异，后一步用于统一各变量参与损失计算和参数更新时的尺度。数据仍按时间顺序以 6:2:2 划分为训练集、验证集和测试集，各集合内部独立生成滑动窗口，避免窗口跨越不同数据划分边界。

经过上述处理后，每个输入样本仍保持原始时间分辨率。为了让后续专家同时观察细粒度变化和较平滑的趋势，需要进一步从同一历史窗口构造不同时间尺度的表示。

1.2 多尺度序列构造

设尺度集合 $S=\{1,2,4\}$ 。尺度 s 表示沿时间维进行聚合时使用的窗口大小。对于任一尺度 s ，采用窗口大小为 s 、步长也为 s 的非重叠平均池化：

$$X_{[n,t]}^{[s]} = \left(\frac{1}{s} \right) \sum_{i=0}^{\lfloor \frac{s-1}{s} X \rfloor} x_{[n, st+i]}, t=0, \dots, \frac{L}{s} - 1. \quad (5)$$

本文使用尺度集合 $S=\{1,2,4\}$ 。在输入长度 $L=96$ 时，尺度 1 保留原始 96 步序列；尺度 2 将相邻 2 个时间点取平均，得到 48 步序列

入，本文使用长度 $q=25$ 的中心移动平均提取趋势项。移动平均相当于在局部时间邻域内进行平滑，为避免序列两端因窗口不足而缩短，边界位置采用端点复制方式补齐，从而保持分解前后的时间长度一致：

$$T_{[n,t]}^{[s]} = \left(\frac{1}{q} \right) \sum_{i=-m}^m \bar{X}_{n,t+i}^{[s]}, q=2m+1=25, \quad (6)$$

$$R_n^{[s]} = X_n^{[s]} - T_n^{[s]}. \quad (7)$$

趋势项 $T^{(s)}$ 和余项 $R^{(s)}$ 沿时间维分别通过线性层映射到预测长度 H ：

$$\hat{Y}_n^{[s]} = W_T^{[s]} T_n^{[s]} + b_T^{[s]} + W_R^{[s]} R_n^{[s]} + b_R^{[s]}. \quad (8)$$

由式（6）和式（7）可得到尺度 s 上的趋势项 $T(s)$ 和余项 $R(s)$ 。趋势项表示经过局部平滑后保留下来的较慢变化部分，余项则由原序列减去趋势项得到，保留未被移动平均解释的局部变化。式（8）分别对两部分沿时间维进行线性映射，并把二者的预测结果相加形成该尺度的候选预测。3 个尺度使用独立 DLinear 专家，是因为尺度 1、2 和 4 的输入长度分别为 96、48 和 24，对应的时间分辨率和时间映射关系并不相同；若强制共用一组尺度间参数，会把不同长度、不同平滑程度的序列约束到同一映射中。同一尺度内部，各 OD 变量共享时间映射参数，模型学习的是这一时间尺度下通用的时间映射形式，而不是为每个 OD 变量分别建立一套线性层。

采用 DLinear 作为尺度专家，主要是为了把预测主干与尺度融合的影响区分开。本文需要比较单尺度预测、固定等权多尺度和样本级自适应多尺度三种设置；若尺度专家本身过于复杂，误差变化会同时受到主干结构和融合机制影响。DLinear 参数关系清晰，在保持基本预测能力的同时，更适合作为

μ_n 、 σ_n 、 ℓ_n 和 dn 分别描述输入窗口的总体水平、离散程度、最近状态和平均变化强度。 μ_n 反映窗口整体流量水平， σ_n 刻画观测值的离散程度， ℓ_n 取窗口末时刻的平均状态， dn 由相邻时间点的一阶变化得到。这 4 个统计量分别提供水平、波动、最近状态和局部变化信息，供路由器判断当前样本更适合依赖哪些时间尺度，而不直接参与未来流量数值的预测。

$$a_n = W_{2ReLU(W_{1x_n} + b_1)} + b_2. \quad (11)$$

四维向量输入隐藏维数为 16 的两层感知器，输出 3 个尺度的未归一化分数。路由器只需判断尺度的相对重要性，不需要再次完成完整的 OD 流量预测，因此本文未引入循环网络、注意力网络等额外时序编码器。使用低维统计量和较小隐藏层，也能把路由模块的参数规模控制在较低水平。其尺度分数计算为式 (11) 得到的 3 个尺度分数仍是未归一化值。为使这些分数可以直接解释为各专家在最终预测中的相对贡献，使用 Softmax 进行归一化。经 Softmax 处理后，每个权重均为非负值，并且 3 个权重之和为 1：

$$\alpha_{|n,s|} = \frac{\exp(a_{|n,s|})}{\sum_{|j \in S|} \exp(a_{|n,j|})}, \alpha_{|n,s|} \geq 0, \sum_s \alpha_{|n,s|} = 1. \quad (12)$$

最终预测为

$$\hat{Y}_n = \sum_{|s \in S|} \alpha_{|n,s|} \hat{Y}_n^{(s)}. \quad (13)$$

式 (13) 利用上述权重对 3 个 DLinear 专家的预测结果进行加权求和，得到最终预测 $\hat{Y}_n$ 。这里的权重是样本级而不是全局固定参数，即不同输入窗口可以得到

占比例较小。因而，从固定等权多尺度模型到本文方法的变化主要是融合方式由常数权重变为样本相关权重，而不是通过大幅增加预测主干规模获得额外容量。

模型的计算过程可以概括为三个环节：平均池化把同一历史窗口转换为 3 个时间分辨率，DLinear 专家分别给出候选预测，路由网络再根据原始窗口的 4 个统计量确定融合权重。多尺度序列决定模型从哪些时间分辨率读取历史信息，尺度专家完成各自的预测，路由网络只负责组合结果。后续实验据此设置单尺度 DLinear、固定等权多尺度模型和本文方法，用同一组专家结构区分多尺度信息与样本级加权的作用。

2 实验与结果分析

实验按外部基线、核心消融和路由权重三个层次组织。DLinear 和 LightTS 用于比较统一数据划分和预测任务下的误差水平；固定等权多尺度模型与本文方法共享尺度集合和 DLinear 专家，用来检验样本级融合方式的影响；随机种子重复实验与路由权重分布则用于观察结果波动和测试阶段的实际尺度分配。

2.1 数据集与实验设置

实验数据取自 CESNET TS-Zoo[7]，包括 1 h 聚合的 Abilene[8]和 GÉANT[9]骨干网流量矩阵。Abilene 共有 4656 个时间点，保留 144 维有效 OD 流量；GÉANT 共有 2849 个时间点，去除恒定通道后保留 524 维有效 OD 流量。两者在序列长度和变量规模上差异较大，能够在相同预测流程下提供不同的数据条件。两个数据集均按时间顺序以 6:2:2 划分为训练集、验证集和测试集，输入长度 $L=96$ ，预测长度 $H=24$ ，预处理方式与第 1.1 节一致。表 1 列出了数据规模和窗口数量。

表 1 数据集与预测任务设置

||
||
||

$$MAE = \left(\frac{1}{N_{|te|HC}} \right) \sum_{|n,h,c|} |Y_{|n,h,c|} - \hat{Y}_{|n,h,c|}|, \tag{15}$$

$$RMSE = \sqrt{MSE}. \tag{16}$$


MSE、MAE 和 RMSE 均在标准化空间中计算，数值越小表示预测误差越低。MSE 对较大误差更敏感，MAE 反映绝对误差的平均水平，RMSE 是 MSE 开方后的结果，可与误差幅值直接对照。正文以 MSE 和 MAE 作为主要比较指标，RMSE 用于补充。表 2 统计随机种子 42~44 的均值±标准差，表 3 统计随机种子 42~49 的均值±标准差，同时给出平均水平和重复实验间的波动。

2.3 两数据集外部基线比较

表 2 列出 3 个共同随机种子下的总体基线结果。本文方法在 Abilene 上的 MSE 为 0.186，在 GÉANT 上为 0.434；相对 DLinear 分别降低 4.06%和 4.43%，相对 LightTS 分别降低 29.89%和 46.83%，MAE 呈相同方向变化。DLinear 与本文尺度专家采用同源结构，后续核心消融继续以它作为单尺度内部基线；LightTS 属于独立外部结构基线，图 3 进一步给出逐随机种子、多指标和参数规模比较。

表 2 三随机种子外部基线比较

数据集	模型	参数量	MSE	MAE
Abilene	DLinear	4656	0.194±0.002	0.188±0.009
Abilene	LightTS	130162	0.265±0.011	0.204±0.008
Abilene	本文方法	8339</		



改进率都为正，但 GÉANT 在不同随机种子之间的波动更明显。




图 5 Abilene 与 GÉANT 上本文方法相对两类基线的八随机种子多指标相对改进分布

固定等权多尺度模型与本文方法共享尺度集合和三个 DLinear 专家，两者的主要区别是融合权重是否随样本变化。表 3 给出三类核心模型的绝对误差均值和标准差，图 5 补充 8 个共同随机种子的相对改进分布，并将比较扩展到 MSE、MAE

图6 八随机种子下样本级自适应路由权重分布

Abilene 中 α_1 、 α_2 和 α_4 的平均权重依次为 0.257、0.319 和 0.424，GÉANT 中依次为 0.283、0.318 和 0.399。两组结果都显示尺度 4 的平均权重最高、尺度 1 最低，三个尺度的均值也与固定等权的 1/3 不同。在本文设置的 24 步预测任务中，路由器整体上更偏向尺度 4 所保留的平滑趋势信息，但尺度 1 和尺度 2 仍保持非零权重，因此最终预测仍由多个时间分辨率共同完成。

表 2、表 3 以及图 3、图 5 和图 6 分别承担不同的比较任务。表 2 给出 DLinear、LightTS 与本文方法的总体误差统计；图 3 只比较独立外部基线 LightTS，展示共同随机种子 42~44 上的多指标降低率和参数规模差异；表 3 和图 5 使用随机种子 42~49 比较 DLinear、固定等权多尺度模型与本文方法，考察多尺度结构和样本级融合方式；图 6 再给出内部尺度权重分布。外部模型比较、内部消融和路由行为因此分开呈现，避免同一结论在多张图中重复表达。

3 结论

本文面向骨干网络 OD 流量中的短时波动和较慢趋势，采用尺度 1、2 和 4 的 DLinear 专家进行多尺度预测，并由轻量路由网络依据输入窗口统计量计算融合权重。Abilene 和 GÉANT 实验表明，本文方法相对 DLinear、LightTS 和固定等权多尺度模型均获得更低的平均预测误差，三个尺度的路由权重也不是固定分配。路由模块仅增加 131 个参数，在较小参数增量下完成了样本级尺度融合，