基于自适应多尺度加权的多变量网络流量预测方法

[请填写作者姓名]

([请填写工作单位] [请填写部门], [省 市 邮编])

摘要：骨干网络源—目的节点对流量同时包含短时起伏与较慢趋势，单一时间分辨率难以兼顾。本文采用尺度 1、2 和 4 的 DLinear 专家，并由输入窗口统计量驱动的轻量路由网络计算 Softmax 融合权重。在 Abilene 和 GÉANT 数据集上，3 个共同随机种子下本文方法相对 DLinear 的 MSE 分别降低 4.06%和 4.43%，相对 LightTS 分别降低 29.89%和 46.83%。8 个随机种子的核心消融进一步加入可学习的全局固定权重对照；本文方法相对该对照的逐种子平均 MSE 改进率分别为 1.80%和 4.31%，分别有 6 次和 7 次取得更低误差。GÉANT 的配对 95%置信区间跨越零，且路由权重变化主要来自随机种子之间，因此当前结果支持平均误差改善，但尚不能证明路由器稳定识别每个窗口的最佳尺度。

关键词：网络流量预测；多变量时间序列；多尺度学习；自适应加权；DLinear

中图分类号：TP393　　**文献标志码：**A

A Multivariate Network Traffic Forecasting Method Based on Adaptive Multiscale Weighting

[Author Name]

([Affiliation] [Department], [City] [Postcode], China; Corresponding author: [Name], E-mail: [E-mail])

Abstract: Backbone origin-destination traffic contains both short-term fluctuations and slower trends. We combine DLinear experts at scales 1, 2, and 4 using Softmax weights generated from input-window statistics. On Abilene and GÉANT, the method reduces MSE relative to DLinear by 4.06% and 4.43%, and relative to LightTS by 29.89% and 46.83%, over three common random seeds. An eight-seed ablation adds a learned global-weight baseline. The mean seed-wise MSE reductions of the adaptive router over this baseline are 1.80% and 4.31%, with improvements in six and seven of eight seeds, respectively. The paired 95% confidence interval for GÉANT includes zero, and most of its pooled router-weight variance arises between seeds. Thus, the observed average error reduction does not yet establish reliable window-specific scale selection.

Key words: network traffic forecasting; multivariate time series; multiscale learning; adaptive weighting; DLinear

骨干网络中的源—目的节点对（origin-destination，OD）流量直接反映不同节点对之间的通信需求。随着云计算、视频业务、数据中心互联及智能网络应用持续增加，业务在网络内部的迁移和聚集更加频繁，OD 流量的时间变化也更复杂。容量规划、拥塞预警、资源调度和流量工程都需要对后续流量状态作出判断，提前获得后一时段的 OD 流量估计有助于网络管理系统预先调整资源。与较平稳的单变量序列相比，OD 流量中往往同时存在周期变化、局部波动和突发变化，不同 OD 变量的数值范围也有明显差异，因此预测模型既要描述较长时间范围内的变化趋势，也要保留对短时状态变化的响应。

网络流量预测已经从传统统计模型逐步扩展到机器学习和深度学习方法。Lohrasbinasab 等[1]对相关方法进行了系统梳理，并指出数据驱动方法在复杂流量预测中的应用不断增加。网络规模扩大后，仅分析单一序列的时间变化已不足以覆盖 OD 变量之间的关联。Qin 等[2]把图神经网络引入通信网络流量预测，在同一模型中处理空间关联和时间依赖；韦烜等[10]针对大型 IP 网络流量矩阵开展分析与预测，讨论了不同

收稿日期：[请填写，格式 YYYY-MM-DD]

基金项目：[基金来源]（[基金项目编号]）

第一作者简介：[姓名]（[出生年]—），[性别（民族，汉族可省略）]，[职称]，[学位（若在读请注明）]，研究方向：[方向 1]；[方向 2]。

通信作者简介：[姓名]（[出生年]—），[性别（民族，汉族可省略）]，[职称]，[学位（若在读请注明）]，研究方向：[方向 1]；[方向 2]，电子邮箱：[邮箱]。

OD 变量之间的关联及其时间变化。唐文杰等[11]则在 CycleLLH 模型中引入周期性信息。现有工作已经涉及时间依赖、变量关联和周期结构等多个方面，也为进一步分析不同时间分辨率下的流量变化提供了基础。

同一段网络流量在不同时间分辨率下呈现的特征并不一致。原始分辨率保留更多局部细节，短时起伏表现得更明显；时间聚合会削弱部分局部扰动，使较慢的变化趋势更容易观察。Zhou 等[3]利用深度回声状态网络进行多尺度网络流量预测，通过不同时间分辨率提取互补信息。另一方面，模型结构开销也需要考虑。DLinear[4]采用时间序列分解和线性映射完成预测；TimeMixer[5]利用多尺度混合机制处理不同分辨率序列；LightTS[6]采用采样导向的 MLP 结构进行快速多变量时间序列预测。本文在这些工作的基础上，把关注点放在多时间尺度信息的利用与模型规模控制之间的平衡。

多尺度方法通常先给定若干时间尺度，再把各尺度结果按既定方式融合。问题在于，不同输入窗口的流量状态并不相同：某些窗口以短时波动为主，另一些窗口则表现为更平缓的趋势。输入状态变化时，尺度 1、2 和 4 对预测的作用也可能发生变化。只使用单一尺度会舍弃其他时间分辨率的信息，而长期采用固定融合比例又难以体现窗口之间的状态差异。基于这一现象，本文不仅构造多个时间尺度，还让各尺度在最终预测中的参与程度随当前输入样本变化。

本文采用样本级自适应多尺度结构处理上述问题。历史窗口按尺度 1、2 和 4 构造多分辨率序列，每个尺度由一个 DLinear 专家给出候选预测。路由网络不重新编码完整时序，而是读取当前输入窗口的总体水平、离散程度、最近状态和变化强度等统计量，生成 Softmax 尺度权重，并据此融合三个专家的结果。这样可以把尺度内预测与尺度间选择分开处理。实验在 Abilene 和 GÉANT 两个公开骨干网数据集上进行，并设置 DLinear、LightTS、固定等权多尺度模型、多个随机种子重复实验和路由权重分析，用于检验预测误差、核心结构消融和尺度分配行为。

1 自适应多尺度网络流量预测方法

图 1 给出模型的整体流程。方法把多尺度预测和尺度选择分成两个模块：尺度 1、2 和 4 的输入分别交给独立 DLinear 专家，路由网络根据当前窗口的统计特征估计 3 个尺度的融合权重。原始 OD 流量先进行对数变换和标准化，再形成 3 个时间分辨率的输入序列；3 个专家得到候选预测后，由样本级权重完成融合。固定等权消融模型保留相同的尺度和专家，因此能够单独比较样本级权重带来的变化。

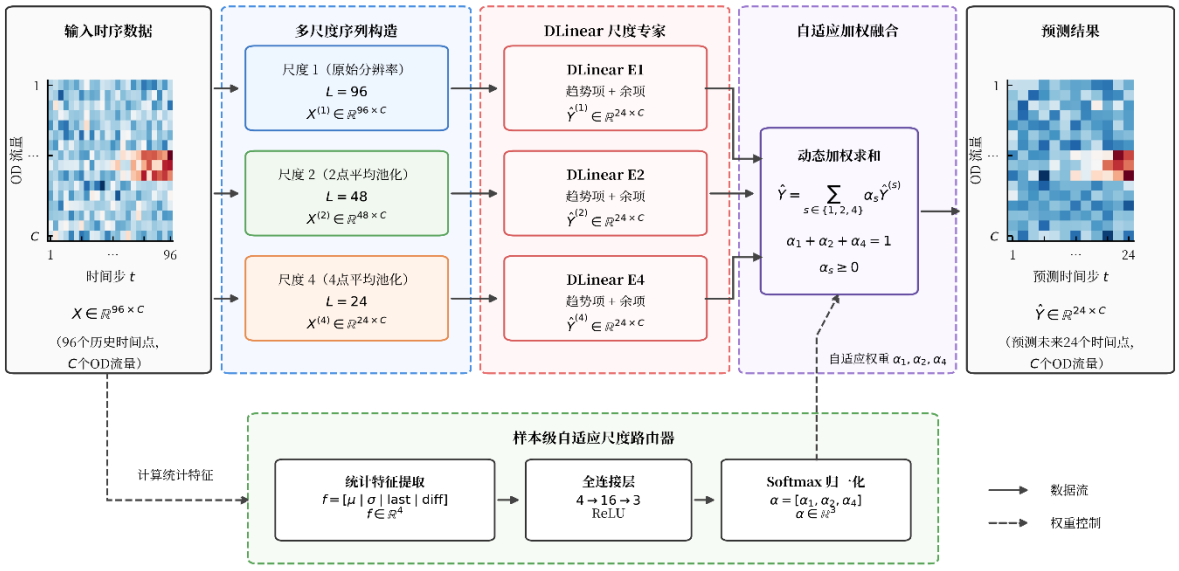


图 1 自适应多尺度网络流量预测方法框架

三个时间尺度保留的信息并不相同。原始尺度包含更多局部变化，较粗尺度经过时间聚合后削弱部分短时扰动，更突出较慢的变化趋势。只使用一个尺度会舍弃其他分辨率的信息；长期采用固定比例又不能随输入窗口变化。本文保留 3 个尺度的独立预测，再由路由网络确定每个样本的组合比例。DLinear 结构较简洁，可在控制模型规模的同时承担各尺度的预测任务，使实验重点落在多尺度输入和样本级融合本身。

1.1 问题定义与数据预处理

记预处理后的多变量流量序列为 xt∈RC，其中 t 表示时间索引，C 表示有效 OD 变量数。连续序列按时间滑动后形成监督学习样本。第 n 个样本包含历史窗口 Xn 和预测目标 Yn：Xn 覆盖连续 L 个时间点，Yn 为紧随其后的 H 个时间点。模型据此利用多个 OD 变量过去 L 步的联合变化估计未来 H 步取值。第 n 个样本对应的输入与目标定义为

$$\boldsymbol{X}_n = \left[x_n, \dots, x_{\{n+L-1\}}\right] \in \boldsymbol{R}^{\{L\times C\}}, \tag{1}$$

$$\boldsymbol{Y}_n = \left[x_{\{n+L\}}, \dots, x_{\{n+L+H-1\}}\right] \in \boldsymbol{R}^{\{H\times C\}}. \tag{2}$$

本文设置输入长度 L=96、预测长度 H=24，变量数 C 由各数据集保留的有效 OD 维度确定，学习映射记为 Ŷn=fθ(Xn)。L 对应一次预测所使用的历史范围，H 表示需要连续预测的未来长度。原始 OD 流量均为非负值，而且不同 OD 变量之间的量级差异较大。若直接以原始数值训练，较大范围的变量会使各维数据处在不一致的数值尺度上，因此先对原始流量 vt,c 作对数变换

$$u_{\{t,c\}} = \log\left(1 + v_{\{t,c\}}\right), \tag{3}$$

再按变量进行标准化：

$$x_{\{t,c\}} = \frac{u_{\{t,c\}} - \mu_c^{\{\mathrm{tr}\}}}{\sigma_c^{\{\mathrm{tr}\}}}. \tag{4}$$

其中 μctr 和 σctr 分别为第 c 个 OD 变量在训练集上的均值和标准差，验证集和测试集均使用训练阶段得到的统计量。log(1+x)先压缩非负流量的数值范围，同时保留流量大小关系；随后按变量标准化，使不同 OD 维度在相近的数值尺度上参与训练。前一步主要缓和原始流量的量级差异，后一步用于统一各变量参与损失计算和参数更新时的尺度。数据仍按时间顺序以 6:2:2 划分为训练集、验证集和测试集，各集合内部独立生成滑动窗口，避免窗口跨越不同数据划分边界。

经过上述处理后，每个输入样本仍保持原始时间分辨率。为了让后续专家同时观察细粒度变化和较平滑的趋势，需要进一步从同一历史窗口构造不同时间尺度的表示。

1.2 多尺度序列构造

设尺度集合 S={1,2,4}。尺度 s 表示沿时间维进行聚合时使用的窗口大小。对于任一尺度 s，采用窗口大小为 s、步长也为 s 的非重叠平均池化：

$$\boldsymbol{X}_{\{n,t\}}^{\{(s)\}} = \left(\frac{1}{s}\right) \Sigma_{\{i=0\}^{\{s-1\}X}_{\{n,st+i\}}}, \quad t = 0, \dots, \frac{L}{s} - 1. \tag{5}$$

本文使用尺度集合 S={1,2,4}。在输入长度 L=96 时，尺度 1 保留原始 96 步序列；尺度 2 将相邻 2 个

时间点取平均，得到 48 步序列；尺度 4 按 4 个时间点进行平均，得到 24 步序列。三者分别对应原始、中等和平滑程度更高的时间表示。尺度 1 不压缩时间轴，因此保留较完整的短时起伏；尺度 2 对局部变化进行适度平滑；尺度 4 进一步削弱短时间内的高频变化，使较慢的变化趋势更突出。这里采用平均池化而不是新增可训练的尺度变换模块，是为了在构造多分辨率输入时不额外增加模型参数。

尺度集合采用 1、2 和 4，主要是为了在 96 步历史窗口内形成三个层次清晰且长度均为整数的时间分辨率，同时控制专家数量。尺度继续增加虽然可以产生更粗的序列，但也会继续缩短有效时间长度并增加新的专家分支。本文并不将{1,2,4}作为经过穷举得到的最优尺度组合，而是把它作为兼顾细粒度信息、趋势信息和模型规模的一组固定设计。采用非重叠池化还使每个原始时间点只参与一次同尺度聚合，尺度变化的含义较为直接。

1.3 DLinear 尺度专家

尺度 1、2 和 4 分别配置一个 DLinear 专家[4]，每个专家只处理本尺度对应的输入序列。DLinear 的核心思路是先将序列拆分为变化较慢的趋势项和围绕趋势变化的余项，再分别完成时间映射。对尺度 s 的输入，本文使用长度 q=25 的中心移动平均提取趋势项。移动平均相当于在局部时间邻域内进行平滑，为避免序列两端因窗口不足而缩短，边界位置采用端点复制方式补齐，从而保持分解前后的时间长度一致：

$$\boldsymbol{T}_{\{n,t\}}^{\{(s)\}} = \left(\frac{1}{q}\right) \Sigma_{\{i=-m\}}^{\{m\}} \bar{\boldsymbol{X}}_{\{n,t+i\}}^{\{(s)\}}, \quad q = 2m + 1 = 25, \tag{6}$$

$$\boldsymbol{R}_n^{\{(s)\}} = \boldsymbol{X}_n^{\{(s)\}} - \boldsymbol{T}_n^{\{(s)\}}. \tag{7}$$

趋势项 $\boldsymbol{T}^{(s)}$和余项 $\boldsymbol{R}^{(s)}$沿时间维分别通过线性层映射到预测长度 H：

$$\hat{\mathrm{Y}}_n^{\{(s)\}} = \boldsymbol{W}_{\mathrm{T}}^{\{(s)\}} \boldsymbol{T}_n^{\{(s)\}} + \boldsymbol{b}_{\mathrm{T}}^{\{(s)\}} + \boldsymbol{W}_{\mathrm{R}}^{\{(s)\}} \boldsymbol{R}_n^{\{(s)\}} + \boldsymbol{b}_{\mathrm{R}}^{\{(s)\}}. \tag{8}$$

由式（6）和式（7）可得到尺度 s 上的趋势项 T(s)和余项 R(s)。趋势项表示经过局部平滑后保留下来的较慢变化部分，余项则由原序列减去趋势项得到，保留未被移动平均解释的局部变化。式（8）分别对两部分沿时间维进行线性映射，并把二者的预测结果相加形成该尺度的候选预测。3 个尺度使用独立 DLinear 专家，是因为尺度 1、2 和 4 的输入长度分别为 96、48 和 24，对应的时间分辨率和时间映射关系并不相同；若强制共用一组尺度间参数，会把不同长度、不同平滑程度的序列约束到同一映射中。同一尺度内部，各 OD 变量共享时间映射参数，模型学习的是这一时间尺度下通用的时间映射形式，而不是为每个 OD 变量分别建立一套线性层。

采用 DLinear 作为尺度专家，主要是为了把预测主干与尺度融合的影响区分开。本文需要比较单尺度预测、固定等权多尺度和样本级自适应多尺度三种设置；若尺度专家本身过于复杂，误差变化会同时受到主干结构和融合机制影响。DLinear 参数关系清晰，在保持基本预测能力的同时，更适合作为统一的尺度专家。

1.4 样本级自适应尺度加权

3 个 DLinear 专家会针对同一样本给出 3 组预测结果，随后需要确定它们在最终输出中的占比。若始终令 3 个尺度均取 1/3，就等价于假设所有输入窗口具有相同的尺度需求。但实际窗口的状态存在差别：局部波动较强时，细粒度信息可能更重要；变化较平稳时，较粗尺度中的趋势信息可能更有价值。为使融合比例能够随样本变化，本文从原始输入 Xn 提取四维统计向量 zn=[μn,σn,ℓn,dn]，用这些统计量描述当前窗口状态，其中

$$\mu_n = \left(\frac{1}{LC}\right)\Sigma_{\{t,c\}}\boldsymbol{X}_{\{n,t,c\}}, \quad \sigma_n = \sqrt{\left(\frac{1}{LC}\right)\Sigma^2_{\{t,c\}}\left(\boldsymbol{X}_{\{n,t,c\}}-\mu_n\right)}, \tag{9}$$

$$\ell_n = \left(\frac{1}{C}\right)\Sigma_c\boldsymbol{X}_{\{n,L-1,c\}}, \quad d_n = \left(\frac{1}{(L-1)C}\right)\Sigma_{\{t=1\}}^{\{L-1\}\Sigma}{}_c\left|\boldsymbol{X}_{\{n,t,c\}}-\boldsymbol{X}_{\{n,t-1,c\}}\right|. \tag{10}$$

μn、σn、ℓn 和 dn 分别描述输入窗口的总体水平、离散程度、最近状态和平均变化强度。μn 反映窗口整体流量水平，σn 刻画观测值的离散程度，ℓn 取窗口末时刻的平均状态，dn 由相邻时间点的一阶变化得到。这 4 个统计量分别提供水平、波动、最近状态和局部变化信息，供路由器判断当前样本更适合依赖哪些时间尺度，而不直接参与未来流量数值的预测。

$$\boldsymbol{a}_n = \boldsymbol{W}_{2\mathrm{ReLU}(\boldsymbol{W}_{1z_n}+\boldsymbol{b}_1)} + \boldsymbol{b}_2. \tag{11}$$

四维向量输入隐藏维数为 16 的两层感知器，输出 3 个尺度的未归一化分数。路由器只需判断尺度的相对重要性，不需要再次完成完整的 OD 流量预测，因此本文未引入循环网络、注意力网络等额外时序编码器。使用低维统计量和较小隐藏层，也能把路由模块的参数规模控制在较低水平。其尺度分数计算为

式（11）得到的 3 个尺度分数仍是未归一化值。为使这些分数可以直接解释为各专家在最终预测中的相对贡献，使用 Softmax 进行归一化。经 Softmax 处理后，每个权重均为非负值，并且 3 个权重之和为 1：

$$\alpha_{\{n,s\}} = \frac{\exp\left(a_{\{n,s\}}\right)}{\Sigma_{\{j\in S\}}\exp\left(a_{\{n,j\}}\right)}, \quad \alpha_{\{n,s\}} \geq 0, \quad \Sigma_s\alpha_{\{n,s\}} = 1. \tag{12}$$

最终预测为

$$\hat{\mathrm{Y}}_n = \Sigma_{\{s\in S\}}\alpha_{\{n,s\}}\hat{\mathrm{Y}}_n^{\{(s)\}}. \tag{13}$$

式（13）利用上述权重对 3 个 DLinear 专家的预测结果进行加权求和，得到最终预测 Ŷn。该组权重由输入窗口计算，并由同一窗口内的全部 OD 变量共享。为了区分多尺度结构、非等权分配与样本相关分配的作用，设置两种共享相同专家的对照：固定等权模型将三个尺度恒定设为 1/3；全局可学习权重模型以三个可训练参数经 Softmax 得到一组常权重，对所有窗口共用。后者与本文方法的差别集中在权重是否依赖输入窗口。

1.5 训练目标与模型复杂度

模型训练以均方误差作为优化目标。误差在训练样本、未来 H 个预测时刻以及全部 C 个 OD 变量上共

同计算，因此每次参数更新同时考虑不同预测步和不同 OD 维度的偏差。对应训练目标为

$$L_{\{\mathrm{MSE}\}} = \left(\frac{1}{NHC}\right) \Sigma_{\{n=1\}}^{\{N\}} \Sigma_{\{h=1\}}^{\{H\}} \Sigma_{\{c=1\}}^{\{C\}} \left(Y_{\{n,h,c\}} - \hat{Y}_{\{n,h,c\}}\right)^2 . \tag{14}$$

参数训练使用 Adam 优化器，并以验证集 MSE 选择最终模型。单尺度 DLinear 包含 4656 个可训练参数；三个尺度专家的固定等权模型包含 8208 个参数；增加三个全局权重参数后为 8211 个参数；样本级路由模型为 8339 个参数。路由网络相对固定等权模型增加 131 个参数，相对全局权重模型增加 128 个参数。各多尺度模型共享专家结构，因此全局权重对照可用于检验输入相关融合的额外作用。

模型的计算过程可以概括为三个环节：平均池化把同一历史窗口转换为 3 个时间分辨率，DLinear 专家分别给出候选预测，路由网络再根据原始窗口的 4 个统计量确定融合权重。多尺度序列决定模型从哪些时间分辨率读取历史信息，尺度专家完成各自的预测，路由网络只负责组合结果。后续实验据此设置单尺度 DLinear、固定等权多尺度模型和本文方法，用同一组专家结构区分多尺度信息与样本级加权的作用。

2 实验与结果分析

实验按外部基线、核心消融和路由行为三个层次组织。DLinear 和 LightTS 提供相同预测任务下的外部误差参照；固定等权、全局可学习常权重与样本级路由模型共享三个尺度专家，依次检验多尺度结构、非等权融合及输入相关权重的作用；八个共同随机种子的配对结果和逐种子权重分析用于评估结果波动。

2.1 数据集与实验设置

实验数据取自 CESNET TS-Zoo[7]，包括 1 h 聚合的 Abilene[8]和 GÉANT[9]骨干网流量矩阵。Abilene 共有 4656 个时间点，保留 144 维有效 OD 流量；GÉANT 共有 2849 个时间点，去除恒定通道后保留 524 维有效 OD 流量。两者在序列长度和变量规模上差异较大，能够在相同预测流程下提供不同的数据条件。两个数据集均按时间顺序以 6:2:2 划分为训练集、验证集和测试集，输入长度 L=96，预测长度 H=24，预处理方式与第 1.1 节一致。表 1 列出了数据规模和窗口数量。

表 1 数据集与预测任务设置

数据集	时间点	有效变量 C	训练/验证/测试时间点	训练/验证/测试窗口	L/H
Abilene	4656	144	2793/931/932	2674/812/813	96/24
GÉANT	2849	524	1709/570/570	1590/451/451	96/24

所有对比模型使用相同的数据划分、输入长度、预测长度、评价指标和批量大小，batch size 统一为 16。实验不为各模型单独搜索最优超参数，而是在统一预测任务下控制数据与训练条件。DLinear、固定等权多尺度、全局可学习权重和本文方法最多训练 30 轮，LightTS 最多训练 50 轮；均根据验证集 MSE 选择测试所用参数，测试集仅用于最终统计。

外部基线比较使用随机种子 42～44 共 3 个共同随机种子。核心消融使用随机种子 42～49 共 8 个共同随机种子，比较 DLinear、固定等权多尺度、全局可学习权重和本文方法。全局权重由等权初始化，与三个专家一同训练，并按相同验证集准则选择模型；随机种子作为配对统计单位。

2.2 对比模型与评价指标

实验设置 DLinear、LightTS、固定等权多尺度和全局可学习权重四类对照。DLinear 用于比较单一尺度与多尺度结构；LightTS 提供独立轻量模型基线。后两种多尺度对照与本文方法保留相同的尺度集合{1,2,4}和 DLinear 专家：固定等权模型始终按 1/3 融合，全局权重模型学习一组对所有窗口共用的 Softmax 权重。

由此，全局权重模型与本文方法的比较更直接地检验输入相关权重是否带来收益。

预测性能采用均方误差（MSE）、平均绝对误差（MAE）和均方根误差（RMSE）评价。MSE 按式（14）计算，MAE 和 RMSE 分别定义为

$$\mathrm{MAE} = \left(\frac{1}{N_{\{\mathrm{te}\}HC}}\right) \Sigma_{\{n,h,c\}} \left|\boldsymbol{Y}_{\{n,h,c\}} - \hat{\mathrm{Y}}_{\{n,h,c\}}\right|, \tag{15}$$

$$\mathrm{RMSE} = \sqrt{\mathrm{MSE}}. \tag{16}$$

MSE、MAE 和 RMSE 均在标准化空间中计算，数值越小表示预测误差越低。MSE 对较大误差更敏感，MAE 反映绝对误差的平均水平，RMSE 是 MSE 开方后的结果，可与误差幅值直接对照。正文以 MSE 和 MAE 作为主要比较指标，RMSE 用于补充。表 2 统计随机种子 42～44 的均值±标准差，表 3 统计随机种子 42～49 的均值±标准差，同时给出平均水平和重复实验间的波动。

2.3 两数据集外部基线比较

表 2 列出 3 个共同随机种子下的总体基线结果。本文方法在 Abilene 上的 MSE 为 0.186，在 GÉANT 上为 0.434；相对 DLinear 分别降低 4.06%和 4.43%，相对 LightTS 分别降低 29.89%和 46.83%，MAE 呈相同方向变化。DLinear 与本文尺度专家采用同源结构，后续核心消融继续以它作为单尺度内部基线；LightTS 属于独立外部结构基线，图 3 进一步给出逐随机种子、多指标和参数规模比较。

表 2 三随机种子外部基线比较

数据集	模型	参数量	MSE	MAE
Abilene	DLinear	4656	0.194±0.002	0.188±0.009
Abilene	LightTS	130162	0.265±0.011	0.204±0.008
Abilene	本文方法	8339	0.186±0.002	0.168±0.001
GÉANT	DLinear	4656	0.454±0.007	0.383±0.006
GÉANT	LightTS	384382	0.817±0.024	0.523±0.014
GÉANT	本文方法	8339	0.434±0.051	0.370±0.031

图 3 聚焦独立外部基线 LightTS，并使用两种方法共同具备的随机种子 42～44。按（LightTS 误差−本文方法误差）/LightTS 误差计算每次实验的相对降低率后，Abilene 上的 MSE、MAE 和 RMSE 平均降低 29.80%、17.57%和 16.23%，GÉANT 上分别降低 46.89%、29.15%和 27.18%。两个数据集的 3 个共同随机种子在三项指标上均为正向降低。参数量方面，本文方法为 8339，LightTS 在 Abilene 和 GÉANT 上分别为 130162 和 384382，本文方法约为其 6.41%和 2.17%。图 3 因此只承担外部结构基线比较，DLinear 和固定等权模型的内部比较放在表 3 和图 5 中。

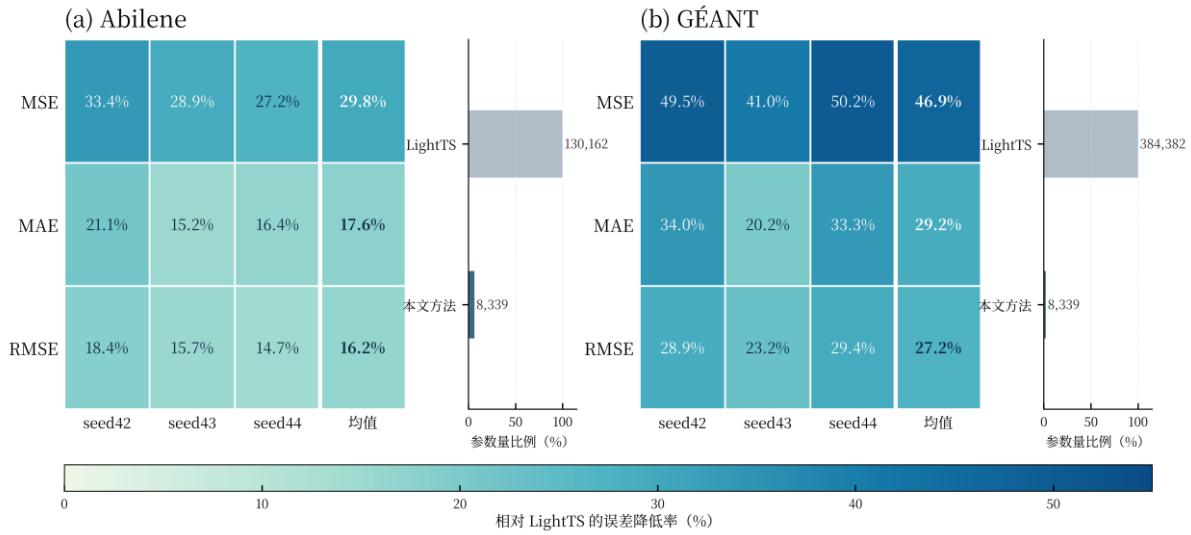


图 3 Abilene 与 GÉANT 上本文方法相对 LightTS 的三随机种子多指标性能提升

两个数据集上的相对降幅并不相同。GÉANT 包含的 OD 变量数高于 Abilene，同时本文方法相对 LightTS 的 MSE 降幅也更大，但现有实验不能把这种差异直接归因于变量规模。固定等权与全局可学习权重对照均采用相同的多尺度专家结构，适合进一步检验融合方式本身的作用。

2.4 八随机种子核心消融与稳定性

表 3 中的核心消融覆盖随机种子 42～49，共重复 8 次。相对单尺度 DLinear，本文方法在 Abilene 和 GÉANT 上的平均 MSE 分别降低 2.77%和 2.37%；相对固定等权模型，平均 MSE 分别降低 1.67%和 4.68%。新增的全局可学习权重模型允许尺度权重不等，但对全部窗口保持恒定。与该模型逐种子配对比较，本文方法的平均 MSE 改进率分别为 1.80%和 4.31%，分别在 6/8 和 7/8 个种子上胜出；t 分布近似的 95%置信区间分别为[0.01%,3.58%]和[−2.51%,11.13%]。Abilene 优势较小，GÉANT 区间跨越零，不能据此断言跨初始化稳定优于全局权重。

表 3 八随机种子核心消融结果（均值±标准差）

数据集	模型	参数量	MSE	MAE
Abilene	DLinear	4656	0.194±0.002	0.189±0.008
Abilene	固定等权多尺度	8208	0.192±0.002	0.191±0.006
Abilene	全局可学习权重	8211	0.192±0.002	0.190±0.006
Abilene	本文方法	8339	0.189±0.003	0.173±0.008
GÉANT	DLinear	4656	0.437±0.016	0.371±0.011
GÉANT	固定等权多尺度	8208	0.447±0.014	0.377±0.009
GÉANT	全局可学习权重	8211	0.446±0.014	0.377±0.009
GÉANT	本文方法	8339	0.426±0.029	0.366±0.018

图 5 汇总随机种子 42～49 下的相对改进结果，比较对象为 DLinear 和固定等权多尺度模型，指标包括 MSE、MAE 和 RMSE。图中的散点对应单次随机种子实验，半小提琴表示 8 次结果的分布，圆点和误差线表示逐随机种子改进率的均值及 95%置信区间，0%虚线表示两种方法误差相同。相对 DLinear 时，Abilene 的 MSE、MAE 和 RMSE 平均改进率为 2.77%、8.01%和 1.40%，其中 MSE 与 RMSE 在 8 次实验中均改

善；GÉANT 分别为 2.35%、1.32%和 1.22%，且跨越 0%的情况更多。相对固定等权模型时，Abilene 三项指标的平均改进率为 1.65%、8.92%和 0.84%，GÉANT 为 4.54%、3.05%和 2.37%。两种基线下的平均改进率都为正，但 GÉANT 在不同随机种子之间的波动更明显。

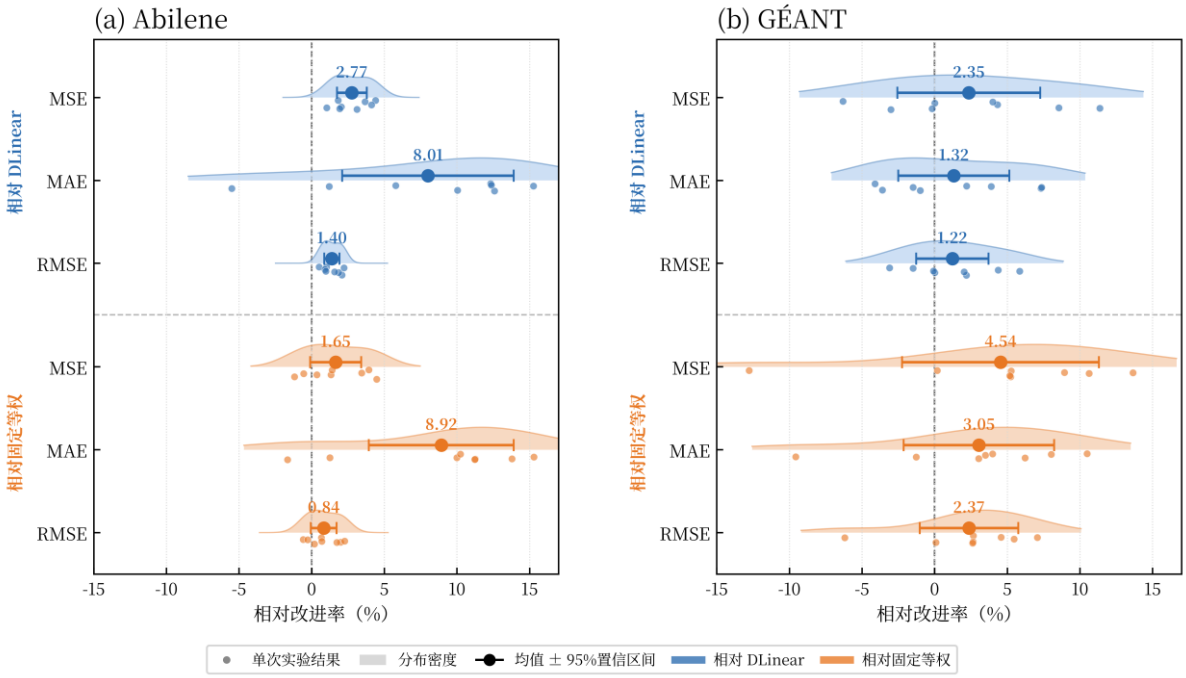


图 5 Abilene 与 GÉANT 上本文方法相对两类基线的八随机种子多指标相对改进分布

固定等权模型只能检验等权融合是否足够；一组经训练得到的全局常权重可进一步控制“权重不等”这一因素。表 3 显示本文方法在两数据集上的平均 MSE 低于全局权重模型，但种子间优势并不稳定，尤其 GÉANT 存在一次明显退化。图 5 仍展示相对 DLinear 和固定等权模型的多指标分布；全局权重的逐种子配对结果见表 3 及本节统计。

2.5 路由权重分析

图 6 分别显示随机种子 42～49 下三个尺度的平均路由权重。每个圆点对应一个种子在全部测试窗口上的均值，误差线为同一种子内测试窗口的标准差，虚线表示 1/3。这样可直接区分模型初始化造成的权重差异与同一模型随窗口变化的幅度。

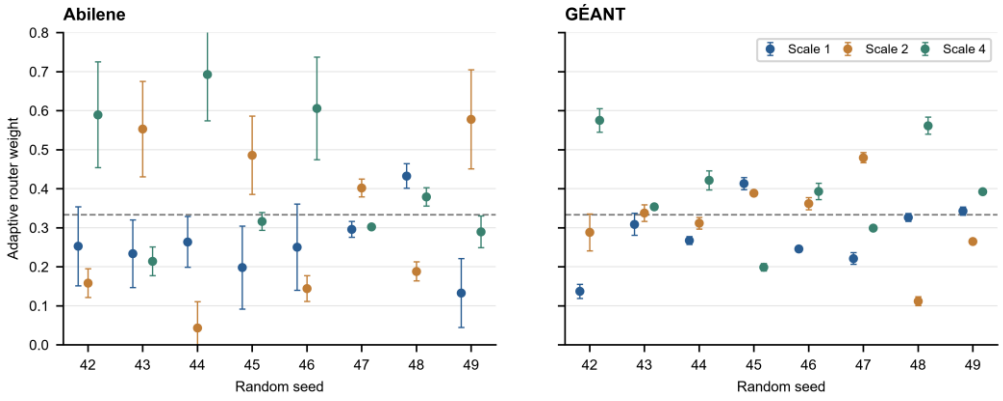


图 6 各随机种子路由权重均值及测试窗口内标准差

Abilene 三个尺度的汇总平均权重为 0.257、0.319 和 0.424，GÉANT 为 0.283、0.318 和 0.399。虽然总体均值偏离 1/3，但 GÉANT 三个尺度的汇总权重方差约 96.2%、95.8%和 97.7%来自种子之间；同一种子内随测试窗口的变化较小。Abilene 的对应比例为 48.7%、86.1%和 80.6%。因此，合并所有种子的权重分布不能单独证明路由器有效识别每个窗口的尺度需求。

进一步以输入窗口平均绝对一阶差分衡量波动强度，并用训练窗口的三分位数阈值划分测试窗口。Abilene 低、中、高波动组分别有 15、406、392 个窗口，本文方法相对全局权重模型的逐种子平均 MSE 改进率分别为 4.43%、1.90%、1.69%；GÉANT 在训练阈值下无低波动测试窗口，中、高组分别有 76、375 个窗口，改进率为 5.85%和 4.06%。Abilene 高波动组的尺度 1 平均权重高于中波动组，但误差优势并未更强；GÉANT 中、高组的权重近似相同。分组结果尚不支持“波动越强，路由收益越大”的解释。

3 结论

本文面向骨干网络 OD 流量中的短时波动和较慢趋势，以尺度 1、2 和 4 的 DLinear 专家构建多尺度预测，并通过轻量路由网络计算输入相关融合权重。在 Abilene 和 GÉANT 上，本文方法相对 DLinear、LightTS 和固定等权模型取得较低平均误差。加入全局可学习权重对照后，样本级路由的逐种子平均 MSE 改进率分别为 1.80%和 4.31%，但 GÉANT 的 95%置信区间跨越零。逐种子权重及波动分组分析也未能充分证明路由器稳定地匹配每个窗口的尺度需求。后续需在更多数据和预测设置下检验这种输入相关融合的稳定收益。

参考文献

[1] LOHRASBINASAB I, KESHAVARZ A, AMIN-NEJAD S, et al. From statistical- to machine learning-based network traffic prediction[J]. Transactions on Emerging Telecommunications Technologies, 2022, 33(4): e4394. DOI: 10.1002/ett.4394.

[2] QIN L, GU H, WEI W, et al. Spatio-temporal communication network traffic prediction method based on graph neural network[J]. Information Sciences, 2024, 679: 121003. DOI: 10.1016/j.ins.2024.121003.

[3] ZHOU J, HAN T, XIAO F, et al. Multiscale network traffic prediction method based on deep echo-state network for Internet of Things[J]. IEEE Internet of Things Journal, 2022, 9(21): 21862-21874. DOI: 10.1109/JIOT.2022.3181807.

[4] ZENG A, CHEN M, ZHANG L, et al. Are transformers effective for time series forecasting?[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2023, 37(9): 11121-11128. DOI: 10.1609/aaai.v37i9.26317.

[5] WANG S, WU H, SHI X, et al. TimeMixer: decomposable multiscale mixing for time series forecasting[C]//International Conference on Learning Representations. 2024.

[6] ZHANG T, ZHANG Y, CAO W, et al. Less is more: fast multivariate time series forecasting with light sampling-oriented MLP structures[EB/OL]. (2022-07-04)[2026-09-20]. https://arxiv.org/abs/2207.01186. DOI: 10.48550/arXiv.2207.01186.

[7] KUREŠ M, KOUMAR J, HYNEK K. CESNET TS-Zoo: a library for reproducible analysis of network traffic time series[C]//2025 21st International Conference on Network and Service Management. 2025. DOI: 10.23919/CNSM67658.2025.11297513.

[8] ZHANG Y, ROUGHAN M, DUFFIELD N, et al. Fast accurate computation of large-scale IP traffic matrices from link loads[J]. ACM SIGMETRICS Performance Evaluation Review, 2003, 31(1): 206-217. DOI: 10.1145/885651.781053.

[9] UHLIG S, QUOITIN B, LEPROPRE J, et al. Providing public intradomain traffic matrices to the research community[J]. ACM SIGCOMM Computer Communication Review, 2006, 36(1): 83-86. DOI: 10.1145/1111322.1111341.

[10] 韦烜, 刘志华, 李青, 等. 大型 IP 网络流量矩阵分析预测的探讨研究[J]. 系统工程与电子技术, 2024, 46(6): 2164-2173. DOI: 10.12305/j.issn.1001-506X.2024.06.35.

[11] 唐文杰, 肖一磊, 孔祥宇, 等. CycleLLH：一种基于周期性整合的新型网络流量预测模型[J]. 计算机学报, 2024, 47(12): 2867-2888. DOI: 10.11897/SP.J.1016.2024.02867.