基于自适应多尺度加权的多变量网络流量预测方法

[请填写作者姓名]

([请填写工作单位] [请填写部门], [省 市 邮编])

摘要：骨干网络源—目的节点对流量兼有短时起伏和较慢趋势，单一时间分辨率难以同时表征两者。本文采用尺度 1、2 和 4 的 DLinear 专家，由轻量路由网络根据输入窗口统计量生成 Softmax 融合权重。在输入长度 96、预测长度 24 的 Abilene 和 GÉANT 实验中，3 个共同随机种子下本文方法相对 DLinear 的 MSE 分别降低 4.07%和 4.54%，相对 LightTS 分别降低 29.80%和 46.89%。8 个随机种子的核心消融加入全局可学习权重和恒定输入路由两类固定权重对照；本文方法相对两者在 Abilene 上的逐种子平均 MSE 改进率均约为 1.80%，在 GÉANT 上分别为 4.31%和 4.97%。GÉANT 的两项配对 95%置信区间均跨越零，且路由权重变化主要来自随机种子之间，因此当前结果支持平均误差改善，但尚不能证明路由器稳定识别每个窗口的最佳尺度。

关键词：网络流量预测；多变量时间序列；多尺度学习；自适应加权；DLinear

中图分类号：TP393　　**文献标志码：**A

A Multivariate Network Traffic Forecasting Method Based on Adaptive Multiscale Weighting

[Author Name]

([Affiliation] [Department], [City] [Postcode], China; Corresponding author: [Name], E-mail: [E-mail])

Abstract: Short-term fluctuations and slower trends coexist in backbone origin-destination traffic. Input-window statistics determine the Softmax weights used to combine DLinear experts at scales 1, 2, and 4. For input length 96 and forecast length 24, results from three common random seeds give MSE reductions of 4.07% on Abilene and 4.54% on GÉANT relative to DLinear. The corresponding reductions relative to LightTS are 29.80% and 46.89%. An eight-seed ablation adds two fixed-weight controls: learned global weights and a router receiving constant input. Mean seed-wise MSE reductions over the two controls are both about 1.80% on Abilene; on GÉANT, they are 4.31% and 4.97%, respectively. Both paired 95% confidence intervals on GÉANT include zero, and most of its pooled router-weight variance arises between seeds. Reliable window-specific scale selection therefore remains unconfirmed despite the average error reduction.

Key words: network traffic forecasting; multivariate time series; multiscale learning; adaptive weighting; DLinear

骨干网络中的源—目的节点对（origin-destination，OD）流量直接反映不同节点对之间的通信需求。容量规划、拥塞预警、资源调度和流量工程需要判断后续的 OD 流量状态。云计算、视频业务、数据中心互联及智能网络应用的增加，使业务迁移和聚集更加频繁，也使这种判断面临更复杂的时间变化。OD 流量中的周期变化常与局部波动、突发变化叠加，各变量的数值范围也不同。相较于较平稳的单变量序列，这类数据要求模型在描述较长时间趋势时仍能响应短时变化。

Lohrasbinasab 等[1]系统梳理了网络流量预测方法，指出机器学习和深度学习等数据驱动方法在复杂流量预测中的应用不断增加，反映了传统统计模型之外的研究扩展。网络规模扩大也使 OD 变量之间的关联更难由单一序列的时间分析覆盖。Qin 等[2]把图神经网络引入通信网络流量预测，在同一模型中处理空间关联和时间依赖；韦烜等[3]针对大型 IP 网络流量矩阵开展分析与预测，讨论了不同 OD 变量之间的关联

收稿日期：[请填写，格式 YYYY-MM-DD]

基金项目：[基金来源]（[基金项目编号]）

第一作者简介：[姓名]（[出生年]—），[性别（民族，汉族可省略）]，[职称]，[学位（若在读请注明）]，研究方向：[方向 1]；[方向 2]。

通信作者简介：[姓名]（[出生年]—），[性别（民族，汉族可省略）]，[职称]，[学位（若在读请注明）]，研究方向：[方向 1]；[方向 2]，电子邮箱：[邮箱]。

及其时间变化。唐文杰等[4]则在 CycleLLH 模型中引入周期性信息。上述研究涉及的时间依赖、变量关联与周期结构，构成了流量预测的不同观察角度。

不同时间分辨率下，流量序列中可观察的变化不同：原始分辨率保留短时起伏等局部细节，时间聚合则平滑部分扰动，突出较慢的趋势。Zhou 等[5]利用深度回声状态网络进行多尺度网络流量预测，通过不同时间分辨率提取互补信息。多尺度信息的利用还需考虑模型结构开销。DLinear[6]采用时间序列分解和线性映射完成预测；TimeMixer[7]利用多尺度混合机制处理不同分辨率序列；LightTS[8]采用采样导向的 MLP 结构进行快速多变量时间序列预测。本文的设计由此同时受多时间尺度信息和模型规模两项要求约束。

多尺度方法通常先给定若干时间尺度，再把各尺度结果按既定方式融合。各输入窗口中短时波动与平缓趋势的占比不同，尺度 1、2 和 4 对预测的作用因而可能随输入状态变化。单一尺度不能保留其他时间分辨率的信息；多尺度采用固定融合比例时，窗口状态差异也未进入权重计算。本文据此构造多个时间尺度，并以当前输入窗口计算融合权重。

针对输入窗口之间的状态差异，本文采用样本级自适应多尺度结构。历史窗口按尺度 1、2 和 4 构造多分辨率序列，每个尺度由一个 DLinear 专家给出候选预测。路由网络不重新编码完整时序，而是读取当前输入窗口的总体水平、离散程度、最近状态和变化强度等统计量，生成 Softmax 尺度权重，并据此融合三个专家的结果。这样可以把尺度内预测与尺度间选择分开处理。实验在 Abilene 和 GÉANT 两个公开骨干网数据集上进行，比较 DLinear、LightTS、固定等权、全局可学习固定权重与恒定输入路由模型，并通过多个随机种子重复实验和路由权重分析检验预测误差、核心结构消融与尺度分配行为。

1 自适应多尺度网络流量预测方法

图 1 给出模型的整体流程。模型包含多尺度预测和尺度选择两个模块：尺度 1、2 和 4 的输入分别交给独立 DLinear 专家，路由网络根据当前窗口的统计特征估计 3 个尺度的融合权重。原始 OD 流量经对数变换和标准化后形成 3 个时间分辨率的输入序列；3 个专家分别预测，再按样本级权重融合。固定等权、全局可学习权重与恒定输入路由对照采用相同的尺度与专家结构，并分别训练，用以比较等权、全局非等权与输入相关融合。

原始尺度保留局部变化，较粗尺度则通过时间聚合削弱短时扰动。三个尺度因而提供了不同平滑程度的历史信息。本文保留 3 个尺度的独立预测，再由路由网络确定每个样本的组合比例。各尺度采用结构较简洁的 DLinear 承担预测任务，以控制模型规模，并为比较多尺度输入与样本级融合提供统一主干。

1.1 问题定义与数据预处理

记预处理后的多变量流量序列为 $\mathbf{x}_t \in \mathbb{R}^C$，t 为时间索引，C 为有效 OD 变量数。监督学习样本由连续序列按时间滑动生成；第 n 个样本的历史窗口$\mathbf{X}_n$与预测目标$\mathbf{Y}_n$：$\mathbf{X}_n$覆盖连续 L 个时间点，$\mathbf{Y}_n$覆盖紧随其后的 H 个时间点。多个 OD 变量过去 L 步的联合变化作为模型输入，用于估计未来 H 步取值。输入与目标定义如下

$$\mathbf{X}_n = [\mathbf{x}_n, \dots, \mathbf{x}_{n+L-1}] \in \mathbb{R}^{L\times C}. \tag{1}$$

$$\mathbf{Y}_n = [\mathbf{x}_{n+L}, \dots, \mathbf{x}_{n+L+H-1}] \in \mathbb{R}^{H\times C}. \tag{2}$$

本文设置输入长度 L=96、预测长度 H=24，变量数 C 由各数据集保留的有效 OD 维度确定，学习映射记为$\hat{\mathbf{Y}}_n = f_\theta(\mathbf{X}_n)$。其中 L 限定历史范围，H 限定连续预测的未来长度。非负的原始 OD 流量在变量之间存在较大量级差异，直接训练时各维数据的数值尺度不一致。为压缩这一差异，先对原始流量$v_{t,c}$作对数变换

$$u_{t,c} = \log(1 + v_{t,c}). \tag{3}$$

再按变量进行标准化：

$$x_{t,c} = \frac{u_{t,c} - \mu_c^{\mathrm{tr}}}{\sigma_c^{\mathrm{tr}}}. \tag{4}$$

其中μ_c^{tr}和σ_c^{tr}分别为第 c 个 OD 变量在训练集上的均值和标准差，验证集和测试集均使用训练阶段得到的统计量。log(1+x)保留非负流量的大小关系，并压缩其数值范围。随后按变量标准化，使各 OD 维度在相近尺度上参与损失计算和参数更新。数据仍按时间顺序以 6:2:2 划分为训练集、验证集和测试集，各集合内部独立生成滑动窗口，避免窗口跨越不同数据划分边界。

预处理不改变输入样本的时间分辨率。各尺度序列均从同一历史窗口构造。

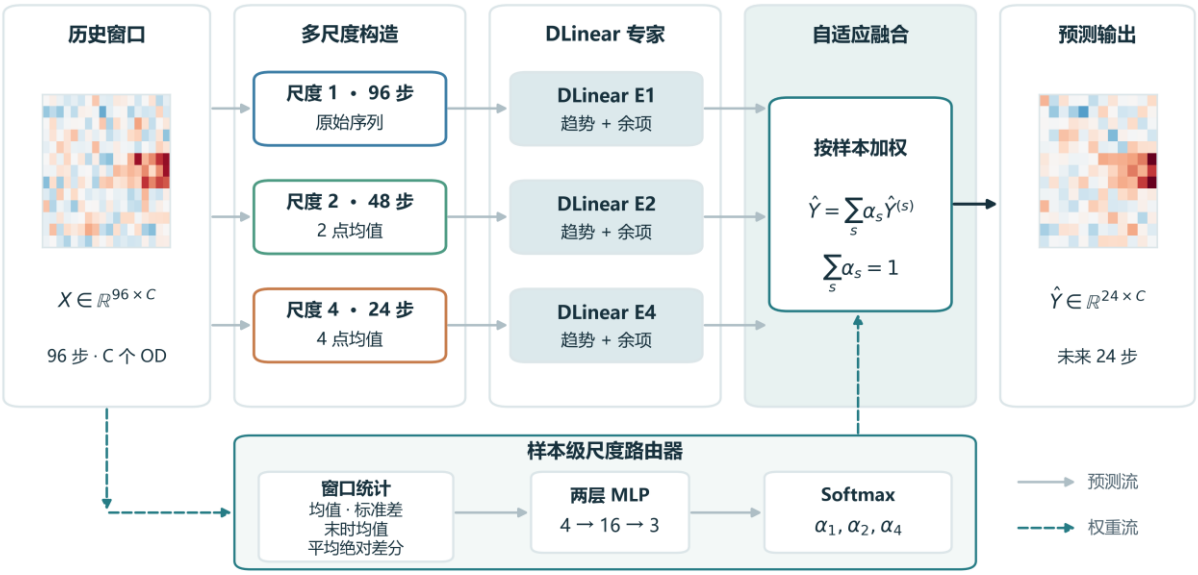


图 1 自适应多尺度网络流量预测方法框架

1.2 多尺度序列构造

设尺度集合 S={1,2,4}。沿时间维采用非重叠平均池化，尺度 s 同时指定聚合窗口大小与步长。任一尺度 s 的池化过程为：

$$\mathbf{X}_{n,t}^{(s)} = \frac{1}{s}\sum_{i=0}^{s-1} \mathbf{X}_{n,st+i}, \quad t = 0, \ldots, \frac{L}{s} - 1. \tag{5}$$

本文使用尺度集合 S={1,2,4}。在输入长度 L=96 时，尺度 1 保留原始 96 步序列；尺度 2 将相邻 2 个时间点取平均，得到 48 步序列；尺度 4 按 4 个时间点进行平均，得到 24 步序列。时间轴在尺度 1 下不被压缩，短时起伏得以保留；尺度 2 和尺度 4 依次增强平滑程度，较粗尺度更突出较慢的趋势。平均池化无需可训练的尺度变换参数，因此多分辨率输入的构造本身不增加模型参数。

选择尺度 1、2 和 4，可由 96 步历史窗口形成三组长度均为整数的序列，同时控制专家数量。继续增加尺度会产生更粗的序列，也会缩短有效时间长度、增加专家分支。尺度组合{1,2,4}按细粒度信息、趋势

信息和模型规模的要求固定设置；由于未经穷举搜索，其最优性尚未验证。采用非重叠池化还使每个原始时间点只参与一次同尺度聚合，尺度变化的含义较为直接。

1.3 DLinear 尺度专家

尺度 1、2 和 4 分别配置一个 DLinear 专家[6]，每个专家只处理本尺度对应的输入序列。DLinear 先分离变化较慢的趋势项及围绕趋势变化的余项，再对两项分别作时间映射。对尺度 s 的输入，本文使用长度 q=25 的中心移动平均提取趋势项。移动平均平滑局部时间邻域。序列边界的窗口不足部分由端点复制补齐，补齐后的序列记为$\tilde{\mathbf{X}}^{(s)}$；越界索引取最近端点值，从而保持分解前后的时间长度一致：

$$\mathbf{T}_{n,t}^{(s)} = \frac{1}{q}\sum_{i=-m}^{m} \tilde{\mathbf{X}}_{n,t+i}^{(s)}, \quad q = 2m+1 = 25. \tag{6}$$

$$\mathbf{R}_{n}^{(s)} = \mathbf{X}_{n}^{(s)} - \mathbf{T}_{n}^{(s)}. \tag{7}$$

趋势项$\mathbf{T}^{(s)}$和余项$\mathbf{R}^{(s)}$沿时间维分别通过线性层映射到预测长度 H：

$$\hat{\mathbf{Y}}_{n}^{(s)} = \mathbf{W}_{T}^{(s)}\mathbf{T}_{n}^{(s)} + \mathbf{b}_{T}^{(s)} + \mathbf{W}_{R}^{(s)}\mathbf{R}_{n}^{(s)} + \mathbf{b}_{R}^{(s)}. \tag{8}$$

由式（6）和式（7）可得到尺度 s 上的趋势项$\mathbf{T}^{(s)}$和余项$\mathbf{R}^{(s)}$。趋势项表示经过局部平滑后保留下来的较慢变化部分，余项则由原序列减去趋势项得到，保留未被移动平均解释的局部变化。式（8）分别对两部分沿时间维进行线性映射，并把二者的预测结果相加形成该尺度的候选预测。3 个尺度使用独立 DLinear 专家，是因为尺度 1、2 和 4 的输入长度分别为 96、48 和 24，对应的时间分辨率和时间映射关系并不相同；若强制共用一组尺度间参数，会把不同长度、不同平滑程度的序列约束到同一映射中。同一尺度内部，各 OD 变量共享时间映射参数，模型学习的是这一时间尺度下通用的时间映射形式，而不是为每个 OD 变量分别建立一套线性层。

采用 DLinear 统一尺度专家，是为减少预测主干结构对融合方式比较的干扰。本文需要比较单尺度预测、固定等权、全局可学习固定权重、恒定输入路由和样本级路由五种设置；若尺度专家本身过于复杂，误差变化会同时受到主干结构和融合机制影响。DLinear 的参数关系清晰，基本预测能力也可保留，便于在统一专家结构下开展这些比较。

1.4 样本级自适应尺度加权

同一样本经 3 个 DLinear 专家得到 3 组预测，最终输出由各组预测的占比决定。令 3 个尺度始终各占 1/3 时，所有输入窗口均使用相同的融合比例。窗口状态并不相同，局部波动较强时可能更依赖细粒度信息，平稳变化时则可能更依赖较粗尺度的趋势信息。为将这种状态差异纳入权重计算，本文从原始输入$\mathbf{X}_n$提取四维统计向量$\mathbf{z}_n = [\mu_n, \sigma_n, \ell_n, d_n]$，用这些统计量描述当前窗口状态，其中

$$\mu_n = \frac{1}{LC}\sum_{t=0}^{L-1}\sum_{c=1}^{C} X_{n,t,c}, \quad \sigma_n = \sqrt{\frac{1}{LC}\sum_{t=0}^{L-1}\sum_{c=1}^{C}(X_{n,t,c} - \mu_n)^2}. \tag{9}$$

$$\ell_n = \frac{1}{C}\sum_{c=1}^{C} X_{n,L-1,c}, \quad d_n = \frac{1}{(L-1)C}\sum_{t=1}^{L-1}\sum_{c=1}^{C} |X_{n,t,c} - X_{n,t-1,c}|. \tag{10}$$

μ_n、σ_n、ℓ_n和d_n分别描述输入窗口的总体水平、离散程度、最近状态和平均变化强度。μ_n反映窗口整体流量水平，σ_n刻画观测值的离散程度，ℓ_n取窗口末时刻的平均状态，d_n由相邻时间点的一阶变化得到。这 4 个统计量分别提供水平、波动、最近状态和局部变化信息，供路由器计算输入相关的尺度权重，而不直接参与未来流量数值的预测。

四维向量输入隐藏维数为 16 的两层感知器，输出 3 个尺度的未归一化分数。路由器只输出尺度融合分数，不承担完整 OD 流量预测。低维统计量配合较小隐藏层即可完成这一计算，本文因而未增加循环网络、注意力网络等时序编码器，以限制路由模块的参数规模。其尺度分数计算为

$$\mathbf{a}_n = \mathbf{W}_2\mathrm{ReLU}(\mathbf{W}_1\mathbf{z}_n + \mathbf{b}_1) + \mathbf{b}_2. \tag{11}$$

对式（11）的 3 个尺度分数作 Softmax 归一化，得到 3 个总和为 1 的非负权重；各专家在最终预测中的相对贡献由这些权重表示：

$$\alpha_{n,s} = \frac{\exp(a_{n,s})}{\sum_{j\in S}\exp(a_{n,j})}, \quad \alpha_{n,s} \geq 0, \quad \sum_{s\in S}\alpha_{n,s} = 1. \tag{12}$$

最终预测为

$$\widehat{\mathbf{Y}}_n = \sum_{s\in S}\alpha_{n,s}\,\widehat{\mathbf{Y}}_n^{(s)}. \tag{13}$$

式（13）利用上述权重对 3 个 DLinear 专家的预测结果进行加权求和，得到最终预测$\widehat{\mathbf{Y}}_n$。该组权重由输入窗口计算，并由同一窗口内的全部 OD 变量共享。为了区分多尺度结构、非等权分配与样本相关分配的作用，设置三种共享相同专家的对照：固定等权模型将三个尺度恒定设为 1/3；全局可学习权重模型以三个可训练参数经 Softmax 得到一组常权重；恒定输入路由模型保留完整路由网络，但训练和推理时都向路由器输入全零窗口，使全部样本共用一组可学习权重。三种模型的尺度专家均接收真实历史窗口。

1.5 训练目标与模型复杂度

训练目标为均方误差，计算范围覆盖训练样本、未来 H 个预测时刻和全部 C 个 OD 变量。各预测步与 OD 维度的偏差由同一目标汇总，并用于参数更新。对应训练目标为

$$\mathcal{L}_{\mathrm{MSE}} = \frac{1}{NHC}\sum_{n=1}^{N}\sum_{h=1}^{H}\sum_{c=1}^{C}(Y_{n,h,c} - \hat{Y}_{n,h,c})^2. \tag{14}$$

Adam 用于模型参数优化，最终模型按验证集 MSE 选择。单尺度 DLinear 包含 4656 个可训练参数；三个尺度专家的固定等权模型包含 8208 个参数；增加三个全局权重参数后为 8211 个参数；样本级路由模型和恒定输入路由模型均为 8339 个标称参数。与固定等权模型相比，路由网络增加 131 个参数；与全局权重模型相比，增加 128 个参数。恒定输入路由虽保留相同结构，恒零输入仍使首层输入权重不参与有效计算。

模型计算依次经过三个环节：平均池化把同一历史窗口转换为 3 个时间分辨率，DLinear 专家分别给出候选预测，路由网络再根据原始窗口的 4 个统计量确定融合权重。后续实验据此设置单尺度 DLinear、

固定等权多尺度、全局可学习固定权重模型、恒定输入路由模型和本文方法，用同一组专家结构区分多尺度信息与样本级加权的作用。

2 实验与结果分析

实验分为外部基线比较、核心消融和路由行为分析三个层次。LightTS 提供独立结构的外部基线，DLinear 提供单尺度参照；固定等权、全局可学习常权重、恒定输入路由与样本级路由模型采用相同的三个尺度专家结构，并分别训练，分别比较多尺度结构、非等权融合与输入相关权重的表现；八个共同随机种子的配对结果和逐种子权重分析用于评估结果波动。

2.1 数据集与实验设置

实验数据取自 CESNET TS-Zoo[9]，包括 1 h 聚合的 Abilene[10]和 GÉANT[11]骨干网流量矩阵。Abilene 共有 4656 个时间点，保留 144 维有效 OD 流量；GÉANT 共有 2849 个时间点，去除恒定通道后保留 524 维有效 OD 流量。两套数据在序列长度、变量规模上的差异，为检验同一预测流程提供了不同的数据条件。划分均沿时间顺序进行，训练集、验证集、测试集的比例为 6:2:2；输入长度 L=96，预测长度 H=24。预处理按第 1.1 节执行，数据规模及窗口数量见表 1。

表 1 数据集与预测任务设置

数据集	时间点	有效变量 C	训练/验证/测试时间点	训练/验证/测试窗口	L/H
Abilene	4656	144	2793/931/932	2674/812/813	96/24
GÉANT	2849	524	1709/570/570	1590/451/451	96/24

所有对比模型使用相同的数据划分、输入长度、预测长度、评价指标和批量大小，batch size 统一为 16。为控制数据与训练条件，实验未分别搜索各模型的最优超参数。DLinear、固定等权多尺度、全局可学习权重、恒定输入路由和本文方法最多训练 30 轮，LightTS 最多训练 50 轮；均根据验证集 MSE 选择测试所用参数，测试集仅用于最终统计。

外部基线比较使用随机种子 42～44 共 3 个共同随机种子。核心消融使用随机种子 42～49 共 8 个共同随机种子，比较 DLinear、固定等权多尺度、全局可学习权重、恒定输入路由和本文方法。全局权重由等权初始化，恒定输入路由对所有窗口使用全零路由输入；两者均与三个专家一同训练，并按相同验证集准则选择模型；随机种子作为配对统计单位。

2.2 对比模型与评价指标

对照包括 DLinear、LightTS、固定等权多尺度、全局可学习权重和恒定输入路由五类模型。DLinear 用于比较单一尺度与多尺度结构；LightTS 提供独立轻量模型基线。后三种多尺度对照与本文方法保留相同的尺度集合{1,2,4}和 DLinear 专家，分别使用等权、全局可学习权重和恒定输入路由权重。后两者均对全部窗口使用一组固定权重，可检验完整模型相对常权重方案的误差变化。

均方误差（MSE）、平均绝对误差（MAE）及均方根误差（RMSE）用于评价预测性能。其中 MSE 采用式（14），MAE 和 RMSE 的定义如下

$$\mathrm{MAE} = \frac{1}{N_{\mathrm{te}}HC}\sum_{n=1}^{N_{\mathrm{te}}}\sum_{h=1}^{H}\sum_{c=1}^{C}\left|Y_{n,h,c} - \hat{Y}_{n,h,c}\right|. \tag{15}$$

$$\mathrm{RMSE} = \sqrt{\mathrm{MSE}}. \tag{16}$$

所有误差均在标准化空间中计算，以较小值为优。正文主要比较 MSE 与 MAE：前者对较大误差更敏感，后者描述平均绝对偏差。RMSE 为 MSE 的平方根，用于补充误差幅值。表 2 统计随机种子 42～44 的均值±标准差，表 3 统计随机种子 42～49 的均值±标准差，分别反映平均水平和随机种子间的波动。相对改进率的统计从共同随机种子开始：分别计算每个种子的改进率，再取平均。表中四舍五入后的均值不用于该百分比计算。

2.3 两数据集外部基线比较

表 2 列出 3 个共同随机种子下的总体基线结果。本文方法在 Abilene 上的 MSE 为 0.186，在 GÉANT 上为 0.434；逐种子计算后相对 DLinear 分别降低 4.07%和 4.54%，相对 LightTS 分别降低 29.80%和 46.89%，MAE 呈相同方向变化。DLinear 与本文尺度专家采用同源结构，后续核心消融也以 DLinear 作为单尺度内部基线；LightTS 属于独立外部结构基线，图 2 进一步给出逐随机种子、多指标和参数规模比较。

表 2 三随机种子外部基线比较

数据集	模型	参数量	MSE	MAE
Abilene	DLinear	4656	0.194±0.002	0.188±0.009
Abilene	LightTS	130162	0.265±0.011	0.204±0.008
Abilene	本文方法	8339	0.186±0.002	0.168±0.001
GÉANT	DLinear	4656	0.454±0.007	0.383±0.006
GÉANT	LightTS	384382	0.817±0.024	0.523±0.014
GÉANT	本文方法	8339	0.434±0.051	0.370±0.031

图 2 以 LightTS 为独立外部基线，使用两种方法共有的随机种子 42～44。每次实验的相对降低率按（LightTS 误差−本文方法误差）/LightTS 误差计算。MSE、MAE 和 RMSE 的平均降幅在 Abilene 上为 29.80%、17.57%和 16.23%，在 GÉANT 上为 46.89%、29.15%和 27.18%。逐种子检查这三项指标，两个数据集的 3 个共同随机种子均有改善。本文方法的 8339 个参数，约为 LightTS 在 Abilene 和 GÉANT 上参数量的 6.41%和 2.17%；LightTS 的对应参数量分别为 130162 和 384382。

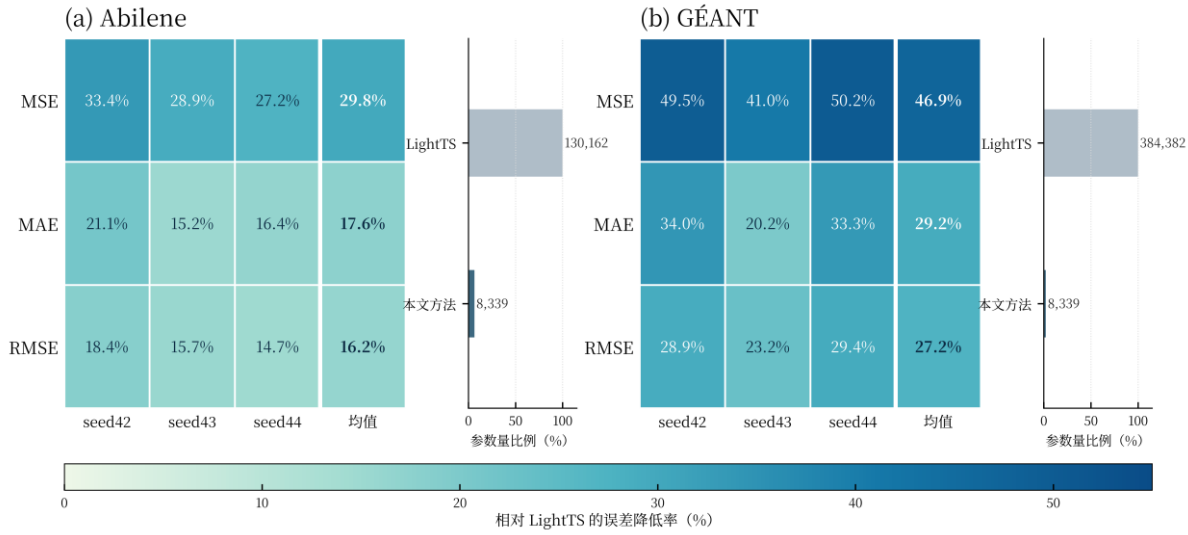


图 2 Abilene 与 GÉANT 上本文方法相对 LightTS 的三随机种子多指标性能提升

GÉANT 的 OD 变量数较多，本文方法相对 LightTS 的 MSE 降幅也高于 Abilene。不过，两者同时出现不能确立变量规模与误差降幅之间的因果关系。固定等权与全局可学习权重对照均采用相同的多尺度专家结构，适合进一步检验融合方式本身的作用。

2.4 八随机种子核心消融与稳定性

表 3 汇总随机种子 42～49 的 8 次核心消融，列出五种模型的参数量、MSE 和 MAE。

表 3 八随机种子核心消融结果（均值±标准差）

数据集	模型	参数量	MSE	MAE
Abilene	DLinear	4656	0.194±0.002	0.189±0.008
Abilene	固定等权多尺度	8208	0.192±0.002	0.191±0.006
Abilene	全局可学习权重	8211	0.192±0.002	0.190±0.006
Abilene	恒定输入路由	8339	0.192±0.002	0.181±0.006
Abilene	本文方法	8339	0.189±0.003	0.173±0.008
GÉANT	DLinear	4656	0.437±0.016	0.371±0.011
GÉANT	固定等权多尺度	8208	0.447±0.014	0.377±0.009
GÉANT	全局可学习权重	8211	0.446±0.014	0.377±0.009
GÉANT	恒定输入路由	8339	0.449±0.012	0.379±0.007
GÉANT	本文方法	8339	0.426±0.029	0.366±0.018

全局可学习权重与恒定输入路由均对所有窗口使用一组可学习权重，后者与本文方法同为 8339 个标称参数。相对这两种对照，本文方法在 Abilene 上的逐种子平均 MSE 改进均约 1.80%，在 GÉANT 上分别为 4.31%和 4.97%，各有 6/8 和 7/8 个种子胜出。相对恒定输入路由的 95%置信区间分别为[0.49%,3.11%]和[−1.62%,11.56%]，相对全局权重则为[0.01%,3.58%]和[−2.51%,11.13%]；GÉANT 两项区间均跨零。

图 3 汇总随机种子 42～49 下的相对改进结果，比较对象为 DLinear 和固定等权多尺度模型，指标包括 MSE、MAE 和 RMSE。8 次结果以半小提琴呈现分布，各随机种子另以散点标出。8 次改进率的均值及 95%置信区间由黑色菱形和横向误差线给出；以 0%虚线为界判断误差是否改善。相对 DLinear 时，Abilene 的 MSE、MAE 和 RMSE 平均改进率为 2.77%、8.01%和 1.40%，其中 MSE 与 RMSE 在 8 次实验中均改善；GÉANT 分别为 2.35%、1.32%和 1.22%，且跨越 0%的情况更多。相对固定等权模型时，Abilene 三项指标的平均改进率为 1.65%、8.92%和 0.84%，GÉANT 为 4.54%、3.05%和 2.37%。平均改进率相对两种基线均为正。GÉANT 的种子间波动较明显，平均收益的稳定性仍需结合置信区间判断。

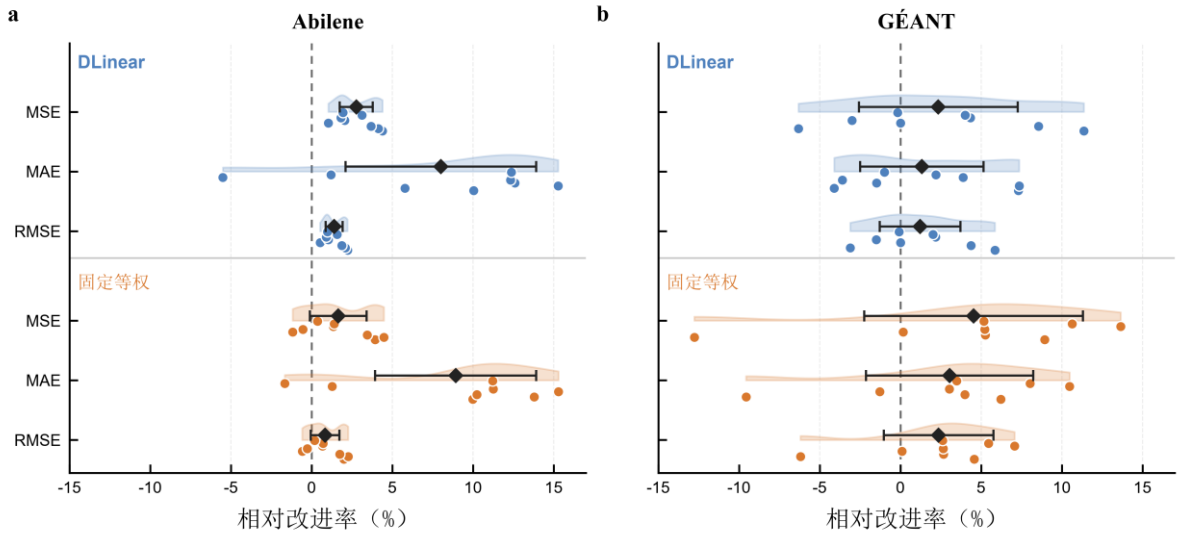


图 3 Abilene 与 GÉANT 上本文方法相对两类基线的八随机种子多指标相对改进分布

固定等权模型检验等权融合，全局可学习权重及恒定输入路由模型提供两种常权重对照。表 3 中本文方法相对两者的平均 MSE 均较低，但 GÉANT 的配对区间均跨越零；其中种子 43 相对恒定输入路由退步 12.78%。恒定输入路由的首层输入权重不起作用，各模型也分别训练。因此，完整方法与两类常权重方案的误差差异，尚不足以唯一识别逐窗口权重变化的贡献。整体偏差与局部误差另由图 4 观察：前者汇总全测试点，后者采用按真实值波动选取的预测轨迹。

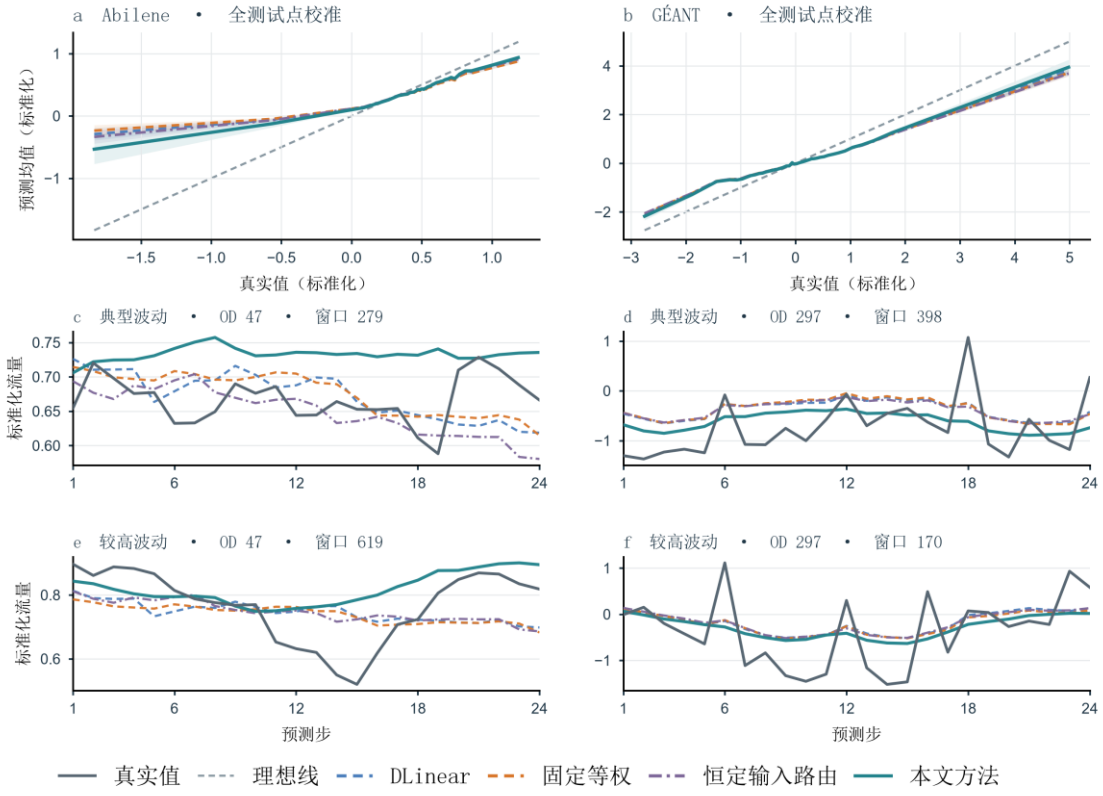


图 4 Abilene 与 GÉANT 全测试点预测校准及典型窗口预测轨迹

图 4(a、b)汇总随机种子 42～49 的全部测试窗口、24 个预测步及有效 OD 通道。按真实值分位点形成最多 40 个区间后，对四种模型分别计算各区间的 8 种子平均预测值。曲线旁的浅色带覆盖种子间±1 个标准差，灰色虚线标示理想预测。高真实值区间内四种模型均低估，本文方法的分组平均偏差较小；逐点误差仍需另行比较。图 4(c～f)固定随机种子 42，仅根据真实序列选择标准差接近第 75 百分位的 OD 通道，再选择波动程度接近中位数和第 90 百分位的窗口。上述选择未依据模型误差。24 步均方误差在四例中的三例低于 DLinear、固定等权与恒定输入路由模型，例外是 Abilene 的典型波动窗口。轨迹只能说明这些局部行为，总体精度按表 3 的配对结果判断。重叠测试窗口不作为独立重复。

2.5 路由权重分析

图 5 展示随机种子 42～49 下三个尺度的路由权重。蓝、绿、橙色小提琴分别对应尺度 1、2 和 4 在全部测试窗口及种子上的汇总分布。彩色散点表示同一种子内各窗口的平均权重；8 个种子均值再汇总为均值±1 个标准差，由黑色菱形和误差线表示。短横线标示汇总分布中位数，水平虚线标示固定等权 1/3。小提琴的宽度受种子间和窗口间差异共同影响，无法直接据此判断同一种子内的窗口响应强度。

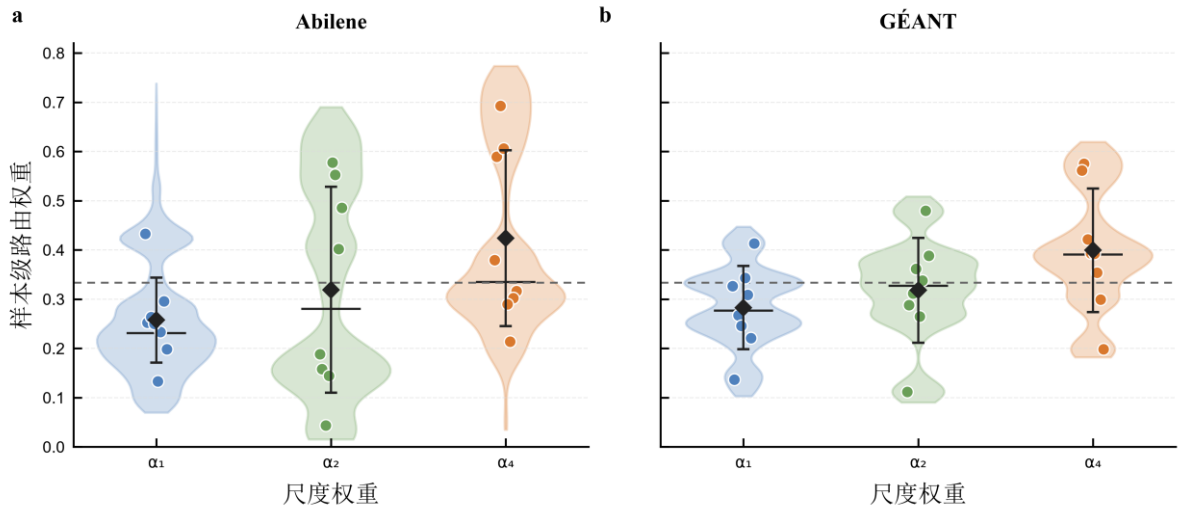


图 5 Abilene 与 GÉANT 的逐窗口路由权重汇总分布及八种子均值

Abilene 三个尺度的汇总平均权重为 0.257、0.319 和 0.424，GÉANT 为 0.283、0.318 和 0.399。总体均值偏离 1/3。种子间差异占 GÉANT 三个尺度汇总权重方差的约 96.2%、95.8%和 97.7%，占 Abilene 对应方差的 48.7%、86.1%和 80.6%。GÉANT 同一种子内的窗口变化较小。图 5 混合了种子间差异与同一种子内的窗口差异。仅凭这类汇总分布，还不能确认路由器对各窗口尺度需求的识别是否有效。

以平均绝对一阶差分度量输入窗口的波动强度，并用训练窗口的三分位数确定测试分组阈值。Abilene 低、中、高波动组分别有 15、406、392 个窗口。本文方法相对全局权重模型的逐种子平均 MSE 改进率分别为 4.43%、1.90%、1.69%；GÉANT 在训练阈值下无低波动测试窗口，中、高组分别有 76、375 个窗口，改进率为 5.85%和 4.06%。尺度 1 的平均权重在 Abilene 高波动组较中波动组更高，却未对应更强的误差优势。GÉANT 的中、高波动组权重近似相同。分组结果尚不支持“波动越强，路由收益越大”的解释。

模型前向开销另行测量。使用预测长度为 24 的 8 个随机种子检查点，在 NVIDIA GTX 1060 上以批量大小 16 对预加载的测试张量计时，本文方法在 Abilene 和 GÉANT 上的平均每批前向耗时分别为 2.65 ms 和 2.61 ms，固定等权模型分别为 2.38 ms 和 2.10 ms，单尺度 DLinear 分别为 0.77 ms 和 0.70 ms。这组计时仅覆盖模型前向计算，端到端部署还需计入数据读取与传输。虽然本文方法参数量较小，三个尺度专家及路由计算仍使推理开销增加。

3 结论

尺度 1、2 和 4 的 DLinear 专家分别预测骨干网络 OD 流量，再由轻量路由网络计算输入相关融合权重，形成兼顾短时波动与较慢趋势的多尺度预测结构。在 Abilene 和 GÉANT 预测长度为 24 的任务中，本文方法的平均误差低于 DLinear、LightTS 和固定等权模型。相对全局可学习权重与恒定输入路由两类常权重对照，本文方法在 Abilene 上的逐种子平均 MSE 改进均约 1.80%；GÉANT 上的对应改进分别为 4.31%和 4.97%，但两项 95%置信区间均跨越零。预测校准显示，各模型在较高流量取值处仍低估，本文方法的高值端平均偏差较小。这一分组结果不能推广为每个测试点均更准确。结合逐种子权重及波动分组分析，路由器能否稳定匹配窗口尺度需求仍缺乏充分证据；输入相关融合的稳定收益需在更多数据与预测设置下检验。

参考文献

[1] LOHRASBINASAB I, KESHAVARZ A, AMIN-NEJAD S, et al. From statistical- to machine learning-based network traffic prediction[J]. Transactions on Emerging Telecommunications Technologies, 2022, 33(4): e4394. DOI: 10.1002/ett.4394.

[2] QIN L, GU H, WEI W, et al. Spatio-temporal communication network traffic prediction method based on graph neural network[J]. Information Sciences, 2024, 679: 121003. DOI: 10.1016/j.ins.2024.121003.

[3] 韦烜, 刘志华, 李青, 等. 大型 IP 网络流量矩阵分析预测的探讨研究[J]. 系统工程与电子技术, 2024, 46(6): 2164-2173. DOI: 10.12305/j.issn.1001-506X.2024.06.35.

[4] 唐文杰, 肖一磊, 孔祥宇, 等. CycleLLH：一种基于周期性整合的新型网络流量预测模型[J]. 计算机学报, 2024, 47(12): 2867-2888. DOI: 10.11897/SP.J.1016.2024.02867.

[5] ZHOU J, HAN T, XIAO F, et al. Multiscale network traffic prediction method based on deep echo-state network for Internet of Things[J]. IEEE Internet of Things Journal, 2022, 9(21): 21862-21874. DOI: 10.1109/JIOT.2022.3181807.

[6] ZENG A, CHEN M, ZHANG L, et al. Are transformers effective for time series forecasting?[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2023, 37(9): 11121-11128. DOI: 10.1609/aaai.v37i9.26317.

[7] WANG S, WU H, SHI X, et al. TimeMixer: decomposable multiscale mixing for time series forecasting[C]//International Conference on Learning Representations. 2024.

[8] ZHANG T, ZHANG Y, CAO W, et al. Less is more: fast multivariate time series forecasting with light sampling-oriented MLP structures[EB/OL]. (2022-07-04)[2026-09-20]. https://arxiv.org/abs/2207.01186. DOI: 10.48550/arXiv.2207.01186.

[9] KUREŠ M, KOUMAR J, HYNEK K. CESNET TS-Zoo: a library for reproducible analysis of network traffic time series[C]//2025 21st International Conference on Network and Service Management. 2025. DOI: 10.23919/CNSM67658.2025.11297513.

[10] ZHANG Y, ROUGHAN M, DUFFIELD N, et al. Fast accurate computation of large-scale IP traffic matrices from link loads[J]. ACM SIGMETRICS Performance Evaluation Review, 2003, 31(1): 206-217. DOI: 10.1145/885651.781053.

[11] UHLIG S, QUOITIN B, LEPROPRE J, et al. Providing public intradomain traffic matrices to the research community[J]. ACM SIGCOMM Computer Communication Review, 2006, 36(1): 83-86. DOI: 10.1145/1111322.1111341.