基于自适应多尺度加权的多变量网络流量预测方法

[请填写作者姓名]

([请填写工作单位] [请填写部门], [省 市 邮编])

摘要：骨干网络源—目的节点对流量兼有短时起伏和较慢趋势，单一时间分辨率难以同时表征两者。本文采用尺度 1、2 和 4 的 DLinear 专家，由轻量路由网络根据输入窗口统计量生成 Softmax 融合权重。在输入长度 96、预测长度 24 的 Abilene 和 GÉANT 实验中，3 个共同随机种子下本文方法相对 DLinear 的 MSE 分别降低 4.07%和 4.54%，相对 LightTS 分别降低 29.80%和 46.89%。8 个随机种子的核心消融加入全局可学习权重和恒定输入路由两类固定权重对照；本文方法相对两者在 Abilene 上的逐种子平均 MSE 改进率均约为 1.80%，在 GÉANT 上分别为 4.31%和 4.97%。GÉANT 的两项配对 95%置信区间均跨越零，且路由权重变化主要来自随机种子之间，因此当前结果支持平均误差改善，但尚不能证明路由器稳定识别每个窗口的最佳尺度。

关键词：网络流量预测；多变量时间序列；多尺度学习；自适应加权；DLinear

中图分类号：TP393　　**文献标志码：**A

A Multivariate Network Traffic Forecasting Method Based on Adaptive Multiscale Weighting

[Author Name]

([Affiliation] [Department], [City] [Postcode], China; Corresponding author: [Name], E-mail: [E-mail])

Abstract: Short-term fluctuations and slower trends coexist in backbone origin-destination traffic. Input-window statistics determine the Softmax weights used to combine DLinear experts at scales 1, 2, and 4. For input length 96 and forecast length 24, results from three common random seeds give MSE reductions of 4.07% on Abilene and 4.54% on GÉANT relative to DLinear. The corresponding reductions relative to LightTS are 29.80% and 46.89%. An eight-seed ablation adds two fixed-weight controls: learned global weights and a router receiving constant input. Mean seed-wise MSE reductions over the two controls are both about 1.80% on Abilene; on GÉANT, they are 4.31% and 4.97%, respectively. Both paired 95% confidence intervals on GÉANT include zero, and most of its pooled router-weight variance arises between seeds. Reliable window-specific scale selection therefore remains unconfirmed despite the average error reduction.

Key words: network traffic forecasting; multivariate time series; multiscale learning; adaptive weighting; DLinear

在骨干网络中，不同节点对之间的通信需求可直接由源—目的节点对（origin-destination，OD）流量反映。容量规划、拥塞预警、资源调度和流量工程需要判断后续的 OD 流量状态。云计算、视频业务、数据中心互联及智能网络应用持续增加，业务在网络内部迁移和聚集的频率随之提高。后续流量状态的判断因而需要面对更加复杂的时间变化。周期变化、局部波动与突发变化常叠加在同一 OD 流量序列中，不同变量又有各自的数值范围。相较于较平稳的单变量序列，这类 OD 数据还包含复杂的短时状态变化；模型在描述较长时间趋势的同时，需要保留对这些短时变化的响应。

Lohrasbinasab 等[1]系统梳理了网络流量预测方法，指出机器学习和深度学习等数据驱动方法在复杂流量预测中的应用不断增加，反映了传统统计模型之外的研究扩展。网络规模扩大也使 OD 变量之间的关联更难由单一序列的时间分析覆盖。Qin 等[2]把图神经网络引入通信网络流量预测，在同一模型中处理空间

收稿日期：[请填写，格式 YYYY-MM-DD]

基金项目：[基金来源]（[基金项目编号]）

第一作者简介：[姓名]（[出生年]—），[性别（民族，汉族可省略）]，[职称]，[学位（若在读请注明）]，研究方向：[方向 1]；[方向 2]。

通信作者简介：[姓名]（[出生年]—），[性别（民族，汉族可省略）]，[职称]，[学位（若在读请注明）]，研究方向：[方向 1]；[方向 2]，电子邮箱：[邮箱]。

关联和时间依赖；韦烜等[3]针对大型 IP 网络流量矩阵开展分析与预测，讨论了不同 OD 变量之间的关联及其时间变化。唐文杰等[4]则在 CycleLLH 模型中引入周期性信息。上述研究涉及的时间依赖、变量关联与周期结构，构成了流量预测的不同观察角度。

同一流量序列在原始时间分辨率下保留较多局部细节，短时起伏也更清晰。进行时间聚合后，部分局部扰动被平滑，较慢的变化趋势更容易观察。可观察的流量特征因而随时间分辨率改变。在 Zhou 等[5]的多尺度网络流量预测研究中，深度回声状态网络从不同时间分辨率的序列中提取信息，以利用各分辨率之间的互补性。多尺度信息的利用还需考虑模型结构开销。DLinear[6]采用时间序列分解和线性映射完成预测；TimeMixer[7]利用多尺度混合机制处理不同分辨率序列；LightTS[8]采用采样导向的 MLP 结构进行快速多变量时间序列预测。因此，本文在利用多时间尺度信息的同时考察模型规模，两项要求共同约束预测结构的设计。

通常的多尺度处理先给定一组时间尺度，各尺度分别得到结果后，再按照既定方式进行融合。尺度 1、2 和 4 在预测中的作用可能随输入状态改变。其依据是：不同输入窗口所包含的短时波动与平缓趋势，占比并不相同。仅使用单一尺度时，其他时间分辨率的信息无法保留；即使构造多尺度序列，固定的融合比例也没有把窗口状态差异用于权重计算。本文在构造多个时间尺度后，将当前输入窗口用于融合权重的计算，使窗口状态能够进入这一环节。

针对输入窗口之间的状态差异，本文采用样本级自适应多尺度结构。历史窗口按尺度 1、2 和 4 构造多分辨率序列，每个尺度由一个 DLinear 专家给出候选预测。路由网络不重新编码完整时序，而是读取当前输入窗口的总体水平、离散程度、最近状态和变化强度等统计量，生成 Softmax 尺度权重，并据此融合三个专家的结果。这样可以把尺度内预测与尺度间选择分开处理。实验在 Abilene 和 GÉANT 两个公开骨干网数据集上进行，比较 DLinear、LightTS、固定等权、全局可学习固定权重与恒定输入路由模型，并通过多个随机种子重复实验和路由权重分析检验预测误差、核心结构消融与尺度分配行为。

1 自适应多尺度网络流量预测方法

图 1 给出模型的整体流程。模型包含多尺度预测和尺度选择两个模块：尺度 1、2 和 4 的输入分别交给独立 DLinear 专家，路由网络根据当前窗口的统计特征估计 3 个尺度的融合权重。原始 OD 流量经对数变换和标准化后形成 3 个时间分辨率的输入序列；3 个专家分别预测，再按样本级权重融合。固定等权、全局可学习权重与恒定输入路由对照采用相同的尺度与专家结构，并分别训练，用以比较等权、全局非等权与输入相关融合。

三个时间尺度的历史信息具有不同的平滑程度。原始尺度保留更多局部变化；较粗尺度经时间聚合后，短时扰动被削弱，较慢的变化趋势得到突出。3 个尺度分别完成独立预测，预测结果均予以保留；每个样本使用何种组合比例，随后由路由网络确定。各尺度采用结构较简洁的 DLinear 承担预测任务，以控制模型规模，并为比较多尺度输入与样本级融合提供统一主干。

1.1 问题定义与数据预处理

记预处理后的多变量流量序列为 $\mathbf{x}_t \in \mathbb{R}^C$，时间索引记为 t，有效 OD 变量数记为 C。将连续序列沿时间轴滑动即可生成监督学习样本；第 n 个样本包含历史窗口$\mathbf{X}_n$与预测目标$\mathbf{Y}_n$：$\mathbf{X}_n$覆盖连续 L 个时间点，$\mathbf{Y}_n$覆盖历史窗口之后连续的 H 个时间点。预测时，模型读取多个 OD 变量过去 L 步的联合变化，并据此估计未来 H 步的取值。第 n 个样本的输入与目标具体定义如下

$$\mathbf{X}_n = [\mathbf{x}_n, \dots, \mathbf{x}_{n+L-1}] \in \mathbb{R}^{L\times C}. \tag{1}$$

$$\mathbf{Y}_n = [\mathbf{x}_{n+L}, \dots, \mathbf{x}_{n+L+H-1}] \in \mathbb{R}^{H\times C}. \tag{2}$$

输入长度与预测长度在本文中分别设置为 L=96 和 H=24。各数据集保留的有效 OD 维度决定变量数 C，待学习的预测映射记为$\hat{\mathbf{Y}}_n = f_\theta(\mathbf{X}_n)$。其中，L 对应一次预测使用的历史范围，H 对应连续预测的未来长度。原始 OD 流量为非负值，变量间却存在较大的量级差异；若直接使用原始数值训练，数值范围较大的变量与其他变量将处于不一致的尺度。为压缩原始流量的数值范围，首先对原始流量$v_{t,c}$作对数变换

$$u_{t,c} = \log(1 + v_{t,c}). \tag{3}$$

再按变量进行标准化：

$$x_{t,c} = \frac{u_{t,c} - \mu_c^{\mathrm{tr}}}{\sigma_c^{\mathrm{tr}}}. \tag{4}$$

其中μ_c^{tr}和σ_c^{tr}分别表示训练集中第 c 个 OD 变量的均值与标准差。验证集和测试集沿用这组训练统计量，不重新估计预处理所需的统计量。数值范围先由 log(1+x)压缩，非负流量之间的大小关系仍被保留。这一步用于缓和原始流量的量级差异。之后按变量进行标准化，使各 OD 维度在相近的数值尺度上参与训练。标准化进一步统一各变量参与损失计算和参数更新时的尺度。训练集、验证集与测试集仍沿时间顺序划分，比例为 6:2:2。滑动窗口在各集合内部独立生成，窗口因而不跨越不同数据划分的边界。

预处理不改变输入样本的时间分辨率。各尺度序列均从同一历史窗口构造，供各专家分别观察细粒度变化和较平滑的趋势。

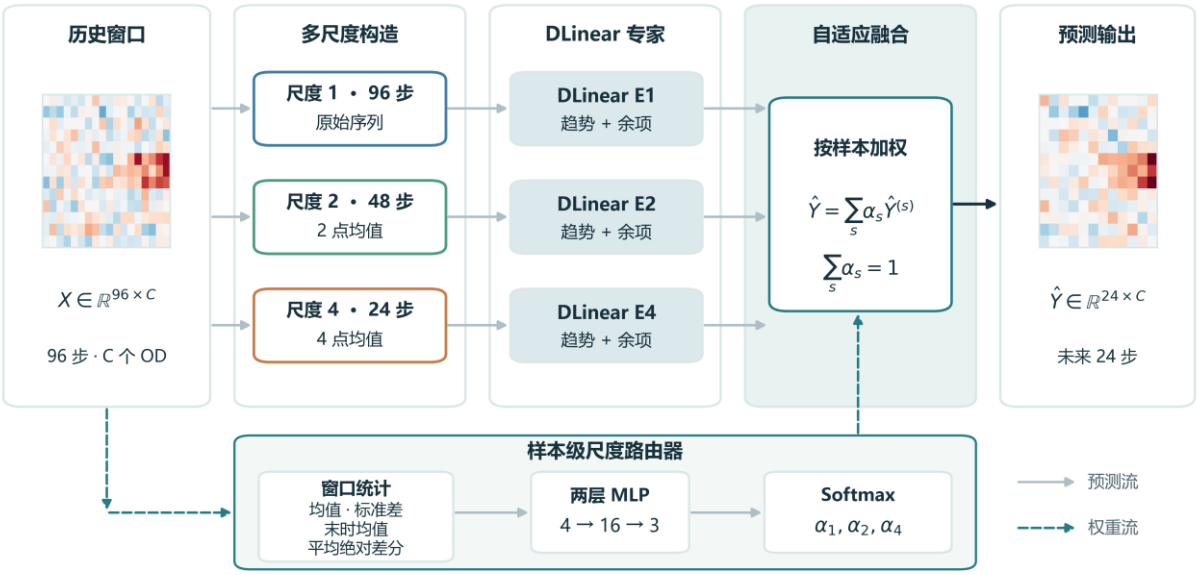


图 1 自适应多尺度网络流量预测方法框架

1.2 多尺度序列构造

设尺度集合 S={1,2,4}。尺度 s 表示沿时间维聚合时的窗口大小。本文采用非重叠平均池化，聚合窗口和步长均设为 s。对任一尺度 s，其池化过程可写为：

$$\mathbf{X}_{n,t}^{(s)} = \frac{1}{s}\sum_{i=0}^{s-1}\mathbf{X}_{n,st+i}, \quad t = 0, \ldots, \frac{L}{s} - 1. \tag{5}$$

本文使用尺度集合 S={1,2,4}。输入长度为 L=96 时，原始 96 步序列在尺度 1 下完整保留；在尺度 2 下，对相邻 2 个时间点求平均后形成 48 步序列；在尺度 4 下，每 4 个时间点的平均值形成一个聚合点，得到 24 步序列。尺度 1 不压缩时间轴，因此较完整地保留短时起伏；尺度 2 对局部变化作适度平滑；尺度 4 进一步削弱短时间内的高频变化，较慢的趋势由此更突出。本文以平均池化构造多分辨率输入，不额外设置可训练的尺度变换模块。平均池化本身不需要此类参数，输入构造因而不增加模型参数。

96 步历史窗口采用尺度 1、2 和 4 时，可形成三组长度均为整数的序列；这一设置也同时控制了尺度专家的数量。若继续增加尺度，得到的序列会更粗，其有效时间长度也随之缩短；增加相应尺度的预测还需要新的专家分支。尺度组合{1,2,4}是一项固定设计，取舍依据为细粒度信息、趋势信息以及模型规模。本文没有进行尺度组合的穷举搜索，因此尚不能把该组合作为最优尺度组合。采用非重叠池化还使每个原始时间点只参与一次同尺度聚合，尺度变化的含义较为直接。

1.3 DLinear 尺度专家

本文为尺度 1、2 和 4 各配置一个 DLinear 专家[6]。专家之间的输入分开处理，每个专家仅接收其对应尺度的序列。序列先由 DLinear 分解为变化较慢的趋势项，以及围绕趋势变化的余项。分解完成后，两项分别进行时间映射。对尺度 s 的输入，本文使用长度 q=25 的中心移动平均提取趋势项。移动平均在局部时间邻域内作平滑。为避免边界位置因窗口不足而使序列缩短，本文以端点复制补齐缺少的部分，所得序列记为$\widetilde{\mathbf{X}}^{(s)}$；越界索引取最近端点值，从而保持分解前后的时间长度一致：

$$\mathbf{T}_{n,t}^{(s)} = \frac{1}{q}\sum_{i=-m}^{m}\widetilde{\mathbf{X}}_{n,t+i}^{(s)}, \quad q = 2m + 1 = 25. \tag{6}$$

$$\mathbf{R}_{n}^{(s)} = \mathbf{X}_{n}^{(s)} - \mathbf{T}_{n}^{(s)}. \tag{7}$$

趋势项$\mathbf{T}^{(s)}$和余项$\mathbf{R}^{(s)}$沿时间维分别通过线性层映射到预测长度 H：

$$\widehat{\mathbf{Y}}_{n}^{(s)} = \mathbf{W}_{T}^{(s)}\mathbf{T}_{n}^{(s)} + \mathbf{b}_{T}^{(s)} + \mathbf{W}_{R}^{(s)}\mathbf{R}_{n}^{(s)} + \mathbf{b}_{R}^{(s)}. \tag{8}$$

由式（6）和式（7）可得到尺度 s 上的趋势项$\mathbf{T}^{(s)}$和余项$\mathbf{R}^{(s)}$。趋势项表示经过局部平滑后保留下来的较慢变化部分，余项则由原序列减去趋势项得到，保留未被移动平均解释的局部变化。式（8）分别对两部分沿时间维进行线性映射，并把二者的预测结果相加形成该尺度的候选预测。3 个尺度使用独立 DLinear 专家，是因为尺度 1、2 和 4 的输入长度分别为 96、48 和 24，对应的时间分辨率和时间映射关系并不相同；若强制共用一组尺度间参数，会把不同长度、不同平滑程度的序列约束到同一映射中。同一尺度内部，各

OD 变量共享时间映射参数，模型学习的是这一时间尺度下通用的时间映射形式，而不是为每个 OD 变量分别建立一套线性层。

在融合方式比较中，预测主干结构也可能影响误差。本文统一采用 DLinear 尺度专家，以减少主干结构对这一比较的干扰。本文需要比较单尺度预测、固定等权、全局可学习固定权重、恒定输入路由和样本级路由五种设置；若尺度专家本身过于复杂，误差变化会同时受到主干结构和融合机制影响。DLinear 具有清晰的参数关系，并保留基本预测能力。这使上述设置能够在统一的尺度专家结构下比较，预测主干与尺度融合的影响也便于分别考察。

1.4 样本级自适应尺度加权

3 个 DLinear 专家分别给出同一样本的 3 组预测结果；形成最终输出时，需要确定各组结果所占的比例。若 3 个尺度始终各占 1/3，这一融合比例将用于全部输入窗口。输入窗口的状态有差别。局部波动较强的窗口可能更依赖细粒度信息；变化平稳的窗口则可能更需要较粗尺度所保留的趋势信息。本文希望融合比例能够随样本状态变化，因而将窗口状态差异纳入权重计算。从原始输入$\mathbf{X}_n$提取四维统计向量$\mathbf{z}_n = [\mu_n, \sigma_n, \ell_n, d_n]$，用这些统计量描述当前窗口状态，其中

$$\mu_n = \frac{1}{LC}\sum_{t=0}^{L-1}\sum_{c=1}^{C} X_{n,t,c}\,, \quad \sigma_n = \sqrt{\frac{1}{LC}\sum_{t=0}^{L-1}\sum_{c=1}^{C}(X_{n,t,c}-\mu_n)^2}. \tag{9}$$

$$\ell_n = \frac{1}{C}\sum_{c=1}^{C} X_{n,L-1,c}\,, \quad d_n = \frac{1}{(L-1)C}\sum_{t=1}^{L-1}\sum_{c=1}^{C}|X_{n,t,c}-X_{n,t-1,c}|. \tag{10}$$

μ_n、σ_n、ℓ_n和d_n分别描述输入窗口的总体水平、离散程度、最近状态和平均变化强度。μ_n反映窗口整体流量水平，σ_n刻画观测值的离散程度，ℓ_n取窗口末时刻的平均状态，d_n由相邻时间点的一阶变化得到。这 4 个统计量分别提供水平、波动、最近状态和局部变化信息，供路由器计算输入相关的尺度权重，而不直接参与未来流量数值的预测。

两层感知器接收四维统计向量，隐藏维数设为 16。其输出对应 3 个尺度，是尚未归一化的尺度分数。路由器负责计算尺度融合分数，完整 OD 流量的预测仍由尺度专家承担。本文使用低维统计量及较小隐藏层完成路由计算，没有增加循环网络、注意力网络等额外时序编码器。由此将路由模块的参数规模控制在较低水平。其尺度分数计算为

$$\mathbf{a}_n = \mathbf{W}_2\mathrm{ReLU}(\mathbf{W}_1\mathbf{z}_n + \mathbf{b}_1) + \mathbf{b}_2. \tag{11}$$

对式（11）的 3 个尺度分数作 Softmax 归一化，得到 3 个总和为 1 的非负权重；各专家在最终预测中的相对贡献由这些权重表示：

$$\alpha_{n,s} = \frac{\exp(a_{n,s})}{\sum_{j\in S}\exp(a_{n,j})}, \quad \alpha_{n,s} \geq 0, \quad \sum_{s\in S}\alpha_{n,s} = 1. \tag{12}$$

最终预测为

$$\widehat{\mathbf{Y}}_n = \sum_{s\in S}\alpha_{n,s}\,\widehat{\mathbf{Y}}_n^{(s)}. \tag{13}$$

式（13）利用上述权重对 3 个 DLinear 专家的预测结果进行加权求和，得到最终预测$\hat{\mathbf{Y}}_n$。该组权重由输入窗口计算，并由同一窗口内的全部 OD 变量共享。为了区分多尺度结构、非等权分配与样本相关分配的作用，设置三种共享相同专家的对照：固定等权模型将三个尺度恒定设为 1/3；全局可学习权重模型以三个可训练参数经 Softmax 得到一组常权重；恒定输入路由模型保留完整路由网络，但训练和推理时都向路由器输入全零窗口，使全部样本共用一组可学习权重。三种模型的尺度专家均接收真实历史窗口。

1.5 训练目标与模型复杂度

本文以均方误差训练模型。损失在训练样本、未来 H 个预测时刻以及全部 C 个 OD 变量上计算，覆盖不同预测步与不同 OD 维度的偏差。各项偏差在同一目标中汇总，用于模型参数更新。对应训练目标为

$$\mathcal{L}_{\mathrm{MSE}} = \frac{1}{NHC}\sum_{n=1}^{N}\sum_{h=1}^{H}\sum_{c=1}^{C}(Y_{n,h,c} - \hat{Y}_{n,h,c})^2. \tag{14}$$

模型参数通过 Adam 优化器更新；验证集 MSE 用于确定训练结束后采用的最终模型。可训练参数在单尺度 DLinear 中为 4656 个，在三个尺度专家的固定等权模型中为 8208 个。在后者基础上增加三个全局权重参数，总数为 8211 个。样本级路由模型与恒定输入路由模型的标称参数数目相同，均为 8339 个。与固定等权模型相比，路由网络增加 131 个参数；与全局权重模型相比，增加 128 个参数。恒定输入路由与样本级路由保留相同网络结构。其输入恒为零，首层输入权重因而不参与有效计算。

模型计算依次经过三个环节：平均池化把同一历史窗口转换为 3 个时间分辨率，DLinear 专家分别给出候选预测，路由网络再根据原始窗口的 4 个统计量确定融合权重。后续实验据此设置单尺度 DLinear、固定等权多尺度、全局可学习固定权重模型、恒定输入路由模型和本文方法，用同一组专家结构区分多尺度信息与样本级加权的作用。

2 实验与结果分析

实验分为外部基线比较、核心消融和路由行为分析三个层次。LightTS 提供独立结构的外部基线，DLinear 提供单尺度参照；固定等权、全局可学习常权重、恒定输入路由与样本级路由模型采用相同的三个尺度专家结构，并分别训练，分别比较多尺度结构、非等权融合与输入相关权重的表现；八个共同随机种子的配对结果和逐种子权重分析用于评估结果波动。

2.1 数据集与实验设置

CESNET TS-Zoo[9]提供本文采用的实验数据。实验使用按 1 h 聚合的 Abilene[10]与 GÉANT[11]骨干网流量矩阵。Abilene 共有 4656 个时间点，保留 144 维有效 OD 流量；GÉANT 共有 2849 个时间点，去除恒定通道后保留 524 维有效 OD 流量。两套数据的序列长度与变量规模存在差异。同一预测流程在这些不同数据条件下的表现，可通过两套实验分别观察。两个数据集均沿时间顺序划分，依次得到训练集、验证集、测试集，比例为 6:2:2。输入长度统一设为 L=96，预测长度统一设为 H=24。预处理按第 1.1 节执行，数据规模及窗口数量见表 1。

表 1 数据集与预测任务设置

数据集	时间点	有效变量 C	训练/验证/测试时间点	训练/验证/测试窗口	L/H
Abilene	4656	144	2793/931/932	2674/812/813	96/24
GÉANT	2849	524	1709/570/570	1590/451/451	96/24

所有对比模型使用相同的数据划分、输入长度、预测长度、评价指标和批量大小，batch size 统一为 16。为控制数据与训练条件，实验未分别搜索各模型的最优超参数。DLinear、固定等权多尺度、全局可学习权重、恒定输入路由和本文方法最多训练 30 轮，LightTS 最多训练 50 轮；均根据验证集 MSE 选择测试所用参数，测试集仅用于最终统计。

外部基线比较使用随机种子 42～44 共 3 个共同随机种子。核心消融使用随机种子 42～49 共 8 个共同随机种子，比较 DLinear、固定等权多尺度、全局可学习权重、恒定输入路由和本文方法。全局权重由等权初始化，恒定输入路由对所有窗口使用全零路由输入；两者均与三个专家一同训练，并按相同验证集准则选择模型；随机种子作为配对统计单位。

2.2 对比模型与评价指标

对照包括 DLinear、LightTS、固定等权多尺度、全局可学习权重和恒定输入路由五类模型。DLinear 用于比较单一尺度与多尺度结构；LightTS 提供独立轻量模型基线。后三种多尺度对照与本文方法保留相同的尺度集合{1,2,4}和 DLinear 专家，分别使用等权、全局可学习权重和恒定输入路由权重。后两者均对全部窗口使用一组固定权重，可检验完整模型相对常权重方案的误差变化。

均方误差（MSE）、平均绝对误差（MAE）及均方根误差（RMSE）用于评价预测性能。其中 MSE 采用式（14），MAE 和 RMSE 的定义如下

$$\mathrm{MAE} = \frac{1}{N_{\mathrm{te}} HC} \sum_{n=1}^{N_{\mathrm{te}}} \sum_{h=1}^{H} \sum_{c=1}^{C} |\, Y_{n,h,c} - \hat{Y}_{n,h,c} |. \tag{15}$$

$$\mathrm{RMSE} = \sqrt{\mathrm{MSE}}. \tag{16}$$

标准化空间是所有误差指标的计算空间，指标越小表示误差越低。正文主要报告 MSE 与 MAE，分别用于观察对较大误差敏感的平方误差和平均绝对偏差。误差幅值另由 RMSE 补充描述，其数值为 MSE 的平方根。随机种子 42～44 的结果在表 2 中以均值±标准差列出；随机种子 42～49 的结果在表 3 中采用同一统计形式。均值描述平均水平，标准差描述随机种子之间的波动。计算相对改进率时，先按共同随机种子配对，得到各个种子的改进率，再对这些改进率取平均。该百分比不是由表内四舍五入后的均值直接计算得到。

2.3 两数据集外部基线比较

表 2 列出 3 个共同随机种子下的总体基线结果。本文方法在 Abilene 上的 MSE 为 0.186，在 GÉANT 上为 0.434；逐种子计算后相对 DLinear 分别降低 4.07%和 4.54%，相对 LightTS 分别降低 29.80%和 46.89%，MAE 呈相同方向变化。DLinear 与本文尺度专家采用同源结构，后续核心消融也以 DLinear 作为单尺度内部基线；LightTS 属于独立外部结构基线，图 2 进一步给出逐随机种子、多指标和参数规模比较。

表 2 三随机种子外部基线比较

数据集	模型	参数量	MSE	MAE
Abilene	DLinear	4656	0.194±0.002	0.188±0.009
Abilene	LightTS	130162	0.265±0.011	0.204±0.008
Abilene	本文方法	8339	0.186±0.002	0.168±0.001
GÉANT	DLinear	4656	0.454±0.007	0.383±0.006
GÉANT	LightTS	384382	0.817±0.024	0.523±0.014
GÉANT	本文方法	8339	0.434±0.051	0.370±0.031

图 2 以 LightTS 为独立外部基线，使用两种方法共有的随机种子 42～44。每次实验的相对降低率按（LightTS 误差−本文方法误差）/LightTS 误差计算。MSE、MAE 和 RMSE 的平均降幅在 Abilene 上为 29.80%、17.57%和 16.23%，在 GÉANT 上为 46.89%、29.15%和 27.18%。逐种子检查这三项指标，两个数据集的 3 个共同随机种子均有改善。本文方法的 8339 个参数，约为 LightTS 在 Abilene 和 GÉANT 上参数量的 6.41%和 2.17%；LightTS 的对应参数量分别为 130162 和 384382。

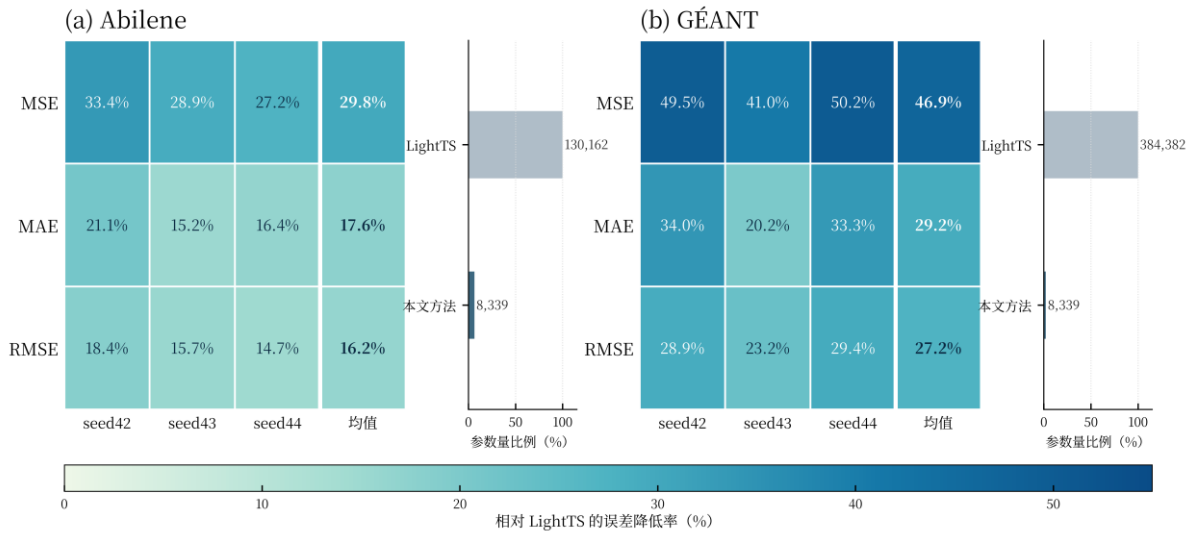


图 2 Abilene 与 GÉANT 上本文方法相对 LightTS 的三随机种子多指标性能提升

GÉANT 的 OD 变量数较多，本文方法相对 LightTS 的 MSE 降幅也高于 Abilene。不过，两者同时出现不能确立变量规模与误差降幅之间的因果关系。固定等权与全局可学习权重对照均采用相同的多尺度专家结构，适合进一步检验融合方式本身的作用。

2.4 八随机种子核心消融与稳定性

表 3 汇总随机种子 42～49 的 8 次核心消融，列出五种模型的参数量、MSE 和 MAE。

表 3 八随机种子核心消融结果（均值±标准差）

数据集	模型	参数量	MSE	MAE
Abilene	DLinear	4656	0.194±0.002	0.189±0.008
Abilene	固定等权多尺度	8208	0.192±0.002	0.191±0.006
Abilene	全局可学习权重	8211	0.192±0.002	0.190±0.006
Abilene	恒定输入路由	8339	0.192±0.002	0.181±0.006
Abilene	本文方法	8339	0.189±0.003	0.173±0.008
GÉANT	DLinear	4656	0.437±0.016	0.371±0.011
GÉANT	固定等权多尺度	8208	0.447±0.014	0.377±0.009
GÉANT	全局可学习权重	8211	0.446±0.014	0.377±0.009
GÉANT	恒定输入路由	8339	0.449±0.012	0.379±0.007
GÉANT	本文方法	8339	0.426±0.029	0.366±0.018

全局可学习权重与恒定输入路由均对所有窗口使用一组可学习权重，后者与本文方法同为 8339 个标称参数。相对这两种对照，本文方法在 Abilene 上的逐种子平均 MSE 改进均约 1.80%，在 GÉANT 上分别为 4.31%和 4.97%，各有 6/8 和 7/8 个种子胜出。相对恒定输入路由的 95%置信区间分别为[0.49%,3.11%]和[−1.62%,11.56%]，相对全局权重则为[0.01%,3.58%]和[−2.51%,11.13%]；GÉANT 两项区间均跨零。

图 3 中各项相对改进结果来自随机种子 42～49。本文方法分别与 DLinear、固定等权多尺度模型比较，并同时考察 MSE、MAE 及 RMSE 三项指标。半小提琴呈现 8 次结果的分布，散点保留每个随机种子的结果。黑色菱形标示 8 次改进率的均值，横向误差线标示 95%置信区间。误差是否改善可参照 0%虚线判断，虚线处对应两种方法的误差相同。相对 DLinear 时，Abilene 的 MSE、MAE 和 RMSE 平均改进率为 2.77%、8.01%和 1.40%，其中 MSE 与 RMSE 在 8 次实验中均改善；GÉANT 分别为 2.35%、1.32%和 1.22%，且跨越 0%的情况更多。相对固定等权模型时，Abilene 三项指标的平均改进率为 1.65%、8.92%和 0.84%，GÉANT 为 4.54%、3.05%和 2.37%。相对两种基线得到的平均改进率均为正值。与此同时，GÉANT 不同随机种子之间的波动较明显；判断平均收益是否稳定，仍需同时观察图中的置信区间。

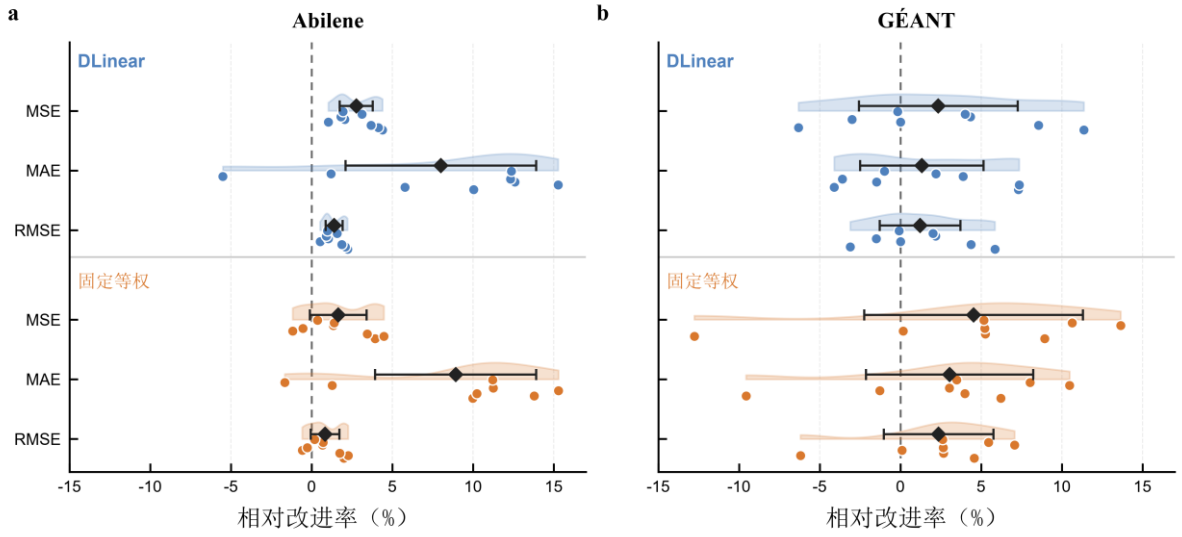


图 3 Abilene 与 GÉANT 上本文方法相对两类基线的八随机种子多指标相对改进分布

等权融合由固定等权模型检验。全局可学习权重与恒定输入路由模型则分别提供常权重对照，共同用于观察改变融合方式后的误差。表 3 中本文方法相对两者的平均 MSE 均较低，但 GÉANT 的配对区间均跨越零；其中种子 43 相对恒定输入路由退步 12.78%。各模型分别训练，而且恒定输入路由的首层输入权重不起作用。由这些对照观察到的，是完整方法与两类常权重方案之间的误差差异；逐窗口权重变化的贡献尚不能被唯一识别。图 4 用于进一步观察整体偏差及局部误差。整体偏差从全测试点汇总，局部误差则结合按真实值波动选取的预测轨迹考察。

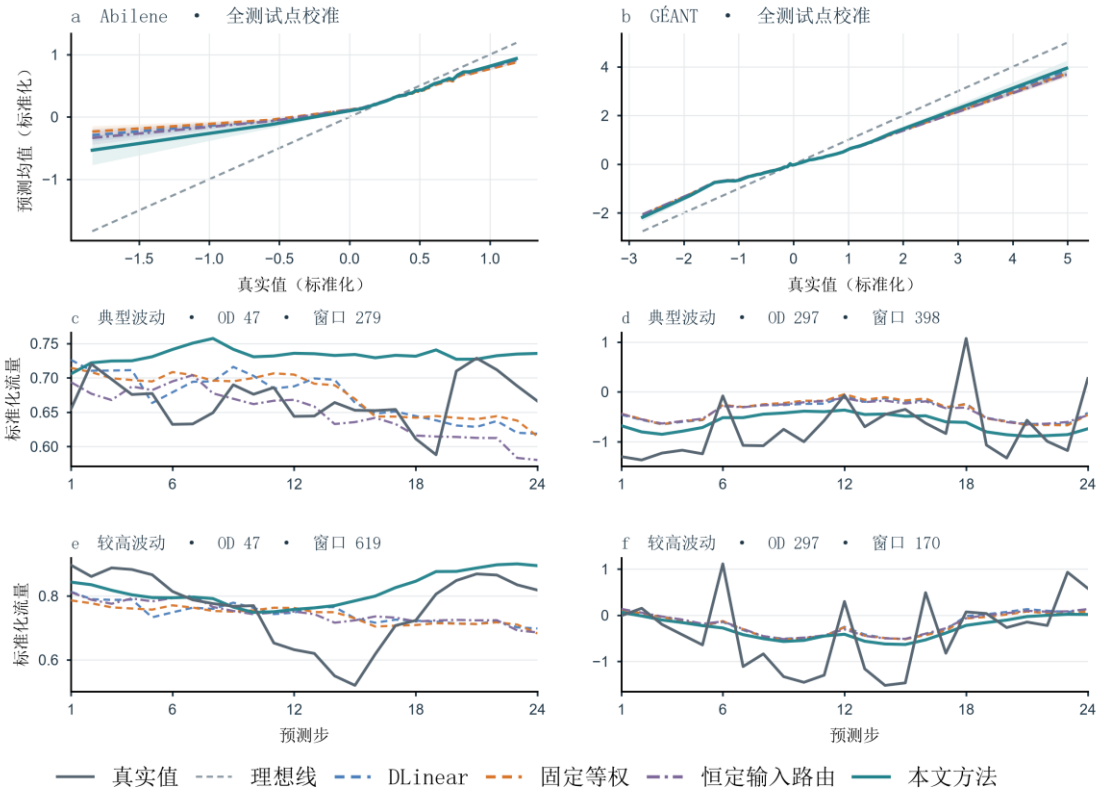


图 4 Abilene 与 GÉANT 全测试点预测校准及典型窗口预测轨迹

图 4(a、b)的统计覆盖随机种子 42～49，纳入全部测试窗口中的 24 个预测步和全部有效 OD 通道。真实值依据分位点分组，区间数最多为 40 个。各区间中，四种模型分别汇总 8 种子的预测值并取平均，作为曲线上的预测值。浅色带表示种子间±1 个标准差，理想预测位置由灰色虚线标示。四种模型在高真实值区间均存在低估。本文方法在这些分组中的平均偏差较小，不过，分组平均结果不能替代每个测试点的误差比较。图 4(c～f)固定随机种子 42，仅根据真实序列选择标准差接近第 75 百分位的 OD 通道，再选择波动程度接近中位数和第 90 百分位的窗口。选取通道和窗口的上述过程只使用真实序列，未依据模型误差挑选案例。本文方法在四例中的三例取得较低的 24 步均方误差，均低于 DLinear、固定等权和恒定输入路由模型；Abilene 典型波动窗口是例外，本文方法在该例中较差。这些轨迹说明的是所选窗口中的局部预测行为，总体精度仍应结合表 3 的配对统计判断。测试窗口之间存在重叠，因此不能把重叠窗口视为独立重复。

2.5 路由权重分析

随机种子 42～49 下三个尺度的路由权重汇总于图 5。全部测试窗口及种子共同形成各尺度的小提琴分布，蓝、绿、橙色依次对应尺度 1、2 和 4。先对同一种子的全部测试窗口计算平均权重，每个种子对应一个彩色散点。再对 8 个种子均值计算均值±1 个标准差，分别以黑色菱形和误差线表示。短横线标示汇总分布中位数，水平虚线标示固定等权 1/3。小提琴分布中既有种子间差异，也有窗口间差异，两者共同影响其宽度。因而，这一宽度不能直接用于判断同一种子内的窗口响应强度。

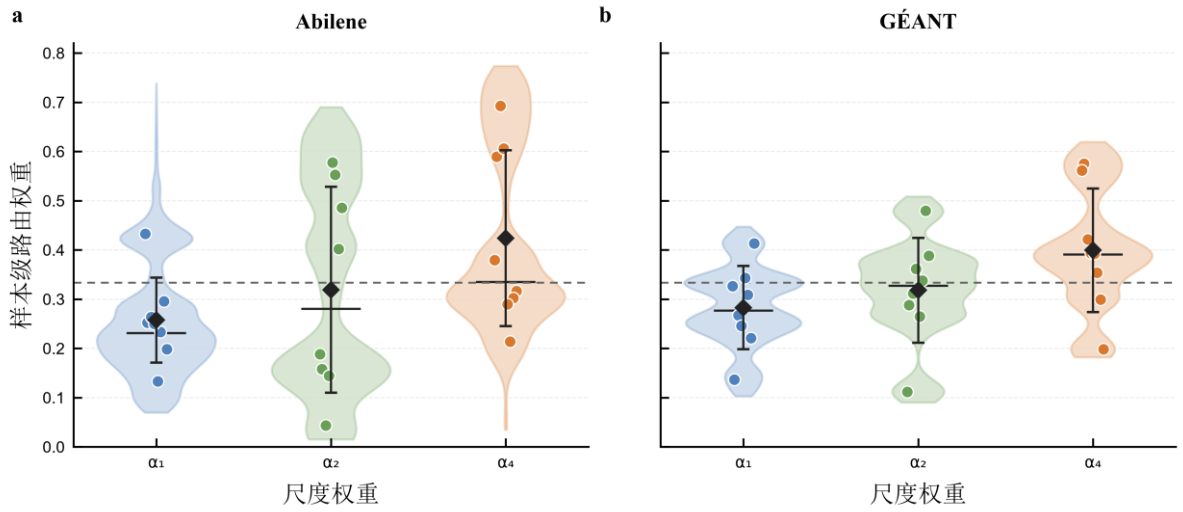


图 5 Abilene 与 GÉANT 的逐窗口路由权重汇总分布及八种子均值

三个尺度在 Abilene 上的汇总平均权重依次为 0.257、0.319 和 0.424，在 GÉANT 上依次为 0.283、0.318 和 0.399。这些总体均值均偏离固定等权的 1/3。从汇总权重方差的来源看，GÉANT 三个尺度中约 96.2%、95.8%和 97.7%的方差来自种子间差异。Abilene 对应的比例分别为 48.7%、86.1%和 80.6%。在 GÉANT 的同一种子内部，随窗口发生的权重变化较小。图 5 展示的汇总分布，把种子间差异与同一种子内部的窗口差异放在一起。若仅依据这一分布判断路由机制，仍缺少路由器能否有效识别各窗口尺度需求的证据。

输入窗口的波动强度由平均绝对一阶差分度量。分组阈值取自训练窗口的三分位数，测试窗口按这些阈值分组。Abilene 低、中、高波动组分别有 15、406、392 个窗口。本文方法相对全局权重模型的逐种子平均 MSE 改进率分别为 4.43%、1.90%、1.69%；GÉANT 在训练阈值下无低波动测试窗口，中、高组分别有 76、375 个窗口，改进率为 5.85%和 4.06%。在 Abilene 上，高波动组的尺度 1 平均权重高于中波动组，而相应的误差优势没有增强。GÉANT 中波动组与高波动组的权重则近似相同。依据这些分组结果，当前还不能支持“波动越强，路由收益越大”的机制解释。

前向计算开销通过另一次计时测量。计时采用预测长度为 24 的 8 个随机种子检查点，运行设备为 NVIDIA GTX 1060；测试张量预先加载，批量大小设为 16。本文方法在 Abilene 和 GÉANT 上的平均每批前向耗时分别为 2.65 ms 和 2.61 ms，固定等权模型分别为 2.38 ms 和 2.10 ms，单尺度 DLinear 分别为 0.77 ms 和 0.70 ms。这里报告的耗时只覆盖模型前向计算，数据读取与传输没有计入。端到端部署时延还应包含这两部分。本文方法虽然参数量较小，三个尺度专家以及路由器的计算仍增加了推理开销。

3 结论

本文用尺度 1、2 和 4 的 DLinear 专家分别预测骨干网络 OD 流量。轻量路由网络随后计算输入相关融合权重，并组合各专家的结果，构成同时处理短时波动与较慢趋势的多尺度预测结构。预测长度为 24 时，在 Abilene 和 GÉANT 两套实验中，本文方法的平均误差均低于作为比较对象的 DLinear、LightTS 和固定等权模型。相对全局可学习权重与恒定输入路由两类常权重对照，本文方法在 Abilene 上的逐种子平均 MSE 改进均约 1.80%；GÉANT 上的对应改进分别为 4.31%和 4.97%，但两项 95%置信区间均跨越零。在预测校准中，各模型对较高流量取值仍有低估；本文方法在高值端的平均偏差相对较小。这是按真实值分组后得到的平均结果，尚不能据此断言每个测试点都更准确。逐种子权重分析与波动分组分析共同表明，路由器能否稳定匹配窗口尺度需求仍缺乏充分证据。对输入相关融合收益的稳定性，还需在更多数据及不同预测设置下继续检验。

参考文献

[1] LOHRASBINASAB I, KESHAVARZ A, AMIN-NEJAD S, et al. From statistical- to machine learning-based network traffic prediction[J]. Transactions on Emerging Telecommunications Technologies, 2022, 33(4): e4394. DOI: 10.1002/ett.4394.

[2] QIN L, GU H, WEI W, et al. Spatio-temporal communication network traffic prediction method based on graph neural network[J]. Information Sciences, 2024, 679: 121003. DOI: 10.1016/j.ins.2024.121003.

[3] 韦烜, 刘志华, 李青, 等. 大型 IP 网络流量矩阵分析预测的探讨研究[J]. 系统工程与电子技术, 2024, 46(6): 2164-2173. DOI: 10.12305/j.issn.1001-506X.2024.06.35.

[4] 唐文杰, 肖一磊, 孔祥宇, 等. CycleLLH：一种基于周期性整合的新型网络流量预测模型[J]. 计算机学报, 2024, 47(12): 2867-2888. DOI: 10.11897/SP.J.1016.2024.02867.

[5] ZHOU J, HAN T, XIAO F, et al. Multiscale network traffic prediction method based on deep echo-state network for Internet of Things[J]. IEEE Internet of Things Journal, 2022, 9(21): 21862-21874. DOI: 10.1109/JIOT.2022.3181807.

[6] ZENG A, CHEN M, ZHANG L, et al. Are transformers effective for time series forecasting?[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2023, 37(9): 11121-11128. DOI: 10.1609/aaai.v37i9.26317.

[7] WANG S, WU H, SHI X, et al. TimeMixer: decomposable multiscale mixing for time series forecasting[C]//International Conference on Learning Representations. 2024.

[8] ZHANG T, ZHANG Y, CAO W, et al. Less is more: fast multivariate time series forecasting with light sampling-oriented MLP structures[EB/OL]. (2022-07-04)[2026-09-20]. https://arxiv.org/abs/2207.01186. DOI: 10.48550/arXiv.2207.01186.

[9] KUREŠ M, KOUMAR J, HYNEK K. CESNET TS-Zoo: a library for reproducible analysis of network traffic time series[C]//2025 21st International Conference on Network and Service Management. 2025. DOI: 10.23919/CNSM67658.2025.11297513.

[10] ZHANG Y, ROUGHAN M, DUFFIELD N, et al. Fast accurate computation of large-scale IP traffic matrices from link loads[J]. ACM SIGMETRICS Performance Evaluation Review, 2003, 31(1): 206-217. DOI: 10.1145/885651.781053.

[11] UHLIG S, QUOITIN B, LEPROPRE J, et al. Providing public intradomain traffic matrices to the research community[J]. ACM SIGCOMM Computer Communication Review, 2006, 36(1): 83-86. DOI: 10.1145/1111322.1111341.