基于自适应多尺度加权的多变量网络流量预测方法

[请填写作者姓名]

([请填写工作单位] [请填写部门], [省 市 邮编])

摘要：骨干网络源—目的节点对流量兼有短时起伏和较慢趋势，单一时间分辨率难以同时表征两者。本文采用尺度 1、2 和 4 的 DLinear 专家，由轻量路由网络根据输入窗口统计量生成 Softmax 融合权重。在输入长度 96、预测长度 24 的 Abilene 和 GÉANT 实验中，3 个共同随机种子下本文方法相对 DLinear 的 MSE 分别降低 4.07%和 4.54%，相对 LightTS 分别降低 29.80%和 46.89%。8 个随机种子的核心消融加入全局可学习权重和恒定输入路由两类固定权重对照；本文方法相对两者在 Abilene 上的逐种子平均 MSE 改进率均约为 1.80%，在 GÉANT 上分别为 4.31%和 4.97%。GÉANT 的两项配对 95%置信区间均跨越零，且路由权重变化主要来自随机种子之间，因此当前结果支持平均误差改善，但尚不能证明路由器稳定识别每个窗口的最佳尺度。

关键词：网络流量预测；多变量时间序列；多尺度学习；自适应加权；DLinear

中图分类号：TP393　　**文献标志码：**A

A Multivariate Network Traffic Forecasting Method Based on Adaptive Multiscale Weighting

[Author Name]

([Affiliation] [Department], [City] [Postcode], China; Corresponding author: [Name], E-mail: [E-mail])

Abstract: Short-term fluctuations and slower trends coexist in backbone origin-destination traffic. Input-window statistics determine the Softmax weights used to combine DLinear experts at scales 1, 2, and 4. For input length 96 and forecast length 24, results from three common random seeds give MSE reductions of 4.07% on Abilene and 4.54% on GÉANT relative to DLinear. The corresponding reductions relative to LightTS are 29.80% and 46.89%. An eight-seed ablation adds two fixed-weight controls: learned global weights and a router receiving constant input. Mean seed-wise MSE reductions over the two controls are both about 1.80% on Abilene; on GÉANT, they are 4.31% and 4.97%, respectively. Both paired 95% confidence intervals on GÉANT include zero, and most of its pooled router-weight variance arises between seeds. Reliable window-specific scale selection therefore remains unconfirmed despite the average error reduction.

Key words: network traffic forecasting; multivariate time series; multiscale learning; adaptive weighting; DLinear

容量规划、拥塞预警、资源调度和流量工程需要预先判断骨干网络的流量状态。源—目的节点对（origin-destination，OD）流量直接对应不同节点对之间的通信需求，后续 OD 流量因此成为上述网络管理任务的预测对象。随着云计算、视频业务、数据中心互联及智能网络应用持续增加，网络内部的业务迁移和聚集更频繁；后续流量状态的时间变化也更加复杂，增加了预测的难度。周期变化、局部波动与突发变化常叠加在同一 OD 流量序列中，不同变量又有各自的数值范围。对较平稳单变量序列的趋势描述，难以完整覆盖这类 OD 数据中的复杂短时变化。预测模型需要同时处理较长时间趋势与短时状态变化，保留对后者的响应。

Lohrasbinasab 等[1]系统梳理了网络流量预测方法，指出机器学习和深度学习等数据驱动方法在复杂流量预测中的应用不断增加，反映了传统统计模型之外的研究扩展。网络规模扩大也使 OD 变量之间的关联

收稿日期：[请填写，格式 YYYY-MM-DD]

基金项目：[基金来源]（[基金项目编号]）

第一作者简介：[姓名]（[出生年]—），[性别（民族，汉族可省略）]，[职称]，[学位（若在读请注明）]，研究方向：[方向 1]；[方向 2]。

通信作者简介：[姓名]（[出生年]—），[性别（民族，汉族可省略）]，[职称]，[学位（若在读请注明）]，研究方向：[方向 1]；[方向 2]，电子邮箱：[邮箱]。

更难由单一序列的时间分析覆盖。Qin 等[2]把图神经网络引入通信网络流量预测，在同一模型中处理空间关联和时间依赖；韦烜等[3]针对大型 IP 网络流量矩阵开展分析与预测，讨论了不同 OD 变量之间的关联及其时间变化。唐文杰等[4]则在 CycleLLH 模型中引入周期性信息。上述研究涉及的时间依赖、变量关联与周期结构，构成了流量预测的不同观察角度。

时间聚合能够平滑部分局部扰动，让较慢的变化趋势更易观察；未经聚合的原始分辨率则保留较多细节，短时起伏更清晰。同一流量序列的可观察特征由此随时间分辨率改变。在 Zhou 等[5]的多尺度网络流量预测研究中，深度回声状态网络从不同时间分辨率的序列中提取信息，以利用各分辨率之间的互补性。利用多尺度信息时，还需要控制模型的结构开销。DLinear[6]将时间序列分解与线性映射用于预测。不同分辨率序列在 TimeMixer[7]中由多尺度混合机制处理，而 LightTS[8]采用采样导向的 MLP 结构实现快速多变量时间序列预测。本文据此把多时间尺度信息与模型规模同时纳入设计要求，考察两者对预测结构的约束。

常见的多尺度处理预先给定时间尺度，分别计算各尺度结果，再按既定方式融合。不同输入窗口中的短时波动和平缓趋势占比并不相同，因而尺度 1、2 和 4 在预测中的作用可能随输入状态改变。仅使用单一尺度时，其他时间分辨率的信息无法保留；即使构造多尺度序列，固定的融合比例也没有把窗口状态差异用于权重计算。本文将当前输入窗口作为融合权重计算的依据。这样，在完成多个时间尺度的构造后，窗口状态也参与各尺度结果的组合。

针对输入窗口之间的状态差异，本文采用样本级自适应多尺度结构。历史窗口按尺度 1、2 和 4 构造多分辨率序列，每个尺度由一个 DLinear 专家给出候选预测。路由网络不重新编码完整时序，而是读取当前输入窗口的总体水平、离散程度、最近状态和变化强度等统计量，生成 Softmax 尺度权重，并据此融合三个专家的结果。这样可以把尺度内预测与尺度间选择分开处理。实验在 Abilene 和 GÉANT 两个公开骨干网数据集上进行，比较 DLinear、LightTS、固定等权、全局可学习固定权重与恒定输入路由模型，并通过多个随机种子重复实验和路由权重分析检验预测误差、核心结构消融与尺度分配行为。

1 自适应多尺度网络流量预测方法

图 1 给出模型的整体流程。模型包含多尺度预测和尺度选择两个模块：尺度 1、2 和 4 的输入分别交给独立 DLinear 专家，路由网络根据当前窗口的统计特征估计 3 个尺度的融合权重。原始 OD 流量经对数变换和标准化后形成 3 个时间分辨率的输入序列；3 个专家分别预测，再按样本级权重融合。固定等权、全局可学习权重与恒定输入路由对照采用相同的尺度与专家结构，并分别训练，用以比较等权、全局非等权与输入相关融合。

原始尺度的局部变化较完整，较粗尺度中的短时扰动则经时间聚合削弱，较慢的趋势更突出。三个时间尺度因而向模型提供平滑程度不同的历史信息。本文先保留 3 个尺度的独立预测结果，再通过路由网络确定每个样本的组合比例。专家统一采用结构较简洁的 DLinear，既控制模型规模，也使多尺度输入与样本级融合的作用可在同一主干下比较。

1.1 问题定义与数据预处理

记预处理后的多变量流量序列为 $\mathbf{x}_t \in \mathbb{R}^C$，其中 t 对应时间索引，C 对应有效 OD 变量数。沿时间轴滑动连续序列，形成用于监督学习的窗口样本。第 n 个样本由历史窗口$\mathbf{X}_n$及预测目标$\mathbf{Y}_n$组成：$\mathbf{X}_n$覆盖连续 L 个时间点，$\mathbf{Y}_n$覆盖历史窗口之后连续的 H 个时间点。多个 OD 变量在过去 L 步内的联合变化提供历史信息，模型利用这些信息估计未来 H 步的取值。上述第 n 个样本的输入和目标可定义为

$$\mathbf{X}_n = [\mathbf{x}_n, \dots, \mathbf{x}_{n+L-1}] \in \mathbb{R}^{L\times C}. \tag{1}$$

$$\mathbf{Y}_n = [\mathbf{x}_{n+L}, \dots, \mathbf{x}_{n+L+H-1}] \in \mathbb{R}^{H\times C}. \tag{2}$$

本文以 L=96 步历史预测 H=24 步未来流量。变量数 C 取各数据集保留的有效 OD 维度数，模型需要学习的预测映射记为$\hat{\mathbf{Y}}_n = f_\theta(\mathbf{X}_n)$。一次预测读取的历史范围由 L 限定，需要连续输出的未来长度由 H 限定。各 OD 变量的原始流量均非负，但量级差异较大。直接在原始数值上训练时，数值范围较大的变量与其他变量尺度不一致，因此先压缩流量的数值范围，对原始流量$v_{t,c}$作对数变换

$$u_{t,c} = \log(1 + v_{t,c}). \tag{3}$$

再按变量进行标准化：

$$x_{t,c} = \frac{u_{t,c} - \mu_c^{\mathrm{tr}}}{\sigma_c^{\mathrm{tr}}}. \tag{4}$$

其中μ_c^{tr}和σ_c^{tr}分别表示训练集中第 c 个 OD 变量的均值与标准差。预处理验证集和测试集时，使用的仍是训练阶段这组统计量，不在这两个集合上重新估计。log(1+x)在保留非负流量大小关系的同时压缩数值范围，缓和原始流量的量级差异。后续标准化按变量进行，各 OD 维度以相近的数值尺度参与训练；损失计算及参数更新中，各变量所用的尺度也由这一步统一。数据按时间先后划为训练集、验证集、测试集，比例仍为 6:2:2。各集合独立生成内部滑动窗口，窗口不跨越集合之间的划分边界。

各尺度共用同一历史窗口，其时间分辨率在预处理阶段保持不变。随后构造不同尺度的序列，使各专家分别观察细粒度变化与较平滑的趋势。

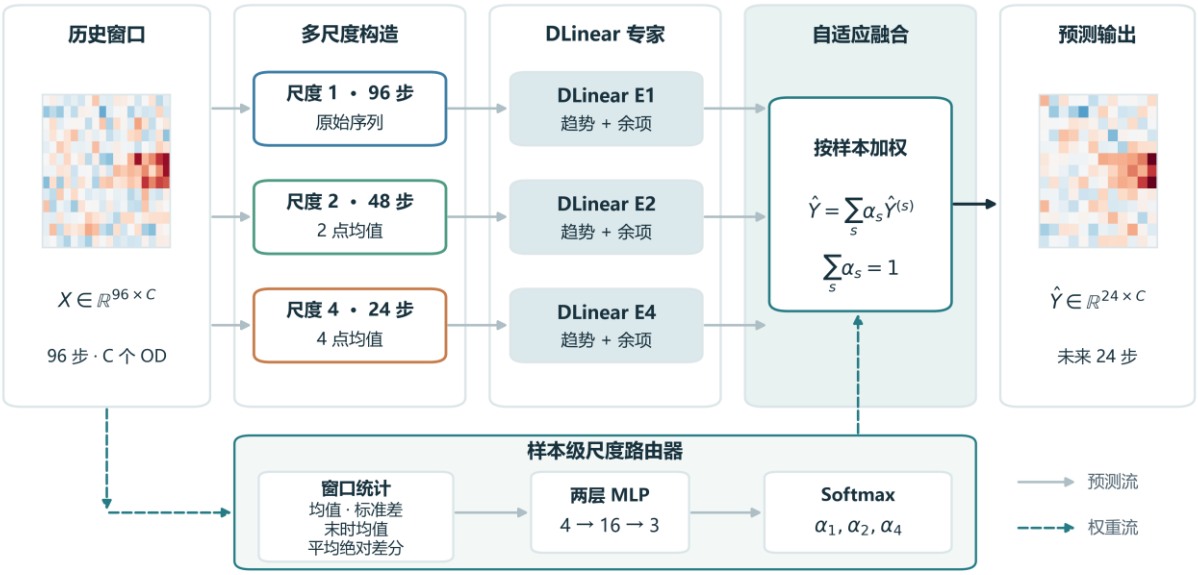


图 1 自适应多尺度网络流量预测方法框架

1.2 多尺度序列构造

设尺度集合 S={1,2,4}。时间维聚合采用非重叠平均池化，窗口大小由尺度 s 指定，步长也取 s。对任一尺度 s，按照这一窗口与步长进行的池化为：

$$\mathbf{X}_{n,t}^{(s)} = \frac{1}{s}\sum_{i=0}^{s-1}\mathbf{X}_{n,st+i}, \quad t = 0, \ldots, \frac{L}{s} - 1. \tag{5}$$

本文使用尺度集合 S={1,2,4}。对于 L=96 的输入，尺度 1 直接保留原始 96 步序列。尺度 2 以相邻 2 个时间点的平均值作为聚合值，形成 48 步序列；尺度 4 则以每 4 个时间点的平均值作为一个聚合点，形成 24 步序列。尺度 1 不压缩时间轴，因此较完整地保留短时起伏；尺度 2 对局部变化作适度平滑；尺度 4 进一步削弱短时间内的高频变化，较慢的趋势由此更突出。构造多分辨率输入时，本文选择无需训练参数的平均池化。尺度变换不另设可训练模块，因此输入构造本身没有新增模型参数。

96 步历史窗口采用尺度 1、2 和 4 时，可形成三组长度均为整数的序列；这一设置也同时控制了尺度专家的数量。若继续增加尺度，得到的序列会更粗，其有效时间长度也随之缩短；增加相应尺度的预测还需要新的专家分支。本文按细粒度信息、趋势信息与模型规模之间的取舍，固定使用尺度组合{1,2,4}。该组合没有经过穷举搜索，其最优性仍未经验证。非重叠池化中，一个原始时间点仅参与一次同尺度聚合，因而各尺度所对应的时间聚合含义较为直接。

1.3 DLinear 尺度专家

尺度 1、2 和 4 各自使用一个 DLinear 专家[6]，每个专家只接收对应尺度的序列，输入在专家之间分开处理。DLinear 先把序列分解为变化较慢的趋势项和围绕趋势变化的余项，再分别对两项作时间映射。对尺度 s 的输入，本文使用长度 q=25 的中心移动平均提取趋势项。平滑在移动平均的局部时间邻域内完成。边界位置不足一个完整窗口时，缺少的部分用端点复制补齐，避免序列长度缩短；补齐后的序列记为$\tilde{\mathbf{X}}^{(s)}$；越界索引取最近端点值，从而保持分解前后的时间长度一致：

$$\mathbf{T}_{n,t}^{(s)} = \frac{1}{q}\sum_{i=-m}^{m}\tilde{\mathbf{X}}_{n,t+i}^{(s)}, \quad q = 2m + 1 = 25. \tag{6}$$

$$\mathbf{R}_{n}^{(s)} = \mathbf{X}_{n}^{(s)} - \mathbf{T}_{n}^{(s)}. \tag{7}$$

趋势项$\mathbf{T}^{(s)}$和余项$\mathbf{R}^{(s)}$沿时间维分别通过线性层映射到预测长度 H：

$$\hat{\mathbf{Y}}_{n}^{(s)} = \mathbf{W}_{T}^{(s)}\mathbf{T}_{n}^{(s)} + \mathbf{b}_{T}^{(s)} + \mathbf{W}_{R}^{(s)}\mathbf{R}_{n}^{(s)} + \mathbf{b}_{R}^{(s)}. \tag{8}$$

由式（6）和式（7）可得到尺度 s 上的趋势项$\mathbf{T}^{(s)}$和余项$\mathbf{R}^{(s)}$。趋势项表示经过局部平滑后保留下来的较慢变化部分，余项则由原序列减去趋势项得到，保留未被移动平均解释的局部变化。式（8）分别对两部分沿时间维进行线性映射，并把二者的预测结果相加形成该尺度的候选预测。3 个尺度使用独立 DLinear 专家，是因为尺度 1、2 和 4 的输入长度分别为 96、48 和 24，对应的时间分辨率和时间映射关系并不相同；若强制共用一组尺度间参数，会把不同长度、不同平滑程度的序列约束到同一映射中。同一尺度内部，各

OD 变量共享时间映射参数，模型学习的是这一时间尺度下通用的时间映射形式，而不是为每个 OD 变量分别建立一套线性层。

预测误差同时可能受到主干结构和融合方式影响。为减少比较融合方式时的主干干扰，本文把各尺度专家统一设置为 DLinear。本文需要比较单尺度预测、固定等权、全局可学习固定权重、恒定输入路由和样本级路由五种设置；若尺度专家本身过于复杂，误差变化会同时受到主干结构和融合机制影响。DLinear 的参数关系清晰，且保留基本预测能力，适合承担当中的统一尺度专家。上述设置共用专家结构，因而便于分别考察预测主干与尺度融合的影响。

1.4 样本级自适应尺度加权

3 个 DLinear 专家分别给出同一样本的 3 组预测结果；形成最终输出时，需要确定各组结果所占的比例。令 3 个尺度始终各占 1/3，全部输入窗口便使用同一融合比例。然而窗口状态有差别：局部波动较强时，细粒度信息可能更有用；变化平稳时，较粗尺度保留的趋势信息可能更有用。为使融合比例随样本状态变化，本文以窗口统计量参与权重计算。具体从原始输入$\mathbf{X}_n$提取四维统计向量$\mathbf{z}_n = [\mu_n, \sigma_n, \ell_n, d_n]$，用这些统计量描述当前窗口状态，其中

$$\mu_n = \frac{1}{LC}\sum_{t=0}^{L-1}\sum_{c=1}^{C} X_{n,t,c}\,, \quad \sigma_n = \sqrt{\frac{1}{LC}\sum_{t=0}^{L-1}\sum_{c=1}^{C}(X_{n,t,c}-\mu_n)^2}. \tag{9}$$

$$\ell_n = \frac{1}{C}\sum_{c=1}^{C} X_{n,L-1,c}\,, \quad d_n = \frac{1}{(L-1)C}\sum_{t=1}^{L-1}\sum_{c=1}^{C}|X_{n,t,c}-X_{n,t-1,c}|. \tag{10}$$

μ_n、σ_n、ℓ_n和d_n分别描述输入窗口的总体水平、离散程度、最近状态和平均变化强度。μ_n反映窗口整体流量水平，σ_n刻画观测值的离散程度，ℓ_n取窗口末时刻的平均状态，d_n由相邻时间点的一阶变化得到。这 4 个统计量分别提供水平、波动、最近状态和局部变化信息，供路由器计算输入相关的尺度权重，而不直接参与未来流量数值的预测。

路由器使用两层感知器，四维统计向量为输入，隐藏维数为 16，输出 3 个尺度的未归一化分数。路由器的任务限于计算尺度融合分数，完整 OD 流量的预测任务仍交给尺度专家。路由计算采用低维统计量与较小隐藏层，参数规模因而保持较低。本文没有再引入循环网络、注意力网络等额外的时序编码器。其尺度分数计算为

$$\mathbf{a}_n = \mathbf{W}_2\mathrm{ReLU}(\mathbf{W}_1\mathbf{z}_n + \mathbf{b}_1) + \mathbf{b}_2. \tag{11}$$

对式（11）的 3 个尺度分数作 Softmax 归一化，得到 3 个总和为 1 的非负权重；各专家在最终预测中的相对贡献由这些权重表示：

$$\alpha_{n,s} = \frac{\exp(a_{n,s})}{\sum_{j\in S}\exp(a_{n,j})}, \quad \alpha_{n,s} \geq 0, \quad \sum_{s\in S}\alpha_{n,s} = 1. \tag{12}$$

最终预测为

$$\widehat{\mathbf{Y}}_n = \sum_{s\in S}\alpha_{n,s}\,\widehat{\mathbf{Y}}_n^{(s)}. \tag{13}$$

式（13）利用上述权重对 3 个 DLinear 专家的预测结果进行加权求和，得到最终预测$\hat{\mathbf{Y}}_n$。该组权重由输入窗口计算，并由同一窗口内的全部 OD 变量共享。为了区分多尺度结构、非等权分配与样本相关分配的作用，设置三种共享相同专家的对照：固定等权模型将三个尺度恒定设为 1/3；全局可学习权重模型以三个可训练参数经 Softmax 得到一组常权重；恒定输入路由模型保留完整路由网络，但训练和推理时都向路由器输入全零窗口，使全部样本共用一组可学习权重。三种模型的尺度专家均接收真实历史窗口。

1.5 训练目标与模型复杂度

本文以均方误差训练模型。损失在训练样本、未来 H 个预测时刻以及全部 C 个 OD 变量上计算，覆盖不同预测步与不同 OD 维度的偏差。各项偏差在同一目标中汇总，用于模型参数更新。对应训练目标为

$$\mathcal{L}_{\mathrm{MSE}} = \frac{1}{NHC}\sum_{n=1}^{N}\sum_{h=1}^{H}\sum_{c=1}^{C}(Y_{n,h,c} - \hat{Y}_{n,h,c})^2. \tag{14}$$

训练采用 Adam 优化器更新参数，并根据验证集 MSE 选择最终使用的模型。可训练参数在单尺度 DLinear 中为 4656 个，在三个尺度专家的固定等权模型中为 8208 个。在后者基础上增加三个全局权重参数，总数为 8211 个。样本级路由模型与恒定输入路由模型的标称参数数目相同，均为 8339 个。路由网络的参数增量相对固定等权模型为 131 个，相对全局权重模型为 128 个。恒定输入路由保留与样本级路由相同的网络结构，但输入恒为零，其首层输入权重不参与有效计算。

模型计算依次经过三个环节：平均池化把同一历史窗口转换为 3 个时间分辨率，DLinear 专家分别给出候选预测，路由网络再根据原始窗口的 4 个统计量确定融合权重。后续实验据此设置单尺度 DLinear、固定等权多尺度、全局可学习固定权重模型、恒定输入路由模型和本文方法，用同一组专家结构区分多尺度信息与样本级加权的作用。

2 实验与结果分析

实验分为外部基线比较、核心消融和路由行为分析三个层次。LightTS 提供独立结构的外部基线，DLinear 提供单尺度参照；固定等权、全局可学习常权重、恒定输入路由与样本级路由模型采用相同的三个尺度专家结构，并分别训练，分别比较多尺度结构、非等权融合与输入相关权重的表现；八个共同随机种子的配对结果和逐种子权重分析用于评估结果波动。

2.1 数据集与实验设置

本文从 CESNET TS-Zoo[9]获取实验数据，采用按 1 h 聚合的 Abilene[10]与 GÉANT[11]骨干网流量矩阵进行预测实验。Abilene 共有 4656 个时间点，保留 144 维有效 OD 流量；GÉANT 共有 2849 个时间点，去除恒定通道后保留 524 维有效 OD 流量。两套数据在序列长度与变量规模上不同，分别运行同一预测流程，可以观察其在不同数据条件下的表现。两个数据集均沿时间顺序划分，依次得到训练集、验证集、测试集，比例为 6:2:2。输入长度统一设为 L=96，预测长度统一设为 H=24。预处理按第 1.1 节执行，数据规模及窗口数量见表 1。

表 1 数据集与预测任务设置

数据集	时间点	有效变量 C	训练/验证/测试时间点	训练/验证/测试窗口	L/H
Abilene	4656	144	2793/931/932	2674/812/813	96/24
GÉANT	2849	524	1709/570/570	1590/451/451	96/24

所有对比模型使用相同的数据划分、输入长度、预测长度、评价指标和批量大小，batch size 统一为 16。为控制数据与训练条件，实验未分别搜索各模型的最优超参数。DLinear、固定等权多尺度、全局可学习权重、恒定输入路由和本文方法最多训练 30 轮，LightTS 最多训练 50 轮；均根据验证集 MSE 选择测试所用参数，测试集仅用于最终统计。

外部基线比较使用随机种子 42～44 共 3 个共同随机种子。核心消融使用随机种子 42～49 共 8 个共同随机种子，比较 DLinear、固定等权多尺度、全局可学习权重、恒定输入路由和本文方法。全局权重由等权初始化，恒定输入路由对所有窗口使用全零路由输入；两者均与三个专家一同训练，并按相同验证集准则选择模型；随机种子作为配对统计单位。

2.2 对比模型与评价指标

对照包括 DLinear、LightTS、固定等权多尺度、全局可学习权重和恒定输入路由五类模型。DLinear 用于比较单一尺度与多尺度结构；LightTS 提供独立轻量模型基线。后三种多尺度对照与本文方法保留相同的尺度集合{1,2,4}和 DLinear 专家，分别使用等权、全局可学习权重和恒定输入路由权重。后两者均对全部窗口使用一组固定权重，可检验完整模型相对常权重方案的误差变化。

均方误差（MSE）、平均绝对误差（MAE）及均方根误差（RMSE）用于评价预测性能。其中 MSE 采用式（14），MAE 和 RMSE 的定义如下

$$\mathrm{MAE} = \frac{1}{N_{\mathrm{te}} HC} \sum_{n=1}^{N_{\mathrm{te}}} \sum_{h=1}^{H} \sum_{c=1}^{C} |\, Y_{n,h,c} - \hat{Y}_{n,h,c} |. \tag{15}$$

$$\mathrm{RMSE} = \sqrt{\mathrm{MSE}}. \tag{16}$$

本文在标准化空间中计算全部误差指标，以较小值表示较低误差。正文的主要指标为 MSE 和 MAE：MSE 对较大误差更敏感，MAE 描述平均绝对偏差；误差幅值由 RMSE 补充，其定义为 MSE 的平方根。随机种子 42～44 的结果在表 2 中以均值±标准差列出；随机种子 42～49 的结果在表 3 中采用同一统计形式。均值对应平均水平，种子间波动由标准差表示。相对改进率也以共同随机种子配对计算，先获得每个种子的改进率，再取这些改进率的平均值；表内四舍五入后的均值不直接用于计算该百分比。

2.3 两数据集外部基线比较

表 2 列出 3 个共同随机种子下的总体基线结果。本文方法在 Abilene 上的 MSE 为 0.186，在 GÉANT 上为 0.434；逐种子计算后相对 DLinear 分别降低 4.07%和 4.54%，相对 LightTS 分别降低 29.80%和 46.89%，MAE 呈相同方向变化。DLinear 与本文尺度专家采用同源结构，后续核心消融也以 DLinear 作为单尺度内部基线；LightTS 属于独立外部结构基线，图 2 进一步给出逐随机种子、多指标和参数规模比较。

表 2 三随机种子外部基线比较

数据集	模型	参数量	MSE	MAE
Abilene	DLinear	4656	0.194±0.002	0.188±0.009
Abilene	LightTS	130162	0.265±0.011	0.204±0.008
Abilene	本文方法	8339	0.186±0.002	0.168±0.001
GÉANT	DLinear	4656	0.454±0.007	0.383±0.006
GÉANT	LightTS	384382	0.817±0.024	0.523±0.014
GÉANT	本文方法	8339	0.434±0.051	0.370±0.031

图 2 以 LightTS 为独立外部基线，使用两种方法共有的随机种子 42～44。每次实验的相对降低率按（LightTS 误差−本文方法误差）/LightTS 误差计算。MSE、MAE 和 RMSE 的平均降幅在 Abilene 上为 29.80%、17.57%和 16.23%，在 GÉANT 上为 46.89%、29.15%和 27.18%。逐种子检查这三项指标，两个数据集的 3 个共同随机种子均有改善。本文方法的 8339 个参数，约为 LightTS 在 Abilene 和 GÉANT 上参数量的 6.41%和 2.17%；LightTS 的对应参数量分别为 130162 和 384382。

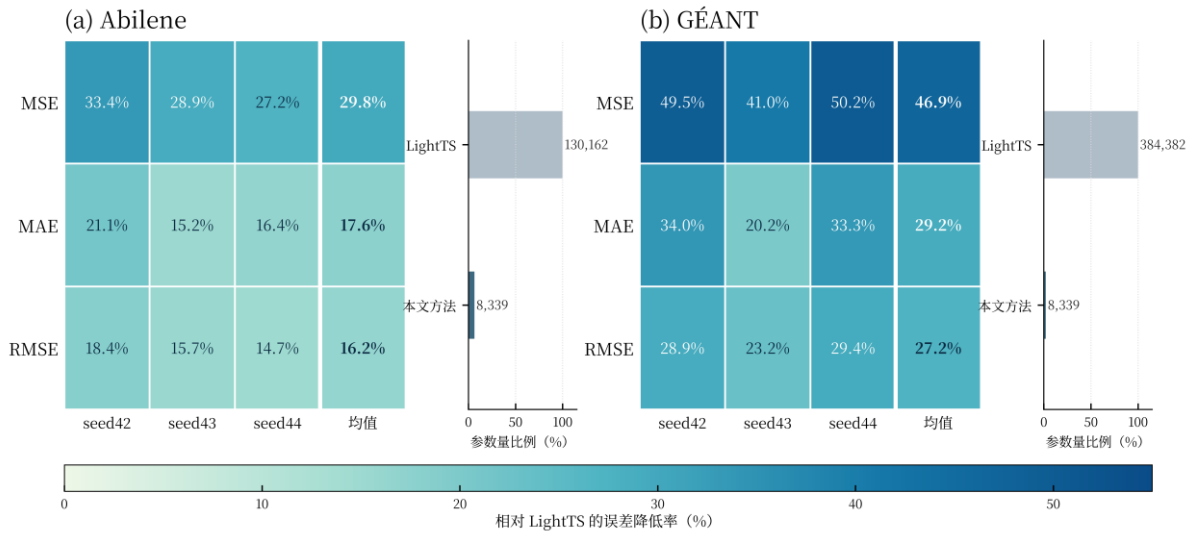


图 2 Abilene 与 GÉANT 上本文方法相对 LightTS 的三随机种子多指标性能提升

GÉANT 的 OD 变量数较多，本文方法相对 LightTS 的 MSE 降幅也高于 Abilene。不过，两者同时出现不能确立变量规模与误差降幅之间的因果关系。固定等权与全局可学习权重对照均采用相同的多尺度专家结构，适合进一步检验融合方式本身的作用。

2.4 八随机种子核心消融与稳定性

表 3 汇总随机种子 42～49 的 8 次核心消融，列出五种模型的参数量、MSE 和 MAE。

表 3 八随机种子核心消融结果（均值±标准差）

数据集	模型	参数量	MSE	MAE
Abilene	DLinear	4656	0.194±0.002	0.189±0.008
Abilene	固定等权多尺度	8208	0.192±0.002	0.191±0.006
Abilene	全局可学习权重	8211	0.192±0.002	0.190±0.006
Abilene	恒定输入路由	8339	0.192±0.002	0.181±0.006
Abilene	本文方法	8339	0.189±0.003	0.173±0.008
GÉANT	DLinear	4656	0.437±0.016	0.371±0.011
GÉANT	固定等权多尺度	8208	0.447±0.014	0.377±0.009
GÉANT	全局可学习权重	8211	0.446±0.014	0.377±0.009
GÉANT	恒定输入路由	8339	0.449±0.012	0.379±0.007
GÉANT	本文方法	8339	0.426±0.029	0.366±0.018

全局可学习权重与恒定输入路由均对所有窗口使用一组可学习权重，后者与本文方法同为 8339 个标称参数。相对这两种对照，本文方法在 Abilene 上的逐种子平均 MSE 改进均约 1.80%，在 GÉANT 上分别为 4.31%和 4.97%，各有 6/8 和 7/8 个种子胜出。相对恒定输入路由的 95%置信区间分别为[0.49%,3.11%]和[−1.62%,11.56%]，相对全局权重则为[0.01%,3.58%]和[−2.51%,11.13%]；GÉANT 两项区间均跨零。

图 3 比较本文方法与 DLinear、固定等权多尺度模型的 MSE、MAE 及 RMSE，结果均来自随机种子 42～49。0%虚线对应两种方法误差相同，可据此判断改进方向。每个种子的结果以散点保留，8 次结果的分布用半小提琴展示；8 次改进率的均值与 95%置信区间分别由黑色菱形及横向误差线表示。相对 DLinear 时，Abilene 的 MSE、MAE 和 RMSE 平均改进率为 2.77%、8.01%和 1.40%，其中 MSE 与 RMSE 在 8 次实验中均改善；GÉANT 分别为 2.35%、1.32%和 1.22%，且跨越 0%的情况更多。相对固定等权模型时，Abilene 三项指标的平均改进率为 1.65%、8.92%和 0.84%，GÉANT 为 4.54%、3.05%和 2.37%。相对两种基线得到的平均改进率均为正值。与此同时，GÉANT 不同随机种子之间的波动较明显；判断平均收益是否稳定，仍需同时观察图中的置信区间。

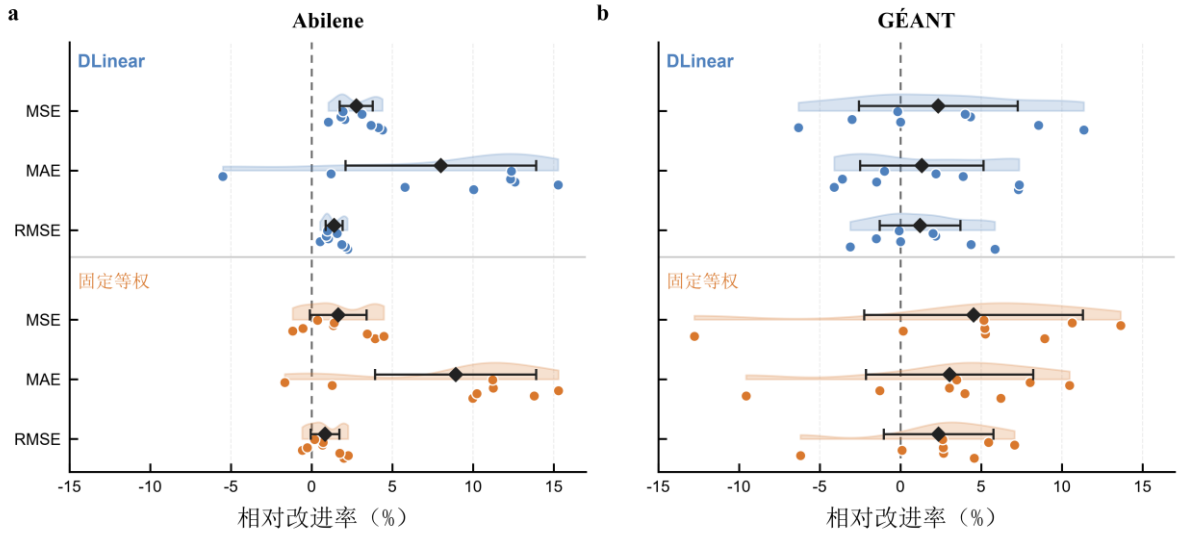


图 3 Abilene 与 GÉANT 上本文方法相对两类基线的八随机种子多指标相对改进分布

等权融合由固定等权模型检验。全局可学习权重与恒定输入路由模型则分别提供常权重对照，共同用于观察改变融合方式后的误差。表 3 中本文方法相对两者的平均 MSE 均较低，但 GÉANT 的配对区间均跨越零；其中种子 43 相对恒定输入路由退步 12.78%。各模型的训练彼此独立，恒定输入路由还存在首层输入权重不起作用的结构差异。因此，误差比较针对完整方法和两类常权重方案，尚不能从中唯一识别逐窗口权重变化的贡献。图 4 用于进一步观察整体偏差及局部误差。整体偏差从全测试点汇总，局部误差则结合按真实值波动选取的预测轨迹考察。

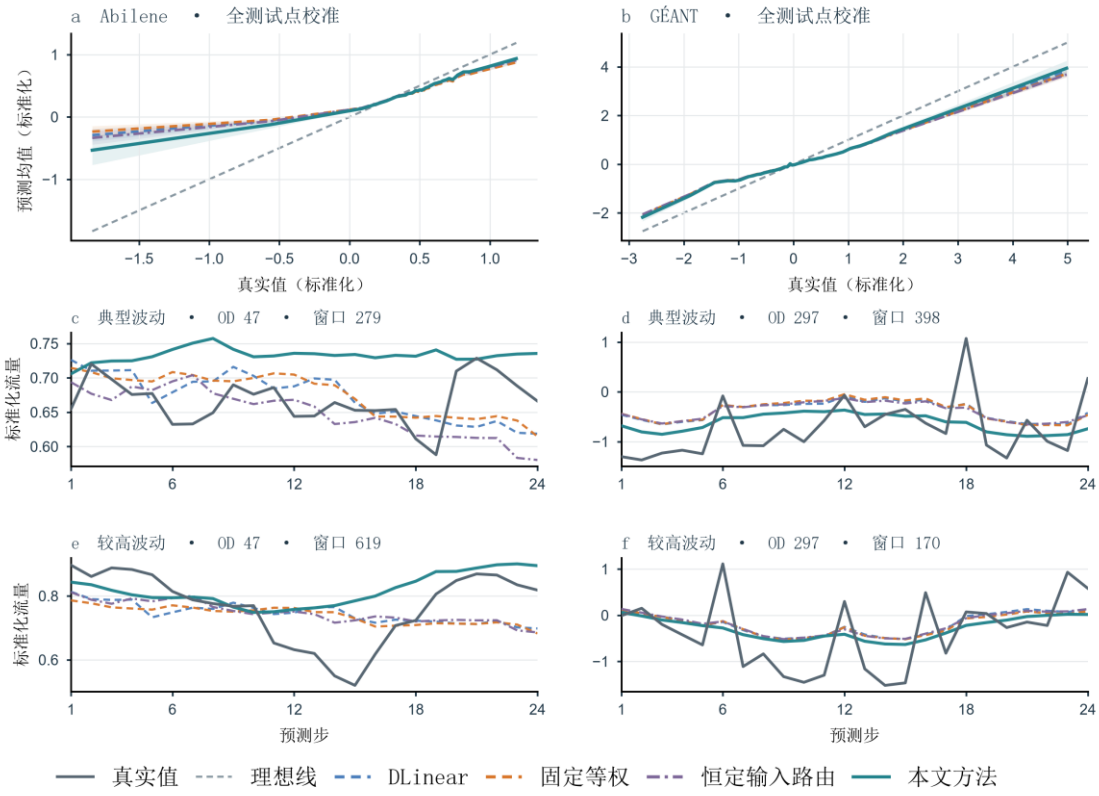


图 4 Abilene 与 GÉANT 全测试点预测校准及典型窗口预测轨迹

图 4(a、b)的统计覆盖随机种子 42～49，纳入全部测试窗口中的 24 个预测步和全部有效 OD 通道。四种模型的曲线采用分组平均预测值：真实值按分位点划为最多 40 个区间，每个区间汇总 8 种子的预测值并取平均。灰色虚线给出理想预测位置，浅色带给出种子间±1 个标准差。在高真实值区间，四种模型的预测都偏低。本文方法的分组平均偏差相对较小；这是区间平均层面的比较，不能替代各测试点的误差比较。图 4(c～f)固定随机种子 42，仅根据真实序列选择标准差接近第 75 百分位的 OD 通道，再选择波动程度接近中位数和第 90 百分位的窗口。选取通道和窗口的上述过程只使用真实序列，未依据模型误差挑选案例。本文方法在四例中的三例取得较低的 24 步均方误差，均低于 DLinear、固定等权和恒定输入路由模型；Abilene 典型波动窗口是例外，本文方法在该例中较差。总体精度以表 3 的配对统计判断，所选轨迹只解释这些窗口内的局部预测行为。测试窗口存在重叠，统计中不将重叠窗口视作独立重复。

2.5 路由权重分析

随机种子 42～49 下三个尺度的路由权重汇总于图 5。全部测试窗口及种子共同形成各尺度的小提琴分布，蓝、绿、橙色依次对应尺度 1、2 和 4。彩色散点以种子为单位，每个点取同一种子全部测试窗口的平均权重。黑色菱形和误差线在此基础上汇总 8 个种子均值，表示其均值±1 个标准差。固定等权 1/3 由水平虚线标示，汇总分布中位数由短横线标示。种子间与窗口间差异都包含在小提琴分布中，宽度受二者共同影响。判断同一种子内的窗口响应强度时，不能直接使用这种混合分布的宽度。

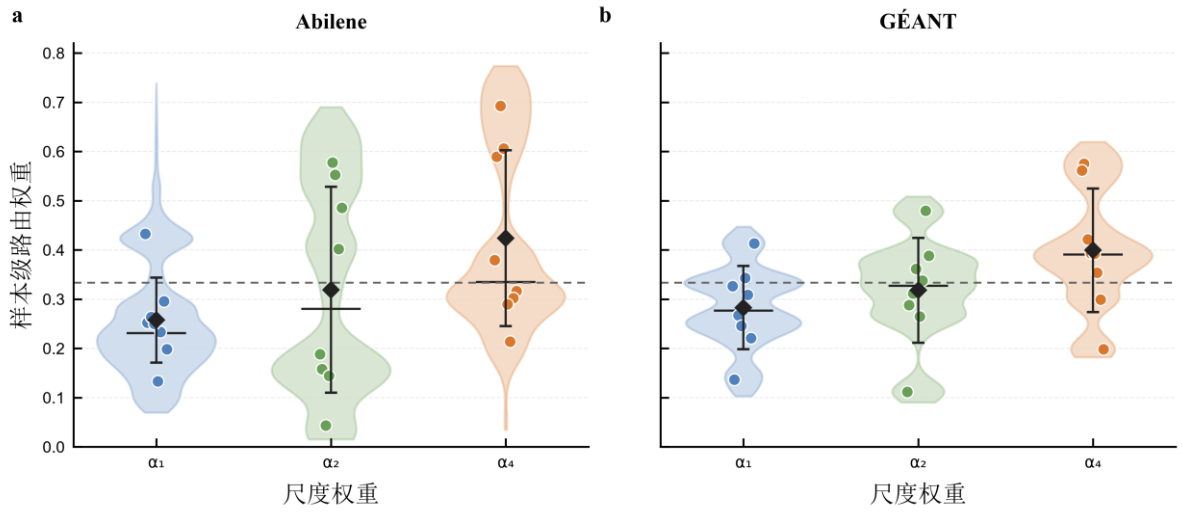


图 5 Abilene 与 GÉANT 的逐窗口路由权重汇总分布及八种子均值

三个尺度在 Abilene 上的汇总平均权重依次为 0.257、0.319 和 0.424，在 GÉANT 上依次为 0.283、0.318 和 0.399。这些总体均值均偏离固定等权的 1/3。从汇总权重方差的来源看，GÉANT 三个尺度中约 96.2%、95.8%和 97.7%的方差来自种子间差异。Abilene 对应的比例分别为 48.7%、86.1%和 80.6%。在 GÉANT 的同一种子内部，随窗口发生的权重变化较小。图 5 展示的汇总分布，把种子间差异与同一种子内部的窗口差异放在一起。若仅依据这一分布判断路由机制，仍缺少路由器能否有效识别各窗口尺度需求的证据。

输入窗口的波动强度由平均绝对一阶差分度量。分组阈值取自训练窗口的三分位数，测试窗口按这些阈值分组。Abilene 低、中、高波动组分别有 15、406、392 个窗口。本文方法相对全局权重模型的逐种子平均 MSE 改进率分别为 4.43%、1.90%、1.69%；GÉANT 在训练阈值下无低波动测试窗口，中、高组分别有 76、375 个窗口，改进率为 5.85%和 4.06%。在 Abilene 上，高波动组的尺度 1 平均权重高于中波动组，而相应的误差优势没有增强。GÉANT 中波动组与高波动组的权重则近似相同。依据这些分组结果，当前还不能支持“波动越强，路由收益越大”的机制解释。

前向计算开销通过另一次计时测量。计时采用预测长度为 24 的 8 个随机种子检查点，运行设备为 NVIDIA GTX 1060；测试张量预先加载，批量大小设为 16。本文方法在 Abilene 和 GÉANT 上的平均每批前向耗时分别为 2.65 ms 和 2.61 ms，固定等权模型分别为 2.38 ms 和 2.10 ms，单尺度 DLinear 分别为 0.77 ms 和 0.70 ms。数据读取及传输不在这组前向计时内，报告的耗时仅覆盖模型前向计算。端到端部署时延需要另计这两部分。较小的参数量并未消除额外计算：三个尺度专家与路由器仍使本文方法的推理开销增加。

3 结论

本文的多尺度预测结构同时处理骨干网络 OD 流量的短时波动与较慢趋势：尺度 1、2 和 4 的 DLinear 专家分别预测，轻量路由网络计算输入相关融合权重，再组合各专家结果。预测长度为 24 时，在 Abilene 和 GÉANT 两套实验中，本文方法的平均误差均低于作为比较对象的 DLinear、LightTS 和固定等权模型。相对全局可学习权重与恒定输入路由两类常权重对照，本文方法在 Abilene 上的逐种子平均 MSE 改进均约 1.80%；GÉANT 上的对应改进分别为 4.31%和 4.97%，但两项 95%置信区间均跨越零。按真实值分组的预测校准仍显示，各模型低估较高流量取值；本文方法的高值端平均偏差相对较小。该平均结果的适用范围是分组统计，不能据此断言本文方法在每个测试点都更准确。逐种子权重分析与波动分组分析共同表明，路由器能否稳定匹配窗口尺度需求仍缺乏充分证据。对输入相关融合收益的稳定性，还需在更多数据及不同预测设置下继续检验。

参考文献

[1] LOHRASBINASAB I, KESHAVARZ A, AMIN-NEJAD S, et al. From statistical- to machine learning-based network traffic prediction[J]. Transactions on Emerging Telecommunications Technologies, 2022, 33(4): e4394. DOI: 10.1002/ett.4394.

[2] QIN L, GU H, WEI W, et al. Spatio-temporal communication network traffic prediction method based on graph neural network[J]. Information Sciences, 2024, 679: 121003. DOI: 10.1016/j.ins.2024.121003.

[3] 韦烜, 刘志华, 李青, 等. 大型 IP 网络流量矩阵分析预测的探讨研究[J]. 系统工程与电子技术, 2024, 46(6): 2164-2173. DOI: 10.12305/j.issn.1001-506X.2024.06.35.

[4] 唐文杰, 肖一磊, 孔祥宇, 等. CycleLLH：一种基于周期性整合的新型网络流量预测模型[J]. 计算机学报, 2024, 47(12): 2867-2888. DOI: 10.11897/SP.J.1016.2024.02867.

[5] ZHOU J, HAN T, XIAO F, et al. Multiscale network traffic prediction method based on deep echo-state network for Internet of Things[J]. IEEE Internet of Things Journal, 2022, 9(21): 21862-21874. DOI: 10.1109/JIOT.2022.3181807.

[6] ZENG A, CHEN M, ZHANG L, et al. Are transformers effective for time series forecasting?[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2023, 37(9): 11121-11128. DOI: 10.1609/aaai.v37i9.26317.

[7] WANG S, WU H, SHI X, et al. TimeMixer: decomposable multiscale mixing for time series forecasting[C]//International Conference on Learning Representations. 2024.

[8] ZHANG T, ZHANG Y, CAO W, et al. Less is more: fast multivariate time series forecasting with light sampling-oriented MLP structures[EB/OL]. (2022-07-04)[2026-09-20]. https://arxiv.org/abs/2207.01186. DOI: 10.48550/arXiv.2207.01186.

[9] KUREŠ M, KOUMAR J, HYNEK K. CESNET TS-Zoo: a library for reproducible analysis of network traffic time series[C]//2025 21st International Conference on Network and Service Management. 2025. DOI: 10.23919/CNSM67658.2025.11297513.

[10] ZHANG Y, ROUGHAN M, DUFFIELD N, et al. Fast accurate computation of large-scale IP traffic matrices from link loads[J]. ACM SIGMETRICS Performance Evaluation Review, 2003, 31(1): 206-217. DOI: 10.1145/885651.781053.

[11] UHLIG S, QUOITIN B, LEPROPRE J, et al. Providing public intradomain traffic matrices to the research community[J]. ACM SIGCOMM Computer Communication Review, 2006, 36(1): 83-86. DOI: 10.1145/1111322.1111341.