基于自适应多尺度加权的多变量网络流量预测方法

[请填写作者姓名]

([请填写工作单位] [请填写部门], [省 市 邮编])

摘要：骨干网络源—目的节点对流量兼有短时起伏和较慢趋势，单一时间分辨率难以同时表征两者。本文采用尺度 1、2 和 4 的 DLinear 专家，由轻量路由网络根据输入窗口统计量生成 Softmax 融合权重。在输入长度 96、预测长度 24 的 Abilene 和 GÉANT 实验中，3 个共同随机种子下本文方法相对 DLinear 的 MSE 分别降低 4.07%和 4.54%，相对 LightTS 分别降低 29.80%和 46.89%。8 个随机种子的核心消融加入全局可学习权重和恒定输入路由两类固定权重对照；本文方法相对两者在 Abilene 上的逐种子平均 MSE 改进率均约为 1.80%，在 GÉANT 上分别为 4.31%和 4.97%。GÉANT 的两项配对 95%置信区间均跨越零，且路由权重变化主要来自随机种子之间，因此当前结果支持平均误差改善，但尚不能证明路由器稳定识别每个窗口的最佳尺度。

关键词：网络流量预测；多变量时间序列；多尺度学习；自适应加权；DLinear

中图分类号：TP393　　**文献标志码：**A

A Multivariate Network Traffic Forecasting Method Based on Adaptive Multiscale Weighting

[Author Name]

([Affiliation] [Department], [City] [Postcode], China; Corresponding author: [Name], E-mail: [E-mail])

Abstract: Short-term fluctuations and slower trends coexist in backbone origin-destination traffic. Input-window statistics determine the Softmax weights used to combine DLinear experts at scales 1, 2, and 4. For input length 96 and forecast length 24, results from three common random seeds give MSE reductions of 4.07% on Abilene and 4.54% on GÉANT relative to DLinear. The corresponding reductions relative to LightTS are 29.80% and 46.89%. An eight-seed ablation adds two fixed-weight controls: learned global weights and a router receiving constant input. Mean seed-wise MSE reductions over the two controls are both about 1.80% on Abilene; on GÉANT, they are 4.31% and 4.97%, respectively. Both paired 95% confidence intervals on GÉANT include zero, and most of its pooled router-weight variance arises between seeds. Reliable window-specific scale selection therefore remains unconfirmed despite the average error reduction.

Key words: network traffic forecasting; multivariate time series; multiscale learning; adaptive weighting; DLinear

源—目的节点对（origin-destination，OD）流量描述骨干网络不同节点对之间的通信需求。容量规划、拥塞预警、资源调度和流量工程需要判断未来流量状态，本文因而预测后续 OD 流量。面向小时级骨干网需求分析，预测结果可作为运维和容量规划的输入，本文不直接生成资源分配动作。在云计算、视频业务、数据中心互联及智能网络应用持续增加的背景下，业务在网络内部的迁移和聚集更频繁。这使后续流量的时间变化更加复杂，也增加了预测难度。周期变化、局部波动与突发变化常叠加在同一 OD 流量序列中，不同变量又有各自的数值范围。这类 OD 数据包含的复杂短时变化，难以仅用较平稳单变量序列的趋势描述完整覆盖。模型在预测较长时间趋势时，仍需响应短时状态变化。

Lohrasbinasab 等[1]系统梳理了网络流量预测方法，指出机器学习和深度学习等数据驱动方法在复杂流量预测中的应用不断增加，反映了传统统计模型之外的研究扩展。网络规模扩大也使 OD 变量之间的关联

收稿日期：[请填写，格式 YYYY-MM-DD]

基金项目：[基金来源]（[基金项目编号]）

第一作者简介：[姓名]（[出生年]—），[性别（民族，汉族可省略）]，[职称]，[学位（若在读请注明）]，研究方向：[方向 1]；[方向 2]。

通信作者简介：[姓名]（[出生年]—），[性别（民族，汉族可省略）]，[职称]，[学位（若在读请注明）]，研究方向：[方向 1]；[方向 2]，电子邮箱：[邮箱]。

更难由单一序列的时间分析覆盖。Qin 等[2]把图神经网络引入通信网络流量预测，在同一模型中处理空间关联和时间依赖；韦烜等[3]针对大型 IP 网络流量矩阵开展分析与预测，讨论了不同 OD 变量之间的关联及其时间变化。唐文杰等[4]则在 CycleLLH 模型中引入周期性信息。上述研究涉及的时间依赖、变量关联与周期结构，构成了流量预测的不同观察角度。

时间分辨率决定同一流量序列中哪些特征更易观察：较多局部细节在原始分辨率下保留，短时起伏也更清晰；时间聚合平滑部分局部扰动后，较慢的变化趋势更突出。在 Zhou 等[5]的多尺度网络流量预测研究中，深度回声状态网络从不同时间分辨率的序列中提取信息，以利用各分辨率之间的互补性。利用多尺度信息还涉及模型结构开销。DLinear[6]通过时间序列分解和线性映射完成预测，TimeMixer[7]以多尺度混合机制处理不同分辨率序列。LightTS[8]则采用采样导向的 MLP 结构，实现快速多变量时间序列预测。本文将多时间尺度信息与模型规模共同作为预测结构的设计约束。

常见流程先给定时间尺度，再分别计算结果并按既定方式融合。各输入窗口中的短时波动和平缓趋势占比不同，尺度 1、2 和 4 的预测作用也可能随窗口状态变化。仅采用单一尺度会缺少其他时间分辨率的信息。构造多尺度序列后，固定融合比例仍不使用窗口状态差异；本文则根据当前输入窗口计算融合权重，将状态信息用于各尺度结果的组合。

针对输入窗口之间的状态差异，本文采用样本级自适应多尺度结构。历史窗口按尺度 1、2 和 4 构造多分辨率序列，每个尺度由一个 DLinear 专家给出候选预测。路由网络不重新编码完整时序，而是读取当前输入窗口的总体水平、离散程度、最近状态和变化强度等统计量，生成 Softmax 尺度权重，并据此融合三个专家的结果。这样可以把尺度内预测与尺度间选择分开处理。实验在 Abilene 和 GÉANT 两个公开骨干网数据集上进行，比较 DLinear、LightTS、固定等权、全局可学习固定权重与恒定输入路由模型，并通过多个随机种子重复实验和路由权重分析检验预测误差、核心结构消融与尺度分配行为。

1 自适应多尺度网络流量预测方法

图 1 给出模型的整体流程。模型包含多尺度预测和尺度选择两个模块：尺度 1、2 和 4 的输入分别交给独立 DLinear 专家，路由网络根据当前窗口的统计特征估计 3 个尺度的融合权重。原始 OD 流量经对数变换和标准化后形成 3 个时间分辨率的输入序列；3 个专家分别预测，再按样本级权重融合。固定等权、全局可学习权重与恒定输入路由对照采用相同的尺度与专家结构，并分别训练，用以比较等权、全局非等权与输入相关融合。

三个时间尺度的区别在于历史信息的平滑程度。原始尺度较完整地保留局部变化，较粗尺度则通过时间聚合减弱短时扰动，突出较慢的趋势。3 个尺度各自预测，保留独立结果后，由路由网络确定每个样本的融合比例。结构较简洁的 DLinear 用于全部专家，控制模型规模，并为多尺度输入和样本级融合提供相同的比较主干。

1.1 预测任务与数据预处理

记预处理后的多变量流量序列为 $\mathbf{x}_t \in \mathbb{R}^C$，t 表示时间索引，C 表示有效 OD 变量数。沿时间轴对连续序列生成滑动窗口，作为监督学习样本；第 n 个样本由历史窗口$\mathbf{X}_n$及预测目标$\mathbf{Y}_n$组成：$\mathbf{X}_n$覆盖连续 L 个时间点，$\mathbf{Y}_n$覆盖其后连续的 H 个时间点。模型读取多个 OD 变量过去 L 步的联合变化作为历史信息，估计未来 H 步的取值。第 n 个样本的输入与目标写为

$$\mathbf{X}_n = [\mathbf{x}_n, \dots, \mathbf{x}_{n+L-1}] \in \mathbb{R}^{L\times C}. \tag{1}$$

$$\mathbf{Y}_n = [\mathbf{x}_{n+L}, \dots, \mathbf{x}_{n+L+H-1}] \in \mathbb{R}^{H\times C}. \tag{2}$$

本文取 L=96 步作为历史输入、H=24 步作为未来预测，C 为各数据集保留的有效 OD 维度数。需要学

习的预测映射记为$\hat{\mathbf{Y}}_n = f_\theta(\mathbf{X}_n)$。一次预测的历史读取范围为 L，连续输出长度为 H。原始 OD 流量均非负，各变量量级相差较大；直接使用原始数值训练时，数值范围较大的变量与其他变量尺度不一致。为压缩数值范围，本文对原始流量$v_{t,c}$作对数变换

$$u_{t,c} = \log(1 + v_{t,c}). \tag{3}$$

再按变量进行标准化：

$$x_{t,c} = \frac{u_{t,c} - \mu_c^{\mathrm{tr}}}{\sigma_c^{\mathrm{tr}}}. \tag{4}$$

其中μ_c^{tr}和σ_c^{tr}分别表示训练集中第 c 个 OD 变量的均值与标准差。验证集和测试集的预处理沿用这组训练统计量，均不重新估计。log(1+x)变换保留非负流量的大小关系，同时压缩数值范围，缓和原有量级差异。随后逐变量标准化，使各 OD 维度在训练、损失计算和参数更新中采用相近数值尺度。数据依时间先后按 6:2:2 划为训练集、验证集和测试集。每个集合内部独立生成滑动窗口，窗口不跨越集合边界。

预处理保留历史窗口原有的时间分辨率，各尺度共用这一窗口。不同尺度序列在此后构造，分别向各专家提供细粒度变化和较平滑的趋势。

在第 2.1 节所用的 1 h 聚合数据上，96 步历史输入对应过去 96 h，24 步预测对应未来 24 h。该设置适用于小时级需求变化分析；若采用逐小时滚动调用，每次仍预测未来 24 h，预测跨度与更新周期应分别理解。

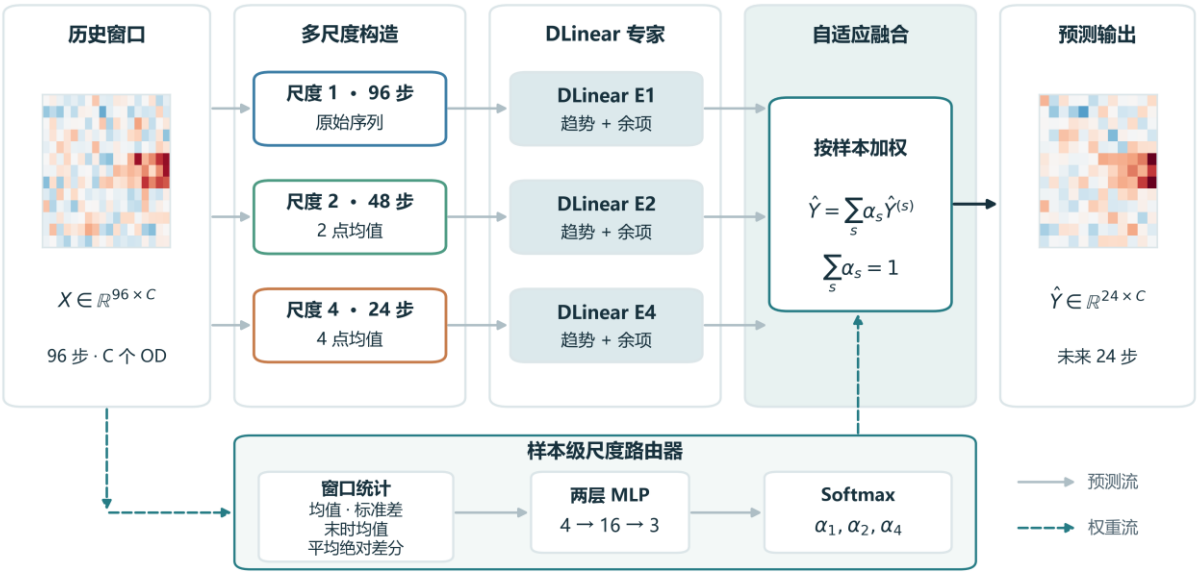


图 1 自适应多尺度网络流量预测方法框架

1.2 多尺度构造与 DLinear 专家

设尺度集合 S={1,2,4}。尺度 s 规定时间维聚合的窗口大小与步长，两者取值相同。采用非重叠平均池化，任一尺度 s 的序列构造为：

$$\mathbf{X}_{n,t}^{(s)} = \frac{1}{s}\sum_{i=0}^{s-1}\mathbf{X}_{n,st+i}, \quad t = 0, \ldots, \frac{L}{s} - 1. \tag{5}$$

本文使用尺度集合 S={1,2,4}。L=96 时，尺度 1 保留原始 96 步输入。相邻 2 个时间点的均值构成尺度 2 的聚合点，序列长度为 48 步；尺度 4 以每 4 个时间点的均值构成聚合点，序列长度为 24 步。尺度 1 不压缩时间轴，保留较完整的短时起伏；尺度 2 适度平滑局部变化。尺度 4 对短时间内的高频变化进一步平滑，较慢的趋势因而更突出。多分辨率输入由无需训练参数的平均池化构造，尺度变换也不另设可训练模块，因而这部分输入构造不增加模型参数。

96 步历史窗口在尺度 1、2 和 4 下均可得到整数长度序列，专家数量由这一尺度设置确定。更多尺度会带来更粗、有效时间长度更短的序列，还需为相应预测增加专家分支。固定尺度组合{1,2,4}是在细粒度信息、趋势信息和模型规模之间作出的取舍。本文未穷举搜索尺度组合，其最优性未经检验。采用非重叠池化时，原始时间点在同一尺度内只参与一次聚合，各尺度的时间聚合含义因此较为直接。

尺度 1、2 和 4 分别交由 DLinear 专家[6]处理，每个专家独立接收对应尺度的序列。DLinear 的预测分两步完成：先分解出变化较慢的趋势项和围绕趋势变化的余项，再对这两项分别作时间映射。对尺度 s 的输入，以长度 q=25 的中心移动平均在局部时间邻域内平滑并提取趋势项。边界处不足完整窗口时，复制端点补齐缺少部分，防止平滑后的序列缩短；补齐后的序列记为$\tilde{\mathbf{X}}^{(s)}$；越界索引取最近端点值，从而保持分解前后的时间长度一致：

$$\mathbf{T}_{n,t}^{(s)} = \frac{1}{q}\sum_{i=-m}^{m}\tilde{\mathbf{X}}_{n,t+i}^{(s)}, \quad q = 2m + 1 = 25. \tag{6}$$

$$\mathbf{R}_{n}^{(s)} = \mathbf{X}_{n}^{(s)} - \mathbf{T}_{n}^{(s)}. \tag{7}$$

趋势项$\mathbf{T}^{(s)}$和余项$\mathbf{R}^{(s)}$沿时间维分别通过线性层映射到预测长度 H：

$$\hat{\mathbf{Y}}_{n}^{(s)} = \mathbf{W}_{T}^{(s)}\mathbf{T}_{n}^{(s)} + \mathbf{b}_{T}^{(s)} + \mathbf{W}_{R}^{(s)}\mathbf{R}_{n}^{(s)} + \mathbf{b}_{R}^{(s)}. \tag{8}$$

由式（6）和式（7）可得到尺度 s 上的趋势项$\mathbf{T}^{(s)}$和余项$\mathbf{R}^{(s)}$。趋势项表示经过局部平滑后保留下来的较慢变化部分，余项则由原序列减去趋势项得到，保留未被移动平均解释的局部变化。式（8）分别对两部分沿时间维进行线性映射，并把二者的预测结果相加形成该尺度的候选预测。3 个尺度使用独立 DLinear 专家，是因为尺度 1、2 和 4 的输入长度分别为 96、48 和 24，对应的时间分辨率和时间映射关系并不相同；若强制共用一组尺度间参数，会把不同长度、不同平滑程度的序列约束到同一映射中。同一尺度内部，各 OD 变量共享时间映射参数，模型学习的是这一时间尺度下通用的时间映射形式，而不是为每个 OD 变量分别建立一套线性层。

1.3 样本级自适应尺度加权

同一样本由 3 个 DLinear 专家分别预测，最终输出由这 3 组结果融合而成。若将 3 个尺度固定设为各占 1/3，融合比例对所有输入窗口相同。窗口状态差异为改变融合比例提供了设计依据：局部波动较强时可能更依赖细粒度信息，变化平稳时可能更依赖较粗尺度的趋势信息。本文依据窗口统计量计算权重，使融合比例随样本状态变化。由原始输入$\mathbf{X}_n$提取四维统计向量$\mathbf{z}_n = [\mu_n, \sigma_n, \ell_n, d_n]$，用这些统计量描述当前窗口状态，其中

$$\mu_n = \frac{1}{LC}\sum_{t=0}^{L-1}\sum_{c=1}^{C} X_{n,t,c}\,, \quad \sigma_n = \sqrt{\frac{1}{LC}\sum_{t=0}^{L-1}\sum_{c=1}^{C}(X_{n,t,c} - \mu_n)^2}. \tag{9}$$

$$\ell_n = \frac{1}{C}\sum_{c=1}^{C} X_{n,L-1,c}\,, \quad d_n = \frac{1}{(L-1)C}\sum_{t=1}^{L-1}\sum_{c=1}^{C} |X_{n,t,c} - X_{n,t-1,c}|. \tag{10}$$

μ_n、σ_n、ℓ_n和d_n分别描述输入窗口的总体水平、离散程度、最近状态和平均变化强度。μ_n反映窗口整体流量水平，σ_n刻画观测值的离散程度，ℓ_n取窗口末时刻的平均状态，d_n由相邻时间点的一阶变化得到。这 4 个统计量分别提供水平、波动、最近状态和局部变化信息，供路由器计算输入相关的尺度权重，而不直接参与未来流量数值的预测。

两层感知器将四维统计向量映射为 3 个尺度的未归一化分数，隐藏层维数设为 16。路由器只计算尺度融合分数，尺度专家承担完整 OD 流量的预测。低维统计量和较小隐藏层用于控制路由参数规模，计算中不额外引入循环网络、注意力网络等时序编码器。其尺度分数计算为

$$\mathbf{a}_n = \mathbf{W}_2\mathrm{ReLU}(\mathbf{W}_1\mathbf{z}_n + \mathbf{b}_1) + \mathbf{b}_2. \tag{11}$$

对式（11）的 3 个尺度分数作 Softmax 归一化，得到 3 个总和为 1 的非负权重；各专家在最终预测中的相对贡献由这些权重表示：

$$\alpha_{n,s} = \frac{\exp(a_{n,s})}{\sum_{j\in S}\exp(a_{n,j})}, \quad \alpha_{n,s} \geq 0, \quad \sum_{s\in S}\alpha_{n,s} = 1. \tag{12}$$

最终预测为

$$\widehat{\mathbf{Y}}_n = \sum_{s\in S}\alpha_{n,s}\,\widehat{\mathbf{Y}}_n^{(s)}. \tag{13}$$

式（13）利用上述权重对 3 个 DLinear 专家的预测结果进行加权求和，得到最终预测$\widehat{\mathbf{Y}}_n$。该组权重由输入窗口计算，并由同一窗口内的全部 OD 变量共享。

1.4 模型训练与预测输出

本文以均方误差训练模型。损失在训练样本、未来 H 个预测时刻以及全部 C 个 OD 变量上计算，覆盖不同预测步与不同 OD 维度的偏差。各项偏差在同一目标中汇总，用于模型参数更新。对应训练目标为

$$\mathcal{L}_{\mathrm{MSE}} = \frac{1}{NHC}\sum_{n=1}^{N}\sum_{h=1}^{H}\sum_{c=1}^{C}(Y_{n,h,c} - \hat{Y}_{n,h,c})^2. \tag{14}$$

训练采用 Adam 优化器更新参数，并根据验证集 MSE 选择最终使用的模型。

模型计算依次经过三个环节：平均池化把同一历史窗口转换为 3 个时间分辨率，DLinear 专家分别给出候选预测，路由网络再根据原始窗口的 4 个统计量确定融合权重。后续实验据此设置单尺度 DLinear、固定等权多尺度、全局可学习固定权重模型、恒定输入路由模型和本文方法，用同一组专家结构区分多尺度信息与样本级加权的作用。

推理时，将历史 OD 窗口按训练阶段确定的规则预处理，再经多尺度专家与路由融合得到未来多步预测。这些输出描述 OD 流量需求，不是链路路由或带宽分配方案；具体管理动作需要由外部模块结合网络条件确定。

2 实验与结果分析

实验分为外部基线比较、核心消融和路由行为分析三个层次。LightTS 提供独立结构的外部基线，DLinear 提供单尺度参照；固定等权、全局可学习常权重、恒定输入路由与样本级路由模型采用相同的三个尺度专家结构，并分别训练，分别比较多尺度结构、非等权融合与输入相关权重的表现；八个共同随机种子的配对结果和逐种子权重分析用于评估结果波动。

2.1 数据集与实验设置

数据取自 CESNET TS-Zoo[9]，包括按 1 h 聚合的 Abilene[10]与 GÉANT[11]骨干网流量矩阵。Abilene 共有 4656 个时间点，保留 144 维有效 OD 流量；GÉANT 共有 2849 个时间点，去除恒定通道后保留 524 维有效 OD 流量。两套数据的序列长度和变量规模不同，分别运行相同预测流程，以观察这些数据条件下的表现。沿原序列的时间顺序划分训练集、验证集和测试集，比例为 6:2:2。输入长度统一设为 L=96，预测长度统一设为 H=24。预处理按第 1.1 节执行，数据规模及窗口数量见表 1。

表 1 数据集与预测任务设置

数据集	时间点	有效变量 C	训练/验证/测试时间点	训练/验证/测试窗口	L/H
Abilene	4656	144	2793/931/932	2674/812/813	96/24
GÉANT	2849	524	1709/570/570	1590/451/451	96/24

所有对比模型使用相同的数据划分、输入长度、预测长度、评价指标和批量大小，batch size 统一为 16。为控制数据与训练条件，实验未分别搜索各模型的最优超参数。DLinear、固定等权多尺度、全局可学习权重、恒定输入路由和本文方法最多训练 30 轮，LightTS 最多训练 50 轮；均根据验证集 MSE 选择测试所用参数，测试集仅用于最终统计。

外部基线比较使用随机种子 42～44 共 3 个共同随机种子。核心消融使用随机种子 42～49 共 8 个共同随机种子，比较 DLinear、固定等权多尺度、全局可学习权重、恒定输入路由和本文方法。全局权重由等权初始化，恒定输入路由对所有窗口使用全零路由输入；两者均与三个专家一同训练，并按相同验证集准则选择模型；随机种子作为配对统计单位。

2.2 对比模型与评价指标

对照包括 DLinear、LightTS、固定等权多尺度、全局可学习权重和恒定输入路由五类模型。DLinear 用于比较单一尺度与多尺度结构；LightTS 提供独立轻量模型基线。后三种多尺度对照与本文方法保留相同的尺度集合{1,2,4}和 DLinear 专家，分别使用等权、全局可学习权重和恒定输入路由权重。后两者均对全部窗口使用一组固定权重，可检验完整模型相对常权重方案的误差变化。

为减少主干结构对融合方式比较的干扰，各尺度专家统一采用 DLinear。预测误差可能同时受到这两方面影响，因此需要控制主干差异。单尺度预测、固定等权、全局可学习固定权重、恒定输入路由和样本级路由共五种设置，均需在这一主干下比较。过于复杂的尺度专家会使主干结构与融合机制对误差变化的影响交织。DLinear 的基本预测能力和清晰参数关系使其适合承担统一尺度专家。共用这一专家结构，便于分别考察预测主干与尺度融合的影响。

为了区分多尺度结构、非等权分配与样本相关分配的作用，设置三种共享相同专家的对照：固定等权模型将三个尺度恒定设为 1/3；全局可学习权重模型以三个可训练参数经 Softmax 得到一组常权重；恒定输入路由模型保留完整路由网络，但训练和推理时都向路由器输入全零窗口，使全部样本共用一组可学习权重。三种模型的尺度专家均接收真实历史窗口。

均方误差（MSE）、平均绝对误差（MAE）及均方根误差（RMSE）用于评价预测性能。其中 MSE 采用式（14），MAE 和 RMSE 的定义如下

$$\mathrm{MAE} = \frac{1}{N_{\mathrm{te}}HC}\sum_{n=1}^{N_{\mathrm{te}}}\sum_{h=1}^{H}\sum_{c=1}^{C}\left|Y_{n,h,c} - \hat{Y}_{n,h,c}\right|. \tag{15}$$

$$\mathrm{RMSE} = \sqrt{\mathrm{MSE}}. \tag{16}$$

误差在标准化空间计算，各指标越小，预测误差越低。正文以 MSE 和 MAE 为主要指标：前者对较大误差更敏感，后者反映平均绝对偏差。RMSE 为 MSE 的平方根，用于补充误差幅值。随机种子 42～44 的结果在表 2 中以均值±标准差列出；随机种子 42～49 的结果在表 3 中采用同一统计形式。均值描述平均水平，标准差描述种子间波动。相对改进率按共同随机种子逐一配对计算，再将所得改进率取平均；该百分比使用逐种子结果，而非表内四舍五入后的均值。

2.3 总体预测性能与基线比较

表 2 列出 3 个共同随机种子下的总体基线结果。本文方法在 Abilene 上的 MSE 为 0.186，在 GÉANT 上为 0.434；逐种子计算后相对 DLinear 分别降低 4.07%和 4.54%，相对 LightTS 分别降低 29.80%和 46.89%，MAE 呈相同方向变化。DLinear 与本文尺度专家采用同源结构，后续核心消融也以 DLinear 作为单尺度内部基线；LightTS 属于独立外部结构基线，图 2 进一步给出逐随机种子、多指标和参数规模比较。

表 2 三随机种子外部基线比较

数据集	模型	参数量	MSE	MAE
Abilene	DLinear	4656	0.194±0.002	0.188±0.009
Abilene	LightTS	130162	0.265±0.011	0.204±0.008
Abilene	本文方法	8339	0.186±0.002	0.168±0.001
GÉANT	DLinear	4656	0.454±0.007	0.383±0.006
GÉANT	LightTS	384382	0.817±0.024	0.523±0.014
GÉANT	本文方法	8339	0.434±0.051	0.370±0.031

图 2 以 LightTS 为独立外部基线，使用两种方法共有的随机种子 42～44。每次实验的相对降低率按（LightTS 误差−本文方法误差）/LightTS 误差计算。MSE、MAE 和 RMSE 的平均降幅在 Abilene 上为 29.80%、17.57%和 16.23%，在 GÉANT 上为 46.89%、29.15%和 27.18%。逐种子检查这三项指标，两个数据集的 3 个共同随机种子均有改善。本文方法的 8339 个参数，约为 LightTS 在 Abilene 和 GÉANT 上参数量的 6.41%和 2.17%；LightTS 的对应参数量分别为 130162 和 384382。

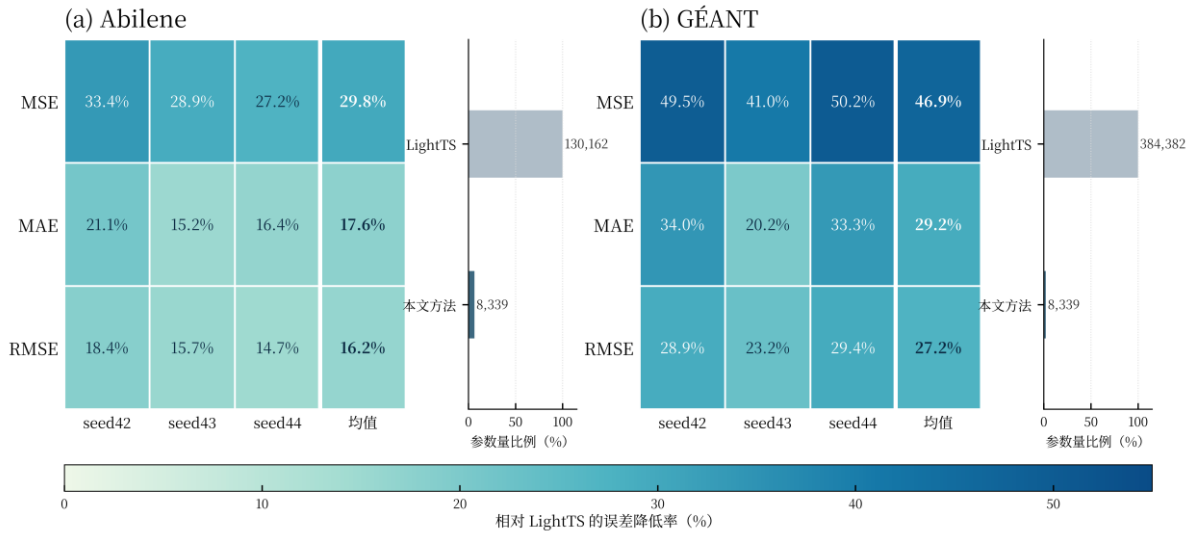


图 2 Abilene 与 GÉANT 上本文方法相对 LightTS 的三随机种子多指标性能提升

GÉANT 的 OD 变量数较多，本文方法相对 LightTS 的 MSE 降幅也高于 Abilene。不过，两者同时出现不能确立变量规模与误差降幅之间的因果关系。固定等权与全局可学习权重对照均采用相同的多尺度专家结构，适合进一步检验融合方式本身的作用。

2.4 八随机种子核心消融与稳定性

表 3 汇总随机种子 42～49 的 8 次核心消融，列出五种模型的参数量、MSE 和 MAE。

表 3 八随机种子核心消融结果（均值±标准差）

数据集	模型	参数量	MSE	MAE
Abilene	DLinear	4656	0.194±0.002	0.189±0.008
Abilene	固定等权多尺度	8208	0.192±0.002	0.191±0.006
Abilene	全局可学习权重	8211	0.192±0.002	0.190±0.006
Abilene	恒定输入路由	8339	0.192±0.002	0.181±0.006
Abilene	本文方法	8339	0.189±0.003	0.173±0.008
GÉANT	DLinear	4656	0.437±0.016	0.371±0.011
GÉANT	固定等权多尺度	8208	0.447±0.014	0.377±0.009
GÉANT	全局可学习权重	8211	0.446±0.014	0.377±0.009
GÉANT	恒定输入路由	8339	0.449±0.012	0.379±0.007
GÉANT	本文方法	8339	0.426±0.029	0.366±0.018

全局可学习权重与恒定输入路由均对所有窗口使用一组可学习权重，后者与本文方法同为 8339 个标称参数。相对这两种对照，本文方法在 Abilene 上的逐种子平均 MSE 改进均约 1.80%，在 GÉANT 上分别为 4.31%和 4.97%，各有 6/8 和 7/8 个种子胜出。相对恒定输入路由的 95%置信区间分别为[0.49%,3.11%]和[−1.62%,11.56%]，相对全局权重则为[0.01%,3.58%]和[−2.51%,11.13%]；GÉANT 两项区间均跨零。

图 3 以 DLinear 和固定等权多尺度模型为对照，列出随机种子 42～49 的 MSE、MAE 及 RMSE 相对改进率。两种方法误差相等的位置由 0%虚线标出，据此判断改进方向。各随机种子的结果用散点表示，8 次结果的分布由半小提琴汇总。黑色菱形和横向误差线分别表示 8 次改进率均值及其 95%置信区间。相对 DLinear 时，Abilene 的 MSE、MAE 和 RMSE 平均改进率为 2.77%、8.01%和 1.40%，其中 MSE 与 RMSE 在 8 次实验中均改善；GÉANT 分别为 2.35%、1.32%和 1.22%，且跨越 0%的情况更多。相对固定等权模型时，Abilene 三项指标的平均改进率为 1.65%、8.92%和 0.84%，GÉANT 为 4.54%、3.05%和 2.37%。两种基线下的平均改进率虽均为正值，GÉANT 的种子间波动仍较明显，平均收益的稳定性需结合图中置信区间判断。

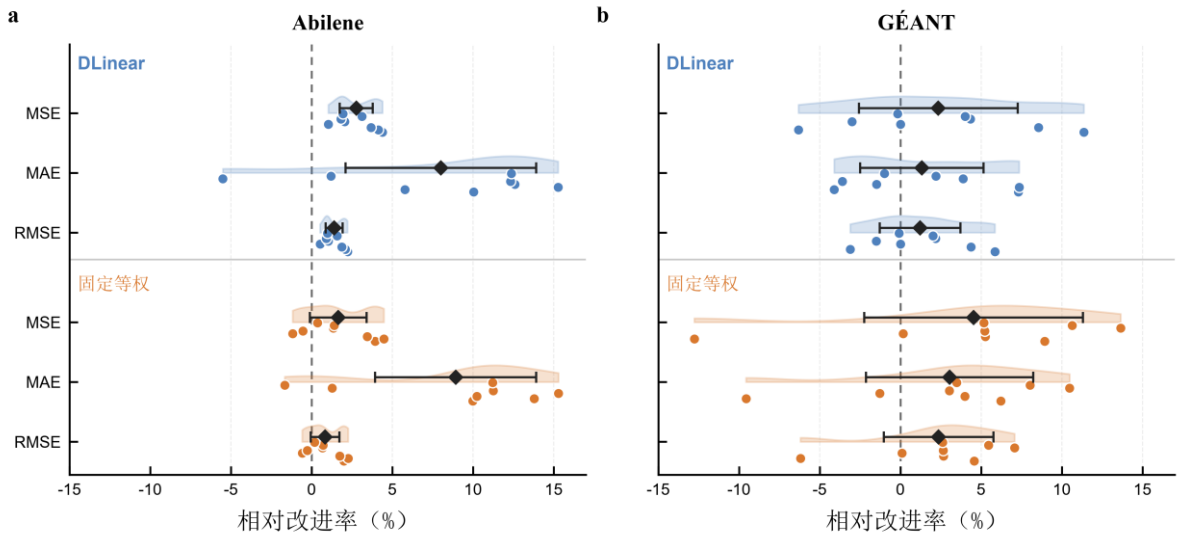


图 3 Abilene 与 GÉANT 上本文方法相对两类基线的八随机种子多指标相对改进分布

等权融合采用固定等权模型检验。全局可学习权重与恒定输入路由作为两类常权重对照，用于考察融合方式改变后的误差。表 3 中本文方法相对两者的平均 MSE 均较低，但 GÉANT 的配对区间均跨越零；其中种子 43 相对恒定输入路由退步 12.78%。这些结果比较的是完整方法与两类常权重方案。各模型独立训练，恒定输入路由的首层输入权重又不起作用，因此误差差异不能唯一归因于逐窗口权重变化。图 4 进一步汇总全测试点的整体偏差，并用按真实值波动选取的预测轨迹考察局部误差。

2.5 预测行为与尺度权重分析

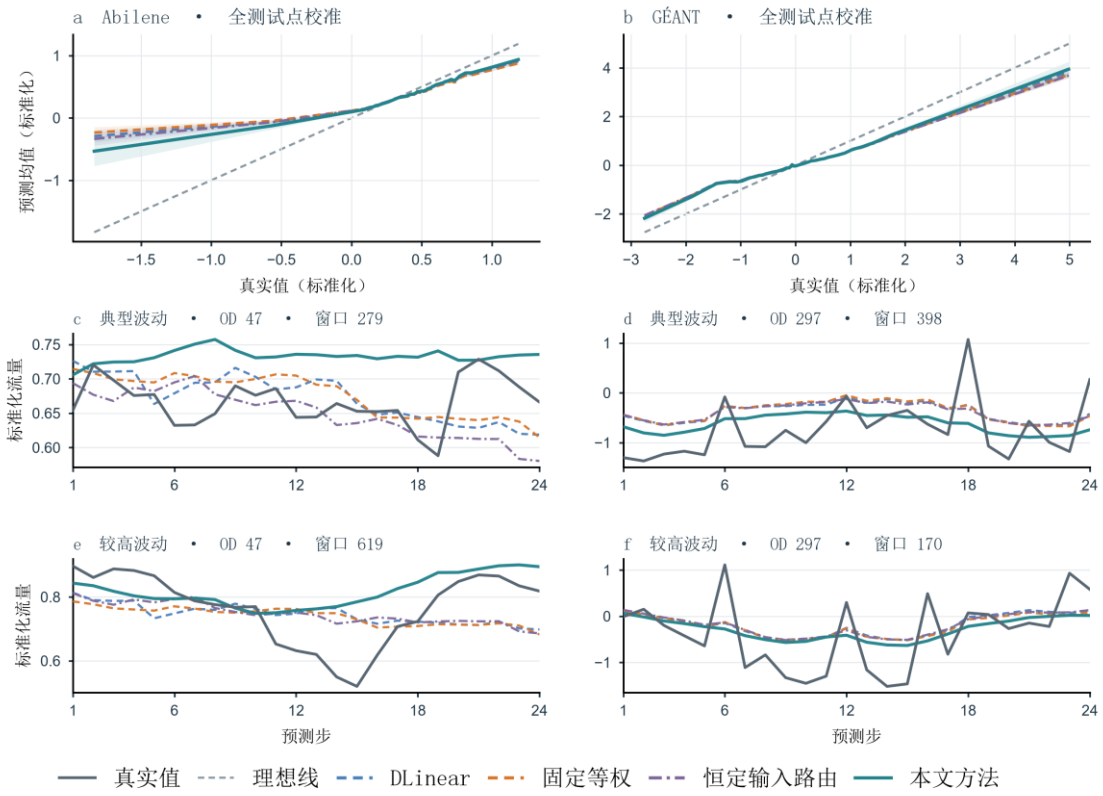


图 4 Abilene 与 GÉANT 全测试点预测校准及典型窗口预测轨迹

图 4(a、b)汇总随机种子 42～49 的全部测试窗口，覆盖 24 个预测步和全部有效 OD 通道。真实值按分位点分为最多 40 个区间，四种模型分别在区间内汇总 8 种子的预测值并取平均，由这些分组平均值构成曲线。灰色虚线给出理想预测位置，浅色带给出种子间±1 个标准差。高真实值区间中，四种模型的分组预测值均偏低，本文方法的平均偏差相对较小。这里比较的是区间平均值，不能代替各测试点的误差判断。图 4(c～f)固定随机种子 42，先依据真实序列选取标准差接近第 75 百分位的 OD 通道，再选波动程度接近中位数和第 90 百分位的窗口。通道及窗口的选择均不依据模型误差，只使用真实序列。本文方法在四例中的三例取得较低的 24 步均方误差，均低于 DLinear、固定等权和恒定输入路由模型；Abilene 典型波动窗口是例外，本文方法在该例中较差。这些轨迹用于解释所选窗口内的局部预测行为，总体精度仍按表 3 的配对统计判断。测试窗口相互重叠，故统计时不把重叠窗口作为独立重复。

随机种子 42～49 的三个尺度权重见图 5，小提琴分布包含全部测试窗口与种子。蓝、绿、橙色分别表示尺度 1、2 和 4。彩色散点显示同一种子在全部测试窗口上的平均权重。对 8 个种子的这些均值再计算均值±1 个标准差，以黑色菱形和误差线表示；固定等权 1/3 与汇总分布中位数分别用水平虚线及短横线标示。小提琴宽度同时受种子间差异与窗口间差异影响。因此，仅凭这一混合分布的宽度，无法判断同一种子内的窗口响应强度。

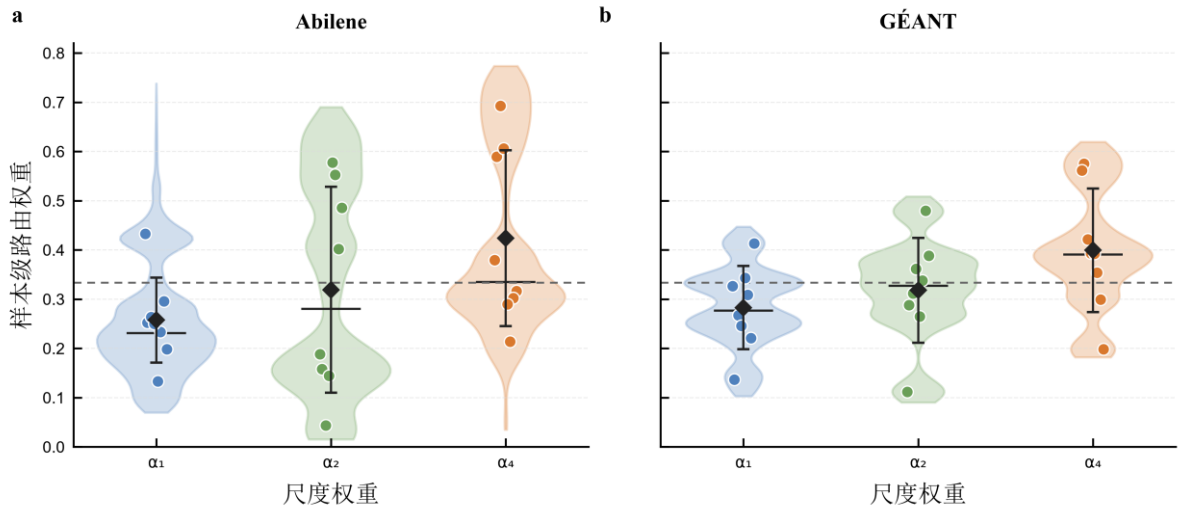


图 5 Abilene 与 GÉANT 的逐窗口路由权重汇总分布及八种子均值

三个尺度在 Abilene 上的汇总平均权重依次为 0.257、0.319 和 0.424，在 GÉANT 上依次为 0.283、0.318 和 0.399。这些总体均值均偏离固定等权的 1/3。从汇总权重方差的来源看，GÉANT 三个尺度中约 96.2%、95.8%和 97.7%的方差来自种子间差异。Abilene 对应的比例分别为 48.7%、86.1%和 80.6%。在 GÉANT 的同一种子内部，随窗口发生的权重变化较小。图 5 展示的汇总分布，把种子间差异与同一种子内部的窗口差异放在一起。若仅依据这一分布判断路由机制，仍缺少路由器能否有效识别各窗口尺度需求的证据。

输入窗口的波动强度由平均绝对一阶差分度量。分组阈值取自训练窗口的三分位数，测试窗口按这些阈值分组。Abilene 低、中、高波动组分别有 15、406、392 个窗口。本文方法相对全局权重模型的逐种子平均 MSE 改进率分别为 4.43%、1.90%、1.69%；GÉANT 在训练阈值下无低波动测试窗口，中、高组分别有 76、375 个窗口，改进率为 5.85%和 4.06%。在 Abilene 上，高波动组的尺度 1 平均权重高于中波动组，而相应的误差优势没有增强。GÉANT 中波动组与高波动组的权重则近似相同。依据这些分组结果，当前还不能支持“波动越强，路由收益越大”的机制解释。

2.6 运行开销与网络管理应用讨论

单尺度 DLinear 含 4656 个可训练参数，使用三个尺度专家的固定等权模型含 8208 个。在固定等权结构上加入三个全局权重参数后，参数总数为 8211 个；样本级路由和恒定输入路由的标称参数数目均为 8339 个。与固定等权及全局权重模型相比，路由网络分别增加 131 个和 128 个参数。恒定输入路由虽然保留样本级路由的网络结构，恒为零的输入却使首层输入权重不参与有效计算。

使用预测长度为 24 的 8 个随机种子检查点单独测量前向计算开销。计时运行于 NVIDIA GTX 1060，预先加载测试张量，并将批量大小设为 16。本文方法在 Abilene 和 GÉANT 上的平均每批前向耗时分别为 2.65 ms 和 2.61 ms，固定等权模型分别为 2.38 ms 和 2.10 ms，单尺度 DLinear 分别为 0.77 ms 和 0.70 ms。前向计时不包含数据读取和传输，端到端部署时延仍需计入这两部分。本文方法的参数量较小，但三个尺度专家及路由器带来的额外计算仍增加推理开销。

应用时，可由运维模块定期读取小时级历史 OD 序列，调用预测模型生成未来一天的需求估计，辅助观察高需求时段与容量变化。这里给出的是使用流程，现有实验仍为离线预测评价，尚未验证在线管理效果。

图 4 显示各模型在高真实值区间仍有低估，本文方法的分组平均偏差相对较小。对于依赖预测的容量评估，这提示需要关注高需求时段的低估风险；分组偏差改善尚不能直接解释为拥塞率下降或调度收益增加。

实际使用还需将预测恢复到原始流量量纲，并结合拓扑、路由和链路容量，才能由 OD 需求进一步分析链路负载。当前误差指标在标准化空间计算，前向计时也不包含完整部署流程，因此不能据此认定端到端运行或资源调度效果。

3 结论

本文构建了处理骨干网络 OD 流量短时波动与较慢趋势的多尺度预测结构。尺度 1、2 和 4 的 DLinear 专家独立预测，轻量路由网络根据输入计算融合权重，将各专家结果组合为最终输出。预测长度为 24 时，在 Abilene 和 GÉANT 两套实验中，本文方法的平均误差均低于作为比较对象的 DLinear、LightTS 和固定等权模型。相对全局可学习权重与恒定输入路由两类常权重对照，本文方法在 Abilene 上的逐种子平均 MSE 改进均约 1.80%；GÉANT 上的对应改进分别为 4.31%和 4.97%，但两项 95%置信区间均跨越零。

按真实值分组的校准结果表明，各模型在高流量端仍有低估，本文方法的平均偏差相对较小。由于该比较以分组平均值为依据，不能推断每个测试点的预测都更准确。现有结果可为小时级骨干网需求分析提供预测参考，实际运维和资源配置收益仍需另行验证。

路由器是否稳定匹配窗口尺度需求，在逐种子权重分析和波动分组分析中仍缺乏充分证据。输入相关融合收益的稳定性，仍需在更多数据与不同预测设置下检验。

参考文献

[1] LOHRASBINASAB I, KESHAVARZ A, AMIN-NEJAD S, et al. From statistical- to machine learning-based network traffic prediction[J]. Transactions on Emerging Telecommunications Technologies, 2022, 33(4): e4394. DOI: 10.1002/ett.4394.

[2] QIN L, GU H, WEI W, et al. Spatio-temporal communication network traffic prediction method based on graph neural network[J]. Information Sciences, 2024, 679: 121003. DOI: 10.1016/j.ins.2024.121003.

[3] 韦烜, 刘志华, 李青, 等. 大型 IP 网络流量矩阵分析预测的探讨研究[J]. 系统工程与电子技术, 2024, 46(6): 2164-2173. DOI: 10.12305/j.issn.1001-506X.2024.06.35.

[4] 唐文杰, 肖一磊, 孔祥宇, 等. CycleLLH：一种基于周期性整合的新型网络流量预测模型[J]. 计算机学报, 2024, 47(12): 2867-2888. DOI: 10.11897/SP.J.1016.2024.02867.

[5] ZHOU J, HAN T, XIAO F, et al. Multiscale network traffic prediction method based on deep echo-state network for Internet of Things[J]. IEEE Internet of Things Journal, 2022, 9(21): 21862-21874. DOI: 10.1109/JIOT.2022.3181807.

[6] ZENG A, CHEN M, ZHANG L, et al. Are transformers effective for time series forecasting?[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2023, 37(9): 11121-11128. DOI: 10.1609/aaai.v37i9.26317.

[7] WANG S, WU H, SHI X, et al. TimeMixer: decomposable multiscale mixing for time series forecasting[C]//International Conference on Learning Representations. 2024.

[8] ZHANG T, ZHANG Y, CAO W, et al. Less is more: fast multivariate time series forecasting with light sampling-oriented MLP structures[EB/OL]. (2022-07-04)[2026-09-20]. https://arxiv.org/abs/2207.01186. DOI: 10.48550/arXiv.2207.01186.

[9] KUREŠ M, KOUMAR J, HYNEK K. CESNET TS-Zoo: a library for reproducible analysis of network traffic time series[C]//2025 21st International Conference on Network and Service Management. 2025. DOI: 10.23919/CNSM67658.2025.11297513.

[10] ZHANG Y, ROUGHAN M, DUFFIELD N, et al. Fast accurate computation of large-scale IP traffic matrices from link loads[J]. ACM SIGMETRICS Performance Evaluation Review, 2003, 31(1): 206-217. DOI: 10.1145/885651.781053.

[11] UHLIG S, QUOITIN B, LEPROPRE J, et al. Providing public intradomain traffic matrices to the research community[J]. ACM SIGCOMM Computer Communication Review, 2006, 36(1): 83-86. DOI: 10.1145/1111322.1111341.