基于自适应多尺度加权的多变量网络流量预测方法

[请填写作者姓名]

（[请填写工作单位] [请填写部门]，[省 市 邮编]）

摘要：为提高小时级骨干网络流量的多步预测精度，构建了轻量自适应多尺度预测模型。模型将历史窗口转换为三种时间分辨率的序列，分别由独立分解线性专家生成候选预测，兼顾局部变化与较慢趋势。路由网络提取窗口的总体水平、离散程度、末时状态和平均变化强度，经两层感知器生成融合权重。在输入 96 步、预测 24 步的 Abilene 和 GÉANT 实验中，3 个共同随机种子的均方误差相对单尺度分解线性模型分别降低 4.07%和 4.54%，相对采样导向轻量模型 LightTS 分别降低 29.80%和 46.89%。8 种子消融中，相对全局可学习权重和恒定输入路由的逐种子平均改进率在 Abilene 上均约 1.80%，在 GÉANT 上分别为 4.31%和 4.97%。结果表明，多尺度预测与低维路由结合取得了较低的平均误差，仅增加少量融合参数，可为未来一天的网络需求分析与容量规划提供参考。

关键词：网络流量预测；多变量时间序列；多尺度学习；自适应加权；线性分解预测

中图分类号：TP393　　**文献标志码：**A

A Multivariate Network Traffic Forecasting Method Based on Adaptive Multiscale Weighting

[Author Name]

([Affiliation] [Department], [City] [Postcode], China; Corresponding author: [Name], E-mail: [E-mail])

Abstract: A lightweight adaptive multiscale model was developed to improve multistep forecasting of hourly backbone traffic. Historical windows were represented at three temporal resolutions, and independent decomposition linear (DLinear) predictors generated candidate forecasts. A two-layer perceptron used four window statistics to calculate fusion weights: overall level, dispersion, final-time state and mean absolute change. Experiments on Abilene and GÉANT used an input length of 96 and a forecast length of 24. Across three common random seeds, mean squared error decreased by 4.07% and 4.54% relative to single-scale DLinear, respectively. The corresponding reductions relative to the sampling-oriented lightweight model LightTS were 29.80% and 46.89%. Eight-seed ablations compared the model with learned global weights and a constant-input router. Mean seed-wise improvements over both controls were approximately 1.80% on Abilene. On GÉANT, the improvements over learned global weights and the constant-input router were 4.31% and 4.97%, respectively. Combining multiscale forecasting with low-dimensional routing achieves lower mean errors with few additional fusion parameters. The forecasts provide a reference for next-day network demand analysis and capacity planning.

Key words: network traffic forecasting; multivariate time series; multiscale learning; adaptive weighting; linear decomposition forecasting

引言

源—目的节点对（origin-destination，OD）流量描述骨干网节点对之间的通信需求。容量规划需要了解各节点对未来的需求变化。本文面向小时级 OD 流量，预测未来一天的需求，为高需求时段观察和容量安排提供参考。云计算、视频业务和数据中心互联增加了业务迁移与聚集，使流量变化更复杂。周期变化、局部波动与突发变化叠加，各 OD 变量量级不同，预测模型需同时刻画较慢趋势与短时变化。

收稿日期：[编辑部填写]

基金项目：[基金来源]（[基金项目编号]）

第一作者简介：[姓名]（[出生年]—），[性别（民族，汉族可省略）]，[职称]，[学位（若在读请注明）]，研究方向：[方向 1]；[方向 2]。

通信作者简介：[姓名]（[出生年]—），[性别（民族，汉族可省略）]，[职称]，[学位（若在读请注明）]，研究方向：[方向 1]；[方向 2]，电子邮箱：[邮箱]。

Lohrasbinasab 等[1]综述了网络流量预测方法，指出机器学习与深度学习等数据驱动方法的应用不断增加。网络规模扩大后，仅分析单一序列难以覆盖 OD 变量之间的关联。Qin 等[2]采用图神经网络处理空间关联与时间依赖；韦烜等[3]分析大型网际协议（Internet protocol，IP）网络流量矩阵的变量关联及时间变化；唐文杰等[4]在 CycleLLH 中引入周期性信息。这些研究从时间依赖、变量关联和周期结构等角度开展预测。

原始时间分辨率保留局部细节，时间聚合平滑短时扰动并突出较慢趋势。Zhou 等[5]采用深度回声状态网络提取多分辨率信息，利用各尺度互补性。分解线性模型（decomposition linear model，DLinear）[6]通过序列分解和线性映射预测，TimeMixer[7]采用多尺度混合，LightTS[8]以采样导向的多层感知器（multilayer perceptron，MLP）实现快速预测。这些方法为多分辨率建模和轻量预测提供了基础，本文在分解线性预测的主干上研究尺度间的融合方式。

对于同一历史窗口，不同时间分辨率保留的信息并不相同。将各尺度预测按固定比例融合，可以利用多尺度信息，但融合比例不会随输入状态变化。因此，本文研究在保持尺度专家结构一致的条件下，依据窗口状态生成融合权重是否能够进一步降低整体预测误差。

本文以独立 DLinear 专家处理尺度 1、2 和 4 的序列，用低维窗口统计量驱动路由网络，生成归一化融合权重。尺度专家负责各分辨率的候选预测，路由网络负责尺度间融合，在保留多尺度信息的同时控制参数规模。在 Abilene 和 GÉANT 上，通过外部基线比较、固定融合对照及多随机种子实验评价整体预测精度，并结合预测轨迹和权重分布分析模型行为。

1 自适应多尺度网络流量预测方法

图 1 给出模型的整体流程。历史 OD 窗口经对数变换和标准化后，构造尺度 1、2 和 4 的输入序列，分别交给独立 DLinear 专家。各专家将趋势项和余项分别映射到 24 步预测，再将两部分结果相加。窗口路由网络根据原始分辨率输入的 4 项统计特征生成 Softmax 权重，对 3 个尺度的候选预测加权求和。

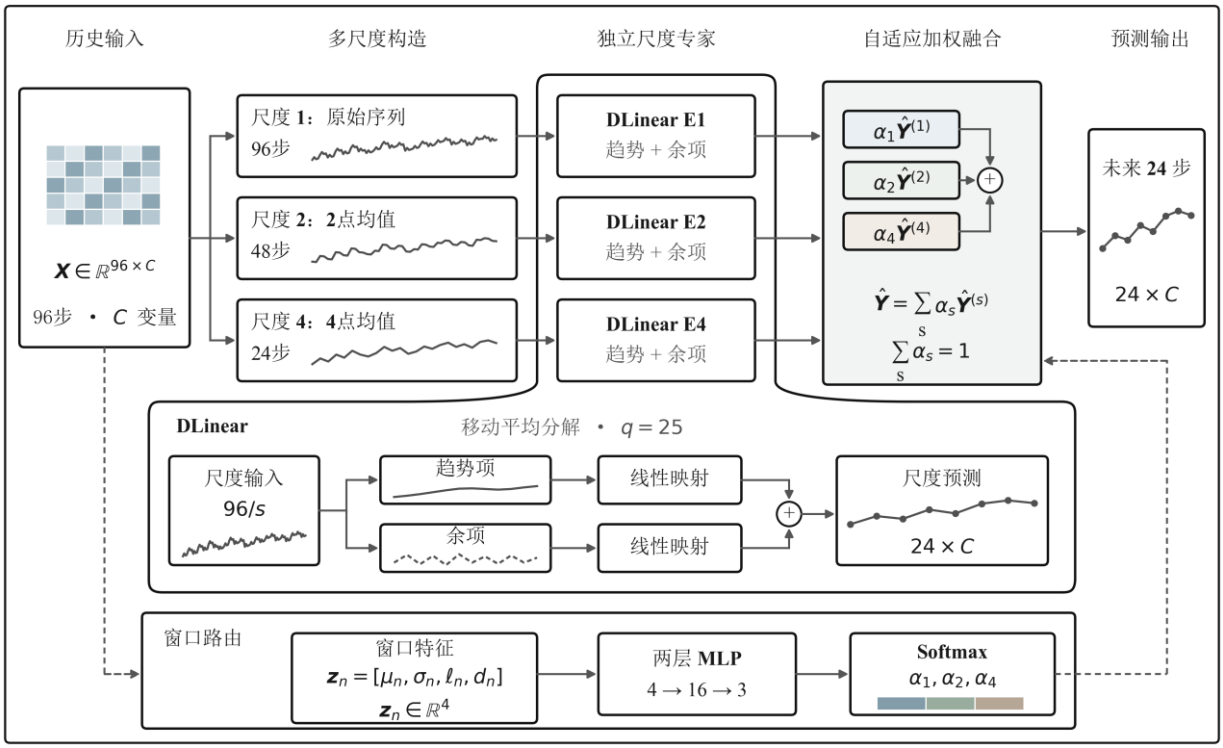


图 1 自适应多尺度预测框架

注：曲边连接表示 DLinear 专家内部的展开；实线为预测计算流程，虚线为窗口特征及融合权重的传递。图中省略样本下标 n，矩阵、曲线及色块仅作计算过程示意。

原始尺度保留局部变化，较粗尺度通过时间聚合突出慢趋势。各尺度独立预测，路由网络确定样本融合比例；统一采用 DLinear 专家控制规模，也为多尺度输入与样本级融合提供相同主干。

1.1 预测任务与数据预处理

记预处理后的多变量流量序列为 $\boldsymbol{x}_t \in \mathbb{R}^C$，t 表示时间索引，C 表示有效 OD 变量数。沿时间轴对连续序列生成滑动窗口，作为监督学习样本；第 n 个样本由历史窗口$\boldsymbol{X}_n$及预测目标$\boldsymbol{Y}_n$组成：$\boldsymbol{X}_n$覆盖连续 L 个时间点，$\boldsymbol{Y}_n$覆盖其后连续的 H 个时间点。模型读取多个 OD 变量过去 L 步的联合变化作为历史信息，估计未来 H 步的取值。第 n 个样本的输入与目标写为

$$\boldsymbol{X}_n = [\boldsymbol{x}_n, \dots, \boldsymbol{x}_{n+L-1}] \in \mathbb{R}^{L\times C}. \tag{1}$$

$$\boldsymbol{Y}_n = [\boldsymbol{x}_{n+L}, \dots, \boldsymbol{x}_{n+L+H-1}] \in \mathbb{R}^{H\times C}. \tag{2}$$

本文取 L=96 步作为历史输入、H=24 步作为未来预测，C 为各数据集保留的有效 OD 维度数。需要学习的预测映射记为$\widehat{\boldsymbol{Y}}_n = f_\theta(\boldsymbol{X}_n)$。一次预测的历史读取范围为 L，连续输出长度为 H。原始 OD 流量均非负，各变量量级相差较大；直接使用原始数值训练时，数值范围较大的变量与其他变量尺度不一致。为压缩数值范围，本文对原始流量$v_{t,c}$作对数变换

$$u_{t,c} = \log(1 + v_{t,c}). \tag{3}$$

再按变量进行标准化：

$$x_{t,c} = \frac{u_{t,c}-\mu_c^{\mathrm{tr}}}{\sigma_c^{\mathrm{tr}}}. \tag{4}$$

其中μ_c^{tr}和σ_c^{tr}分别表示训练集中第 c 个 OD 变量的均值与标准差。验证集和测试集的预处理沿用这组训练统计量，均不重新估计。log(1+x)变换保留非负流量的大小关系，同时压缩数值范围，缓和原有量级差异。随后逐变量标准化，使各 OD 维度在训练、损失计算和参数更新中采用相近数值尺度。数据依时间先后按 6:2:2 划为训练集、验证集和测试集。每个集合内部独立生成滑动窗口，窗口不跨越集合边界。

预处理保留历史窗口原有的时间分辨率，各尺度共用这一窗口。不同尺度序列在此后构造，分别向各专家提供细粒度变化和较平滑的趋势。

在第 2.1 节所用的 1 h 聚合数据上，96 步历史输入对应过去 96 h，24 步预测对应未来 24 h。该设置可用于观察小时级需求变化，并提供未来一天的流量预测。

1.2 多尺度构造与 DLinear 专家

设尺度集合 S={1,2,4}。尺度 s 规定时间维聚合的窗口大小与步长，两者取值相同。采用非重叠平均池化，任一尺度 s 的序列构造为：

$$\boldsymbol{X}_{n,t}^{(s)} = \frac{1}{s}\sum_{i=0}^{s-1} \boldsymbol{X}_{n,st+i}, \quad t = 0, \dots, \frac{L}{s} - 1. \tag{5}$$

L=96 时，尺度 1 保留原始 96 步序列；尺度 2 取相邻 2 点均值，得到 48 步；尺度 4 取相邻 4 点均值，得到 24 步。三者分别保留短时起伏、适度平滑局部变化及进一步突出慢趋势。非重叠平均池化无需训练参数，多尺度构造不增加模型参数。

尺度组合{1,2,4}将 96 步历史分为整数长度序列，在细粒度信息、趋势信息与模型规模之间作出取舍。增加尺度会缩短序列并增加专家分支。同一尺度内，每个原始时间点仅参与一次聚合。

尺度 1、2 和 4 分别交由 DLinear 专家[6]处理，每个专家独立接收对应尺度的序列。DLinear 的预测分两步完成：先分解出变化较慢的趋势项和围绕趋势变化的余项，再对这两项分别作时间映射。对尺度 s 的输入，以长度 q=25 的中心移动平均在局部时间邻域内平滑并提取趋势项。边界处不足完整窗口时，复制端点补齐缺少部分，防止平滑后的序列缩短；补齐后的序列记为$\widetilde{\boldsymbol{X}}^{(s)}$；越界索引取最近端点值，从而保持分解前后的时间长度一致：

$$\boldsymbol{T}_{n,t}^{(s)} = \frac{1}{q}\sum_{i=-m}^{m} \widetilde{\boldsymbol{X}}_{n,t+i}^{(s)}, \quad q = 2m + 1 = 25. \tag{6}$$

$$\boldsymbol{R}_n^{(s)} = \boldsymbol{X}_n^{(s)} - \boldsymbol{T}_n^{(s)}. \tag{7}$$

趋势项$\boldsymbol{T}^{(s)}$和余项$\boldsymbol{R}^{(s)}$沿时间维分别通过线性层映射到预测长度 H：

$$\widehat{\boldsymbol{Y}}_n^{(s)} = \boldsymbol{W}_{\mathrm{T}}^{(s)}\boldsymbol{T}_n^{(s)} + \boldsymbol{b}_{\mathrm{T}}^{(s)} + \boldsymbol{W}_{\mathrm{R}}^{(s)}\boldsymbol{R}_n^{(s)} + \boldsymbol{b}_{\mathrm{R}}^{(s)}. \tag{8}$$

由式（6）和式（7）可得到尺度 s 上的趋势项$\boldsymbol{T}^{(s)}$和余项$\boldsymbol{R}^{(s)}$。趋势项表示经过局部平滑后保留下来的较慢变化部分，余项则由原序列减去趋势项得到，保留未被移动平均解释的局部变化。式（8）分别对两部分沿时间维进行线性映射，并把二者的预测结果相加形成该尺度的候选预测。3 个尺度使用独立 DLinear 专家，是因为尺度 1、2 和 4 的输入长度分别为 96、48 和 24，对应的时间分辨率和时间映射关系并不相同；若强制共用一组尺度间参数，会把不同长度、不同平滑程度的序列约束到同一映射中。同一尺度内部，各 OD 变量共享时间映射参数，模型学习的是这一时间尺度下通用的时间映射形式，而不是为每个 OD 变量分别建立一套线性层。

1.3 样本级自适应尺度加权

同一样本由 3 个 DLinear 专家分别预测，最终输出由这 3 组结果融合而成。若将 3 个尺度固定设为各占 1/3，融合比例对所有输入窗口相同。窗口状态差异为改变融合比例提供了设计依据：局部波动较强时可能更依赖细粒度信息，变化平稳时可能更依赖较粗尺度的趋势信息。本文依据窗口统计量计算权重，使融合比例随样本状态变化。由原始输入$\boldsymbol{X}_n$提取四维统计向量$\boldsymbol{z}_n = [\mu_n, \sigma_n, \ell_n, d_n]$，用这些统计量描述当前窗口状态，其中

$$\mu_n = \frac{1}{LC}\sum_{t=0}^{L-1}\sum_{c=1}^{C} X_{n,t,c}, \quad \sigma_n = \sqrt{\frac{1}{LC}\sum_{t=0}^{L-1}\sum_{c=1}^{C}(X_{n,t,c} - \mu_n)^2}. \tag{9}$$

$$\ell_n = \frac{1}{C}\sum_{c=1}^{C} X_{n,L-1,c}, \quad d_n = \frac{1}{(L-1)C}\sum_{t=1}^{L-1}\sum_{c=1}^{C} |X_{n,t,c} - X_{n,t-1,c}|. \tag{10}$$

μ_n、σ_n、ℓ_n和d_n分别描述输入窗口的总体水平、离散程度、最近状态和平均变化强度。μ_n反映窗口整体流量水平，σ_n刻画观测值的离散程度，ℓ_n取窗口末时刻的平均状态，d_n由相邻时间点的一阶变化得到。这 4 个统计量分别提供水平、波动、最近状态和局部变化信息，供路由器计算输入相关的尺度权重，而不直接参与未来流量数值的预测。

两层感知器将四维统计向量映射为 3 个尺度的未归一化分数，隐藏层维数设为 16。路由器只计算尺度融合分数，尺度专家承担完整 OD 流量的预测。低维统计量和较小隐藏层用于控制路由参数规模，计算中不额外引入循环网络、注意力网络等时序编码器。隐藏层采用修正线性单元（rectified linear unit，ReLU）。其尺度分数计算为

$$\boldsymbol{a}_n = \boldsymbol{W}_2\mathrm{ReLU}(\boldsymbol{W}_1\boldsymbol{z}_n + \boldsymbol{b}_1) + \boldsymbol{b}_2. \tag{11}$$

对式（11）的 3 个尺度分数作 Softmax 归一化，得到 3 个总和为 1 的非负权重；各专家在最终预测中的相对贡献由这些权重表示：

$$\alpha_{n,s} = \frac{\exp(a_{n,s})}{\sum_{j\in S}\exp(a_{n,j})}, \quad \alpha_{n,s} \geq 0, \quad \sum_{s\in S}\alpha_{n,s} = 1. \tag{12}$$

最终预测为

$$\widehat{\boldsymbol{Y}}_n = \sum_{s\in S}\alpha_{n,s}\,\widehat{\boldsymbol{Y}}_n^{(s)}. \tag{13}$$

式（13）利用上述权重对 3 个 DLinear 专家的预测结果进行加权求和，得到最终预测$\widehat{\boldsymbol{Y}}_n$。该组权重由输入窗口计算，并由同一窗口内的全部 OD 变量共享。

1.4 模型训练与预测输出

本文以均方误差（mean squared error，MSE）训练模型。损失在训练样本、未来 H 个预测时刻以及全部 C 个 OD 变量上计算，覆盖不同预测步与不同 OD 维度的偏差。各项偏差在同一目标中汇总，用于模型参数更新。对应训练目标为

$$\mathcal{L}_{\mathrm{MSE}} = \frac{1}{NHC}\sum_{n=1}^{N}\sum_{h=1}^{H}\sum_{c=1}^{C}(Y_{n,h,c} - \hat{Y}_{n,h,c})^2. \tag{14}$$

训练采用自适应矩估计（adaptive moment estimation，Adam）优化器更新参数，并根据验证集 MSE 选择最终使用的模型。

推理时，将历史 OD 窗口按训练阶段确定的规则预处理，再经多尺度专家与路由融合得到未来多步预测。预测结果可作为后续网络需求分析的输入。

2 实验与结果分析

实验从总体预测性能、融合方式消融、预测与权重行为以及运行开销四方面评价模型。

2.1 数据集与实验设置

数据取自 CESNET TS-Zoo[9]的 1 h 聚合 Abilene[10]和 GÉANT[11]流量矩阵。Abilene 含 4656 个时间点、144 维有效 OD 变量；GÉANT 含 2849 个时间点，去除恒定通道后保留 524 维。两套数据均按时间顺序以 6:2:2 划分，采用 L=96、H=24 和第 1.1 节预处理，规模与窗口数见表 1。

表 1 数据集与预测任务设置

数据集	时间点	有效变量 C	训练/验证/测试时间点	训练/验证/测试窗口	L/H
Abilene	4656	144	2793/931/932	2674/812/813	96/24
GÉANT	2849	524	1709/570/570	1590/451/451	96/24

对比设置包括单尺度 DLinear、独立轻量基线 LightTS、固定等权多尺度、全局可学习权重、恒定输入路由及本文方法。四种多尺度模型采用相同的 DLinear 主干和尺度集合{1,2,4}，比较不同融合方式。

固定等权模型将各尺度权重设为 1/3；全局权重模型用 3 个由等权初始化的可训练参数，经 Softmax 生成全局固定权重；恒定输入路由保留本文方法的路由网络，训练与推理均输入全零特征向量，使所有窗口共用融合权重。三类对照的专家均接收真实历史窗口，用于区分多尺度信息、非等权融合与输入相关分配的作用。

所有模型使用相同的数据划分、输入和预测长度、评价指标及批量大小 16，均采用 Adam 优化器，未分别搜索最优超参数。DLinear 及各多尺度模型的学习率为 0.001，最多训练 30 轮，验证集 MSE 连续 6 轮无改善时提前停止；LightTS 的学习率为 0.0001，最多训练 50 轮，早停耐心值为 10 轮。可训练融合参数与尺度专家共同优化，各模型均按验证集 MSE 选择参数，测试集仅用于最终统计。

LightTS 采用 THUML 的公开实现，分块长度为 24、模型维度参数为 512；DLinear 及各尺度专家的移动平均窗口均为 25，路由隐藏层维度为 16。软件版本为 Python 3.11.9 和 PyTorch 2.5.1。

外部基线比较使用随机种子 42～44 共 3 个共同随机种子；核心消融使用 42～49 共 8 个共同随机种子，比较 DLinear、三类固定融合对照及本文方法，并以随机种子作为配对统计单位。

均方误差（MSE）、平均绝对误差（mean absolute error，MAE）及均方根误差（root mean squared error，RMSE）用于评价预测性能。其中 MSE 采用式（14），MAE 和 RMSE 的定义如下

$$\mathrm{MAE} = \frac{1}{N_{\mathrm{te}}HC}\sum_{n=1}^{N_{\mathrm{te}}}\sum_{h=1}^{H}\sum_{c=1}^{C}|Y_{n,h,c} - \hat{Y}_{n,h,c}|. \tag{15}$$

$$\mathrm{RMSE} = \sqrt{\mathrm{MSE}}. \tag{16}$$

指标在标准化空间计算，越小越好。MSE 对较大误差敏感，MAE 反映平均绝对偏差，RMSE 补充误差幅值。表 2 与表 3 分别以均值±标准差汇总种子 42～44 和 42～49 的结果，标准差反映种子间波动。相对改进率先按共同种子配对计算，再取平均，不使用表内四舍五入后的均值。95%置信区间依据配对种子改进率的均值和标准误，采用自由度为 7 的 t 分布计算。

2.2 总体预测性能与基线比较

表 2 列出 3 个共同随机种子下的总体基线结果。本文方法在 Abilene 上的 MSE 为 0.186，在 GÉANT 上为 0.434；逐种子计算后相对 DLinear 分别降低 4.07%和 4.54%，相对 LightTS 分别降低 29.80%和 46.89%，MAE 呈相同方向变化。图 2 进一步展示本文方法与 LightTS 的逐种子、多指标结果及参数规模。

表 2 三随机种子外部基线比较

数据集	模型	参数量	MSE	MAE
Abilene	DLinear	4656	0.194±0.002	0.188±0.009
Abilene	LightTS	130162	0.265±0.011	0.204±0.008
Abilene	本文方法	8339	0.186±0.002	0.168±0.001
GÉANT	DLinear	4656	0.454±0.007	0.383±0.006
GÉANT	LightTS	384382	0.817±0.024	0.523±0.014
GÉANT	本文方法	8339	0.434±0.051	0.370±0.031

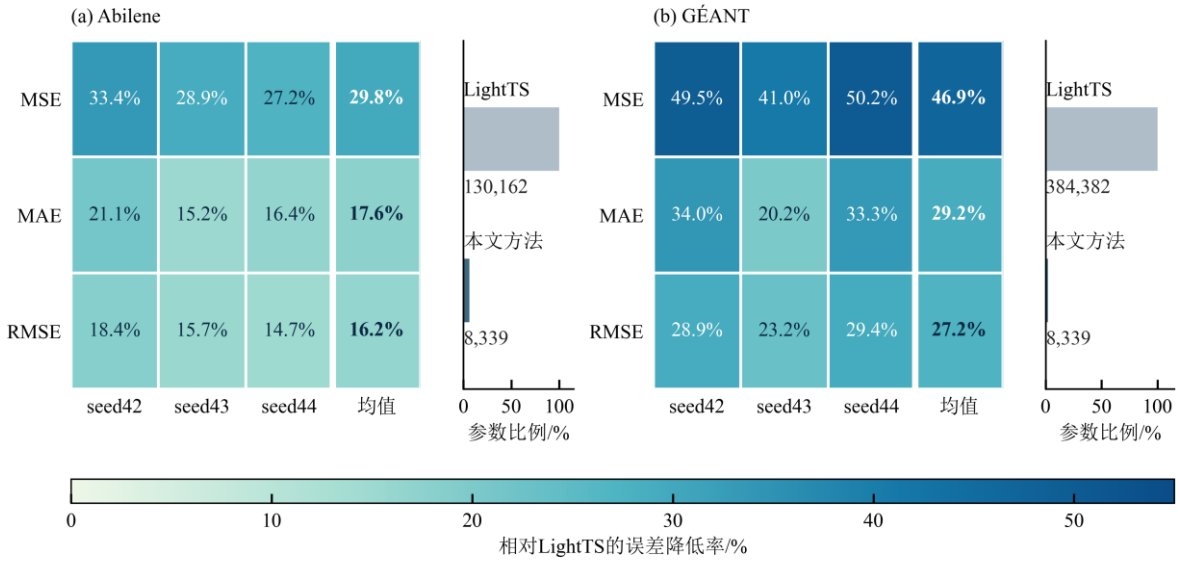


图 2 相对 LightTS 的误差降低率与参数规模

注：使用共同随机种子 42～44。误差降低率按（LightTS 误差−本文方法误差）/LightTS 误差计算；参数比例以各数据集的 LightTS 参数量为参照。

MSE、MAE 和 RMSE 的平均降幅在 Abilene 上为 29.80%、17.57%和 16.23%，在 GÉANT 上为 46.89%、29.15%和 27.18%。逐种子检查这三项指标，两个数据集的 3 个共同随机种子均有改善。本文方法的 8339 个参数，约为 LightTS 在 Abilene 和 GÉANT 上参数量的 6.41%和 2.17%；LightTS 的对应参数量分别为 130162 和 384382。

本文方法在 OD 规模不同的两套数据上均优于 LightTS，GÉANT 的 MSE 降幅更高。下节以相同多尺度专家检验融合方式。

2.3 八随机种子核心消融与稳定性

表 3 汇总随机种子 42～49 的 8 次核心消融，列出五种模型的参数量、MSE 和 MAE。

表 3 八随机种子核心消融结果（均值±标准差）

数据集	模型	参数量	MSE	MAE
Abilene	DLinear	4656	0.194±0.002	0.189±0.008
Abilene	固定等权多尺度	8208	0.192±0.002	0.191±0.006
Abilene	全局可学习权重	8211	0.192±0.002	0.190±0.006
Abilene	恒定输入路由	8339	0.192±0.002	0.181±0.006
Abilene	本文方法	8339	0.189±0.003	0.173±0.008
GÉANT	DLinear	4656	0.437±0.016	0.371±0.011
GÉANT	固定等权多尺度	8208	0.447±0.014	0.377±0.009
GÉANT	全局可学习权重	8211	0.446±0.014	0.377±0.009
GÉANT	恒定输入路由	8339	0.449±0.012	0.379±0.007
GÉANT	本文方法	8339	0.426±0.029	0.366±0.018

相对全局可学习权重和恒定输入路由，本文方法在 Abilene 上的逐种子平均 MSE 改进均约 1.80%，在 GÉANT 上分别为 4.31%和 4.97%，各有 6/8 和 7/8 个种子胜出。相对恒定输入路由的 95%置信区间分别为[0.49%,3.11%]和[−1.62%,11.56%]，相对全局权重则为[0.01%,3.58%]和[−2.51%,11.13%]；GÉANT 两项区间均跨零。

图 3 进一步展示本文方法相对 DLinear 和固定等权多尺度模型的逐种子改进分布。

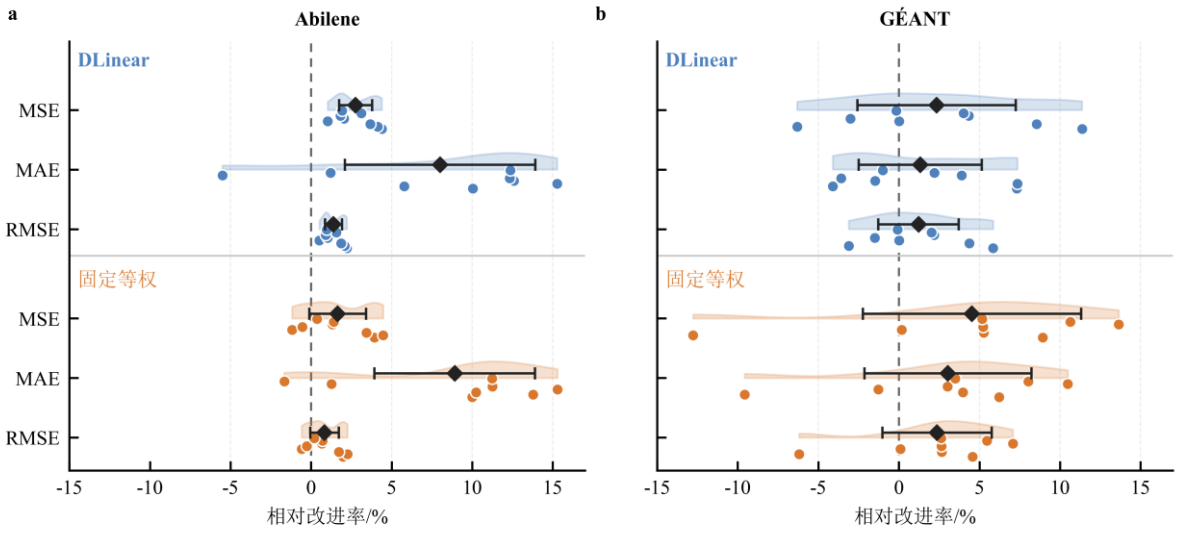


图 3 相对两类基线的多指标改进分布

注：使用共同随机种子 42～49，n=8。散点为单个种子的改进率，半小提琴汇总其分布；黑色菱形为均值，横向误差线为 95%置信区间，0%虚线表示误差相同。

相对 DLinear 时，Abilene 的 MSE、MAE 和 RMSE 平均改进率为 2.77%、8.01%和 1.40%，其中 MSE 与 RMSE 在 8 次实验中均改善；GÉANT 分别为 2.35%、1.32%和 1.22%，且跨越 0%的情况更多。相对固定等权模型时，Abilene 三项指标的平均改进率为 1.65%、8.92%和 0.84%，GÉANT 为 4.54%、3.05%和 2.37%。两种基线下的平均改进率均为正值，图 3 同时展示了不同随机种子的结果分布。

表 3 的两类常权重对照中，本文方法在八次重复实验中的平均 MSE 较低；GÉANT 种子 43 相对恒定输入路由退步 12.78%。图 4 进一步汇总全测试点的预测偏差，并展示按真实序列波动选取的典型轨迹。

2.4 预测行为与尺度权重分析

图 4 从全测试点分组预测与典型窗口轨迹两个层面展示预测行为。

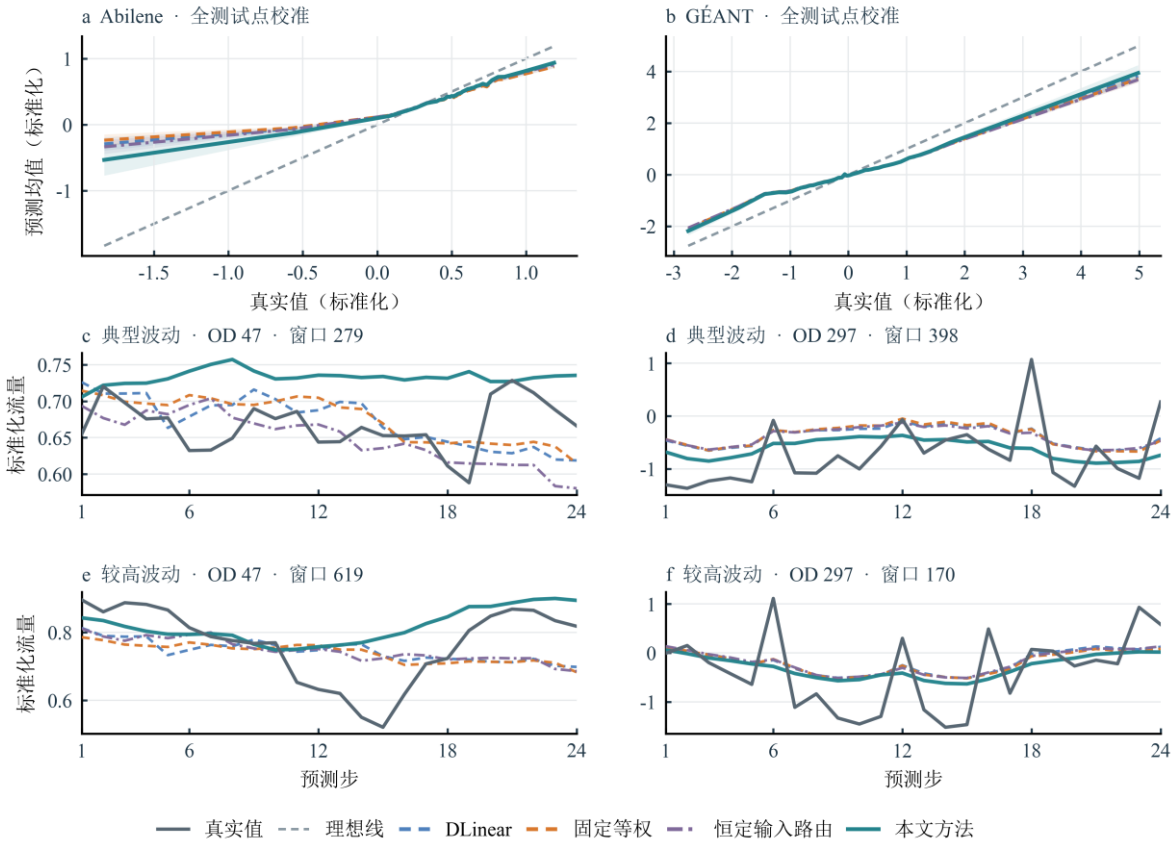


图 4 分组预测校准与典型窗口轨迹

注：（a、b）汇总种子 42～49 的全部测试窗口、24 个预测步及有效 OD 通道；真实值按分位点分为最多 40 组，曲线为分组平均预测，浅色带为种子间±1 个标准差，灰色虚线为理想线。（c～f）使用种子 42，选取真实序列标准差接近第 75 百分位的 OD 通道及波动程度接近中位数、第 90 百分位的窗口；选例仅依据真实序列。

高真实值区间中，四种模型的分组预测值均偏低，本文方法的平均偏差相对较小。本文方法在四例中的三例取得较低的 24 步均方误差，均低于 DLinear、固定等权和恒定输入路由模型；Abilene 典型波动窗口是例外，本文方法在该例中较差。图 4 以分组结果和典型轨迹展示预测行为，整体误差结果见表 3。

图 5 展示 3 个尺度的权重分布及各随机种子的平均权重。

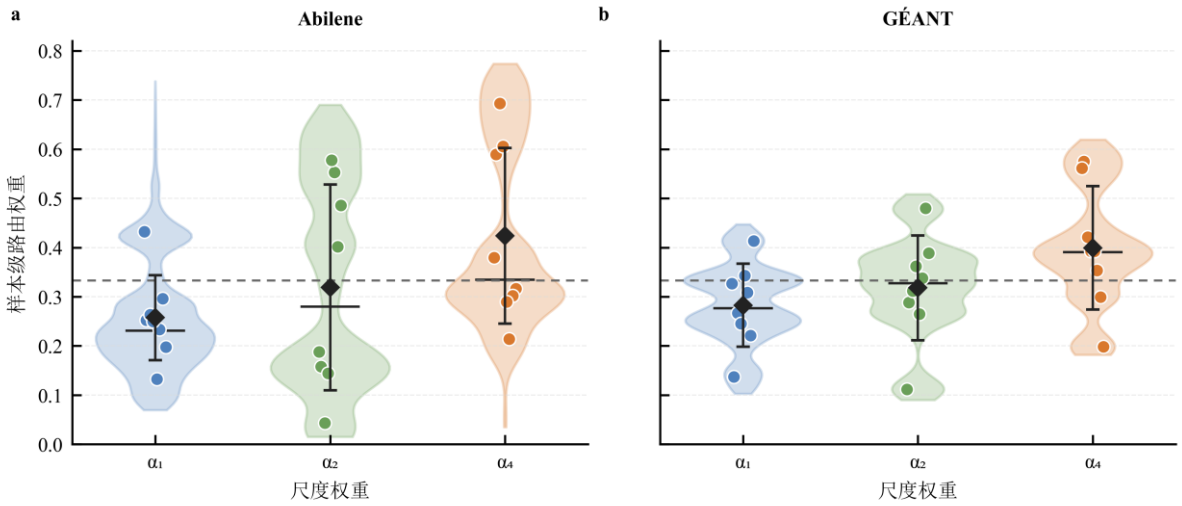


图 5 尺度权重分布与种子均值

注：使用种子 42～49，n=8。蓝、绿、橙分别对应尺度 1、2、4；小提琴汇总全部种子与测试窗口，彩色点为各种子的窗口平均权重，黑色菱形及误差线为 8 个种子均值的均值±1 个标准差。水平虚线为固定等权 1/3，短横线为汇总分布中位数；小提琴宽度包含种子间与窗口间差异。

三个尺度在 Abilene 上的汇总平均权重依次为 0.257、0.319 和 0.424，在 GÉANT 上依次为 0.283、0.318 和 0.399。这些总体均值均偏离固定等权的 1/3。从汇总权重方差的来源看，GÉANT 三个尺度中约 96.2%、95.8%和 97.7%的方差来自种子间差异。Abilene 对应的比例分别为 48.7%、86.1%和 80.6%。在 GÉANT 的同一种子内部，随窗口发生的权重变化较小。图 5 显示了不同尺度的总体权重偏好及其在随机种子间的变化。

输入窗口的波动强度由平均绝对一阶差分度量。分组阈值取自训练窗口的三分位数，测试窗口按这些阈值分组。Abilene 低、中、高波动组分别有 15、406、392 个窗口。本文方法相对全局权重模型的逐种子平均 MSE 改进率分别为 4.43%、1.90%、1.69%；GÉANT 在训练阈值下无低波动测试窗口，中、高组分别有 76、375 个窗口，改进率为 5.85%和 4.06%。在 Abilene 上，高波动组的尺度 1 平均权重高于中波动组，而相应的误差优势没有增强。GÉANT 中波动组与高波动组的权重则近似相同。分组结果表明，不同波动条件下的误差改善幅度有所差异。

2.5 运行开销与网络管理应用讨论

单尺度 DLinear 含 4656 个可训练参数，使用三个尺度专家的固定等权模型含 8208 个。在固定等权结构上加入三个全局权重参数后，参数总数为 8211 个；样本级路由和恒定输入路由的标称参数数目均为 8339 个。与固定等权及全局权重模型相比，路由网络分别增加 131 个和 128 个参数。恒定输入路由虽然保留样本级路由的网络结构，恒为零的输入却使首层输入权重不参与有效计算。

使用预测长度为 24、种子 42～49 的 8 个检查点单独测量前向计算开销。模型置于评估模式并关闭梯度计算，测试张量预先加载，批量大小为 16。每个检查点先预热 20 批，再对完整测试集重复计时 10 次；每次总耗时除以批次数，先对 10 次计时取平均，再对 8 个检查点取平均。本文方法在 Abilene 和 GÉANT 上的平均每批前向耗时分别为 2.65 ms 和 2.61 ms，固定等权模型分别为 2.38 ms 和 2.10 ms，单尺度 DLinear 分别为 0.77 ms 和 0.70 ms。计时仅覆盖模型前向计算，不含数据读取与传输。

在小时级网络管理场景中，运维模块可随观测序列更新，读取最近 96 h 的各 OD 流量，按训练阶段的预处理规则构造历史窗口，输出未来 24 h 各 OD 的逐小时需求估计。一次预测同时覆盖全部有效 OD 变量，便于按时间和节点对组织后续需求分析。

预测输出处于标准化空间。用于实际需求分析时，应先利用训练阶段保存的逐 OD 统计量逆标准化，再作逆对数变换，恢复原始流量量纲。随后可结合网络拓扑和路由关系，将各 OD 的预测需求汇总到对应链路，并与链路容量比较，为容量安排提供参考。

以训练集各 OD 的第 90 百分位为高需求阈值，仅评价真实值超过相应阈值的测试预测点。使用种子 42～49 和 24 步预测，在标准化空间统计 MAE 和平均低估幅度。后者在全部高需求预测点上平均真实值减预测值的正值部分。Abilene、GÉANT 的高需求预测点占比分别为 13.61%和 13.00%。

按 8 个种子的均值±标准差汇总，本文方法在 Abilene 上的高需求 MAE 和平均低估幅度分别为 0.147±0.013、0.137±0.017，相对全局可学习权重的逐种子平均降幅为 17.22%、20.49%，8 个种子均改善。GÉANT 两项指标为 0.632±0.060、0.577±0.080，平均降幅为 3.59%、6.30%，均有 6/8 个种子改善。

图 4 的校准分析与上述量化结果共同表明，本文方法的高需求平均绝对误差和低估幅度较低，Abilene 改善较稳定；GÉANT 两项配对改进率的 95%置信区间均跨零。该结果可为需求上升时段的观察和容量复核提供参考。

3 结语

自适应多尺度加权将独立分解线性专家与低维窗口路由结合，以较小参数规模完成小时级骨干网流量预测。两套数据的重复实验显示，其平均误差低于所设单尺度及固定融合对照，可为未来一天的需求分析提供参考。后续需在更多网络数据和预测长度下检验适用性。

参考文献

[1] LOHRASBINASAB I, KESHAVARZ A, AMIN-NEJAD S, et al. From statistical- to machine learning-based network traffic prediction[J]. Transactions on Emerging Telecommunications Technologies, 2022, 33(4): e4394. DOI: 10.1002/ett.4394.

[2] QIN Liang, GU Huaxi, WEI Wenting, et al. Spatio-temporal communication network traffic prediction method based on graph neural network[J]. Information Sciences, 2024, 679: 121003. DOI: 10.1016/j.ins.2024.121003.

[3] 韦烜, 刘志华, 李青, 等. 大型 IP 网络流量矩阵分析预测的探讨研究[J]. 系统工程与电子技术, 2024, 46(6): 2164-2173. DOI: 10.12305/j.issn.1001-506X.2024.06.35.

[4] 唐文杰, 肖一磊, 孔祥宇, 等. CycleLLH：一种基于周期性整合的新型网络流量预测模型[J]. 计算机学报, 2024, 47(12): 2867-2888. DOI: 10.11897/SP.J.1016.2024.02867.

[5] ZHOU Jian, HAN Taotao, XIAO Fu, et al. Multiscale network traffic prediction method based on deep echo-state network for Internet of Things[J]. IEEE Internet of Things Journal, 2022, 9(21): 21862-21874. DOI: 10.1109/JIOT.2022.3181807.

[6] ZENG Ailing, CHEN Muxi, ZHANG Lei, et al. Are transformers effective for time series forecasting?[J]. Proceedings of the AAAI Conference on Artificial Intelligence. 2023, 37(9): 11121-11128. DOI: 10.1609/aaai.v37i9.26317.

[7] WANG Shiyu, WU Haixu, SHI Xiaoming, et al. TimeMixer: decomposable multiscale mixing for time series forecasting[C/OL]//International Conference on Learning Representations. 2024[2026-10-03]. https://openreview.net/forum?id=7oLshfEIC2.

[8] ZHANG Tianping, ZHANG Yizhuo, CAO Wei, et al. Less is more: fast multivariate time series forecasting with light sampling-oriented MLP structures[EB/OL]. (2022-07-04)[2026-10-03]. https://arxiv.org/abs/2207.01186. DOI: 10.48550/arXiv.2207.01186.

[9] KUREŠ M, KOUMAR J, HYNEK K. CESNET TS-Zoo: a library for reproducible analysis of network traffic time series[C]//2025 21st International Conference on Network and Service Management. New York: IEEE, 2025: 1-5. DOI: 10.23919/CNSM67658.2025.11297513.

[10] ZHANG Yin, ROUGHAN M, DUFFIELD N, et al. Fast accurate computation of large-scale IP traffic matrices from link loads[J]. ACM SIGMETRICS Performance Evaluation Review, 2003, 31(1): 206-217. DOI: 10.1145/885651.781053.

[11] UHLIG S, QUOITIN B, LEPROPRE J, et al. Providing public intradomain traffic matrices to the research community[J]. ACM SIGCOMM Computer Communication Review, 2006, 36(1): 83-86. DOI: 10.1145/1111322.1111341.